ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN



PROPOSAL ĐỀ TÀI CUỐI KỲ

BEIJING MULTI-SITE AIR QUALITY
DỰ ĐOÁN NỒNG ĐỘ PM2.5 TẠI BẮC KINH

Nhóm :	10
Đề tài :	Đề tài số 10 – Beijing Multi-Site Air Quality
Lớp :	DCT124C3
Môn học :	Machine Learning
Nhóm trưởng :	Trần Lê Gia Bảo – 3124411038
Thành viên 2 :	Tô Thành Nhân – 3124411198
Thành viên 3 :	Đào Hữu Tài – 3124411261
Thành viên 4 :	Huỳnh Nhật Quang – 3124411245
Thành viên 5 :	Nguyễn Thanh Tuấn – 3124411337

TP HỒ CHÍ MINH, NĂM 2026

PROPOSAL ĐỀ TÀI CUỐI KỲ – MÔN MÁY HỌC

Dự đoán nồng độ PM2.5 tại Bắc Kinh bằng dữ liệu chất lượng không khí đa trạm

(Đề tài số 10 – Beijing Multi-Site Air Quality, bài toán Regression)

1. Thông tin nhóm

Nhóm: 10 **Tên đề tài:** Beijing Multi-Site Air Quality – Dự đoán nồng độ PM2.5

STT	Họ và tên	MSSV	Vai trò	Nhiệm vụ chính (dự kiến)
1	Trần Lê Gia Bảo	3124411038	Nhóm trưởng	Điều phối, thiết kế pipeline và chia dữ liệu theo thời gian, mô hình Gradient Boosting, tổng hợp báo cáo
2	Tô Thành Nhân	3124411198	Thành viên	Tải và mô tả dữ liệu, EDA, trực quan hóa
3	Đào Hữu Tài	3124411261	Thành viên	Tiền xử lý, xây dựng đặc trưng, baseline Linear Regression và persistence
4	Huỳnh Nhật Quang	3124411245	Thành viên	Mô hình Random Forest, tinh chỉnh siêu tham số cho các mô hình cây
5	Nguyễn Thanh Tuấn	3124411337	Thành viên	Đánh giá cuối trên tập test, phân tích sai số theo trạm/mùa, permutation importance, README và kiểm tra chạy lại

Mọi thành viên cùng review code và báo cáo; phân công có thể điều chỉnh trong quá trình thực hiện.

2. Giới thiệu bài toán

Bối cảnh. Bụi mịn PM2.5 (hạt có đường kính ≤ 2,5 µm) thâm nhập sâu vào đường hô hấp và là chỉ số trọng tâm khi đánh giá chất lượng không khí đô thị. Bắc Kinh là một trong những thành phố được quan trắc dày đặc và có nhiều đợt ô nhiễm nghiêm trọng, nên bộ dữ liệu quan trắc theo giờ tại nhiều trạm là nguồn dữ liệu thực tế phù hợp để xây dựng mô hình dự đoán.

Lý do chọn đề tài và ý nghĩa thực tiễn. Dữ liệu có nguồn gốc rõ ràng (UCI, giấy phép CC BY 4.0), quy mô đủ lớn để so sánh nhiều mô hình, đồng thời có đặc điểm thú vị về mặt Máy học: chuỗi thời gian, nhiều trạm, giá trị thiếu và mối quan hệ phi tuyến giữa khí tượng và ô nhiễm. Một mô hình dự đoán PM2.5 đáng tin cậy có thể hỗ trợ cảnh báo sớm, khuyến cáo sức khỏe cộng đồng và bổ sung cho các trạm bị thiếu dữ liệu.

Mục tiêu và câu hỏi nghiên cứu.

- Xây dựng mô hình hồi quy dự đoán nồng độ PM2.5 (µg/m³) của giờ kế tiếp từ dữ liệu ô nhiễm, khí tượng và thời gian đến giờ hiện tại.
- **CH1:** Mô hình phi tuyến (Random Forest, Gradient Boosting) cải thiện bao nhiêu so với baseline tuyến tính, đo bằng MAE, RMSE, R^2 trên tập kiểm thử theo thời gian?
- **CH2:** Nhóm đặc trưng nào (giá trị trễ của PM2.5, khí tượng, thời gian, trạm) đóng góp nhiều nhất vào độ chính xác?
- **CH3:** Sai số của mô hình thay đổi thế nào theo trạm, theo mùa và trong các đợt ô nhiễm cao?

3. Xác định bài toán Máy học

Hạng mục	Nội dung
Loại bài toán	Hồi quy (Regression) trên dữ liệu chuỗi thời gian nhiều trạm; học có giám sát.
Đầu vào (Input)	Với mỗi trạm tại giờ *t*: PM10, SO2, NO2, CO, O3, TEMP, PRES, DEWP, RAIN, WSPM, wd, trạm, đặc trưng thời gian (giờ, tháng, thứ trong tuần), cùng các đặc trưng trễ (lag) và trung bình trượt của PM2.5 và các biến khác, **chỉ tính từ quá khứ**.
Đầu ra (Target)	Nồng độ PM2.5 (µg/m³) tại giờ *t*+1 của cùng trạm (dự đoán liên tục).
Phạm vi mở rộng (nếu còn thời gian)	Thử chân trời dự đoán dài hơn (ví dụ *t*+24) để xem sai số tăng thế nào theo độ dài chân trời.

4. Mô tả dữ liệu

Nguồn: Chen, S. (2017). *Beijing Multi-Site Air Quality* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5RK5G. Đường dẫn: https://archive.ics.uci.edu/dataset/501/beijing+multi+site+air+quality+data. Giấy phép CC BY 4.0 (cho phép sử dụng với điều kiện ghi nguồn).

Đặc điểm theo trang mô tả của UCI: dữ liệu theo giờ từ 12 trạm quan trắc quốc gia tại Bắc Kinh, thu từ Beijing Municipal Environmental Monitoring Center; dữ liệu khí tượng được ghép từ trạm thời tiết gần nhất của Cơ quan Khí tượng Trung Quốc (CMA). Thời gian từ 01/03/2013 đến 28/02/2017. **Số mẫu: 420.768** (12 trạm × 35.064 giờ). Bảng biến liệt kê **18 cột**; giá trị thiếu ghi là NA. Nhóm sẽ kiểm tra lại số dòng, số cột và kiểu dữ liệu ngay khi tải dữ liệu thực tế và cập nhật trong báo cáo cuối kỳ.

Thuộc tính	Ý nghĩa	Vai trò
No	Số thứ tự dòng	Bỏ (chỉ là chỉ số)
year, month, day, hour	Thời điểm quan trắc	Ghép thành mốc thời gian; sinh đặc trưng thời gian
PM2.5	Nồng độ bụi mịn PM2.5 (µg/m³)	**Target** (dịch sang giờ t+1); giá trị trễ làm Input
PM10, SO2, NO2, CO, O3	Nồng độ các chất ô nhiễm khác (µg/m³)	Input
TEMP, PRES, DEWP	Nhiệt độ (°C), áp suất (hPa), nhiệt độ điểm sương (°C)	Input
RAIN, WSPM	Lượng mưa (mm), tốc độ gió (m/s)	Input
wd	Hướng gió (biến phân loại)	Input (mã hóa)
station	Tên trạm quan trắc (12 trạm)	Input (mã hóa) và dùng để phân tích theo trạm

5. Phương pháp dự kiến: EDA, tiền xử lý, xây dựng đặc trưng

5.1. Khám phá dữ liệu (EDA). Mỗi thao tác đều gắn với một câu hỏi cụ thể, không thực hiện máy móc:

- Thống kê mô tả, kiểm tra kiểu dữ liệu, tỷ lệ giá trị thiếu theo cột và theo trạm, bản ghi trùng (theo cặp trạm–thời điểm), giá trị bất thường (ví dụ âm, hoặc vượt xa ngưỡng vật lý).
- Phân bố PM2.5 (histogram, log-scale), vì phân bố thường lệch phải, từ đó quyết định có cần biến đổi hay chỉ dùng độ đo phù hợp.
- Biến động PM2.5 theo giờ trong ngày, theo tháng/mùa, theo năm và so sánh giữa các trạm; kiểm tra tự tương quan để biện minh cho đặc trưng trễ.
- Ma trận tương quan giữa PM2.5 và các biến khí tượng/ô nhiễm; quan hệ PM2.5 với tốc độ và hướng gió.

5.2. Tiền xử lý.

- **Giá trị thiếu:** không điền giá trị cho Target; bỏ các dòng thiếu Target khi huấn luyện/đánh giá. Với đặc trưng, điền theo từng trạm bằng forward-fill có giới hạn số giờ (chỉ dùng quá khứ), phần còn lại điền bằng trung vị tính từ tập huấn luyện, kèm cột cờ báo thiếu. Cách này tránh nội suy dùng thông tin tương lai.
- **Giá trị bất thường:** không loại các đợt ô nhiễm cực cao nếu là hiện tượng có thật (đây chính là trường hợp quan trọng cần dự đoán); chỉ xử lý các giá trị vô lý về mặt vật lý hoặc nghi do lỗi cảm biến sau khi đã xem xét.
- **Mã hóa:** wd và station dùng One-Hot; thời gian dùng mã hóa tuần hoàn sin/cos cho giờ và tháng.
- **Chuẩn hóa:** StandardScaler chỉ áp dụng cho Linear Regression (mô hình dựa trên cây không cần); scaler được fit trên tập huấn luyện rồi mới áp dụng cho tập còn lại.

5.3. Xây dựng đặc trưng. Giá trị trễ của PM2.5 (1, 2, 3, 6, 12, 24 giờ), trung bình trượt (6, 24 giờ) và độ lệch so với trung bình trượt, giá trị trễ của các biến khí tượng chính, đặc trưng thời gian (giờ, tháng, thứ trong

tuần, cuối tuần). Mọi đặc trưng trễ/trượt được tính **riêng từng trạm** và chỉ dựa trên thông tin trước thời điểm dự đoán để tránh rò rỉ dữ liệu.

6. Mô hình dự kiến

Mô hình	Vai trò	Cơ sở lựa chọn
Linear Regression	Baseline	Đơn giản, dễ diễn giải; làm mốc để đo mức cải thiện của mô hình phi tuyến.
Random Forest Regressor	Mô hình so sánh 1	Bắt được quan hệ phi tuyến và tương tác giữa đặc trưng, ít nhạy với thang đo và ngoại lệ, giảm phương sai nhờ trung bình nhiều cây.
Gradient Boosting Regressor	Mô hình so sánh 2	Học tuần tự để giảm sai số còn lại, thường mạnh trên dữ liệu dạng bảng; cho phép kiểm soát độ phức tạp qua learning rate và độ sâu cây.

Ngoài ra nhóm dùng thêm một mốc tham chiếu đơn giản là *persistence* (dự đoán PM2.5 giờ t+1 bằng PM2.5 giờ t) để kiểm tra xem các mô hình có thật sự học được điều gì hơn việc lặp lại giá trị gần nhất. Các mô hình dùng chung một pipeline tiền xử lý, một cách chia dữ liệu và cùng độ đo để so sánh công bằng. Lưu ý khả thi: Gradient Boosting của scikit-learn chạy chậm trên hơn 400 nghìn dòng; nếu cần, nhóm sẽ dùng HistGradientBoostingRegressor (cùng họ thuật toán) hoặc huấn luyện trên tập con có kiểm soát và ghi rõ trong báo cáo.

7. Kế hoạch thực nghiệm

Chia dữ liệu theo trình tự thời gian (không xáo trộn ngẫu nhiên) để mô hình không nhìn thấy tương lai:

Tập	Khoảng thời gian (dự kiến)	Mục đích
Train + Validation	03/2013 – 08/2016	Huấn luyện và chọn mô hình; validation bằng TimeSeriesSplit (expanding window, 5 fold).
Test	09/2016 – 02/2017	Đánh giá cuối cùng, chỉ dùng một lần sau khi đã chốt cấu hình.

Tập kiểm thử chủ yếu nằm trong mùa thu–đông, thường có ô nhiễm cao hơn; do đó nhóm sẽ báo cáo kết quả theo từng tháng/mùa để nhận diện chênh lệch phân bố giữa train và test. Mốc thời gian cụ thể có thể điều chỉnh sau khi EDA.

- **Độ đo:** MAE, RMSE và R^2 (không dùng Accuracy). Báo cáo tổng thể, theo từng trạm, theo mùa và riêng trên nhóm giờ PM2.5 cao. Độ đo chính để chọn mô hình: RMSE trên validation, đối chiếu cùng MAE.
- **Tinh chỉnh siêu tham số (≥ 1 mô hình, dự kiến cả hai mô hình cây):** RandomizedSearchCV kết hợp TimeSeriesSplit. Random Forest: n_estimators, max_depth, min_samples_leaf, max_features. Gradient Boosting: n_estimators, learning_rate, max_depth, subsample. Tiêu chí chọn: RMSE trung bình trên các fold validation thấp nhất, có xét độ ổn định giữa các fold; so sánh kết quả trước và sau tinh chỉnh trên cùng tập kiểm thử.
- **Phân tích kết quả:** so sánh baseline với hai mô hình; biểu đồ giá trị dự đoán và thực tế, phân bố sai số (residual) theo thời gian, trạm và mức PM2.5; đối chiếu sai số train và validation/test để nhận diện overfitting hoặc underfitting; permutation importance để trả lời CH2; nêu ưu và nhược điểm của từng mô hình dựa trên số liệu thực nghiệm.

8. Kết quả dự kiến và sản phẩm bàn giao

Nhóm chưa huấn luyện mô hình ở giai đoạn proposal nên **không đưa ra con số kết quả** và không khẳng định trước mô hình nào tốt nhất. Giả thuyết cần kiểm chứng: các mô hình dựa trên cây nhiều khả năng vượt baseline tuyến tính nhờ nắm bắt quan hệ phi tuyến, và đặc trưng trễ của PM2.5 là nhóm có đóng góp lớn; tuy nhiên mức cải thiện và việc có overfitting hay không sẽ chỉ được kết luận từ thực nghiệm.

- Notebook/source code chạy lại được (cố định random seed) và file README hướng dẫn cài đặt, chạy chương trình.
- Báo cáo gồm: mô tả dữ liệu, EDA, tiền xử lý, so sánh mô hình, tinh chỉnh, phân tích sai số, kết luận và hạn chế; trích dẫn đầy đủ nguồn dữ liệu và tài liệu tham khảo.
- Hướng phát triển (tùy tiến độ): thử dự đoán nhiều chân trời, mô hình riêng cho từng trạm, hoặc demo nhỏ hiển thị dự đoán so với thực tế.

9. Kế hoạch thực hiện và phân công

Giai đoạn	Công việc chính	Phụ trách	Sản phẩm
Tuần 1	Chốt đề tài, tải và mô tả dữ liệu, EDA, thiết lập repo và cấu trúc thư mục	TV2, TV1	Báo cáo EDA, notebook 01
Tuần 2	Tiền xử lý, xử lý giá trị thiếu, xây dựng đặc trưng trễ/thời gian, chia dữ liệu theo thời gian	TV3, TV1	Pipeline tiền xử lý, notebook 02
Tuần 3	Baseline (Linear Regression, persistence), Random Forest, Gradient Boosting với cùng quy trình	TV3, TV4, TV1	Bảng so sánh ban đầu
Tuần 4	Tinh chỉnh siêu tham số, đánh giá cuối trên tập test, phân tích sai số theo trạm/mùa và importance	TV4, TV5, TV1	Kết quả tinh chỉnh, biểu đồ phân tích
Tuần 5	Hoàn thiện báo cáo, README, kiểm tra chạy lại từ đầu, chuẩn bị trình bày	Cả nhóm (TV5 phụ trách README)	Báo cáo, source code, README

Tiến độ tính theo tuần kể từ khi proposal được duyệt; nhóm sẽ co giãn theo hạn nộp cuối kỳ do giảng viên quy định.

10. Tài liệu tham khảo

[1] Chen, S. (2017). Beijing Multi-Site Air Quality [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5RK5G

[2] Zhang, S., Guo, B., Dong, A., He, J., Xu, Z., Chen, S. (2017). Cautionary tales on air-quality improvement in Beijing. Proceedings of the Royal Society A.

[3] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

[4] Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232.

[5] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.