ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

NGUYỄN TẤN ĐẠI

DỰ ĐOÁN HÀM LƯỢNG CHẤT Ô NHIỄM TRONG BỤI PM_{10} SỬ DỤNG MÔ HÌNH HỌC SÂU VÀ DỮ LIỆU QUAN TRẮC

KHÓA LUẬN TỐT NGHIỆP

NGÀNH: CÔNG NGHỆ THÔNG TIN
TRÌNH ĐỘ ĐÀO TẠO: ĐẠI HỌC

TP. HỒ CHÍ MINH, THÁNG 05 NĂM 2026

ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

NGUYỄN TẤN ĐẠI

DỰ ĐOÁN HÀM LƯỢNG CHẤT Ô NHIỄM TRONG BỤI PM_{10} SỬ DỤNG MÔ HÌNH HỌC SÂU VÀ DỮ LIỆU QUAN TRẮC

KHÓA LUẬN TỐT NGHIỆP

NGÀNH: CÔNG NGHỆ THÔNG TIN
TRÌNH ĐỘ ĐÀO TẠO: ĐẠI HỌC

NGƯỜI HƯỚNG DẪN: TS. TRỊNH TẤN ĐẠT

TP. HỒ CHÍ MINH, THÁNG 05 NĂM 2026

LỜI CAM ĐOAN

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi, các số liệu và kết quả nghiên cứu nêu trong khóa luận là trung thực, được các đồng tác giả cho phép sử dụng và chưa từng được công bố trong bất kì một công trình nào khác.

Tác giả khóa luận

Nguyễn Tấn Đại

LỜI CẢM ƠN

Trong quá trình thực hiện khóa luận tốt nghiệp với đề tài "Dự đoán hàm lượng chất ô nhiễm trong bụi PM_{10} sử dụng mô hình học sâu và dữ liệu quan trắc", em đã nhận được sự quan tâm, dìu dắt và hỗ trợ quý báu từ nhà trường, quý thầy cô, gia đình và bạn bè. Những sự giúp đỡ ấy là nguồn động lực lớn lao, góp phần quan trọng để em có thể hoàn thành khóa luận này.

Trước hết, em xin bày tỏ lòng biết ơn chân thành đến Trường Đại học Sài Gòn và Khoa Công nghệ thông tin đã tạo điều kiện thuận lợi, cung cấp môi trường học tập nghiêm túc cùng những kiến thức nền tảng quý báu, là hành trang quan trọng để em có thể thực hiện khóa luận này.

Em xin bày tỏ lòng biết ơn sâu sắc đến thầy Trịnh Tấn Đạt và cô Nguyễn Thị Tuyết Nam vì đã tận tình hướng dẫn, định hướng chuyên môn và dành nhiều thời gian góp ý trong suốt quá trình thực hiện khóa luận. Sự chỉ bảo tận tâm, những nhận xét sâu sắc và sự khích lệ kịp thời từ thầy cô đã giúp em có thêm định hướng đúng đắn, khắc phục những khó khăn gặp phải và hoàn thành đề tài một cách tốt nhất trong khả năng của mình.

Em cũng xin chân thành cảm ơn quý Thầy Cô trong Khoa Công nghệ thông tin đã hết lòng giảng dạy, truyền đạt kiến thức và luôn hỗ trợ em trong quá trình học tập tại trường cũng như giúp đỡ em hình thành một thái độ học tập nghiêm túc.

Bên cạnh đó, em xin gửi lời tri ân sâu sắc đến gia đình, bạn bè và những người thân yêu đã luôn ở bên cạnh, động viên, chia sẻ và là nguồn cổ vũ tinh thần to lớn để em có thêm nghị lực và quyết tâm hoàn thành khóa luận tốt nghiệp này.

Dù đã nỗ lực hết mình, song do hạn chế về thời gian, kiến thức và kinh nghiệm nghiên cứu nên khóa luận chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý và chỉ dẫn quý báu từ quý Thầy Cô và bạn đọc để khóa luận được hoàn thiện hơn.

MỤC LỤC

TRANG PHỤ BÌA ..... **i**

LỜI CAM ĐOAN ..... **ii**

LỜI CẢM ƠN ..... **iii**

DANH MỤC CÁC TỪ VIẾT TẮT **7**

DANH MỤC CÁC BẢNG **9**

DANH MỤC CÁC SƠ ĐỒ **14**

DANH MỤC CÁC HÌNH ẢNH **15**

DANH MỤC CÁC BIỂU ĐỒ **17**

MỞ ĐẦU **25**

1. Lý do chọn đề tài **25**

1.1. Bối cảnh thực tiễn ***25***

1.2. Bối cảnh lý thuyết ***26***

2. Tổng quan nghiên cứu **27**

3. Mục tiêu nghiên cứu **30**

3.1. Mục tiêu chung ***30***

3.2. Mục tiêu riêng ***30***

4. Nhiệm vụ nghiên cứu **31**

5. Đối tượng nghiên cứu **31**

6. Phạm vi nghiên cứu **32**

6.1. Phạm vi không gian ***32***

6.2. Phạm vi thời gian ***32***

6.3. Phạm vi nội dung ***32***

7. Phương pháp nghiên cứu **33**

8. Ý nghĩa khoa học và thực tiễn của đề tài **33**

9. Cấu trúc của đề tài **35**

NỘI DUNG **36**

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT **36**

1.1. Giới thiệu ***36***

1.2. Tổng quan về PM_{10} ***36***

1.2.1. Khái niệm và đặc tính của bụi PM_{10} *36*

1.2.2. Nguồn gốc phát sinh *37*

1.2.3. Cơ chế phân tán không gian *38*

1.2.4. Các yếu tố ảnh hưởng đến nồng độ bụi PM_{10} *39*

1.3. Tổng quan về mô hình học sâu dự đoán chuỗi thời gian theo tiếp cận không gian ***40***

1.3.1. Sơ lược về đồ thị *41*

1.3.2. Mô hình GCN cải tiến *47*

1.3.3. Mô hình GAT tinh chỉnh *54*

1.4. Tổng quan về mô hình dự đoán chuỗi thời gian theo thời gian ***60***

1.4.1. Mô hình RNN *61*

1.4.2. Mô hình LSTM *64*

1.4.3. Mô hình BiLSTM *72*

1.5. Tổng quan về MHA ***76***

1.5.1. Quá trình lan truyền tiến của cơ chế MHA *77*

1.5.2. Quá trình lan truyền ngược của cơ chế MHA *78*

1.6. Tóm tắt chương ***79***

CHƯƠNG 2: MÔ TẢ VÀ XỬ LÝ DỮ LIỆU **80**

2.1. Giới thiệu 80

2.2. Phân bố địa lý của các trạm khí tượng trong dữ liệu thu thập 80

2.3. Các đặc trưng trong dữ liệu thu thập 82

2.4. Mô tả dữ liệu thô 83

2.4.1. Lượng dữ liệu thu thập từ các trạng khí tượng theo thời gian 83

2.4.2. Lượng dữ liệu thiếu tại các trạm 84

2.4.3. Lượng bản ghi trùng lặp tại các trạm 85

2.4.4. Thống kê mô tả đặc trưng trước tiền xử lý 86

2.5. Mô tả dữ liệu sau khi tiền xử lý 93

2.5.1. Bước 1 – Thay thế các bản ghi có giá trị thiếu 93

2.5.2. Bước 2 – Xác định các mốc thời gian chung giữa các trạm quan trắc và thực hiện lọc dữ liệu 94

2.5.3. Thống kê mô tả đặc trưng sau khi tiền xử lý dữ liệu 96

2.5.4. Lượng giá trị ngoại lai của từng đặc trưng tại các trạm khí tượng 104

2.6. Tóm tắt chương 106

CHƯƠNG 3: PHÂN TÍCH DỮ LIỆU 107

3.1. Giới thiệu 107

3.2. Phân tích phân bố không gian của hàm lượng chất ô nhiễm tại các trạm khí tượng 107

3.2.1. Sự ảnh hưởng của vĩ độ lên hàm lượng chất ô nhiễm tại các trạm khí tượng 107

3.2.2. Sự tương quan đặc trưng giữa các trạm khí tượng 112

3.3. Phân tích xu hướng biến đổi hàm lượng chất ô nhiễm theo thời gian tại các trạm khí tượng 115

3.3.1. Xu hướng biến đổi hàm lượng chất ô nhiễm theo giờ trong giai đoạn 2020 – 2025 tại các trạm khí tượng 115

3.3.2. Xu hướng biến đổi hàm lượng chất ô nhiễm theo tháng trong giai đoạn 2020 – 2025 tại các trạm khí tượng 125

3.4. Tóm tắt chương..... 143

CHƯƠNG 4: PHƯƠNG PHÁP ĐỀ XUẤT 144

4.1. Giới thiệu 144

4.2. Các bước tiền xử lý..... 144

4.2.1. Các bước tiền xử lý dữ liệu cho quá trình phân tích xu hướng 144

4.2.2. Các bước tiền xử lý dữ liệu cho quá trình dự đoán bằng mô hình học sâu 145

4.3. Đề xuất mô hình sử dụng trong đề tài..... 151

4.3.1. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM + MHA..... 153

4.3.2. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA..... 155

4.3.3. Kiến trúc mô hình cải tiến đề xuất 158

4.3.4. Các mô hình thử nghiệm khác..... 164

4.4. Tóm tắt chương..... 170

CHƯƠNG 5: THIẾT LẬP, KẾT QUẢ VÀ ĐÁNH GIÁ THỰC NGHIỆM 172

5.1. Giới thiệu 172

5.2. Thiết lập thực nghiệm 172

5.2.1. Môi trường thực nghiệm 172

5.2.2. Dữ liệu đầu vào và đầu ra của mô hình..... 173

5.3. Kết quả thực nghiệm và đánh giá..... 175

5.3.1. Kết quả thực nghiệm mô hình GCN cải tiến – LSTM/BiLSTM + MHA 175

5.3.2. Kết quả thực nghiệm mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA 185

5.3.3. Kết quả thực nghiệm mô hình GAT đề xuất – LSTM/BiLSTM + MHA 196

5.4. So sánh kết quả thực nghiệm 207

5.4.1. Đặc trưng pb_mean_2h 207

5.4.2. Đặc trưng zn_mean_2h 211

5.5. Tóm tắt chương 215

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 216

1. Tóm tắt kết quả nghiên cứu 216

1.1. Về mặt phân tích dữ liệu 216

1.2. Về mặt thực nghiệm 217

2. Hạn chế của nghiên cứu 218

3. Hướng phát triển trong tương lai 219

TÀI LIỆU THAM KHẢO 220

PHỤ LỤC 227

PHỤ LỤC A. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GCN CẢI TIẾN 227

A.1. Kết quả dự đoán với pb_mean_2h 227

A.1.1. GCN cải tiến – LSTM + MHA 227

A.1.2. GCN cải tiến – BiLSTM + MHA 228

A.2. Kết quả dự đoán với zn_mean_2h 230

A.2.1. GCN cải tiến – LSTM + MHA 230

A.2.2. GCN cải tiến – BiLSTM + MHA 231

PHỤ LỤC B. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GAT TINH CHỈNH 233

B.1. Kết quả dự đoán với pb_mean_2h 233

B.1.1. GAT tinh chỉnh – LSTM + MHA 233

B.1.2. GAT tinh chỉnh – BiLSTM + MHA 234

B.2. Kết quả dự đoán với zn_mean_2h 236

B.2.1. GAT tinh chỉnh – LSTM + MHA 236

B.2.2. GAT tinh chỉnh – BiLSTM + MHA 237

PHỤ LỤC C. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GAT ĐỀ XUẤT 239

C.1. Kết quả dự đoán với pb_mean_2h 239

C.1.1. GAT đề xuất – LSTM + MHA 239

C.1.2. GAT đề xuất – BiLSTM + MHA 240

C.2. Kết quả dự đoán với zn_mean_2h 242

C.2.1. GAT đề xuất – LSTM + MHA 242

C.2.2. GAT đề xuất – BiLSTM + MHA 243

PHỤ LỤC D. SO SÁNH KẾT QUẢ THỰC NGHIỆM 245

D.1. Đặc trưng pb_mean_2h 245

D.1.1. Nhóm mô hình đề xuất 245

D.1.2. Nhóm mô hình không sử dụng cơ chế MHA 246

D.2. Đặc trưng zn_mean_2h 248

D.2.1. Nhóm mô hình đề xuất 248

D.2.2. Nhóm mô hình không sử dụng cơ chế MHA 249

DANH MỤC CÁC TỪ VIẾT TẮT

TT	Từ viết tắt	Từ tiếng Anh	Từ tiếng Việt
1	WHO	World Health Organization	Tổ chức Y tế Thế giới
2	ESG	Environmental, Social, Governance	Môi trường, Xã hội, Quản trị
3	TP. HCM	Ho Chi Minh city	Thành phố Hồ Chí Minh
4	R^2	R-squared	Hệ số xác định
5	MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
6	RMSE	Root Mean Squared Error	Căn bậc hai sai số bình phương trung bình
7	Pb_mean_2h	Lead means over 2-hour periods	Hàm lượng chì trung bình trong chu kỳ 2 giờ (có trong mẫu bụi PM_{10})
8	Zn_mean_2h	Zinc means over 2-hour periods	Hàm lượng kẽm trung bình trong chu kỳ 2 giờ (có trong mẫu bụi PM_{10})

9	GCN, GCNN	Graph Convolutional Neural Network	Mạng nơ-ron tích chập đồ thị
10	GAT	Graph Attention Network	Mạng nơ-ron chú ý đồ thị
11	RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
12	LSTM	Long Short-Term Memory	Mạng bộ nhớ dài hạn – ngắn hạn
13	BiLSTM	Bidirectional Long Short-Term Memory	Mạng bộ nhớ dài hạn – ngắn hạn hai chiều
14	MHA	Multi – Head Attention	Đa đầu chú ý
15	QCVN	National Technical Regulation	Quy chuẩn Việt Nam
16	LATITUDE	Latitude	Vĩ độ địa lý của điểm đo
17	LATITUDE	Longitude	Kinh độ địa lý của điểm đo
18	Year	Year	Năm đo đạc
19	Month	Month	Tháng đo dạc
20	Day	Day	Ngày đo đạc
21	Hour	Hour	Giờ đo đạc

DANH MỤC CÁC BẢNG

TT	Tên bảng	Trang
1	Bảng 2. 1. Kinh độ và vĩ độ của các trạm khí tượng	81
2	Bảng 2. 2. Lượng dữ liệu thu thập từ các trạm khí tượng theo thời gian	83
3	Bảng 2. 3. Lượng dữ liệu thiếu tại các trạm khí tượng	84
4	Bảng 2. 4. Lượng bản ghi trùng lặp tại các trạm khí tượng	85
5	Bảng 2. 5. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Chuncheon	86
6	Bảng 2. 6. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Seoul	86
7	Bảng 2. 7. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Incheon	87
8	Bảng 2. 8. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Ansan	88
9	Bảng 2. 9. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Seosan	88
10	Bảng 2. 10. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Cheongju	89
11	Bảng 2. 11. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Daejon	90
12	Bảng 2. 12. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Iksan	90

13	Bảng 2. 13. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Ulsan	91
14	Bảng 2. 14. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Gwangju	92
15	Bảng 2. 15. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Jeju	92
16	Bảng 2. 16. Chi tiết lượng dữ liệu theo thời gian sau khi lọc	95
17	Bảng 2. 17. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Chuncheon	96
18	Bảng 2. 18. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Seoul	97
19	Bảng 2. 19. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Incheon	98
20	Bảng 2. 20. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Ansan	98
21	Bảng 2. 21. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Seosan	99
22	Bảng 2. 22. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Cheongju	100
23	Bảng 2. 23. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Daejon	100
24	Bảng 2. 24. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Iksan	101
25	Bảng 2. 25. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Ulsan	102
26	Bảng 2. 26. Thống kê mô tả đặc sau trước tiền xử lý của trạm Gwangju	102
27	Bảng 2. 27. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Jeju	103

28	Bảng 4. 1. Kích thước đầu vào, đầu ra của mô hình GCN cải tiến – LSTM/BiLSTM + MHA	154
29	Bảng 4. 2. Các tham số đầu vào trong mô hình GCN cải tiến – LSTM/BiLSTM + MHA	154
30	Bảng 4. 3. Kích thước đầu vào, đầu ra của mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA	156
31	Bảng 4. 4. Các tham số đầu vào trong mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA	157
32	Bảng 4. 5. Kích thước đầu vào, đầu ra của mô hình đề xuất cải tiến	160
33	Bảng 4. 6. Các tham số đầu vào trong mô hình đề xuất cải tiến	160
34	Bảng 4. 7. Kích thước đầu vào, đầu ra của mô hình GCN cải tiến – LSTM/BiLSTM	165
35	Bảng 4. 8. Các tham số đầu vào trong mô hình GCN cải tiến – LSTM/BiLSTM	166
36	Bảng 4. 9. Kích thước đầu vào, đầu ra của mô hình GAT tinh chỉnh – LSTM/BiLSTM	167
37	Bảng 4. 10. Các tham số đầu vào trong mô hình GAT tinh chỉnh – LSTM/BiLSTM	168
38	Bảng 4. 11. Kích thước đầu vào, đầu ra của mô hình GAT đề xuất – LSTM/BiLSTM	169
39	Bảng 4. 12. Các tham số đầu vào trong mô hình GAT đề xuất – LSTM/BiLSTM	170

40	Bảng 5. 1. Thư viện sử dụng trong đề tài	172
41	Bảng 5. 2. Các tham số đầu vào của mô hình	173
42	Bảng 5. 3. Số lượng chuỗi đầu vào	174
43	Bảng 5. 4. Các tham số đầu ra của mô hình	174
44	Bảng 5. 5. Ma trận kề giữa các trạm khí tượng	174
45	Bảng PL - A. 1. Hiệu suất của mô hình GCN cải tiến – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h	227
46	Bảng PL - A. 2. Hiệu suất của mô hình GCN cải tiến – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h	228
47	Bảng PL - A. 3. Hiệu suất của mô hình GCN cải tiến – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h	230
48	Bảng PL - A. 4. Hiệu suất của mô hình GCN cải tiến – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h	231
49	Bảng PL - B. 1. Hiệu suất của mô hình GAT tinh chỉnh – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h	233
50	Bảng PL - B. 2. Hiệu suất của mô hình GAT tinh chỉnh – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h	234
51	Bảng PL - B. 3. Hiệu suất của mô hình GAT tinh chỉnh – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h	236
52	Bảng PL - B. 4. Hiệu suất của mô hình GAT tinh chỉnh – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h	237

53	Bảng PL - C. 1. Hiệu suất của mô hình GAT đề xuất – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h	239
54	Bảng PL - C. 2. Hiệu suất của mô hình GAT đề xuất – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h	240
55	Bảng PL - C. 3. Hiệu suất của mô hình GAT đề xuất – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h	242
56	Bảng PL - C. 4. Hiệu suất của mô hình GAT đề xuất – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h	243
57	Bảng PL - D. 1. So sánh hiệu quả khi dự báo pb_mean_2h của các mô hình đề xuất sử dụng trong đề tài	245
58	Bảng PL - D. 2. So sánh hiệu quả khi dự báo pb_mean_2h của các mô hình không sử dụng MHA trong đề tài	246
59	Bảng PL - D. 3. So sánh hiệu quả khi dự báo zn_mean_2h của các mô hình đề xuất sử dụng trong đề tài	248
60	Bảng PL - D. 4. So sánh hiệu quả khi dự báo zn_mean_2h của các mô hình không sử dụng MHA trong đề tài	249

DANH MỤC CÁC SƠ ĐỒ

TT	Tên sơ đồ	Trang
1	Sơ đồ 4. 1. Tổng quan tiền xử lý đầu vào cho mô hình	147
2	Sơ đồ 4. 2. Quy trình xây dựng mô hình và đánh giá hiệu xuất	152
3	Sơ đồ 4. 3. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM + MHA do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất	153
4	Sơ đồ 4. 4. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA được sử dụng trong đề tài	156
5	Sơ đồ 4. 5. Tổng quan kiến trúc mô hình đề xuất cải tiến	159
6	Sơ đồ 4. 6. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất	165
7	Sơ đồ 4. 7. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất	167
8	Sơ đồ 4. 8. Kiến trúc mô hình GAT đề xuất – LSTM/BiLSTM	169

DANH MỤC CÁC HÌNH ẢNH

TT	Tên hình ảnh	Trang
1	Hình 1. 1. Kích thước của các loại bụi PM so với kích thước của 1 sợi tóc người	37
2	Hình 1. 2. Đồ thị vô hướng	42
3	Hình 1. 3. Đồ thị có hướng	42
4	Hình 1. 4. Mô tả bậc của đỉnh trong các đồ thị vô hướng	43
5	Hình 1. 5. Mô tả bậc của đỉnh trong đồ thị có hướng	43
6	Hình 1. 6. Ma trận biểu diễn đặc trưng nút cho trạm thứ N có $\boldsymbol{X} \in \boldsymbol{R}^{\boldsymbol{N} \times \boldsymbol{B} \times \boldsymbol{ICL} \times \boldsymbol{IFL}}$	44
7	Hình 1. 7. Danh sách cạnh E	45
8	Hình 1. 8. Giai đoạn 1 thực hiện thu thập thông điệp từ các nút láng giềng	49
9	Hình 1. 9. Giai đoạn 2 thực hiện tổng hợp thông điệp từ các nút láng giềng	51
10	Hình 1. 10. Minh họa khối tính toán hệ số chú ý với nút i và nút láng giềng j tại đầu chú ý thứ 1	55
11	Hình 1. 11. Giai đoạn 1 tính toán hệ số chú ý	56
12	Hình 1. 12. RNN với cơ chế vòng lặp	61

13	Hình 1. 13. Mô hình RNN khi trải thẳng cơ chế vòng lặp	62
14	Hình 1. 14. Chi tiết hoạt động trong 1 trạng thái ẩn của mô hình RNN tại thời điểm t	63
15	Hình 1. 15. Mô hình LSTM khi trải thẳng cơ chế vòng lặp	66
16	Hình 1. 16. Chi tiết cổng quên trong ô nhớ của mô hình LSTM tại thời điểm t	67
17	Hình 1. 17. Chi tiết cổng đầu vào trong 1 ô nhớ của mô hình LSTM tại thời điểm t	68
18	Hình 1. 18. Chi tiết cổng đầu ra trong 1 ô nhớ của mô hình LSTM tại thời điểm t	68
19	Hình 1. 19. Chi tiết trạng thái ô nhớ ứng viên trong 1 ô nhớ của mô hình LSTM tại thời điểm t	69
20	Hình 1. 20. Chi tiết trạng thái ô nhớ trong 1 ô nhớ của mô hình LSTM tại thời điểm t	70
21	Hình 1. 21. Chi tiết trạng thái ẩn trong 1 ô nhớ của mô hình LSTM tại thời điểm t	71
22	Hình 1. 22. Mô hình BiLSTM khi trải thẳng cơ chế vòng lặp	73
23	Hình 4. 1. Minh họa quá trình chuẩn hóa dữ liệu trong khoảng [-1; 1]	149
24	Hình 4. 2. Mô tả cửa sổ dữ liệu với k = 3	150
25	Hình 4. 3. Mô tả so sánh cách tạo cửa sổ dữ liệu theo cách truyền thống và cách đề xuất với k = 3	151

DANH MỤC CÁC BIỂU ĐỒ

TT	Tên biểu đồ	Trang
1	Biểu đồ 2. 1. Lượng dữ liệu trước và sau khi lọc của các trạm khí tượng	95
2	Biểu đồ 2. 2. Lượng giá trị ngoại lai của đặc trưng pb_mean_2h sau tiền xử lý	104
3	Biểu đồ 2. 3. Lượng giá trị ngoại lai của đặc trưng zn_mean_2h sau tiền xử lý	105
4	Biểu đồ 3. 1. Sự ảnh hưởng của vĩ độ đến pb_mean_2h trong ngày tại các trạm khí tượng	109
5	Biểu đồ 3. 2. Sự ảnh hưởng của vĩ độ đến zn_mean_2h trong ngày tại các trạm khí tượng	111
6	Biểu đồ 3. 3. Tương quan pb_mean_2h giữa các trạm khí tượng	113
7	Biểu đồ 3. 4. Tương quan zn_mean_2h giữa các trạm khí tượng	114
8	Biểu đồ 3. 5. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Seoul	116
9	Biểu đồ 3. 6. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Incheon	117
10	Biểu đồ 3. 7. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Ansan	118

11	Biểu đồ 3. 8. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Seosan	119
12	Biểu đồ 3. 9. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Daejon	121
13	Biểu đồ 3. 10. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Iksan	122
14	Biểu đồ 3. 11. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Ulsan	123
15	Biểu đồ 3. 12. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Gwangju	124
16	Biểu đồ 3. 13. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Jeju	125
17	Biểu đồ 3. 14. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Seoul (2020 – 2025)	126
18	Biểu đồ 3. 15. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Seoul (2020 – 2025)	127
19	Biểu đồ 3. 16. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Incheon (2020 – 2025)	128
20	Biểu đồ 3. 17. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Incheon (2020 – 2025)	129
21	Biểu đồ 3. 18. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Ansan (1990 – 2025)	130

22	Biểu đồ 3. 19. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Ansan (2020 – 2025)	130
23	Biểu đồ 3. 20. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Seosan (2020 – 2025)	132
24	Biểu đồ 3. 21. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Seosan (2020 – 2025)	132
25	Biểu đồ 3. 22. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Daejon (2020 – 2025)	133
26	Biểu đồ 3. 23. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Daejon (2020 – 2025)	134
27	Biểu đồ 3. 24. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Iksan (2020 – 2025)	135
28	Biểu đồ 3. 25. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Iksan (2020 – 2025)	136
29	Biểu đồ 3. 26. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Ulsan (2020 - 2025)	137
30	Biểu đồ 3. 27. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Ulsan (2020 - 2025)	138
31	Biểu đồ 3. 28: Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Gwangju (2020 - 2025)	139
32	Biểu đồ 3. 29. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Gwangju (2020 - 2025)	140

33	Biểu đồ 3. 30. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Jeju (2020 - 2025)	141
34	Biểu đồ 3. 31. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Jeju (2020 - 2025)	142
35	Biểu đồ 5. 1. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h	176
36	Biểu đồ 5. 2. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h	176
37	Biểu đồ 5. 3. Mức độ hiệu quả của mô hình GCN cải tiến – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	177
38	Biểu đồ PL - A. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GCN cải tiến – LSTM + MHA tại các trạm trên tập kiểm tra	228
39	Biểu đồ 5. 4. Mức độ hiệu quả của mô hình GCN cải tiến – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	179
40	Biểu đồ PL - A. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GCN cải tiến – BiLSTM + MHA tại các trạm trên tập kiểm tra	229
41	Biểu đồ 5. 5. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h	180

42	Biểu đồ 5. 6. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h	181
43	Biểu đồ 5. 7. Mức độ hiệu quả của mô hình GCN cải tiến – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	182
44	Biểu đồ PL - A. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GCN cải tiến – LSTM + MHA tại các trạm trên tập kiểm tra	231
45	Biểu đồ 5. 8. Mức độ hiệu quả của mô hình GCN cải tiến – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	184
46	Biểu đồ PL - A. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GCN cải tiến – BiLSTM + MHA tại các trạm trên tập kiểm tra	232
47	Biểu đồ 5. 9. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h	186
48	Biểu đồ 5. 10. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h	186
49	Biểu đồ 5. 11. Mức độ hiệu quả của mô hình GAT tinh chỉnh – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	188
50	Biểu đồ PL - B. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT tinh chỉnh – LSTM + MHA tại các trạm trên tập kiểm tra	234

51	Biểu đồ 5. 12. Mức độ hiệu quả của mô hình GAT tinh chỉnh – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	189
52	Biểu đồ PL - B. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT tinh chỉnh – BiLSTM + MHA tại các trạm trên tập kiểm tra	235
53	Biểu đồ 5. 13. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h	191
54	Biểu đồ 5. 14. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h	191
55	Biểu đồ 5. 15. Mức độ hiệu quả của mô hình GAT tinh chỉnh – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	193
56	Biểu đồ PL - B. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT tinh chỉnh – LSTM + MHA tại các trạm trên tập kiểm tra	237
57	Biểu đồ 5. 16. Mức độ hiệu quả của mô hình GAT tinh chỉnh – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	194
58	Biểu đồ PL - B. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT tinh chỉnh – BiLSTM + MHA tại các trạm trên tập kiểm tra	238
59	Biểu đồ 5. 17. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h	196

60	Biểu đồ 5. 18. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h	197
61	Biểu đồ 5. 19. Mức độ hiệu quả của mô hình GAT đề xuất – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	198
62	Biểu đồ PL - C. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT đề xuất – LSTM + MHA tại các trạm trên tập kiểm tra	240
63	Biểu đồ 5. 20. Mức độ hiệu quả của mô hình GAT đề xuất – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	200
64	Biểu đồ PL - C. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT đề xuất – BiLSTM + MHA tại các trạm trên tập kiểm tra	241
65	Biểu đồ 5. 21. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h	201
66	Biểu đồ 5. 22. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h	202
67	Biểu đồ 5. 23. Mức độ hiệu quả của mô hình GAT đề xuất – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	203
68	Biểu đồ PL - C. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT đề xuất – LSTM + MHA tại các trạm trên tập kiểm tra	243

69	Biểu đồ 5. 24. Mức độ hiệu quả của mô hình GAT đề xuất – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra	205
70	Biểu đồ PL - C. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT đề xuất – BiLSTM + MHA tại các trạm trên tập kiểm tra	244
71	Biểu đồ 5. 25: So sánh độ chính xác trung bình dự báo của các mô hình trên đặc trưng pb_mean_2h	207
72	Biểu đồ 5. 26. So sánh độ chính xác trung bình dự báo của các biến thể mô hình không có MHA trên đặc trưng pb_mean_2h	209
73	Biểu đồ 5. 27. So sánh độ chính xác trung bình dự báo của các mô hình trên đặc trưng zn_mean_2h	211

MỞ ĐẦU

1. Lý do chọn đề tài

1.1. Bối cảnh thực tiễn

Trong thực tiễn hiện nay, ô nhiễm không khí đã trở thành một trong những thách thức môi trường nghiêm trọng trên toàn cầu. Theo khảo sát của WHO vào năm 2021 trên các hướng dẫn toàn cầu về chất lượng không khí đối với bụi mịn ($PM_{2.5}$ và PM_{10}), ozone, nitơ điôxít, lưu huỳnh điôxít và carbon monoôxít, các chỉ số bụi mịn, đặc biệt là PM_{10}, thường xuyên vượt ngưỡng khuyến nghị của WHO, điều này gây ảnh hưởng trực tiếp đến sức khỏe cộng đồng và chất lượng môi trường sống [28]. Đồng thời, xu hướng toàn cầu đang chuyển dịch mạnh mẽ theo các tiêu chuẩn phát triển bền vững, tiêu biểu là khung ESG, cùng với các cam kết đạt phát thải ròng bằng "0" (Net-Zero) [18]. Tại Việt Nam, các cam kết này đã được cụ thể hóa thông qua Nghị định số 06/2022/NĐ-CP, đặt nền tảng cho việc kiểm soát phát thải và phát triển thị trường carbon [4].

Trước bối cảnh đó, doanh nghiệp hiện nay đang phải đối mặt với áp lực ngày càng gia tăng trong việc tuân thủ các quy định về phát thải và minh bạch thông tin môi trường. Không chỉ dừng lại ở việc kiểm soát khí thải nhà kính, các doanh nghiệp còn phải giám sát chặt chẽ các chỉ số ô nhiễm không khí như PM_{10} nhằm đáp ứng yêu cầu ESG và các tiêu chuẩn quốc tế. Đồng thời, sự hình thành và phát triển của thị trường tín chỉ carbon toàn cầu đã làm gia tăng tính cạnh tranh và khắt khe trong việc đánh giá hiệu quả giảm phát thải, buộc doanh nghiệp phải chứng minh được hiệu quả môi trường thực tế của mình [19].

Một vấn đề thực tiễn nổi bật là sự biến động của nồng độ PM_{10} có thể tác động trực tiếp đến giá trị doanh nghiệp cũng như giá trị giao dịch của tín chỉ carbon. Theo nghiên cứu gần đây của Jiyoung Park, và cộng sự, (2025) [17] dựa trên việc sử dụng các kỹ thuật học máy để dự báo giá trị doanh nghiệp trong tương lai bao gồm thông

tin về các hoạt động môi trường cho thấy rằng hiệu suất môi trường, bao gồm kiểm soát ô nhiễm không khí có mối quan hệ chặt chẽ với điểm ESG và giá trị thị trường của doanh nghiệp. Khi doanh nghiệp kiểm soát tốt các nguồn phát thải và cải thiện chất lượng không khí không chỉ nâng cao uy tín mà còn góp phần gia tăng giá trị của tín chỉ carbon trên thị trường. Ngược lại, nếu chất lượng môi trường suy giảm, đặc biệt là khi nồng độ PM_{10} gia tăng, doanh nghiệp có thể đối mặt với rủi ro giảm giá trị thương hiệu, suy giảm điểm ESG và giảm giá trị giao dịch của các chứng chỉ carbon [27].

Tuy nhiên, trong thực tế triển khai, các phương pháp hiện nay chủ yếu dựa trên hệ thống quan trắc môi trường, chỉ cung cấp thông tin về trạng thái ô nhiễm tại thời điểm đã xảy ra. Điều này khiến doanh nghiệp rơi vào trạng thái bị động trong việc ứng phó, không có khả năng dự báo sớm để điều chỉnh kế hoạch sản xuất, vận hành hoặc chiến lược giảm phát thải [21]. Hạn chế này làm gia tăng chi phí tuân thủ, giảm hiệu quả kiểm soát môi trường và tiềm ẩn rủi ro làm suy giảm giá trị kinh tế.

1.2. Bối cảnh lý thuyết

Nhu cầu thực tiễn đặt ra là cần có một công cụ dự đoán chính xác diễn biến chất lượng không khí, đặc biệt là nồng độ PM_{10}, điều này nhằm hỗ trợ doanh nghiệp và cơ quan quản lý chủ động trong việc ra quyết định. Một công cụ dự báo hiệu quả không chỉ giúp tối ưu hóa chi phí kiểm soát phát thải mà còn góp phần bảo vệ giá trị doanh nghiệp và nâng cao hiệu quả tham gia thị trường tín chỉ carbon.

Từ những lý do trên, việc ứng dụng các mô hình học sâu kết hợp với dữ liệu quan trắc môi trường được xem là một hướng tiếp cận tiềm năng. Theo nghiên cứu của Ihunanya Udodiri Ajakwe, và cộng sự, (2025) [32] dựa trên xu hướng và kỹ thuật tích hợp Internet vạn vật (IoT) cùng quản lý dữ liệu quan trắc ô nhiễm, cho thấy mô hình học sâu có khả năng khai thác dữ liệu lớn và nắm bắt các mối quan hệ phi tuyến phức tạp trong dự báo chất lượng không khí, từ đó nâng cao độ chính xác dự báo PM_{10}. Do đó, đề tài "Dự đoán hàm lượng chất ô nhiễm trong bụi PM_{10} sử dụng mô hình học sâu và dữ liệu quan trắc" có ý nghĩa thực tiễn cao, góp phần giải quyết

khoảng trống trong công tác dự báo môi trường, hỗ trợ doanh nghiệp chủ động ứng phó, tối ưu chi phí và bảo vệ giá trị trong bối cảnh chuyển đổi xanh hiện nay.

2. Tổng quan nghiên cứu

Trong bối cảnh ô nhiễm không khí ngày càng nghiêm trọng, bụi mịn PM_{10} không chỉ trực tiếp làm suy giảm chất lượng không khí mà còn đóng vai trò "chất mang" vận chuyển các chất ô nhiễm thứ cấp. Có nghiên cứu nhấn mạnh rằng bụi PM_{10} thường tập trung các kim loại nặng độc hại (As, Cd, Cr, Cu, Zn, Pb, Ni) từ các hoạt động giao thông và công nghiệp [31]. Các chất này có khả năng xâm nhập sâu vào cơ thể qua đường hô hấp và tích lũy sinh học, gây ra tác động nguy hiểm cho sức khỏe con người và hệ sinh thái [31]. Nghiên cứu gần đây của Anuradha Yenkikar, và cộng sự, (2025) [7] đã sử dụng mô hình lai Random Forest + ARIMA để dự báo chỉ số chất lượng không khí tại Ấn Độ và đạt hệ số xác định $R^2 \approx 0{,}94$, khẳng định lợi thế của các mô hình có khả năng khai thác quan hệ phi tuyến. Hơn thế nữa, nghiên cứu của Rajnish Rakholia, và cộng sự, (2023) [15] về mô hình học máy đa đầu ra cho dự báo ô nhiễm không khí khu vực tại TP.HCM cũng chỉ ra rằng các kiến trúc học sâu (CNN, RNN/LSTM) có khả năng trích xuất các đặc trưng phi tuyến phức tạp từ dữ liệu lớn, "phá vỡ giới hạn" của các phương pháp dự báo truyền thống. Tương tự, nghiên cứu của Nur'atiah Zaini, và cộng sự, (2022) [6] qua bài tổng quan hệ thống mạng nơ-ron học sâu cho dự báo chuỗi thời gian tổng kết rằng các mô hình học sâu lai thường cho độ chính xác cao hơn rõ rệt so với mô hình đơn lẻ. Những kết quả này cho thấy cần thiết phải phát triển mô hình dự báo tiên tiến để nâng cao độ chính xác dự báo PM_{10} và các thành phần liên quan.

**** Tình hình nghiên cứu trong nước:***

Tại Việt Nam, các nghiên cứu về PM_{10} chủ yếu tập trung vào phân tích đặc điểm ô nhiễm và thành phần hóa học. Nghiên cứu gần đây của Thi Hieu Bui and Thi Phuong Mai Nguyen, (2023) [29] khảo sát bụi PM_{10} tại tỉnh Bắc Giang và cho thấy khu vực công nghiệp có nồng độ PM_{10} và hàm lượng kim loại nặng (As, Cd, Cr, Ni, Pb, V, Zn) cao nhất, trong khi chỉ số nguy cơ sinh học HQ của crom vượt ngưỡng an

toàn (> 1) tại khu vực này. Một nghiên cứu khác của Nguyen Thi Phuong Mai, và cộng sự, (2021) [20] đánh giá thí điểm các kim loại vết trong PM_{10} tại các trạm giao thông ở Bắc Giang cũng xác nhận PM_{10} và các kim loại vết tăng cao ở những vị trí có mật độ giao thông lớn (đặc biệt Cd, Mn, Cr vượt giới hạn WHO). Tại TP. HCM, nghiên cứu của Minh Tri Truong, và cộng sự, (2022) [12] đã tiến hành phân tích dữ liệu môi trường đã phát hiện ra rằng các hoạt động giao thông và đốt cháy chính là nguồn thải chủ yếu, với thứ tự nồng độ kim loại trong PM_{10} là Al > Fe > Sr > Mn > Pb…; đồng thời nghiên cứu này cũng nhận thấy nồng độ Cr và Mn trong bụi gây nguy cơ ung thư cao ở trẻ em. Đối với hướng dự báo, một số công trình mới bắt đầu ứng dụng mô hình học máy. Tiêu biểu như nghiên cứu của Rajnish Rakholia, và cộng sự, (2023) [15] đã xây dựng mô hình học máy đa đầu ra để dự báo các chỉ số ô nhiễm không khí (NO_2, SO_2, CO, O_3) ở TP. HCM, đánh giá với các chỉ số RMSE và MAPE và báo cáo mô hình tổng quát cho hiệu suất vượt trội so với các mô hình đơn trị trước đây. Gần đây, trong nghiên cứu của Hoang-Viet Tran, và cộng sự, (2025) [13] cũng phát triển nhiều mô hình học sâu (LSTM – LSTM, Echo State Network, các mô hình lai) cho dữ liệu ô nhiễm ở TP. HCM, nghiên cứu này cho kết quả sai số dự báo thấp nhất với LSTM – LSTM và ESN, điều này cho thấy rằng mô hình lai kết hợp nhiều mạng đã cho độ chính xác hứa hẹn. Tuy nhiên, các nghiên cứu trong nước vẫn còn hạn chế về định lượng dự báo chuyên sâu: hiếm công trình nào công bố đầy đủ các chỉ số hiệu suất như RMSE, MAE hay R^2 cho chuỗi PM_{10} dài hạn. Phần lớn chỉ mới dừng ở phân tích hiện trạng hoặc sử dụng mô hình cơ bản, thiếu các đánh giá định lượng chi tiết về độ tin cậy của mô hình dự báo.

Nhìn chung, các công trình trong nước đã tạo nền tảng quan trọng về đặc tính hóa học và nguồn thải bụi PM_{10}, song tồn tại ba hạn chế chính. Thứ nhất, chưa có nhiều mô hình dự báo định lượng chính xác cao cho PM_{10} tại Việt Nam; các nghiên cứu dự báo còn thưa thớt và thiếu minh chứng bằng chỉ số số. Thứ hai, ít có công trình ứng dụng đầy đủ phương pháp học sâu tiên tiến; trong khi đó, các mô hình hiện đại ở nước ngoài chưa được thử nghiệm kỹ trên dữ liệu đặc thù Việt Nam (với điều kiện khí hậu, nguồn phát thải khác biệt). Thứ ba, hầu hết chỉ quan tâm dự báo nồng

độ tổng khối lượng PM_{10}, rất hiếm nghiên cứu đi sâu vào dự báo thành phần ô nhiễm cấu thành bên trong (đặc biệt là các kim loại nặng tích tụ). Đây là khoảng trống lớn trong mô hình hóa môi trường hiện nay, trong khi khả năng dự báo thành phần độc chất là then chốt để đánh giá rủi ro sức khỏe.

**** Tình hình nghiên cứu nước ngoài:***

Trên thế giới, đặc biệt từ sau năm 2020, xu thế ứng dụng học sâu trong dự báo chất lượng không khí ngày càng phổ biến. Học sâu nổi lên như một công nghệ tổng quát để khai thác các tri thức phức tạp từ dữ liệu lớn, giúp "phá vỡ giới hạn" của các phương pháp dự báo truyền thống trong lĩnh vực ô nhiễm không khí. Cùng quan điểm trên, nghiên cứu của Nur'atiah Zaini, và cộng sự, (2022) [6] đã tổng hợp cho thấy các mô hình học sâu lai (kết hợp nhiều lớp mạng) thường cho độ chính xác cao hơn rõ rệt so với các mô hình đơn lẻ. Trong các nghiên cứu thực nghiệm, đặc biệt tại Hàn Quốc, nhiều mô hình học sâu lai đã chứng tỏ hiệu suất vượt trội. Chẳng hạn, nghiên cứu của Sujin Park, và cộng sự, (2026) [16] đã phát triển mô hình lai CNN – BiGRU – LSTM để dự báo PM_{10} ở Hàn Quốc, kết quả báo cáo cho thấy rằng các mô hình kết hợp (CNN – BiGRU, CNN – BiGRU – LSTM) cải thiện đáng kể hiệu suất so với các mô hình học sâu đơn thuần. Tương tự, Guang Yang, và cộng sự, (2020) [8] đã áp dụng mô hình lai CNN – LSTM và CNN – GRU cho dữ liệu ô nhiễm ở Seoul (2015–2018); kết quả cho thấy mô hình lai cho sai số thấp nhất ở năm khu vực mẫu thử, với RMSE dự báo PM_{10} tại khu Gangnam đạt khoảng 1,688 $\mu g/m^3$ và MAE là 1,161 $\mu g/m^3$. Hơn thế nữa, một nghiên cứu khác của Eman Hashim and Tayseer Atia, (2025) [25] đã áp dụng thành công mô hình CNN – BiLSTM – Attention trên bộ dữ liệu Bắc Kinh và thu được hệ số xác định $R^2 \approx 0{,}890$ đối với PM_{10}. Một nghiên cứu khác tại Ankara cũng báo cáo với mô hình LSTM đạt $R^2 \approx 0{,}95$ và RMSE $\approx 7{,}94\ \mu g/m^3$ cho PM_{10} [30]. Những nghiên cứu này chứng minh rằng các kiến trúc học sâu lai (CNN – LSTM, BiLSTM + Attention, Transformer,…) có khả năng nắm bắt các mô hình phi tuyến và chuỗi thời gian dài của PM_{10} với độ chính xác cao (thường đạt từ $R^2 \sim 0{,}87 - 0{,}95$ và RMSE ~ $7{,}9 - 10\ \mu g/m^3$). Các mô hình cũng đã được tích hợp đa dạng đầu vào (điều kiện khí tượng, lưu lượng giao thông, mức phát thải công

nghiệp,…) giúp mở rộng khả năng áp dụng sang các khu vực khác như Việt Nam [30].

**** Khoảng trống nghiên cứu:***

Qua khảo sát các công trình trong và ngoài nước, tôi nhận thấy ba khoảng trống chính cần tập trung. Thứ nhất, các nghiên cứu trong nước chủ yếu mới dừng ở phân tích thành phần và cơ chế ô nhiễm, thiếu hụt các mô hình dự báo định lượng chính xác (nhất là ứng dụng sâu học hiện đại) và chưa có đánh giá định lượng minh bạch ($R^2, MAE, RMSE, \ldots$). Thứ hai, tính khả thi của các mô hình học sâu tiên tiến (đã thành công ở các quốc gia phát triển) trên dữ liệu khí hậu và nguồn thải đặc thù của Việt Nam vẫn chưa được kiểm chứng đầy đủ; do đó cần có quá trình điều chỉnh chuyên sâu thay vì áp dụng nguyên thủy. Thứ ba, hầu hết mô hình hiện nay chỉ dự báo tổng nồng độ bụi PM_{10}, hầu như chưa có nghiên cứu nào dự báo riêng hàm lượng thành phần ô nhiễm thứ cấp (như hàm lượng kim loại nặng) trong PM_{10}. Đây là yếu tố then chốt cho đánh giá rủi ro sức khỏe cộng đồng.

3. Mục tiêu nghiên cứu

3.1. Mục tiêu chung

- Tìm hiểu và xây dựng mô hình, thuật toán phù hợp để có thể đưa vào dự đoán chính xác hàm lượng chất ô nhiễm trong bụi PM_{10}.

3.2. Mục tiêu riêng

- Hệ thống hoá cơ sở lý luận và kinh nghiệm thực tế trong việc xây dựng mô hình chuỗi thời gian dự đoán hàm lượng chất ô nhiễm trong bụi PM_{10}.

- Đánh giá độ chính xác của mô hình chuỗi thời gian dự đoán hàm lượt chất ô nhiễm trong bụi PM_{10}, chỉ ra những điểm đã làm tốt, chưa làm tốt và nguyên nhân.

- Đưa ra hệ thống các giải pháp toàn diện và khả thi dựa trên dự đoán của mô hình chuỗi thời gian dự đoán hàm lượng chất ô nhiễm trong bụi PM_{10} và tình trạng chung của khu vực được khảo sát nhằm đưa ra cảnh báo về các đợt ô nhiễm sắp diễn ra.

4. Nhiệm vụ nghiên cứu

Trước hết, nghiên cứu tiến hành thu thập, tổng hợp và xử lý dữ liệu quan trắc môi trường liên quan đến bụi PM_{10} và hàm lượng các chất ô nhiễm (Pb, Zn) từ hệ thống các trạm khí tượng tại Hàn Quốc, đồng thời chuẩn hóa và đồng bộ dữ liệu nhằm xây dựng bộ dữ liệu chuỗi thời gian có tính nhất quán và độ tin cậy cao phục vụ cho quá trình mô hình hóa. Trên cơ sở đó, nghiên cứu thực hiện phân tích đặc điểm dữ liệu, bao gồm xu hướng biến động, tính mùa vụ và mối quan hệ phụ thuộc theo thời gian của các đại lượng, qua đó làm rõ bản chất phi tuyến và tính phức tạp của bài toán dự báo chất lượng không khí, đồng thời tạo tiền đề cho việc lựa chọn và thiết kế mô hình phù hợp.

Tiếp theo, nghiên cứu tiến hành xây dựng, triển khai và so sánh các mô hình học sâu phục vụ dự báo hàm lượng chất ô nhiễm trong bụi PM_{10}, bao gồm các kiến trúc kết hợp giữa mạng nơ-ron tích chập đồ thị và các mô hình chuỗi thời gian như LSTM, BiLSTM, cùng với các biến thể có và không tích hợp cơ chế MHA. Trên nền tảng đó, nghiên cứu đề xuất mô hình cải tiến nhằm nâng cao khả năng học biểu diễn không gian – thời gian, sau đó thực hiện huấn luyện, hiệu chỉnh siêu tham số và kiểm định mô hình trên bộ dữ liệu Hàn Quốc, đồng thời đánh giá hiệu suất thông qua hệ số xác định R^2 và các chỉ số định lượng như MAE, RMSE. Kết quả nghiên cứu được phân tích và so sánh nhằm xác định mô hình tối ưu, qua đó tạo điều kiện thảo luận khả năng ứng dụng và chuyển giao mô hình cho điều kiện dữ liệu tại Việt Nam trong công tác giám sát và dự báo chất lượng không khí trong các nghiên cứu trong tương lai.

5. Đối tượng nghiên cứu

- Hàm lượng chất ô nhiễm (Pb và Zn) trong bụi PM_{10}.
- Mô hình học sâu được phát triển để dự báo hàm lượng chất ô nhiễm (dựa trên GCN cải tiến – LSTM/BiLSTM, GCN cải tiến – LSTM/BiLSTM + MHA).
- Phương pháp xây dựng và huấn luyện mô hình học máy và học sâu cho bài toán dự báo.

6. Phạm vi nghiên cứu

6.1. Phạm vi không gian

Đề tài được thực hiện thông qua việc thu thập dữ liệu hàm lượng chất ô nhiễm tại 11 trạm khí tượng khác nhau, trên toàn quốc, phân bố tại các vùng địa lý khác nhau của Hàn Quốc.

Phân bổ địa lý của các trạm khí tượng như sau:

- **Khu vực miền Bắc:**
  - + Vùng phía Bắc: Trạm khí tượng Chuncheon.
  - + Vùng thủ đô: Trạm khí tượng Seoul.
  - + Vùng thủ đô: Trạm khí tượng Incheon.
  - + Vùng thủ đô: Trạm khí tượng Ansan.
- **Khu vực miền Trung:**
  - + Vùng duyên hải phía Tây: Trạm khí tượng Seosan.
  - + Vùng nội địa miền Trung: Trạm khí tượng Cheongju.
  - + Vùng nội địa miền Trung: Trạm khí tượng Daejon.
- **Khu vực miền Nam:**
  - + Vùng Tây Nam: Trạm khí tượng Iksan.
  - + Vùng Đông Nam: Trạm khí tượng Ulsan.
  - + Vùng Tây Nam: Trạm khí tượng Gwangju.
  - + Vùng đảo cực Nam: Trạm khí tượng Jeju.

6.2. Phạm vi thời gian

Trong khoảng thời gian từ 01/01/2020 đến 29/12/2025.

6.3. Phạm vi nội dung

Nghiên cứu tập trung vào việc dự báo và so sánh hiệu quả của mô hình học sâu hiện đại và các cải tiến của nó, bao gồm: GCN cải tiến – LSTM/ BiLSTM, GCN cải tiến – LSTM/BiLSTM + MHA và các mô hình đề xuất trong dự báo hàm lượng chất

ô nhiễm (Pb và Zn) trong bụi PM_{10} (pb_mean_2h, zn_mean_2h). Các mô hình được đánh giá theo các chỉ số: R^2, MAE, RMSE.

7. Phương pháp nghiên cứu

Phương pháp hệ thống hoá tài liệu: xuất phát từ bối cảnh thực tiễn ô nhiễm không khí, đặc biệt là nồng độ bụi PM_{10} tại các khu vực đô thị và công nghiệp, cùng với xu hướng toàn cầu về tiêu chuẩn ESG và lộ trình Net – Zero của các quốc gia, trọng tâm tìm kiếm sẽ tập trung vào ba hướng nghiên cứu chính: các mô hình học máy, học sâu được ứng dụng trong dự báo chất lượng không khí và chuỗi thời gian.

Phương pháp điều tra, khảo sát dữ liệu: đề tài nghiên cứu sẽ chủ yếu nghiên cứu sử dụng dữ liệu điều tra khảo sát của 11 trạm khí tượng tại các địa điểm khác nhau tại Hàn Quốc.

Phương pháp phân tích và xử lý dữ liệu: sau khi thu thập được số liệu khảo sát, tôi sẽ tiến hành làm sạch và chuẩn bị dữ liệu cho mô hình học sâu thông qua các bước tiền xử lý dữ liệu, rút trích đặc trưng.

Phương pháp thực nghiệm và đánh giá mô hình dự đoán: cài đặt thực nghiệm, đánh giá kết quả trên tập dữ liệu thu thập.

8. Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đã bổ sung và hoàn thiện hệ thống lý luận về dự báo hàm lượng chất ô nhiễm (Pb và Zn) trong bụi PM_{10} trong bối cảnh ô nhiễm không khí gia tăng và yêu cầu kiểm soát phát thải ngày càng nghiêm ngặt, đặc biệt tại các khu vực đô thị và công nghiệp. Nghiên cứu tập trung phát triển và cải tiến trực tiếp mô hình GCN cải tiến – LSTM/BiLSTM + MHA nhằm khai thác hiệu quả mối quan hệ không gian – thời gian trong dữ liệu quan trắc môi trường. Cụ thể, mô hình được xây dựng lại theo hướng lai GCN bằng GAT nhằm nâng cao khả năng học trọng số thích nghi giữa các nút trong mạng lưới trạm quan trắc. Đồng thời, nghiên cứu đề xuất cơ chế độ lệch khoảng cách thích nghi nhằm đưa yếu tố khoảng cách địa lý vào quá trình tính toán hệ số chú ý, điều này giúp mô hình phản ánh tốt hơn ảnh hưởng

không gian thực tế giữa các khu vực. Điểm đặc biệt của nghiên cứu là dữ liệu đầu vào được xây dựng dưới dạng chuỗi thời gian đơn biến (univariate time series), trong đó lần lượt giá trị hàm lượng chất ô nhiễm (Pb và Zn) trong bụi PM_{10} theo thời gian được sử dụng làm tín hiệu chính, còn thông tin không gian được mã hóa thông qua cấu trúc đồ thị và cơ chế chú ý. Kết hợp với LSTM/BiLSTM và cơ chế MHA để nắm bắt các phụ thuộc thời gian dài hạn, mô hình đề xuất có khả năng học biểu diễn không gian – thời gian một cách hiệu quả ngay cả trong điều kiện dữ liệu đầu vào đơn biến. Từ đó, nghiên cứu thiết lập cơ sở đánh giá hiệu quả của mô hình đề xuất trong việc dự báo PM_{10} nhằm làm rõ ưu điểm của hướng tiếp cận học sâu tích hợp không gian – thời gian so với các phương pháp truyền thống.

Về mặt thực tiễn, nghiên cứu xây dựng công cụ dự báo hàm lượng chất ô nhiễm (Pb và Zn) trong bụi PM_{10} phục vụ giám sát và cảnh báo sớm chất lượng không khí tại các khu vực đô thị và công nghiệp, điều này góp phần nâng cao hiệu quả quản lý môi trường và bảo vệ sức khỏe cộng đồng thông qua khả năng tích hợp vào hệ thống quan trắc. Việc phát triển và cải tiến mô hình theo hướng GAT-LSTM/BiLSTM kết hợp cơ chế độ lệch khoảng cách thích nghi giúp nâng cao độ chính xác và tính ổn định của dự báo trong điều kiện dữ liệu thực tế có tính biến động cao và hạn chế về số lượng biến đầu vào. Kết quả nghiên cứu là cơ sở khoa học hỗ trợ cơ quan quản lý và doanh nghiệp trong việc lập kế hoạch kiểm soát phát thải, tối ưu hóa vận hành và giảm thiểu rủi ro môi trường. Trong bối cảnh thị trường tín chỉ carbon và các tiêu chuẩn ESG ngày càng khắt khe, dự báo chính xác hàm lượng chất ô nhiễm giúp doanh nghiệp chủ động điều chỉnh hoạt động sản xuất, qua đó duy trì chất lượng môi trường, bảo vệ giá trị doanh nghiệp và nâng cao giá trị giao dịch của chứng chỉ carbon. Đồng thời, công cụ dự báo còn hỗ trợ trong lĩnh vực y tế công cộng thông qua cảnh báo sớm các đợt ô nhiễm không khí, trong quản lý đô thị nhằm điều tiết hoạt động giao thông và công nghiệp, cũng như trong hoạch định chính sách phát triển bền vững.

9. Cấu trúc của đề tài

Ngoài phần mở đầu, kết luận và danh mục tài liệu tham khảo, nội dung chính của bài tiểu luận gồm 5 chương chính:

Chương 1: Cơ sở lý thuyết

Chương 2: Mô tả và xử lý dữ liệu

Chương 3: Phân tích dữ liệu

Chương 4: Phương pháp đề xuất

Chương 5: Thiết lập, kết quả và đánh giá thực nghiệm

NỘI DUNG

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1. Giới thiệu

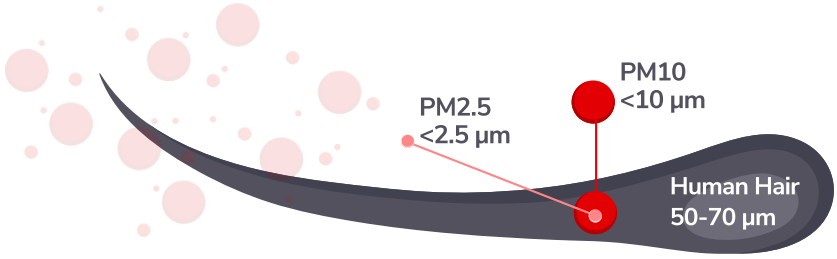
Trong chương này, tôi sẽ giới thiệu một cách khái quát về các cơ sở lý thuyết nền tảng phục vụ cho việc xây dựng mô hình dự đoán nồng độ bụi PM10 theo tiếp cận học sâu kết hợp không gian – thời gian.

Đầu tiên, phần 1.2 trình bày khái niệm, đặc tính, nguồn gốc phát sinh, cơ chế phân tán không gian và các yếu tố ảnh hưởng đến nồng độ bụi PM10 nhằm làm cơ sở để hiểu rõ bản chất của bài toán dự đoán. Tiếp theo, phần 1.3 giới thiệu tổng quan về lý thuyết đồ thị và hai kiến trúc học sâu theo tiếp cận không gian là GCN cải tiến và GAT tinh chỉnh nhằm phục vụ cho việc mô hình hóa mối quan hệ phụ thuộc không gian giữa các trạm quan trắc. Sau đó, phần 1.4 trình bày các mô hình học sâu xử lý chuỗi thời gian bao gồm RNN, LSTM và BiLSTM, đây là nền tảng để nắm bắt các phụ thuộc thời gian trong dữ liệu quan trắc. Phần 1.5 trình bày cơ chế chú ý đa đầu (MHA) với cả quá trình lan truyền tiến và lan truyền ngược, đây là thành phần bổ trợ quan trọng nhằm nâng cao khả năng biểu diễn của mô hình đề xuất. Cuối cùng, phần 1.6 sẽ tổng kết lại các điểm chính được trình bày trong chương này.

1.2. Tổng quan về PM_{10}

1.2.1. Khái niệm và đặc tính của bụi PM_{10}

Theo Bộ Tài nguyên và Môi trường, (2013) [5], bụi PM_{10} hay Particulate Matter 10 là các hạt lơ lửng trong không khí có đường kính khí động học nhỏ hơn hoặc bằng 10 micromet (μm). Chúng nhỏ hơn tóc người và có kích thước chỉ bằng $1/5$ đến $1/7$ kích thước tóc người. Kích thước vật lý siêu nhỏ này cho phép chúng có khả năng xâm nhập sâu vào phế quản và phổi khi bị con người hít phải thông qua đường không khí.



Hình 1. 1. Kích thước của các loại bụi PM so với kích thước của 1 sợi tóc người

Về thành phần, PM_{10} là hỗn hợp phức tạp gồm vật chất vô cơ (muối sulfat, nitrat, cation amoni), muối biển (NaCl), hợp chất hữu cơ (cacbon tổng hợp, PAH, VOC), tro bụi và các kim loại nặng. Theo nghiên cứu của Bùi Quang Trung, và cộng sự, (2021) [1] phân tích bụi PM_{10} ở Hà Nội đã ghi nhận Fe, Al, Zn, Pb có thành phần khối lượng lớn nhất trong hỗn hợp bụi. Ngoài ra, các thành phần hóa học như Pb và Zn thường được dùng làm nguyên tố nguồn vì Zn, Pb thường liên quan đến hoạt động công nghiệp, giao thông và đốt than/gỗ với đặc tính vật lý nhẹ, có diện tích bề mặt lớn nên dễ bám giữ các chất hữu cơ và khí, và thường tồn tại trong không khí hàng giờ đến vài ngày.

Về tác động sức khỏe, WHO Guidelines Approved by the Guidelines Review Committee, (2021) [28] báo cáo mỗi năm hàng triệu người tử vong liên quan đến ô nhiễm không khí, trong đó bụi mịn $PM_{2.5}$ và PM_{10} là yếu tố rủi ro lớn gây bệnh tim mạch, hô hấp, đột quỵ, COPD, ung thư và sinh non. Ở Việt Nam, ô nhiễm bụi PM_{10} được xem là "sát thủ vô hình", ảnh hưởng đặc biệt nghiêm trọng đến trẻ em, người già và người bệnh mạn tính. Hiện nay, giới hạn quốc gia QCVN cho phép nồng độ trung bình 24h PM_{10} là 150 $\mu g/m^3$, tuy nhiên nhiều đô thị lớn thường xuyên vượt giá trị này [5].

1.2.2. Nguồn gốc phát sinh

Các nguồn phát sinh PM_{10} chia làm hai nhóm chính: tự nhiên và nhân tạo.

Nguồn tự nhiên bao gồm bụi cát sa mạc, tro núi lửa, phấn hoa, vi sinh vật trong không khí, và muối biển từ sóng biển (NaCl). Ví dụ, bão cát từ Trung Á có thể mang bụi hạt thô vào miền Bắc Việt Nam trong mùa khô.

Nguồn nhân tạo phong phú hơn: Theo nghiên cứu của Bùi Quang Trung, và cộng sự, (2021) [1] cho thấy Pb trong PM_{10} thường phát sinh từ khí thải các nhà máy sản xuất thép, nhựa, nhuộm và các lò đốt rác; ngoài ra, nghiên cứu còn chỉ ra rằng Zn thường phát sinh từ khí thải các nhà máy sản xuất thép, đốt rác và khí thải phương tiện giao thông sử dụng nhiên liệu xăng. Các sản phẩm đốt từ động cơ và lốp xe cũng giải phóng Zn và các kim loại khác (Cu, Cd). Bên cạnh đó, một phần PM_{10} là thứ cấp do các phản ứng hóa học trong không khí (từ tiền chất khí SO_2, NOx, NO_3 tạo ra sulfate, nitrate kết tủa).

1.2.3. Cơ chế phân tán không gian

Về mặt không gian, sau khi phát thải, PM_{10} được vận chuyển theo các cơ chế khí quyển: vận chuyển gió (advection) mang hạt đi theo hướng gió lớn, tạo ra hiện tượng lan truyền vùng xa; khuếch tán (turbulent diffusion) từ áp suất không khí cao đến thấp giúp phân tán và pha loãng bụi. Ngoài ra, nhiệt độ, độ ẩm và độ cao lớp đối lưu cũng có tầm ảnh hưởng lớn: ban ngày, lớp đối lưu cao hơn giúp phân tán nhanh; ban đêm, nghịch nhiệt có thể cô lập bụi gần mặt đất. Bụi từ khu vực xa (như từ sườn phía Tây Nam lên Bắc Kinh, Trung Quốc) gây ảnh hưởng bụi PM_{10} tăng đột biến tại địa phương, với hệ thống áp cao kết hợp nghịch nhiệt duy trì nồng độ cao như theo nghiên cứu của F Wang, và cộng sự, (2010) [9]. Một nghiên cứu khác của Eunhye Kim, và cộng sự, (2023) [22] cũng chỉ ra rằng bụi PM lơ lửng tại khu vực phát thải được thổi lên cao nhờ khuếch tán đứng (vertical diffusion) và vận chuyển dọc (vertical advection) rồi lan truyền ngang tới khu vực khác bằng advection ở tầng khí quyển trên, thường nhanh hơn tầng sát mặt đất. Bên cạnh đó, bụi PM_{10} còn bị lắng đọng do trọng lực và rửa trôi bởi mưa.

Về mặt thời gian, việc vận chuyển bụi PM_{10} xuyên vùng tạo ra một độ trễ nhất định giữa các khu vực. Ví dụ, khi gió thổi bụi từ một tỉnh lên cao, đến một tỉnh phía đông có thể mất từ vài giờ đến vài ngày. Độ trễ này có thể phân tích bằng các phương pháp thống kê: hàm tương quan chéo (cross-correlation) giữa hai chuỗi thời gian nồng độ PM_{10} ở hai trạm để xác định khoảng thời gian dịch giữa hai đỉnh; kiểm định

Granger causality để kiểm tra xem lịch sử PM_{10} ở nơi trước có ảnh hưởng tiên lượng được tới nơi sau không; hoặc hồi quy tuyến tính có độ trễ (lagged regression). Hơn thế nữa, các mô hình hành trình hạt (ví dụ HYSPLIT) được dùng để theo dõi đường đi của luồng không khí, từ đó xác định nguồn gốc bụi. Tương tự, F Wang, và cộng sự, (2010) [9] đã dùng HYSPLIT kết hợp phân cụm quỹ đạo cho thấy hướng gió tây nam đưa PM_{10} vào Bắc Kinh, và xác định luồng khối khí hội tụ do địa hình núi đã thúc đẩy ô nhiễm cao.

1.2.4. Các yếu tố ảnh hưởng đến nồng độ bụi PM_{10}

Nồng độ bụi PM_{10} tại một địa điểm chịu chi phối bởi hai nhóm yếu tố chính: nguồn thải (cục bộ và lan truyền) và điều kiện khí tượng – địa hình.

- *Nguồn phát thải*: Bao gồm hoạt động giao thông, công nghiệp, sinh hoạt và tự nhiên quanh khu vực. Lượng phát thải tăng làm tăng nồng độ ngay lập tức; ví dụ trạm đo tại đường giao thông thường thấy PM_{10} cao hơn trạm nền. Bên cạnh đó, vào giờ cao điểm buổi sáng và chiều, khi mật độ xe cộ lớn, nồng độ bụi tăng đột biến; ngược lại nồng độ giảm thấp vào giữa trưa và ban đêm khi giao thông vắng và tầng đối lưu dâng cao. Sự biến động theo mùa cũng rõ rệt: tại miền Bắc Việt Nam, mùa khô (tháng 10 đến tháng 4 hằng năm) nồng độ PM_{10} cao hơn gấp đôi so với mùa mưa, do đốt than, rơm rạ sau thu hoạch và ít mưa rửa trôi. Trong khi đó, miền Trung và Nam Trung Bộ có sự khác biệt theo mùa kém rõ.
- *Khí tượng và địa hình*: Gió mạnh giúp khuếch tán bụi, trong khi gió nhẹ và áp cao gây stagnation (đình trệ). Mưa và độ ẩm cao giúp giữ hoặc rửa trôi bụi, điều này góp phần làm giảm nồng độ bụi PM_{10}; ngược lại khô hanh và mờ sương thường tăng tích tụ bụi. Mô hình thời tiết đặc trưng như mùa gió mùa Đông Bắc khô lạnh hay Tây Nam ẩm ướt cũng ảnh hưởng lớn. Ngoài ra, hình dạng địa hình như thung lũng, vùng chân núi có thể giữ bụi lại, còn vùng bờ biển chịu gió biển mạnh giúp pha loãng bụi. Những nghiên cứu ở Việt Nam nhận thấy rằng các thành phố ven biển phía Nam có chỉ số bụi thấp hơn, trong

khi các vùng cao, đồng bằng kín gió thường ô nhiễm hơn. Tóm lại, sự thay đổi chu kỳ ngày/đêm và theo mùa do tầng đối lưu thay đổi, cùng các hiện tượng gió địa phương (gió biển, gió núi) là những cơ chế khí tượng quan trọng điều khiển mức độ phân tán bụi [22].

1.3. Tổng quan về mô hình học sâu dự đoán chuỗi thời gian theo tiếp cận không gian

Bài toán dự báo hàm lượng chất ô nhiễm là một thách thức phức tạp, chịu sự chi phối mạnh mẽ bởi yếu tố vị trí địa lý của hệ thống các trạm quan trắc. Nồng độ chất ô nhiễm thực tế không chỉ biến thiên theo các yếu tố khí tượng cơ bản mà còn bị định hình bởi đặc điểm địa hình và vị trí phân bố đặc thù của từng trạm.

Cụ thể, sự khác biệt về cao độ và mật độ không khí khiến các trạm vùng núi cao thường ghi nhận mức độ ô nhiễm thấp hơn so với các khu vực đồng bằng và thung lũng. Tương tự, với đặc thù địa lý của một bán đảo, các trạm ven biển tại Hàn Quốc chịu tác động trực tiếp từ hơi nước đại dương nên thường có độ ẩm và khả năng điều hòa không khí khác biệt so với các trạm nằm sâu trong nội địa. Đặc biệt, sự phân hóa địa hình phức tạp (như khu vực đồi núi phía Đông so với vùng đồng bằng đô thị hóa cao ở phía Tây) kết hợp cùng hệ thống gió mùa đặc trưng (mùa đông hanh khô mang theo bụi xuyên biên giới và mùa hè nóng ẩm) đã tạo nên những đặc tính riêng biệt về vi khí hậu và quy luật biến thiên hàm lượng chất ô nhiễm theo từng vùng lãnh thổ.

Bên cạnh các đặc điểm địa lý riêng lẻ, nồng độ chất ô nhiễm còn tồn tại sự tương quan không gian chặt chẽ giữa các trạm khí tượng lân cận. Cụ thể hơn, các trạm quan trắc nằm trong cùng một khu vực thường có xu hướng biến thiên hàm lượng chất ô nhiễm tương đồng do chia sẻ chung các điều kiện vi khí hậu và nguồn thải địa phương. Tuy nhiên, các phương pháp truyền thống thường không thể khai thác mối quan hệ không gian này vì thường chỉ xem xét xử lý từng trạm riêng lẻ, mà bỏ qua yếu tố sự phụ thuộc giữa các trạm lân cận. Do đó, mô hình GCN sẽ là giải pháp hiệu quả để khai thác vấn đề này, khi mô hình này có khả năng mô hình hóa dữ

liệu theo cấu trúc đồ thị, nơi mỗi nút trong đồ thị đại diện cho 1 trạm khí tượng và các cạnh liên kết giữa các nút đại diện cho sự tương quan giữa các trạm khí tượng.

Trong phạm vi đề tài này, tôi kế thừa nền tảng lý thuyết của mô hình GCN cải tiến đã được trình bày từ khóa luận tốt nghiệp trước đó, đồng thời phát triển theo hướng tiếp cận mới dựa trên mô hình dự đoán chuỗi thời gian theo tiếp cận không gian không gian sử dụng GAT. Để làm rõ cơ sở lý thuyết của phương pháp, tôi sẽ giới thiệu một số khái niệm đồ thị quan trọng liên quan đến mô hình, đồng thời trình bày chi tiết lý thuyết nền tảng của GCN cải tiến.

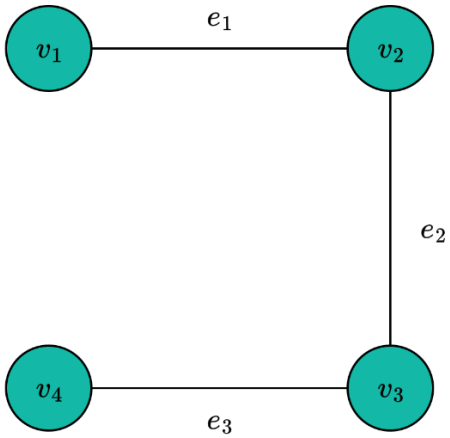
1.3.1. Sơ lược về đồ thị

Ý tưởng chính của mô hình GCN cải tiến và các biến thể của chúng đều có cơ chế hoạt động dựa trên cấu trúc đồ thị, do đó trong phần này tôi sẽ sơ lược 1 số lý thuyết đồ thị có liên quan đến mô hình GCN cải tiến và các mô hình đề xuất được sử dụng trong đề tài.

1.3.1.1. Định nghĩa về đồ thị

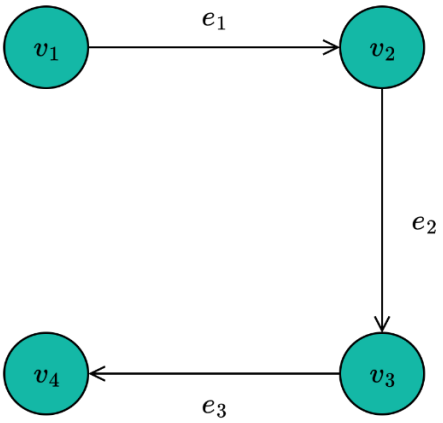
Đồ thị [2] là một mô hình toán học biểu diễn các cấu trúc rời rạc bao gồm một tập các phần tử kết hợp với một tập các quan hệ giữa các cặp phần tử của chúng. Một đồ thị được ký hiệu là $G(V, E)$, trong đó: G đại diện cho đồ thị, V là tập đỉnh, và E là tập cạnh. Dựa vào tính chất thứ tự của các cạnh, đồ thị có thể được phân thành hai loại chính: đồ thị vô hướng và đồ thị có hướng.

Đồ thị vô hướng $G(V, E)$, gồm 1 tập V các đỉnh, và 1 tập E các cạnh. Khi này $e = (u, v) \in E$ ứng với một cặp không có thứ tự các đỉnh $u, v \in V$.



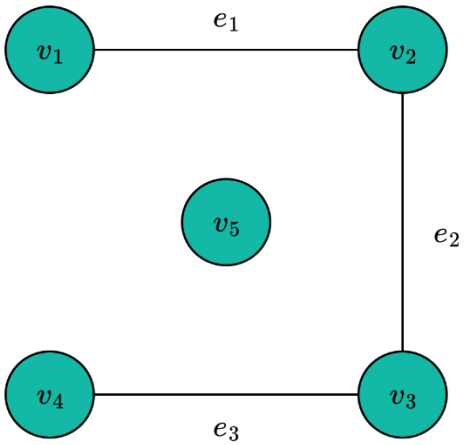
Hình 1. 2. Đồ thị vô hướng

Đồ thị có hướng $G(V, E)$, gồm 1 tập V các đỉnh, và 1 tập E các cạnh. Khi này $e = (u, v) \in E$ ứng với một cặp có thứ tự các đỉnh $u, v \in V$.



Hình 1. 3. Đồ thị có hướng

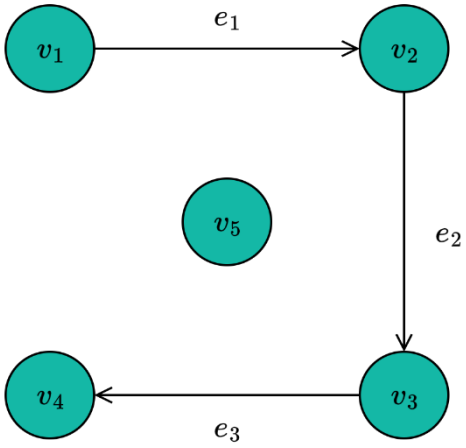
Giả sử hai đỉnh v_1 và v_2 kề nhau, nếu có cạnh $e = (v_1, v_2)$ thì cạnh e là cạnh liên thuộc với v_1 và v_2. Trong đồ thị vô hướng, bậc của đỉnh v là số cạnh liên thuộc với nó, được ký hiệu là $deg(v)$, đỉnh bậc 0 gọi là đỉnh cô lập, đỉnh bậc 1 gọi là đỉnh treo.



Hình 1. 4. Mô tả bậc của đỉnh trong các đồ thị vô hướng

Dựa vào Hình 1. 4, nhận thấy rằng $deg(v_1) = deg(v_2) = deg(v_3) = 1$, $deg(v_5) = 0$. Như vậy đỉnh v_5 được gọi là cô lập trong đồ thị vô hướng.

Trong đồ thị có hướng, bậc của đỉnh v được chia thành 2 loại – bán bậc ra của đỉnh v chỉ số lượng cạnh đi ra khỏi đỉnh v, ký hiệu là $deg^+(v)$; bán bậc vào của đỉnh v chỉ số lượng cạnh đi vào đỉnh v, ký hiệu là $deg^-(v)$. Đỉnh có bán bậc ra hoặc bán bậc vào là 0 được gọi là đỉnh cô lập, đỉnh có tổng bán bậc ra và bán bậc vào bằng 1 được gọi là đỉnh treo.



Hình 1. 5. Mô tả bậc của đỉnh trong đồ thị có hướng

Dựa vào Hình 1. 5, nhận thấy rằng$deg^+(v_1) = 0$, $deg^-(v_1) = 1$, $deg^+(v_2) = deg^-(v_2) = 1$, $deg^+(v_3) = deg^-(v_3) = 1$, $deg^+(v_4) = 1$,

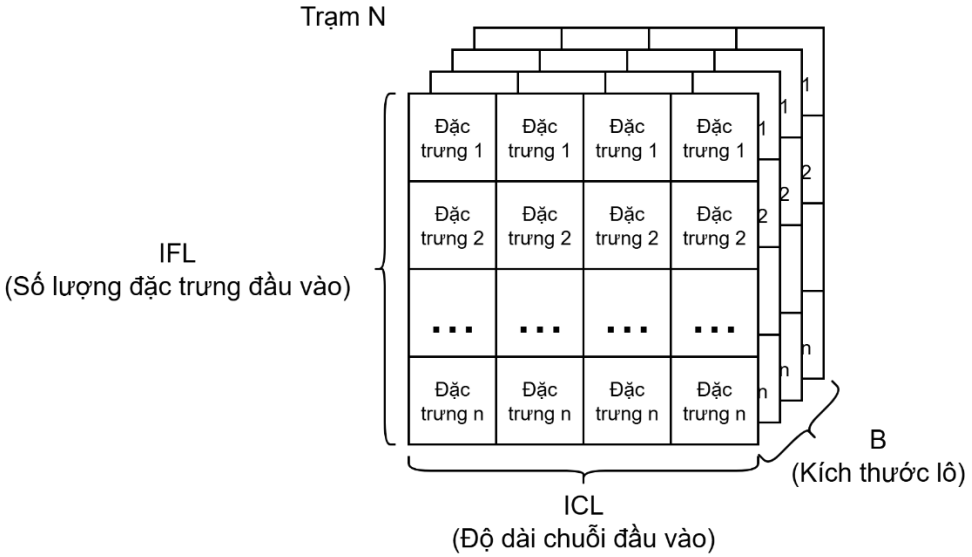
$deg^-(v_4) = 0, deg^+(v_5) = deg^-(v_5) = 0$ Như vậy đỉnh v_4 được gọi là đỉnh treo, đỉnh v_5 gọi là đỉnh cô lập trong đồ thị có hướng.

1.3.1.2. Biểu diễn đồ thị

Biểu diễn đồ thị là cách chuyển đổi cấu trúc đồ thị về dạng dữ liệu số để phục vụ cho quá trình tính toán trong các mô hình học sâu trên đồ thị. Tùy theo từng kiến trúc mô hình, các dạng biểu diễn có thể được sử dụng khác nhau nhằm khai thác hiệu quả mối quan hệ giữa các đỉnh trong đồ thị. Các biểu diễn đồ thị được sử dụng trong đề tài bao gồm:

- **Ma trận biểu diễn đặc trưng nút $X \in R^{N \times B \times ICL \times IFL}$:**

Ma trận này chứa các vector biểu diễn đặc trưng của mỗi nút, trong đó N là số lượng nút trong đồ thị, B là kích thước lô, ICL là độ dài chuỗi đầu vào, IFL là số đặc trưng đầu vào. Ma trận X được mở rộng thêm 2 chiều với chiều B để mô hình có thể xử lý nhiều mẫu dữ liệu đồng thời, linh hoạt và tăng hiệu quả trong quá trình huấn luyện, chiều ICL để mô hình có thể xử lý dữ liệu thời gian, và thực hiện kết hợp với các mô hình tuần tự khai thác mối quan hệ thời gian như LSTM và BiLSTM.

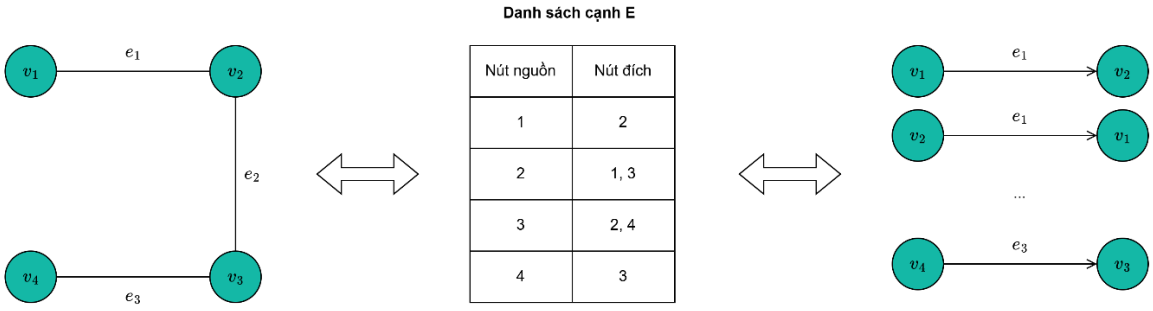


Hình 1. 6. Ma trận biểu diễn đặc trưng nút cho trạm thứ N có $X \in R^{N \times B \times ICL \times IFL}$

Giả sử dữ liệu đầu vào X có dạng $X \in R^{2\times3\times3\times2}$, chúng ta có thể hiểu rằng X đầu vào gồm 2 trạm khí tượng, mỗi trạm gồm 3 lô dữ liệu, mỗi lô gồm 3 chuỗi đầu vào và mỗi chuỗi đầu vào có 2 đặc trưng.

- **Danh sách cạnh $\boldsymbol{E = \{(i_1, j_1); (i_2, j_2); \dots; (i_N, j_N)\}}$:**

Danh sách này chứa cấu trúc kết nối của đồ thị, trong đó i là nút nguồn và j là nút đích. Việc lưu trữ cấu trúc đồ thị dưới dạng danh sách cạnh E thay vì ma trận kề A như GCN giúp mô hình tối ưu hóa bộ nhớ và hiệu suất tính toán trong mô hình.



Hình 1. 7. Danh sách cạnh E

- **Ma trận trọng số $\boldsymbol{W \in R^{IFL\times OFL}}$:**

Ma trận trọng số này thực hiện biến đổi các đặc trưng từ không gian đầu vào IFL sang không gian đầu ra OFL.

- **Ma trận khoảng cách $\boldsymbol{D \in R^{N\times N}}$:**

Ma trận trên được tính toán thông qua khoảng cách giữa các trạm thông qua công thức tính Haversine, công thức này được dùng để tính khoảng cách giữa 2 điểm trên bề mặt cầu (như Trái Đất) dựa trên kinh độ và vĩ độ của chúng. Sau đó sử dụng công thức này tính khoảng cách của từng trạm khí tượng.

Giả sử có 2 điểm tọa độ địa lý của 2 trạm khí tượng $(\emptyset_1, \lambda_1)$ và $(\emptyset_2, \lambda_2)$ với $\emptyset$ là vĩ độ và λ là kinh độ (đơn vị radian) và R = 6371 km là bán kính Trái Đất.

Khi đó khoảng cách Harversine sẽ được tính như sau:

$$\Delta\emptyset = \emptyset_2 - \emptyset_1;\ \Delta\lambda = \lambda_2 - \lambda_1 \qquad (1.1)$$

$$a = \sin^2\left(\frac{\Delta\emptyset}{2}\right) + \cos(\emptyset_1).\cos(\emptyset_2).\sin^2\left(\frac{\Delta\lambda}{2}\right) \quad (1.2)$$

$$c = 2.\arctan2\left(\sqrt{a}, \sqrt{1-a}\right) \quad (1.3)$$

$$Haversine = R.c \quad (1.4)$$

Dựa vào công thức tính khoảng cách Haversine giữa 2 trạm khí tượng trên, ta thực hiện tạo ma trận khoảng cách D của tất cả các trạm khí tượng.

$$D_{ij} = \begin{cases} Haversine((\emptyset_1, \lambda_1), (\emptyset_2, \lambda_2)), & khi\ i \neq i \\ 0, & khi\ i = j \end{cases} \quad (1.5)$$

- **Ma trận kề $\boldsymbol{A \in R^{N\,x\,N}}$:**

Trong lý thuyết đồ thị, mối quan hệ giữa các nút có thsể được mô hình hóa thông qua các cạnh, phản ánh mức độ liên kết hoặc phụ thuộc giữa các thực thể trong hệ thống. Đối với bài toán dự báo chất lượng không khí, việc xác định cấu trúc liên kết giữa các trạm khí tượng đóng vai trò quan trọng trong việc biểu diễn sự phụ thuộc không gian của dữ liệu.

Dựa trên cơ sở này, phương pháp xây dựng ma trận kề dựa trên hệ số tương quan đã được đề xuất trong khóa luận tốt nghiệp của Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] và được sử dụng trong đề tài. Cụ thể, với mỗi cặp trạm khí tượng, nhóm tác giả trên đã tính toán hệ số tương quan Pearson dựa trên dữ liệu nhiệt độ cảm nhận. Nếu giá trị tương quan lớn hơn hoặc bằng một ngưỡng xác định trước, hai trạm sẽ được xem là có liên kết và một cạnh sẽ được thiết lập giữa hai nút tương ứng trong đồ thị. Ngược lại, nếu giá trị tương quan nhỏ hơn ngưỡng này, liên kết sẽ không được hình thành.

Để thuận tiện cho việc theo dõi, thuật toán tính toán ma trận kề được thiết kế và trình bày lại như sau:

Thuật toán: Compute_Corellation(X, threshold):

---

1. n ← số lượng trạm khí tượng

2. A ← ma trận zeros kích thước n x n
3. for i ← 0 to n do:
4. for j ← 0 to n do:
5. C ← PearsonCorrelation(X[:, i], X[:, j])
6. if $|C| \geq threshold$ then A[i, j] = 1
7. else then A[i, j] = 0
8. A[i, i] = 0 // Loại bỏ self-loop
9. return A, C

Dựa trên cơ chế xây dựng liên kết như trên, ma trận kề A được hình thành nhằm biểu diễn cấu trúc kết nối giữa các trạm khí tượng. Từ ma trận này, danh sách cạnh E được trích xuất bằng cách xác định tất cả các cặp chỉ số (i, j) sao cho $A_{ij} = 1$, trong đó i và j lần lượt đại diện cho nút nguồn và nút đích.

1.3.2. Mô hình GCN cải tiến

Mô hình khai thác đặc trưng không gian này được Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất sau khi cải tiến từ mô hình GCN tinh chỉnh trong Keras Team, (2023) [23], tôi tạm gọi là mô hình cải tiến của GCN tinh chỉnh, lấy tên là GCN cải tiến.

Mô hình GCN tinh chỉnh được phát triển nhằm khắc phục một số hạn chế của mô hình GCN truyền thống, đặc biệt trong việc xử lý dữ liệu chuỗi trên đồ thị và nâng cao tính linh hoạt trong cơ chế kết hợp thông tin giữa các nút. Nhờ đó, mô hình có khả năng biểu diễn tốt hơn các đặc trưng không gian trong những bài toán thực tế có tính chất động. Tuy nhiên, mô hình này vẫn chưa phản ánh đầy đủ mức độ ảnh hưởng khác nhau giữa các nút trong không gian, khi mà cơ chế kết hợp thông tin chủ yếu vẫn dựa trên cấu trúc liên kết của đồ thị mà chưa xét đến yếu tố khoảng cách địa lý.

Trên cơ sở đó, mô hình GCN cải tiến được phát triển từ GCN tinh chỉnh bằng cách tích hợp thêm cơ chế trọng số khoảng cách giữa các nút. Cụ thể, khoảng cách giữa các nút được sử dụng như một yếu tố điều chỉnh mức độ ảnh hưởng trong quá trình lan truyền thông tin, giúp mô hình phản ánh rõ hơn mối quan hệ không gian giữa các điểm quan trắc. Việc bổ sung thông tin khoảng cách không chỉ làm tăng tính biểu diễn của mô hình mà còn góp phần nâng cao hiệu quả dự báo trong các bài toán có phụ thuộc mạnh vào yếu tố không gian.

1.3.2.1. Quá trình lan truyền tiến của mô hình GCN cải tiến

- **Đầu vào của mô hình:**

Quá trình lan truyền tiến của GCN cải tiến trong bài toán dự báo chuỗi thời gian bắt đầu từ lúc nhận đầu vào là tensor $X \in R^{N \times B \times ICL \times IFL}$. Trong quá trình này các giá trị đầu vào thực hiện tính toán bên trong ô nhớ.

- **Đầu ra của mô hình:**

Đầu ra của mô hình GCN cải tiến là giá trị tensor dự báo $X' \in R^{N \times B \times ICL \times OFL}$ sau khi tính toán xong lô cuối cùng.

- **Cơ chế lan truyền thông tin của mô hình:**

Dựa vào khung mô hình GCN tinh chỉnh của tác giả Arash Khodadadi công bố vào năm 2023 kết hợp thông tin trọng số cho các canh trong cấu trúc đồ thị, GCN cải tiến của nhóm tác giả Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất có các giai đoạn như sau:

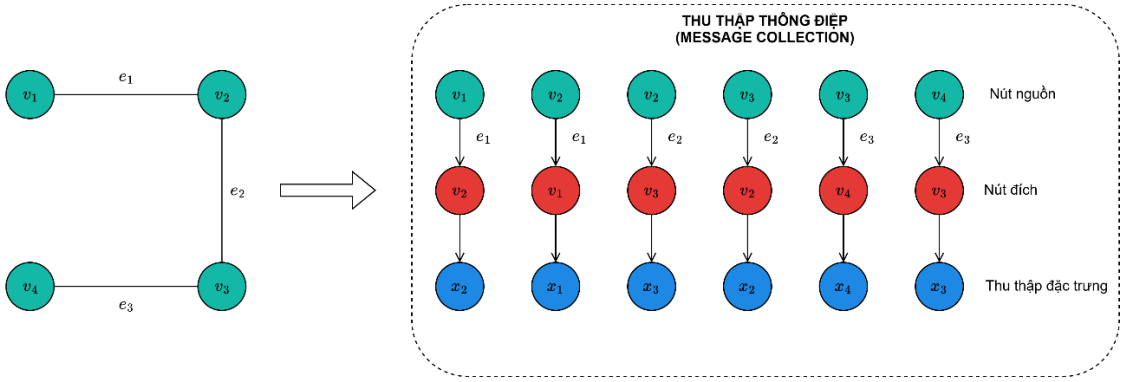
Giai đoạn 1: Thu thập thông tin từ các nút láng giềng:

Giai đoạn này sử dụng ma trận biểu diễn đặc trưng X và danh sách cạnh E để thực hiện thu thập thông điệp các nút láng giềng j về nút i mà không tự động self - loop.

$$M_{i,j}^{(l)} = x_j^{(l)} \tag{1.6}$$

Trong đó:

- $M_{i,j}^{(l)}$ là thông điệp từ nút j về nút i tại lớp GCN cải tiến thứ l.
- $x_j^{(l)}$ là vector biểu diễn đặc trưng của nút j tại lớp GCN cải tiến thứ l.



Hình 1. 8. Giai đoạn 1 thực hiện thu thập thông điệp từ các nút láng giềng

Giai đoạn 2: Tổng hợp thông điệp từ các nút láng giềng:

Giai đoạn này được thiết kế linh hoạt trong việc sử dụng phương pháp tổng hợp. Thay vì chỉ sử dụng phép nhân ma trận đơn thuần để tổng hợp thông điệp của mô hình GCN gốc thì giai đoạn này có 3 lựa chọn tổng hợp là phương pháp tính tổng (SUM), phương pháp tính trung bình ($MEAN$), phương pháp tính giá trị lớn nhất (MAX).

Tuy nhiên, ở giai đoạn 2 nhóm tác giả đề xuất đã cải tiến bằng cách tích hợp ma trận khoảng cách giữa các trạm vào quá trình tổng hợp thông điệp. Cụ thể, thông điệp từ mỗi nút láng giềng sẽ được gán trọng số dựa trên khoảng cách không gian thực tế giữa các trạm, sử dụng hàm kernel Gaussian với tham số có thể học được.

$$w_{i,j} = exp\left(-\frac{d_w.\left(D_{i,j}\right)^2}{2.\sigma^2}\right) \tag{1.7}$$

Trong đó:

- $w_{i,j} \in [0,1)$ là trọng số dùng để điều chỉnh độ quan trọng của nút j đối với nút i.

- d_w là tham số học được trong quá trình huấn luyện được biểu diễn dưới dạng tham số vô hướng.
- $D_{i,j}$ là khoảng cách giữa hai nút từ ma trận khoảng cách.
- σ là tham số cố định.

Sau đó, mô hình sẽ tiến hành tổng hợp thông tin từ các nút láng giềng kết hợp với trọng số khoảng cách vừa tìm được:

$$M_{i,j}^{w} = w_{i,j}.M_{i,j}^{(l)} \tag{1.8}$$

Cuối cùng, các đặc trưng M_{ij}^{w} sẽ được tổng hợp $(AGGREGATE)$ về nút nguồn i bằng các phương pháp tính SUM, $MEAN$ hoặc MAX như sau:

SUM:

$$m_i^{(l)} = \sum_{j \in N(i)} M_{i,j}^{w} \tag{1.9}$$

MEAN:

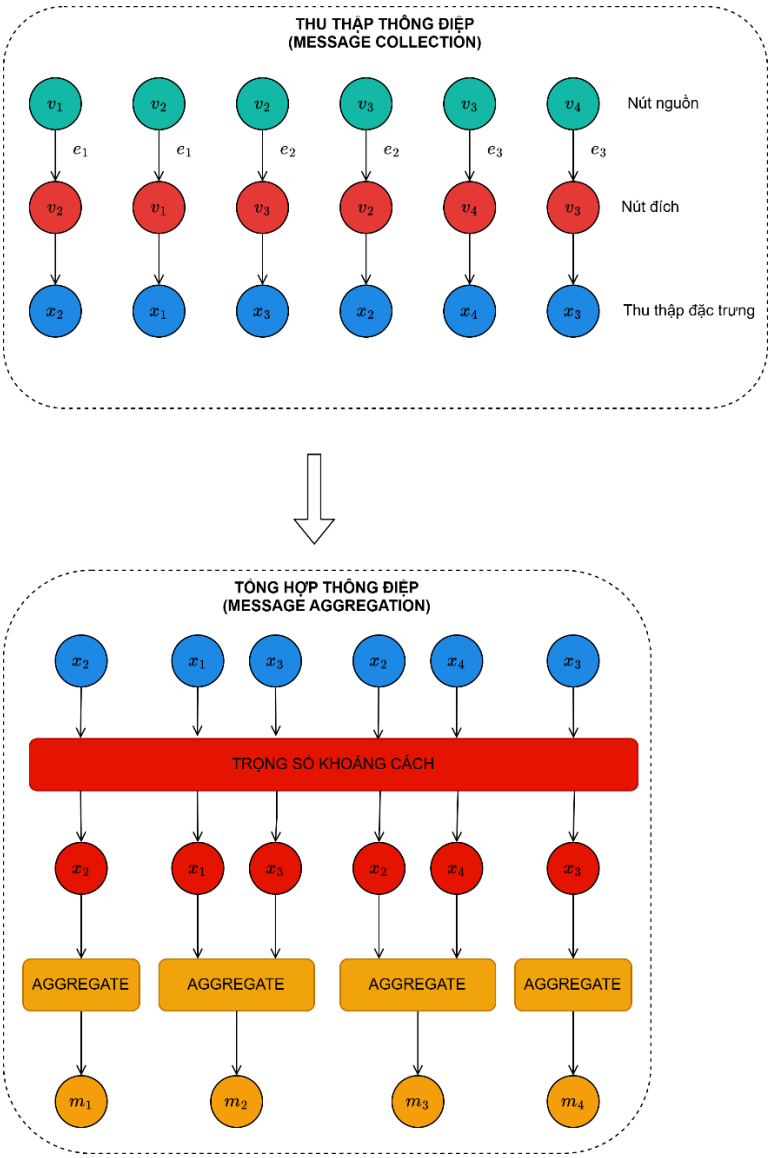
$$m_i^{(l)} = \frac{1}{|N(i)|} \sum_{j \in N(i)} M_{i,j}^{w} \tag{1.10}$$

MAX:

$$m_i^{(l)} = max_{j \in N(i)} M_{i,j}^{w} \tag{1.11}$$

Trong đó:

- $m_i^{(l)}$ là thông tin đã tổng hợp cho nút i tại lớp GCN cải tiến thứ l.
- $N(i)$ là tập các nút láng giềng của i.



Hình 1. 9. Giai đoạn 2 thực hiện tổng hợp thông điệp từ các nút láng giềng

Giai đoạn 3: Cập nhật biểu diễn đặc trưng của nút:

Giai đoạn này thực hiện cập nhật $(UPDATE)$ biểu diễn đặc trưng của x_i và thông điệp đã tổng hợp từ các nút láng giềng m_i bằng cách nhân với ma trận trọng số $W^{(l)}$. Ma trận trọng số $W^{(l)}$ đóng vai trò như một bộ lọc, giúp trích xuất và nhấn mạnh các thông tin quan trọng từ thông điệp đã tổng hợp.

$$x_i = x_i^{(l)}.W^{(l)} \tag{1.12}$$

$$m_i = m_i^{(l)}.W^{(l)} \tag{1.13}$$

Sau đó, các đặc trưng đã được cập nhật sẽ được kết hợp biểu diễn đặc trưng bằng các phương pháp $CONCAT$ hoặc ADD như sau:

CONCAT:

$$x_i^{(l+1)} = f(x_i \| m_i) \tag{1.14}$$

ADD:

$$x_i^{(l+1)} = f(x_i + m_i) \tag{1.15}$$

Trong đó:

- f là hàm kích hoạt.
- m_i là thông tin đã tổng hợp cho nút i tại lớp GCN cải tiến thứ l.
- $N(i)$ là tập các nút láng giềng của i.

Sau đó, tại lớp cuối cùng L sẽ thực hiện tính toán bằng cách đưa kết quả $X^{(L)}$ qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = X^{(L)}.W_y + b_y \tag{1.16}$$

1.3.2.2. Quá trình lan truyền ngược của mô hình GCN cải tiến

Quá trình lan truyền ngược của GCN cải tiến xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 2 ma trận trọng số như, $W^{(l)}, W_y$ và các ngưỡng bias như d_w, b_y.

Dựa vào quy tắc đạo hàm chuỗi thì đạo hàm các ma trận trọng số và các giá trị ngưỡng bias tại các bước timestep như sau:

- ***Đạo hàm cho ma trận trọng số $W^{(l)}$:***

  Giả sử $u_i = x_i^{(l)}.W^{(l)}$ và $v_i = m_i^{(l)}.W^{(l)}$ là các giá trị trung gian

$$\frac{\partial L}{\partial W^{(l)}} = \sum_{i=1}^{N} \left(\left(x_i^{(l)}\right)^T . \frac{\partial L}{\partial u_i} + \left(m_i^{(l)}\right)^T . \frac{\partial L}{\partial v_i} \right) \tag{1.17}$$

- ***Đạo hàm cho ma trận trọng số W_y:***

$$\frac{\partial L}{\partial W_y} = \left(X^{(L)}\right)^T . \frac{\partial L}{\partial y} \tag{1.18}$$

- ***Đạo hàm cho tham số vô hướng d_w:***

$$\frac{\partial L}{\partial d_w} = \sum_{i=1}^{N} \sum_{j \in N(i)} \left[\frac{\partial L}{\partial M_{i,j}^w} . M_{i,j}^{(l)} . \left(-w_{i,j} . \frac{\left(D_{i,j}\right)^2}{2\sigma^2} \right) \right] \tag{1.19}$$

- ***Đạo hàm cho giá trị ngưỡng b_y:***

$$\frac{\partial L}{\partial b_y} = \sum_{i=1}^{N} \left(\frac{\partial L}{\partial y_i} \right) \tag{1.20}$$

1.3.2.3. Ưu và nhược điểm của mô hình GCN cải tiến

Mô hình GCN cải tiến cho thấy khả năng khai thác hiệu quả đặc trưng không gian thông qua cơ chế lan truyền thông tin giữa các nút trong đồ thị. Bằng cách tận dụng mối quan hệ tương quan giữa các trạm khí tượng, mô hình có thể học được các biểu diễn đặc trưng mang tính toàn cục thay vì chỉ phụ thuộc vào dữ liệu cục bộ của từng trạm riêng biệt. Đặc biệt, việc tích hợp thêm trọng số khoảng cách giữa các nút giúp mô hình phản ánh rõ hơn mức độ ảnh hưởng không gian giữa các trạm, từ đó nâng cao khả năng học đặc trưng so với các phương pháp chỉ tập trung vào yếu tố thời gian. Điều này cho thấy GCN cải tiến là một hướng tiếp cận tiềm năng đối với các bài toán dự báo dữ liệu môi trường có cấu trúc không gian.

Tuy nhiên, bên cạnh những ưu điểm đạt được, mô hình GCN cải tiến vẫn còn tồn tại một số hạn chế nhất định. Trước hết, hiệu quả của mô hình phụ thuộc khá lớn vào mức độ tương quan giữa các nút trong đồ thị; khi mối quan hệ giữa các trạm khí tượng yếu hoặc không đồng nhất, khả năng lan truyền thông tin sẽ giảm đáng kể, dẫn đến hiệu suất dự báo chưa cao. Ngoài ra, mặc dù đã bổ sung trọng số khoảng cách, cơ chế lan truyền thông tin của mô hình vẫn mang tính cố định và chưa thể linh hoạt học được mức độ quan trọng giữa các nút lân cận trong quá trình huấn luyện. Điều

này làm hạn chế khả năng biểu diễn của mô hình đối với các bộ dữ liệu có tính phi tuyến cao hoặc biến động mạnh theo không gian.

1.3.3. Mô hình GAT tinh chỉnh

Mô hình GAT được trình bày lần đầu tiên trong nghiên cứu của Petar Veličković, và cộng sự, (2017) [10]. Mô hình được giới thiệu với ưu điểm vượt trội hơn so với mô hình GCN truyền thống khi cho phép gán các trọng số chú ý khác nhau cho từng nút láng giềng, khắc phục được hạn chế tổng hợp thông tin đồng nhất của GCN. Nhờ cơ chế attention, GAT có khả năng học linh hoạt mức độ ảnh hưởng giữa các nút trong quá trình lan truyền thông tin.

Tuy nhiên, trong các bài toán thực tế như dự đoán nồng độ bụi mịn PM_{10} dựa trên dữ liệu từ các trạm khí tượng, mô hình GAT gốc vẫn chưa khai thác đầy đủ các yếu tố đặc thù của dữ liệu không gian, đặc biệt là thông tin về khoảng cách địa lý giữa các nút. Do đó, trong nghiên cứu này, tôi đề xuất phát triển mô hình GAT tinh chỉnh bằng cách kế thừa và tích hợp các cải tiến từ mô hình GCN cải tiến bao gồm trọng số khoảng cách và bỏ cơ chế self-loop nhằm nâng cao khả năng biểu diễn và khai thác hiệu quả hơn mối quan hệ không gian trong dữ liệu. Đồng thời, tôi cũng áp dụng cơ chế đa đầu chú ý để tăng cường khả năng học của mô hình.

1.3.3.1. Quá trình lan truyền tiến của mô hình GAT tinh chỉnh

- **Đầu vào của mô hình:**

Tương tự như GCN cải tiến, quá trình lan truyền của GAT tinh chỉnh nhận đầu vào là tensor $X \in R^{N \times B \times ICL \times IFL}$. Dữ liệu này mang thông tin đặc trưng của các trạm khí tượng qua các bước thời gian và được tính toán tuần tự bên trong mạng.

- **Đầu ra của mô hình:**

Đầu ra của mô hình GAT tinh chỉnh là giá trị dự báo $X' \in R^{N \times B \times ICL \times OFL}$ sau khi tính toán xong lô cuối cùng.

- **Cơ chế lan truyền thông tin của mô hình:**

Dựa vào khung mô hình GCN cải tiến của các tác giả Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3], mô hình GAT tinh chỉnh do tôi đề xuất có các giai đoạn như sau:

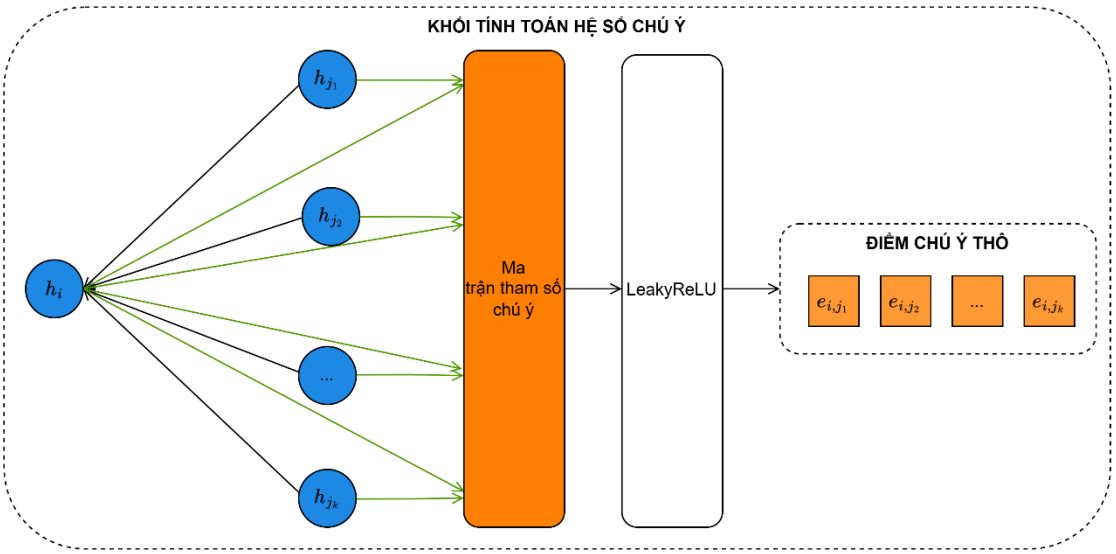
Giai đoạn 1: Tính toán hệ số chú ý

Ở giai đoạn này, mô hình sẽ tính toán hệ số chú ý để xác định độ quan trọng của nút láng giềng j đối với nút nguồn i. Nhằm kế thừa tính ổn định trong việc trích xuất đặc trưng từ mô hình GCN tiền nhiệm, các nút được biến đổi tuyến tính thông qua một ma trận trọng số W duy nhất, sau đó kết hợp và đưa qua hàm kích hoạt phi tuyến tính ($LeakyReLU$) cùng với vector tham số chú ý a:

$$h_i^{(l)} = x_i^{(l)}.W^{(l)} \tag{1.21}$$

$$h_j^{(l)} = x_j^{(l)}.W^{(l)} \tag{1.22}$$

$$e_{i,j}^k = LeakyReLU\left(\left((a^k)^{(l)}\right)^T.\left[h_i^{(l)} \| h_j^{(l)}\right]\right) \tag{1.23}$$



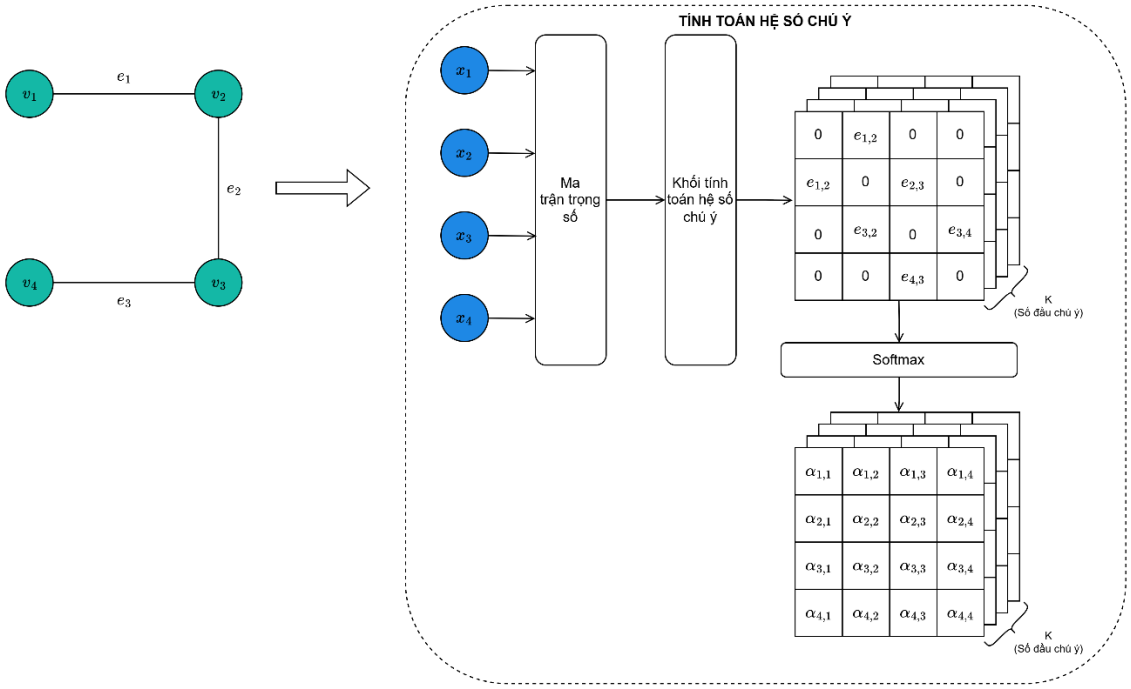
Hình 1. 10. Minh họa khối tính toán hệ số chú ý với nút i và nút láng giềng j tại đầu chú ý thứ 1

Sau đó, hàm softmax được áp dụng trên toàn bộ các nút láng giềng của i để chuẩn hóa các hệ số thành trọng số chú ý $\alpha_{i,j}$:

$$\alpha_{i,j}^{k} = \frac{exp\left(e_{i,j}^{k}\right)}{\sum_{k \in N(i)} exp\left(e_{i,k}^{k}\right)} \tag{1.24}$$

Trong đó:

- $e_{i,j}$ là điểm chú ý thô giữa nút i và j.
- $\alpha_{i,j}$ là hệ số chú ý đã được chuẩn hóa.
- $W^{(l)}$ là ma trận bộ lọc học được của cơ chế chú ý tại lớp GAT tinh chỉnh thứ l.
- $a^{(l)}$ là ma trận tham số chú ý học được của cơ chế chú ý tại lớp GAT tinh chỉnh thứ l.
- K là số lượng đầu chú ý.
- $\|$ là phép nối hai véc-tơ.



Hình 1. 11. Giai đoạn 1 tính toán hệ số chú ý

Giai đoạn 2: Thu thập thông tin từ các nút láng giềng:

Giai đoạn này sử dụng ma trận biểu diễn đặc trưng X đã được biến đổi tuyến tính thông qua một ma trận trọng số W duy nhất và danh sách cạnh E để thực hiện thu thập thông điệp các nút láng giềng j về nút i mà không không tự dộng self - loop.

$$M_{i,j}^{(l)} = \frac{1}{K} \sum_{k=1}^{K} \sum_{j \in N(i)} h_j^{(l)} . \alpha_{i,j}^{k} \tag{1.25}$$

Trong đó:

- $M_{i,j}^{(l)}$ là thông điệp từ nút j về nút i tại lớp GAT tinh chỉnh thứ l.
- $\alpha_{i,j}$ là hệ số chú ý đã được chuẩn hóa.
- $x_j^{(l)}$ là vector biểu diễn đặc trưng của nút j tại lớp GAT tinh chỉnh thứ l.

Giai đoạn 3: Tổng hợp thông điệp từ các nút láng giềng:

Nhằm kiểm soát mức độ ảnh hưởng của cơ chế attention bằng thực tế địa lý, tôi vẫn thực hiện tích hợp ma trận khoảng cách giữa các trạm sử dụng kernel Gaussian. Cụ thể, thông điệp từ mỗi nút láng giềng sẽ được gán trọng số dựa trên khoảng cách không gian thực tế giữa các trạm, sử dụng hàm kernel Gaussian với tham số có thể học được.

$$w_{i,j} = exp\left(- \frac{d_w . \left(D_{i,j}\right)^2}{2 . \sigma^2} \right) \tag{1.26}$$

Trong đó:

- $w_{i,j} \in [0, 1)$ là trọng số dùng để điều chỉnh độ quan trọng của nút j đối với nút i.
- d_w là tham số học được trong quá trình huấn luyện được biểu diễn dưới dạng tham số vô hướng.
- $D_{i,j}$ là khoảng cách giữa hai nút từ ma trận khoảng cách.
- σ là tham số cố định.

Sau đó, mô hình sẽ tiến hành tổng hợp thông tin từ các nút láng giềng kết hợp với trọng số khoảng cách vừa tìm được:

$$M_{i,j}^{w} = w_{i,j}.M_{i,j}^{(l)} \tag{1.27}$$

Cuối cùng, các đặc trưng M_{ij}^{w} sẽ được tổng hợp $(AGGREGATE)$ về nút nguồn i bằng các phương pháp tính SUM, $MEAN$ hoặc MAX như sau:

SUM:

$$m_i^{(l)} = \sum_{j \in N(i)} M_{i,j}^{w} \tag{1.28}$$

MEAN:

$$m_i^{(l)} = \frac{1}{|N(i)|} \sum_{j \in N(i)} M_{i,j}^{w} \tag{1.29}$$

MAX:

$$m_i^{(l)} = max_{j \in N(i)} M_{i,j}^{w} \tag{1.30}$$

Trong đó:

- $m_i^{(l)}$ là thông tin đã tổng hợp cho nút i tại lớp GAT tinh chỉnh thứ l.
- $N(i)$ là tập các nút láng giềng của i.

Giai đoạn 4: Cập nhật biểu diễn đặc trưng của nút:

Giai đoạn này thực hiện cập nhật $(UPDATE)$ biểu diễn đặc trưng của x_i bằng cách nhân với ma trận trọng số W. Ma trận trọng số $W^{(l)}$ đóng vai trò như một bộ lọc, giúp trích xuất và nhấn mạnh các thông tin quan trọng từ thông điệp đã tổng hợp.

$$x_i = x_i^{(l)}.W^{(l)} \tag{1.31}$$

$$m_i = m_i^{(l)} \tag{1.32}$$

Sau đó, các đặc trưng đã được cập nhật sẽ được kết hợp biểu diễn đặc trưng bằng các phương pháp CONCAT hoặc ADD như sau:

CONCAT:

$$x_i^{(l+1)} = f(x_i \| m_i) \tag{1.33}$$

ADD:

$$x_i^{(l+1)} = f(x_i + m_i) \tag{1.34}$$

Trong đó:

- f là hàm kích hoạt.
- m_i là thông tin đã tổng hợp cho nút i.
- $N(i)$ là tập các nút láng giềng của i.

Sau đó, tại lớp cuối cùng L sẽ thực hiện tính toán bằng cách đưa kết quả $X^{(L)}$ qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = X^{(L)}.W_y + b_y \tag{1.35}$$

1.3.3.2. Quá trình lan truyền ngược của mô hình GAT tinh chỉnh

Quá trình lan truyền ngược của GCN cải tiến xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 3 ma trận trọng số như, $W^{(l)}, W_y$ và các ngưỡng bias như a, d_w, b_y.

Dựa vào quy tắc đạo hàm chuỗi thì đạo hàm các ma trận trọng số và các giá trị ngưỡng bias tại các bước timestep như sau:

- ***Đạo hàm cho ma trận trọng số $W^{(l)}$:***

$$\frac{\partial L}{\partial W^{(l)}} = \sum_{i=1}^{N} \left(\left(x_i^{(l)}\right)^T . \frac{\partial L}{\partial h_i^{(l)}} \right) \tag{1.36}$$

- ***Đạo hàm cho ma trận trọng số W_y:***

$$\frac{\partial L}{\partial W_y} = \left(X^{(L)}\right)^T . \frac{\partial L}{\partial y} \tag{1.37}$$

- ***Đạo hàm cho ma trận tham số chú ý a:***

  Ma trận tham số chú ý a chỉ tham gia vào quá trình tính điểm chú ý thô $e_{i,j}^{k}$, do đó đạo hàm của nó được tổng hợp trên toàn bộ các cạnh (i,j) thuộc đầu chú ý thứ k như sau:

$$u_{i,j}^{k} = (a^{k})^{T}.\left[h_i^{(l)} \| h_j^{(l)}\right] \tag{1.38}$$

$$\frac{\partial L}{\partial a^{k}} = \sum_{i=1}^{N} \sum_{j \in N(i)} \left(\frac{\partial L}{\partial e_{i,j}^{k}} . LeakyReLU'\left(u_{i,j}^{k}\right).\left[h_i^{(l)} \| h_j^{(l)}\right]^{T} \right) \tag{1.39}$$

- ***Đạo hàm cho tham số vô hướng $\mathbf{d_w}$:***

$$\frac{\partial L}{\partial d_w} = \sum_{i=1}^{N} \sum_{j \in N(i)} \left[\frac{\partial L}{\partial M_{i,j}^{w}} . M_{i,j}^{(l)} . \left(-w_{i,j} . \frac{\left(D_{i,j}\right)^{2}}{2\sigma^{2}} \right) \right] \tag{1.40}$$

- ***Đạo hàm cho giá trị ngưỡng $\mathbf{b_y}$:***

$$\frac{\partial L}{\partial b_y} = \sum_{i=1}^{N} \left(\frac{\partial L}{\partial y_i} \right) \tag{1.41}$$

1.4. Tổng quan về mô hình dự đoán chuỗi thời gian theo thời gian

Dự báo hàm lượng chất ô nhiễm không chỉ phụ thuộc vào vị trí địa lý của các trạm khí tượng mà còn chịu tác động đáng kể từ yếu tố thời gian. Giá trị hàm lượng chất ô nhiễm thường có tính chu kỳ và biến đổi liên tục theo giờ, theo ngày, theo mùa cũng như dưới ảnh hưởng của các hiện tượng thời tiết bất thường. Do đó, việc khai thác đặc trưng thời gian đóng vai trò quan trọng trong quá trình nhận diện xu hướng biến động của dữ liệu, góp phần nâng cao độ chính xác và khả năng phản ánh thực tế của mô hình dự báo.

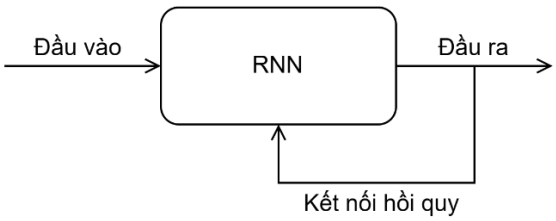
Trong đề tài này, tôi lựa chọn hai mô hình phổ biến trong lĩnh vực xử lý dữ liệu chuỗi thời gian là LSTM và BiLSTM. Các mô hình này có khả năng học các mối quan hệ phụ thuộc theo thời gian, đồng thời hạn chế hiệu quả hiện tượng vanishing

gradient và exploding gradient thường xuất hiện trong các mô hình xử lý chuỗi truyền thống.

Tuy nhiên, trước khi đi sâu vào hai mô hình trên, tôi sẽ trình bày sơ lược về mô hình RNN – kiến trúc nền tảng đóng vai trò cơ sở cho sự phát triển và cải tiến của LSTM và BiLSTM.

1.4.1. Mô hình RNN

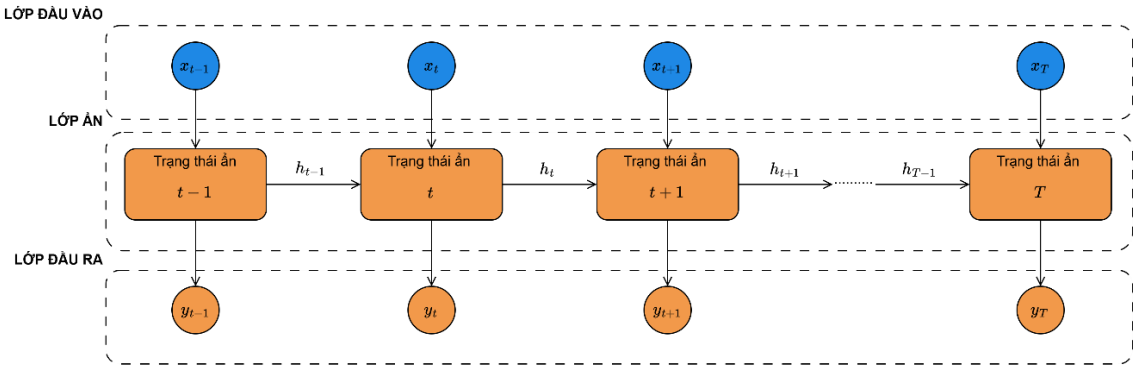
Mạng nơ-ron hồi quy hay RNN [14] được thiết kế với cơ chế vòng lặp bên trong, cho phép thông tin được lưu giữ và truyền từ bước này sang bước tiếp theo trong chuỗi thời gian. Nhờ đó, thay vì làm phẳng dữ liệu và mất đi mối liên kết giữa các thời điểm, RNN có khả năng duy trì và học được các phụ thuộc theo thời gian, giúp mô hình nắm bắt tốt hơn xu hướng và quy luật biến động trong dữ liệu chuỗi.



Hình 1. 12. RNN với cơ chế vòng lặp

Khi biểu diễn cơ chế lặp của mạng RNN dưới dạng trải phẳng theo thời gian, mô hình có thể được xem như một chuỗi các mạng giống nhau liên kết với nhau, trong đó đầu ra tại thời điểm trước sẽ được sử dụng làm đầu vào cho thời điểm tiếp theo. Mỗi bước trong chuỗi này được biểu diễn thông qua một trạng thái ẩn (hidden state).

Tại mỗi thời điểm t, trạng thái ẩn sẽ nhận đầu vào là dữ liệu x_t. Sau quá trình tính toán, mạng sẽ cập nhật trạng thái ẩn và sinh ra đầu ra tương ứng h_t. Đối với các bài toán hồi quy chuỗi thời gian, đầu ra cuối cùng của mô hình thường được lấy tại bước thời gian cuối cùng T, ký hiệu là y.



Hình 1. 13. Mô hình RNN khi trải thẳng cơ chế vòng lặp

1.4.1.1. Quá trình lan truyền tiến của mô hình RNN

- **Đầu vào của mô hình:**

Quá trình lan truyền tiến của mô hình RNN trong dự báo chuỗi thời gian bắt đầu từ lúc nhận đầu vào $x_1, x_2, \dots, x_T$. Trong quá trình này các giá trị đầu vào thực hiện tính toán bên trong trạng thái ẩn.

- **Đầu ra của mô hình:**

Đầu ra của mô hình RNN là giá trị trạng thái ẩn (h_T) tại bước thời gian cuối cùng. Giá trị h_T này khi qua 1 lớp tuyến tính sẽ tạo được đầu ra y dự đoán.

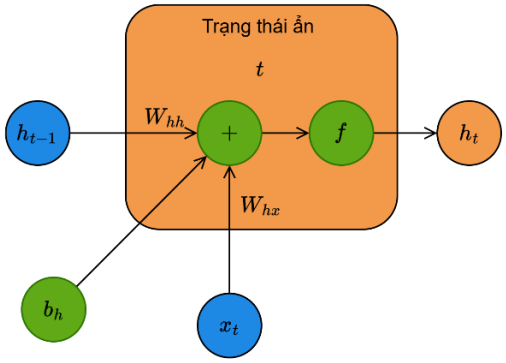
- **Cơ chế lan truyền tiến của mô hình:**

Tại bước thời gian t, đầu vào của trạng thái ẩn sẽ là chuỗi dữ liệu đầu vào x_t và giá trị trạng thái ẩn từ trạng thái ẩn phía trước h_{t-1}.

$$h_t = f(W_{hh}.h_{t-1} + W_{hx}.x_t + b_h) \quad (1.42)$$

Trong đó:

- f là hàm kích hoạt.
- W_{hh} là ma trận trọng số kết nối giữa trạng thái ẩn h_t với trạng thái ẩn trước đó h_{t-1}.
- W_{hx} là ma trận trọng số kết nối giữa đầu vào hiện tại x_t với trạng thái ẩn t.
- b_h là véc-tơ độ lệch của trạng thái ẩn t.



Hình 1. 14. Chi tiết hoạt động trong 1 trạng thái ẩn của mô hình RNN tại thời điểm t

Sau đó, tại trạng thái ẩn t tương ứng với đầu vào x_t sẽ thực hiện tính toán bằng cách đưa kết quả h_t qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = W_{hy}.h_T + b_y \tag{1.43}$$

1.4.1.2. Quá trình lan truyền ngược của mô hình RNN

Quá trình lan truyền ngược của mô hình RNN xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 3 ma trận trọng số như, W_{hx}, W_{hy}, W_{hh} và các ngưỡng bias như b_h, b_y.

Dựa vào quy tắc đạo hàm chuỗi thì đạo hàm các ma trận trọng số và các giá trị ngưỡng bias tại các bước timestep như sau:

- **Đạo hàm cho ma trận trọng số W_{hh}:**

$$\frac{\partial L}{\partial W_{hh}} = (h_{t-1})^T.f'(W_{hh}.h_{t-1} + W_{hx}.x_t).\left(W_{hy}\right)^T.\frac{\partial L}{\partial y} \tag{1.44}$$

- **Đạo hàm cho ma trận trọng số W_{hx}:**

$$\frac{\partial L}{\partial b_h} = (x_t)^T.f'(W_{hh}.h_{t-1} + W_{hx}.x_t).\left(W_{hy}\right)^T.\frac{\partial L}{\partial y} \tag{1.45}$$

- **Đạo hàm cho ma trận trọng số W_{hy}:**

$$\frac{\partial L}{\partial W_{hy}} = (h_n)^T.\frac{\partial L}{\partial y} \tag{1.46}$$

- **Đạo hàm cho giá trị ngưỡng b_h:**

$$\frac{\partial L}{\partial b_h} = f'(W_{hh}.h_{t-1} + W_{hx}.x_t).\left(W_{hy}\right)^T.\frac{\partial L}{\partial y} \quad (1.47)$$

- **Đạo hàm cho giá trị ngưỡng b_y:**

$$\frac{\partial L}{\partial b_y} = \frac{\partial L}{\partial y} \quad (1.48)$$

1.4.1.3. Ưu và nhược điểm của mô hình RNN

Mô hình RNN có khả năng học và nắm bắt xu hướng biến đổi của dữ liệu theo thời gian nhờ cơ chế xử lý tuần tự các phần tử trong chuỗi. Tuy nhiên, RNN thường được xem là mạng có bộ nhớ ngắn hạn do khả năng ghi nhớ các phụ thuộc dài hạn còn hạn chế. Nguyên nhân chủ yếu đến từ hai vấn đề thường gặp trong quá trình huấn luyện là vanishing gradient và exploding gradient. Hiện tượng vanishing gradient xảy ra khi giá trị đạo hàm trở nên quá nhỏ trong quá trình lan truyền ngược, khiến mô hình khó học được thông tin từ các bước thời gian ở xa. Khi gradient tiến dần về 0, trọng số của mạng gần như không được cập nhật, làm giảm khả năng ghi nhớ các mối quan hệ dài hạn trong dữ liệu chuỗi.

Ngược lại, exploding gradient xuất hiện khi giá trị đạo hàm tăng quá lớn trong quá trình huấn luyện, dẫn đến việc cập nhật trọng số trở nên mất ổn định và khiến mô hình dễ bị phân kỳ. Hiện tượng này thường phát sinh do việc nhân lặp lại các ma trận trọng số qua nhiều bước thời gian, tạo ra sự tăng trưởng theo cấp số mũ của gradient. Chính vì những hạn chế đó, các biến thể cải tiến của RNN như LSTM và BiLSTM đã được đề xuất nhằm giảm thiểu ảnh hưởng của vanishing gradient và exploding gradient, đồng thời nâng cao khả năng học các phụ thuộc dài hạn trong dữ liệu chuỗi thời gian.

1.4.2. Mô hình LSTM

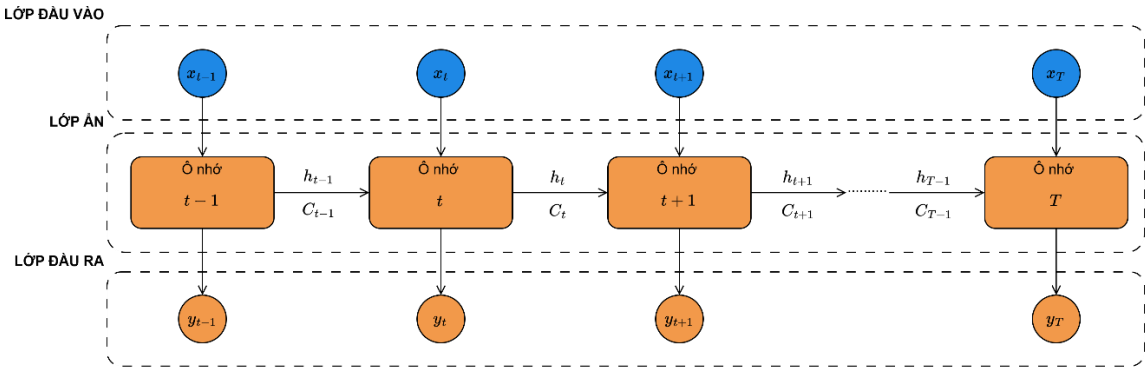
LSTM [24] là một biến thể nâng cao của RNN, được phát triển nhằm xử lý hiệu quả các bài toán dữ liệu chuỗi thời gian. Tương tự RNN, LSTM có khả năng tiếp

nhận và xử lý dữ liệu theo trình tự thời gian, từ đó học được mối quan hệ giữa các bước thời gian trong chuỗi. Tuy nhiên, ưu điểm nổi bật của LSTM là khả năng khắc phục hiện tượng vanishing gradient và exploding gradient – những vấn đề khiến RNN truyền thống gặp hạn chế trong việc ghi nhớ thông tin dài hạn.

Về bản chất, LSTM được phát triển dựa trên kiến trúc của RNN nên vẫn kế thừa khả năng xử lý dữ liệu theo trình tự thời gian. Tuy nhiên, điểm khác biệt quan trọng của LSTM nằm ở việc bổ sung cơ chế trạng thái ô nhớ (cell state) cùng các cổng điều khiển thông tin, giúp mô hình giảm đáng kể ảnh hưởng của hiện tượng vanishing gradient và exploding gradient thường gặp trong RNN truyền thống. Nhờ đó, LSTM có khả năng duy trì và học thông tin trong khoảng thời gian dài hiệu quả hơn.

Trong khi kiến trúc RNN truyền thống chỉ sử dụng các trạng thái kết hợp với các hàm kích hoạt đơn giản khiến quá trình lan truyền gradient qua nhiều bước thời gian dễ gặp hiện tượng suy giảm hoặc bùng nổ thì LSTM được thiết kế với cấu trúc ô nhớ phức tạp hơn nhằm khắc phục hạn chế này. Bên trong mỗi ô nhớ bao gồm ba cơ chế cổng điều khiển thông tin là cổng đầu vào (input gate), cổng quên (forget gate) và cổng đầu ra (output gate). Cơ chế này cho phép mô hình linh hoạt lựa chọn thông tin cần lưu giữ, cập nhật hoặc loại bỏ thay vì ghi nhớ toàn bộ dữ liệu quá khứ như RNN, từ đó cải thiện đáng kể khả năng học các phụ thuộc dài hạn trong dữ liệu chuỗi thời gian.

Tương tự RNN, tại mỗi thời điểm t, đầu vào của mỗi ô nhớ trong LSTM là dữ liệu x_t, đầu ra cuối cùng của mô hình thường được lấy tại bước thời gian cuối cùng T, ký hiệu là y. Trong mỗi ô nhớ, mô hình sẽ thực hiện quy tình tính toán để cập nhật tạo đầu ra h_t. Tuy nhiên, khác với RNN, LSTM không chỉ sinh ra trạng thái ẩn h_t mà còn duy trì thêm trạng thái ô nhớ (cell state) C_t. Đây được xem là thành phần cốt lõi của kiến trúc LSTM, đóng vai trò lưu trữ và truyền tải những thông tin quan trọng xuyên suốt các bước thời gian, giúp mô hình duy trì khả năng nhớ dài hạn và hiệu quả hơn.



Hình 1. 15. Mô hình LSTM khi trải thẳng cơ chế vòng lặp

1.4.2.1. Quá trình lan truyền tiến và cơ chế cổng của mô hình LSTM

- **Đầu vào của mô hình:**

Quá trình lan truyền tiến của LSTM trong dự báo chuỗi thời gian bắt đầu từ lúc nhận đầu vào $x_1, x_2, \dots, x_T$. Trong quá trình này các giá trị đầu vào thực hiện tính toán bên trong ô nhớ và đi qua các cơ chế cổng.

- **Đầu ra của mô hình:**

Đầu ra của mô hình LSTM là giá trị trạng thái ẩn h_T và giá trị trạng thái ô nhớ C_T tại bước thời gian cuối cùng. Giá trị h_T này khi qua 1 lớp tuyến tính sẽ tạo được đầu ra y dự đoán.

- **Cơ chế lan truyền tiến của mô hình:**

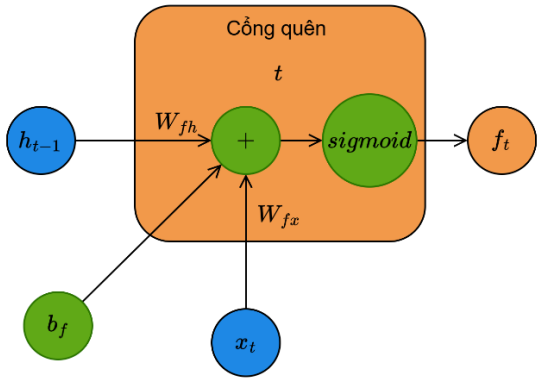
Tại thời điểm t, đầu vào của ô nhớ bao gồm dữ liệu chuỗi x_t và giá trị trạng thái ẩn của bước thời gian trước h_{t-1}. Sau đó, thông tin sẽ lần lượt xử lý tuần tự thông qua các cơ chế cổng bên trong ô nhớ LSTM, bao gồm: cổng quên (forget gate), cổng đầu vào (input gate), cổng đầu ra (output gate).

Trong đó, cổng quên có nhiệm vụ xác định thông tin cần giữ lại từ trạng thái ô nhớ ở bước thời gian trước $(t-1)$. Cổng này nhận đầu vào là dữ liệu x_t tại thời điểm t cùng với trạng thái ẩn trước đó h_{t-1} để tính toán mức độ thông tin cần loại bỏ hoặc duy trì.

$$f_t = \sigma\left(W_{fh}.h_{t-1} + W_{fx}.x_t + b_f\right) \quad (1.49)$$

Trong đó:

- σ là hàm sigmoid.
- W_{fh} là ma trận trọng số kết nối giữa đầu vào hiện tại x_t với cổng quên t.
- W_{fx} là ma trận trọng số kết nối giữa giá trị trạng thái ẩn h_{t-1} của ô nhớ trước đó với cổng quên t.
- b_f là véc-tơ độ lệch của cổng quên t.



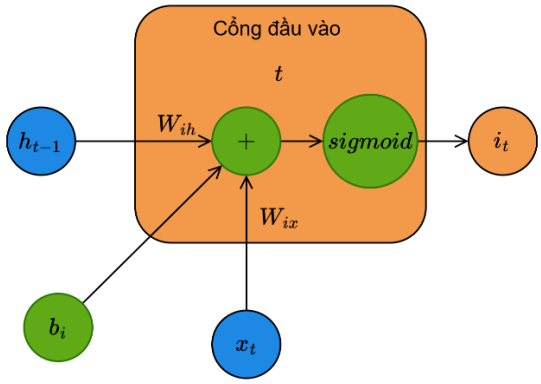
Hình 1. 16. Chi tiết cổng quên trong ô nhớ của mô hình LSTM tại thời điểm t

Tiếp thep, cổng đầu vào có chức năng xác định lượng thông tin mới từ dữ liệu hiện tại cần được bổ sung vào trạng thái ô nhớ. Tương tự cổng quên, cổng này nhận đầu vào là dữ liệu x_t tại thời điểm t cùng với trạng thái ẩn trước đó h_{t-1} để đánh giá và lựa chọn những thông tin quan trọng cần được cập nhật vào ô nhớ hiện tại.

$$i_t = \sigma(W_{ih}.h_{t-1} + W_{ix}.x_t + b_i) \quad (1.50)$$

Trong đó:

- σ là hàm sigmoid.
- W_{ih} là ma trận trọng số kết nối giữa đầu vào hiện tại x_t với cổng đầu vào t.
- W_{ix} là ma trận trọng số kết nối giữa giá trị trạng thái ẩn h_{t-1} của ô nhớ trước đó với cổng đầu vào t.
- b_t là véc-tơ độ lệch của cổng đầu vào t.



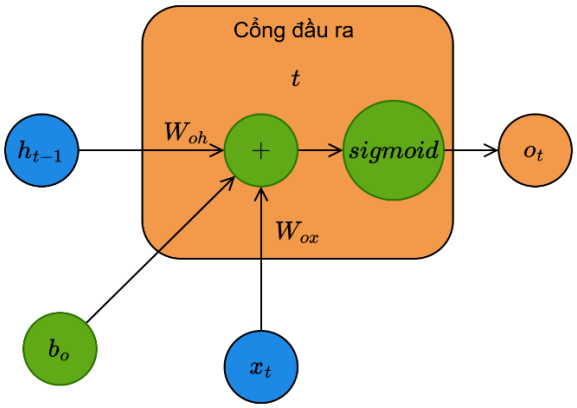
Hình 1. 17. Chi tiết cổng đầu vào trong 1 ô nhớ của mô hình LSTM tại thời điểm t

Cuối cùng, cổng đầu ra có nhiệm vụ xác định lượng thông tin từ trạng thái ô nhớ hiện tại sẽ được xuất ra để tạo thành trạng thái ẩn của bước thời gian hiện tại. Cổng này nhận đầu vào là dữ liệu x_t tại thời điểm t cùng với trạng thái ẩn trước đó h_{t-1}, từ đó chọn lọc những thông tin quan trọng cần được truyền ra ngoài ô nhớ.

$$o_t = \sigma(W_{oh}.h_{t-1} + W_{ox}.x_t + b_o) \tag{1.51}$$

Trong đó:

- σ là hàm sigmoid.
- W_{oh} là ma trận trọng số kết nối giữa đầu vào hiện tại x_t với cổng đầu ra t.
- W_{ox} là ma trận trọng số kết nối giữa giá trị trạng thái ẩn h_{t-1} của ô nhớ trước đó với cổng đầu ra t.
- b_o là véc-tơ độ lệch của cổng đầu ra t.



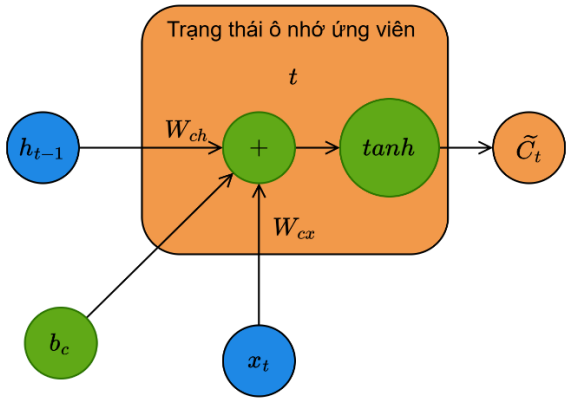
Hình 1. 18. Chi tiết cổng đầu ra trong 1 ô nhớ của mô hình LSTM tại thời điểm t

Tiếp theo, trạng thái ô nhớ ứng viên có nhiệm vụ tạo ra các giá trị ứng viên mới trong khoảng $[-1,1]$, đại diện cho những thông tin tiềm năng cần được bổ sung vào trạng thái ô nhớ. Thành phần này nhận đầu vào là dữ liệu x_t tại thời điểm t cùng với trạng thái ẩn trước đó h_{t-1}, từ đó sinh ra các thông tin mới phục vụ cho quá trình cập nhật ô nhớ hiện tại.

$$\tilde{C}_t = tanh(W_{ch}.h_{t-1} + W_{cx}.x_t + b_c) \quad (1.52)$$

Trong đó:

- W_{ch} là ma trận trọng số kết nối giữa đầu vào hiện tại x_t với giá trị trạng thái ô nhớ ứng viên t.
- W_{cx} là ma trận trọng số kết nối giữa giá trị trạng thái ẩn h_{t-1} của ô nhớ trước đó với giá trị trạng thái ô nhớ ứng viên t.
- b_c là véc-tơ độ lệch của giá trị trạng thái ô nhớ ứng viên t.



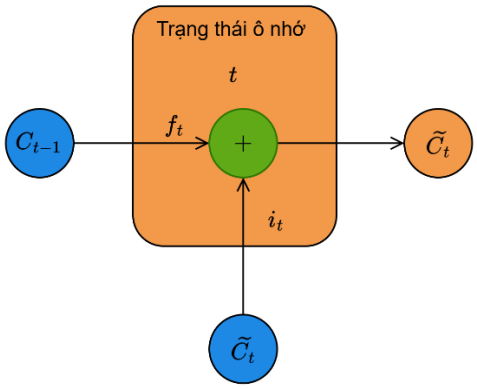
Hình 1. 19. Chi tiết trạng thái ô nhớ ứng viên trong 1 ô nhớ của mô hình LSTM tại thời điểm t

Sau đó, trạng thái ô nhớ C_t đóng vai trò là thành phần cốt lõi của mạng LSTM, chịu trách nhiệm lưu trữ và duy trì thông tin quan trọng xuyên suốt các bước thời gian. Thành phần này quyết định những thông tin nào cần được loại bỏ từ trạng thái ô nhớ trước đó $(t-1)$ và những thông tin mới nào cần được bổ sung vào ô nhớ tại thời điểm hiện tại t. Đồng thời, trạng thái ô nhớ C_t không chỉ là đầu ra của ô nhớ hiện tại mà còn được truyền tiếp làm đầu vào cho ô nhớ ở bước thời gian kế tiếp $(t+1)$.

$$C_t = f_t . C_{t-1} + i_t . \tilde{C}_t \tag{1.53}$$

Trong đó:

- f_t là giá trị của cổng quên t.
- C_{t-1} là giá trị của trạng thái ô nhớ $(t-1)$.
- i_t là giá trị của cổng đầu vào t.
- $\tilde{C}_t$ là giá trị của trạng thái ô nhớ ứng viên t.



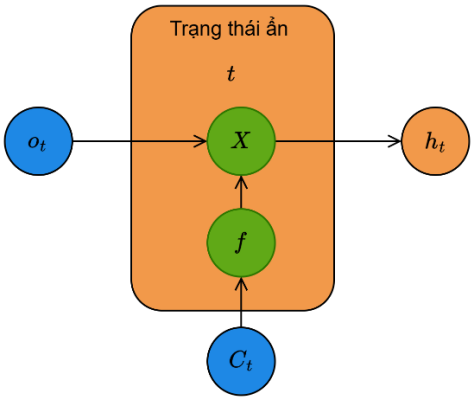
Hình 1. 20. Chi tiết trạng thái ô nhớ trong 1 ô nhớ của mô hình LSTM tại thời điểm t

Cuối cùng, trạng thái ẩn h_t là thành phần đầu ra của mạng LSTM tại bước thời gian hiện tại. Khác với trạng thái ô nhớ C_t, trạng thái ẩn h_t chỉ cho phép một phần thông tin đã được chọn lọc thông qua cổng output o_t được truyền ra ngoài ô nhớ, thay vì sử dụng toàn bộ thông tin được lưu trữ trong trạng thái ô nhớ C_t. Nhờ cơ chế này, mô hình có thể kiểm soát hiệu quả lượng thông tin cần truyền đến các bước thời gian tiếp theo hoặc đầu ra của mạng.

$$h_t = o_t . f(C_t) \tag{1.54}$$

Trong đó:

- o_t là giá trị của cổng đầu ra t.
- f là hàm kích hoạt.
- C_t là giá trị của trạng thái ô nhớ t.



Hình 1. 21. Chi tiết trạng thái ẩn trong 1 ô nhớ của mô hình LSTM tại thời điểm t

Sau đó, tại trạng thái ẩn t tương ứng với đầu vào x_t sẽ thực hiện tính toán bằng cách đưa kết quả h_t qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = W_{hy}.h_T + b_y \tag{1.55}$$

1.4.2.2. Quá trình lan truyền ngược của mô hình LSTM

Quá trình lan truyền ngược của LSTM xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 8 ma trận trọng số như W_{fh}, W_{fx}, $W_{ih}, W_{ix}, W_{oh}, W_{ox}, W_{ch}, W_{cx}, W_{hy}$ và các ngưỡng bias như b_f, b_i, b_o, b_c, b_y.

1.4.2.3. Ưu và nhược điểm của mô hình LSTM

Khi so sánh với RNN truyền thống, LSTM được xem là phiên bản cải tiến hiệu quả hơn nhờ khả năng học và ghi nhớ các phụ thuộc dài hạn trong dữ liệu thay vì nhanh chóng làm mất thông tin như RNN. Hệ thống các cổng điều khiển trong LSTM cho phép mô hình chọn lọc và duy trì những thông tin quan trọng, từ đó nâng cao khả năng ghi nhớ và học đặc trưng theo thời gian.

Tuy nhiên, bên cạnh những ưu điểm đó, cấu trúc cổng phức tạp của LSTM cũng làm cho chi phí tính toán và thời gian xử lý tăng lên đáng kể. Ngoài ra, việc tính toán trạng thái ẩn tại thời điểm hiện tại vẫn phụ thuộc vào trạng thái ẩn của bước thời gian

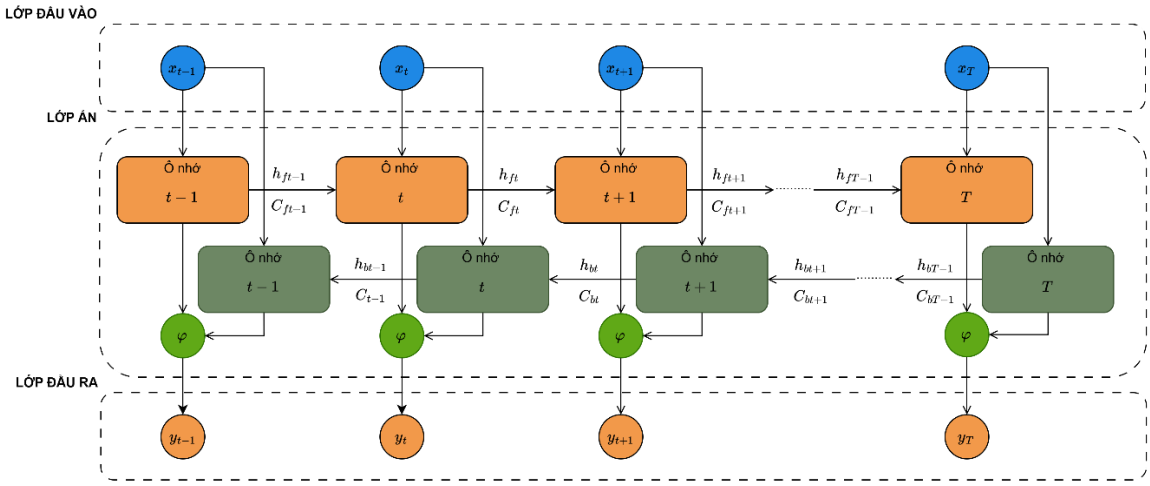
trước, khiến mô hình phải xử lý dữ liệu theo cách tuần tự. Điều này làm hạn chế khả năng song song hóa trong quá trình huấn luyện và suy luận của mô hình.

1.4.3. Mô hình BiLSTM

Mặc dù RNN và LSTM có khả năng học được các xu hướng biến đổi của dữ liệu theo thời gian nhưng các mô hình này chỉ xử lý thông tin theo một chiều duy nhất từ quá khứ đến hiện tại. Trong khi đó, ở nhiều bài toán thực tế, thông tin tại các thời điểm phía sau cũng có thể mang ý nghĩa quan trọng đối với việc biểu diễn dữ liệu ở thời điểm hiện tại. Vì lý do đó, mô hình BiLSTM được đề xuất nhằm khai thác đồng thời cả hai hướng thời gian, bao gồm chiều thuận từ quá khứ đến hiện tại và chiều nghịch từ hiện tại về quá khứ. Nhờ cơ chế này, BiLSTM có thể học được mối quan hệ thời gian đầy đủ hơn, từ đó cải thiện khả năng biểu diễn dữ liệu và nâng cao độ chính xác của mô hình dự báo.

Được phát triển dựa trên nền tảng của LSTM, BiLSTM do Alex Graves and Jürgen Schmidhuber, (2005) [26] đề xuất vẫn kế thừa cơ chế ô nhớ cùng hệ thống các cổng điều khiển thông tin đặc trưng của mô hình này. Tuy nhiên, thay vì chỉ sử dụng một luồng xử lý thông tin, BiLSTM triển khai hai ô nhớ hoạt động song song tại mỗi thời điểm t. Một ô nhớ xử lý dữ liệu theo chiều từ quá khứ đến hiện tại, trong khi ô nhớ còn lại xử lý dữ liệu theo chiều ngược lại, từ tương lai về quá khứ.

Tương tự LSTM, tại mỗi bước thời gian t, đầu vào của các ô nhớ trong BiLSTM là dữ liệu x_t. Đối với các bài toán hồi quy, đầu ra của mô hình thường được lấy tại bước thời gian cuối cùng T, ký hiệu là y. Ở mỗi thời điểm, BiLSTM tạo ra hai trạng thái ẩn bao gồm h_{ft}– biểu diễn trạng thái ẩn theo chiều từ quá khứ đến hiện tại và h_{bt}– biểu diễn trạng thái ẩn theo chiều từ hiện tại về quá khứ. Đồng thời, mô hình cũng duy trì hai trạng thái ô nhớ tương ứng là C_{ft} cho chiều thuận và C_{bt} cho chiều nghịch, giúp lưu trữ thông tin ở cả hai hướng thời gian trong quá trình học.



Hình 1. 22. Mô hình BiLSTM khi trải thẳng cơ chế vòng lặp

1.4.3.1. Quá trình lan truyền tiến của mô hình BiLSTM

- **Đầu vào của mô hình:**

Quá trình lan truyền tiến của mô hình BiLSTM trong bài toán dự báo chuỗi thời gian bắt đầu từ lúc nhận đầu vào $x_1, x_2,..., x_T$. Trong quá trình này các giá trị đầu vào thực hiện tính toán bên trong ô nhớ ở cả 2 chiều thời gian và đi qua các cơ chế cổng.

- **Đầu ra của mô hình:**

Đầu ra của mô hình BiLSTM là giá trị trạng thái ẩn h_T của 2 chiều thời gian và giá trị trạng thái ô nhớ C_T tại bước thời gian cuối cùng của 2 chiều thời gian. Hai giá trị trạng thái ẩn của 2 chiều thời gian sẽ được kết hợp thông qua hàm kết hợp φ rồi qua lớp tuyến tính sẽ tạo ra đầu ra của mô hình y.

- **Luồng thời gian thuận của mô hình:**

Như đã đề cập, BiLSTM kế thừa kiến trúc các ô nhớ từ mô hình LSTM nên quá trình lan truyền tiến trong mỗi ô nhớ sẽ hoạt động giống với quá trình lan truyền tiến của mô hình LSTM. Tuy nhiên, BiLSTM có 2 luồng thời gian riêng biệt, luồng thời gian thuận (từ quá khứ đến hiện tại) và luồng thời gian ngược (từ hiện tại về quá khứ).

Tại luồng thời gian thuận – Quá trình lan truyền tiến sẽ thực hiện hoàn toàn giống với LSTM, quá trình này sẽ xử lý tuần tự chuỗi đầu vào từ x_1 đến x_T.

+ **Cơ chế cổng tại luồng thời gian thuận:**

Cổng forget:

$$f_{ft} = \sigma\left(W_{ffh}.h_{ft-1} + W_{ffx}.x_t + b_{ff}\right) \quad (1.56)$$

Cổng input:

$$i_{ft} = \sigma\left(W_{fih}.h_{ft-1} + W_{fix}.x_t + b_{fi}\right) \quad (1.57)$$

Cổng output:

$$o_{ft} = \sigma\left(W_{foh}.h_{ft-1} + W_{fox}.x_t + b_{fo}\right) \quad (1.58)$$

+ **Trạng thái ô nhớ tại lường thời gian thuận:**

Trạng thái ô nhớ ứng viên:

$$\tilde{C}_{ft} = tanh\left(W_{fch}.h_{ft-1} + W_{fcx}.x_t + b_{fc}\right) \quad (1.59)$$

Trạng thái ô nhớ:

$$C_{ft} = f_{ft}.C_{ft-1} + i_{ft}.\tilde{C}_{ft} \quad (1.60)$$

+ **Trạng thái ẩn tại luồng thời gian thuận:**

Trạng thái ẩn:

$$h_{ft} = o_{ft}.f\left(C_{ft}\right) \quad (1.61)$$

- **Luồng thời gian ngược của mô hình:**

Tại luồng thời gian ngược – Quá trình truyền tiến sẽ thực hiện ngược lại với với LSTM, quá trình này sẽ xử lý tuần tự chuỗi đầu vào từ x_T đến x_1.

+ **Cơ chế cổng tại luồng thời gian ngược:**

Cổng forget:

$$f_{bt} = \sigma\left(W_{bfh}.h_{bt-1} + W_{bfx}.x_t + b_{bf}\right) \quad (1.62)$$

Cổng input:

$$i_{bt} = \sigma(W_{bih}.h_{bt-1} + W_{bix}.x_t + b_{bi}) \quad (1.63)$$

Cổng output:

$$o_{bt} = \sigma(W_{boh}.h_{bt-1} + W_{box}.x_t + b_{bo}) \quad (1.64)$$

+ **Trạng thái ô nhớ tại lường thời gian ngược:**

Trạng thái ô nhớ ứng viên:

$$\tilde{C}_{bt} = tanh(W_{bch}.h_{bt-1} + W_{bcx}.x_t + b_{bc}) \quad (1.65)$$

Trạng thái ô nhớ:

$$C_{bt} = f_{bt}.C_{ft-1} + i_{bt}.\tilde{C}_{bt} \quad (1.66)$$

+ **Trạng thái ẩn tại luồng thời gian ngược:**

Trạng thái ẩn:

$$h_{bt} = o_{bt}.f(C_{bt}) \quad (1.67)$$

Sau đó, tại trạng thái ẩn ft và bt tương ứng với đầu vào x_t sẽ thực hiện tính toán bằng cách đưa kết quả h_{ft} và h_{bt} qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = W_y.\varphi(h_{fT}, h_{bT}) + b_y \quad (1.68)$$

1.4.3.2. Quá trình lan truyền ngược của mô hình BiLSTM

Quá trình lan truyền ngược của LSTM xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 8 ma trận trọng số và 4 giá trị ngưỡng.

Tại luồng thời gian thuận – Tại luồng này cần các công thức đạo hàm để cập nhật cho các ma trận trọng số như W_{ffh}, W_{ffx}, W_{fih}, W_{fix}, W_{foh}, W_{fox}, W_{fch}, W_{fcx} và các giá trị ngưỡng như b_{ff}, b_{fi}, b_{fo}, b_{fc}.

Tại luồng thời gian ngược – Tại luồng này cần các công thức đạo hàm để cập nhật cho các ma trận trọng số như W_{bfh}, W_{bfx}, W_{bih}, W_{bix}, W_{boh}, W_{box}, W_{bch}, W_{bcx} và các giá trị ngưỡng như b_{bf}, b_{bi}, b_{bo}, b_{bc}.

1.3.3.3. Ưu và nhược điểm của mô hình BiLSTM

Mô hình BiLSTM được xây dựng dựa trên kiến trúc ô nhớ của LSTM nên vẫn kế thừa khả năng học các phụ thuộc dài hạn trong dữ liệu chuỗi, đồng thời hạn chế hiệu quả hiện tượng vanishing gradient và exploding gradient. Điểm nổi bật của BiLSTM nằm ở cơ chế xử lý dữ liệu theo hai chiều thời gian gồm chiều thuận từ quá khứ đến hiện tại và chiều nghịch từ hiện tại về quá khứ. Nhờ khả năng khai thác thông tin theo cả hai hướng, mô hình có thể học được mối quan hệ thời gian đầy đủ hơn, qua đó nâng cao hiệu quả biểu diễn dữ liệu và cải thiện độ chính xác trong bài toán dự báo.

Tuy nhiên, bên cạnh những ưu điểm đạt được, việc xử lý đồng thời hai hướng thời gian cũng khiến kiến trúc BiLSTM trở nên phức tạp hơn so với LSTM thông thường. Đối với các tập dữ liệu đơn giản hoặc có kích thước không đủ lớn, mô hình dễ xảy ra hiện tượng overfitting nếu quá trình tinh chỉnh tham số không phù hợp. Ngoài ra, BiLSTM còn yêu cầu thời gian tính toán lớn hơn do phải xử lý dữ liệu trên cả hai chiều thời gian, đồng thời tiêu tốn nhiều tài nguyên bộ nhớ hơn vì cần lưu trữ trạng thái ẩn của cả hai hướng xử lý.

1.5. Tổng quan về MHA

Cơ chế MHA hay cơ chế đa đầu chú ý được đề xuất trong kiến trúc Transformer bởi Ashish Vaswani, và cộng sự, (2017) [11]. Ý tưởng chính của cơ chế này là cho phép mô hình học đồng thời nhiều mối quan hệ đặc trưng khác nhau giữa các phần tử trong chuỗi đầu vào thông qua nhiều đầu chú ý hoạt động song song. Mỗi đầu sẽ tập trung vào một khía cạnh riêng biệt của dữ liệu, từ đó giúp mô hình khai thác thông tin toàn diện hơn.

Trong bài toán dự báo chuỗi thời gian, cơ chế MHA còn giúp mô hình xác định mức độ quan trọng của từng bước thời gian đối với giá trị cần dự báo. Thay vì chỉ xử lý tuần tự như các mô hình RNN hay LSTM truyền thống, MHA cho phép mô hình học được các phụ thuộc gần và xa trong chuỗi dữ liệu một cách hiệu quả hơn. Nhờ đó, mô hình có khả năng nắm bắt được các xu hướng biến động, tính chu kỳ và các mối quan hệ dài hạn giữa các thời điểm trong chuỗi thời gian.

1.5.1. Quá trình lan truyền tiến của cơ chế MHA

- **Đầu vào của mô hình:**

Quá trình lan truyền tiến của cơ chế MHA trong bài toán dự báo chuỗi thời gian bắt đầu từ lúc nhận đầu vào $x_1, x_2, \dots, x_T$. Trong quá trình này các giá trị đầu vào sẽ được ánh xạ sang các ma trận truy vấn Q, khóa K và giá trị V.

- **Đầu ra của mô hình:**

Đầu ra của cơ chế MHA là giá trị tensor biểu diễn đặc trưng mới sau khi tổng hợp thông tin attention từ nhiều đầu chú ý khác nhau.

- **Cơ chế lan truyền thông tin của mô hình:**

Tại bước thời gian t, đầu vào của cơ chế chú ý sẽ là chuỗi dữ liệu đầu vào x_t.

$$Q^k = x_t . W_Q^k \tag{1.69}$$

$$K^k = x_t . W_K^k \tag{1.70}$$

$$V^k = x_t . W_V^k \tag{1.71}$$

Trong đó:

- W_Q là ma trận trọng số dùng để tạo truy vấn.
- W_K là ma trận trọng số dùng để tạo khóa.
- W_V là ma trận trọng số dùng để tạo giá trị.

Tiếp theo, tôi thực hiện tính toán giá trị trọng số chú ý của chuỗi dữ liệu đầu vào x_t.

$$h_t^k = softmax\left(\frac{Q^k.(K^k)^T}{\sqrt{d_k}}\right).V^k \quad (1.72)$$

$$h_t = (h_t^1 \,||\, h_t^2 \,||\, \dots \,||\, h_t^k).W_O \quad (1.73)$$

Trong đó:

- d_k là số chiều của véc-tơ truy vấn/khóa.
- W_O là ma trận trọng số đầu ra.

Sau đó, tại giá trị trọng số chú ý t tương ứng với đầu vào x_t sẽ thực hiện tính toán bằng cách đưa kết quả h_t qua một lớp tuyến tính để có đầu ra và biểu đồ tính toán biểu diễn quá trình lan truyền tiến của lớp cuối cùng như sau:

$$y = W_{hy}.h_T + b_y \quad (1.74)$$

1.5.2. Quá trình lan truyền ngược của cơ chế MHA

Quá trình lan truyền ngược của cơ chế MHA xảy ra sau quá trình tính toán hàm mất mát, quá trình này được thực hiện để cập nhật 5 ma trận trọng số như, W_Q, W_K, W_V, W_O, W_{hy} và ngưỡng bias b_y.

Dựa vào quy tắc đạo hàm chuỗi thì đạo hàm các ma trận trọng số và các giá trị ngưỡng bias tại các bước timestep như sau:

- **Đạo hàm cho ma trận trọng số W_Q:**

$$\frac{\partial L}{\partial W_Q} = (x_t)^T.\frac{\partial L}{\partial Q} \quad (1.75)$$

- **Đạo hàm cho ma trận trọng số W_K:**

$$\frac{\partial L}{\partial W_K} = (x_t)^T.\frac{\partial L}{\partial K} \quad (1.76)$$

- **Đạo hàm cho ma trận trọng số W_V:**

$$\frac{\partial L}{\partial W_V} = (x_t)^T.\frac{\partial L}{\partial V} \quad (1.77)$$

- **Đạo hàm cho ma trận trọng số W_O:**

$$\frac{\partial L}{\partial W_O} = (h_t)^T . \frac{\partial L}{\partial (h_t^1 \,||\, h_t^2 \,||\, \dots \,||\, h_t^k)} \tag{1.78}$$

- **Đạo hàm cho ma trận trọng số W_{hy}:**

$$\frac{\partial L}{\partial W_{hy}} = (h_t^1 \,||\, h_t^2 \,||\, \dots \,||\, h_t^k)^T . \frac{\partial L}{\partial y} \tag{1.79}$$

- **Đạo hàm cho giá trị ngưỡng b_y:**

$$\frac{\partial L}{\partial b_y} = \frac{\partial L}{\partial y} \tag{1.80}$$

1.6. Tóm tắt chương

Chương 1 là chương nền tảng đóng vai trò then chốt trong toàn bộ nghiên cứu.

Trong chương này, các khái niệm cơ bản về bụi PM10 bao gồm đặc tính vật lý, nguồn gốc phát sinh và cơ chế phân tán đã được hệ thống hóa, giúp làm rõ tính phức tạp và tầm quan trọng của bài toán dự đoán nồng độ bụi trong môi trường thực tế. Bên cạnh đó, lý thuyết đồ thị cùng hai kiến trúc GCN cải tiến và GAT tinh chỉnh đã được trình bày nhằm xử lý hiệu quả các phụ thuộc không gian giữa các trạm quan trắc. Ngoài ra, các mô hình RNN, LSTM và BiLSTM cung cấp công cụ lý thuyết để khai thác các xu hướng và phụ thuộc theo chiều thời gian trong dữ liệu chuỗi liên tục. Cơ chế MHA góp phần giúp mô hình tập trung vào các đặc trưng quan trọng trong từng bước thời gian, nâng cao độ chính xác dự đoán.

CHƯƠNG 2: MÔ TẢ VÀ XỬ LÝ DỮ LIỆU

2.1. Giới thiệu

Trong chương này, tôi sẽ tập trung trình bày chi tiết về tập dữ liệu được sử dụng trong đề tài.

Đầu tiên, phần 2.2 giới thiệu phân bố địa lý của các trạm khí tượng trong bộ dữ liệu thu thập, cung cấp cái nhìn tổng quát về phạm vi không gian của dữ liệu. Tiếp theo, phần 2.3 mô tả các đặc trưng có trong bộ dữ liệu thu thập, bao gồm ý nghĩa và vai trò của từng biến đầu vào. Sau đó, phần 2.4 tập trung mô tả dữ liệu thô thông qua việc phân tích lượng dữ liệu thu thập, dữ liệu thiếu, bản ghi trùng lặp và thống kê mô tả trước tiền xử lý nhằm đánh giá chất lượng ban đầu của dữ liệu. Phần 2.5 trình bày chi tiết quy trình tiền xử lý dữ liệu từng bước, bao gồm xử lý giá trị thiếu, đồng bộ hóa mốc thời gian giữa các trạm, thống kê mô tả sau tiền xử lý và đánh giá lượng giá trị ngoại lai. Phần 2.6 sẽ đưa ra kết luận của chương này.

Dữ liệu sử dụng trong đề tài được thu thập với tần xuất 2 giờ một lần tại các tỉnh thành Hàn Quốc thông qua API của Airkorea – hệ thống thông tin chất lượng không khí quốc gia thuộc sở hữu của Bộ Môi trường và do Tập đoàn Môi trường Hàn Quốc (K-eco) quản lý. Đây là một nền tảng uy tín chuyên cung cấp dữ liệu chất lượng không khí theo thời gian thực với độ chính xác và độ tin cậy cao trên phạm vi toàn lãnh thổ Hàn Quốc. Bộ dữ liệu bao gồm thông tin khí tượng chi tiết dùng để áp dụng cho chủ đề dự báo hàm lượng chất ô nhiễm trong bụi PM_{10} từ 11 trạm khí tượng trải dài từ Bắc vào Nam tại Hàn Quốc, được ghi nhận liên tục trong suốt giai đoạn từ năm 2020 đến tháng 10 năm 2025.

2.2. Phân bố địa lý của các trạm khí tượng trong dữ liệu thu thập

Đề tài được thực hiện thông qua việc thu thập dữ liệu hàm lượng chất ô nhiễm tại 11 trạm khí tượng khác nhau, trên toàn quốc, phân bố tại các vùng địa lý khác nhau của Hàn Quốc.

Phân bổ địa lý của các trạm khí tượng như sau:

- **Khu vực miền Bắc:**
  + Vùng phía Bắc: Trạm khí tượng Chuncheon.
  + Vùng thủ đô: Trạm khí tượng Seoul.
  + Vùng thủ đô: Trạm khí tượng Incheon.
  + Vùng thủ đô: Trạm khí tượng Ansan.
- **Khu vực miền Trung:**
  + Vùng duyên hải phía Tây: Trạm khí tượng Seosan
  + Vùng nội địa miền Trung: Trạm khí tượng Cheongju
  + Vùng nội địa miền Trung: Trạm khí tượng Daejon
- **Khu vực miền Nam:**
  + Vùng Tây Nam: Trạm khí tượng Iksan
  + Vùng Đông Nam: Trạm khí tượng Ulsan
  + Vùng Tây Nam: Trạm khí tượng Gwangju
  + Vùng đảo cực Nam: Trạm khí tượng Jeju

Bảng 2. 1. Kinh độ và vĩ độ của các trạm khí tượng

Trạm khí tượng	Kinh độ	Vĩ độ
Chuncheon	127,733	37,9
Seoul	126,967	37,567
Incheon	126,633	37,467
Ansan	126,65	37,19
Seosan	126,45	36,78
Cheongju	127,45	36,63
Daejon	127,23	36,21
Iksan	126,9576	35,9483

Ulsan	129,352	35,594
Gwangju	126,9	35,167
Jeju	126,533	33,517

2.3. Các đặc trưng trong dữ liệu thu thập

Bộ dữ liệu thu thập được gồm có 8 đặc trưng để phục vụ cho bài toán dự báo hàm lượng chất ô nhiễm, bao gồm:

- **Đặc trưng thời gian (giờ, ngày, tháng, năm):**

Các yếu tố khí tượng luôn biến đổi theo giờ, ngày, tháng và năm, tạo nên những chu kỳ thời tiết đặc trưng theo mùa và thời điểm trong năm. Chính sự thay đổi này khiến hàm lượng chất ô nhiễm trong bụi PM_{10} cũng dao động theo thời gian, chịu ảnh hưởng gián tiếp từ quy luật tự nhiên của khí hậu và môi trường sống.

- **Đặc trưng kinh độ - LONGITUDE (°):**

LONGITUDE hay còn gọi là kinh độ, là các đường kinh tuyến tưởng tượng nối từ cực Bắc đến cực Nam của Trái Đất, có chức năng chia bề mặt Trái Đất theo chiều dọc. Các đường này được sử dụng để xác định vị trí theo hướng Đông – Tây và thường được biểu diễn bằng đơn vị độ, phút và giây.

Kinh độ là một trong hai tọa độ địa lý quan trọng dùng để xác định chính xác vị trí của các trạm khí tượng. Bên cạnh đó, thông tin về kinh độ còn hỗ trợ đánh giá đặc điểm khí hậu của từng khu vực được quan trắc trong tập dữ liệu.

Giá trị kinh độ có thể được xác định bằng nhiều phương pháp khác nhau tùy thuộc vào mô hình biểu diễn Trái Đất được sử dụng. Trong các hệ thống định vị hiện đại như GPS và các nền tảng bản đồ số, mô hình ellipsoid thường được sử dụng thay cho mô hình Trái Đất hình cầu nhằm giảm sai số trong quá trình tính toán khoảng cách giữa các vị trí địa lý. Kinh độ được xác định dựa trên mô hình ellipsoid này được gọi là kinh độ trắc địa và cũng là loại kinh độ được sử dụng trong bộ dữ liệu của đề tài.

- **Đặc trưng vĩ độ - LATITUDE (°):**

LATITUDE hay còn gọi là vĩ độ, là các đường vĩ tuyến tưởng tượng chạy theo hướng Đông – Tây quanh bề mặt Trái Đất, có chức năng chia Trái Đất thành nhiều vùng từ cực Bắc đến cực Nam. Các đường này được sử dụng để xác định vị trí theo trục Bắc – Nam. Trong bộ dữ liệu nghiên cứu, mỗi trạm khí tượng đều được gắn với một giá trị vĩ độ riêng biệt và giá trị được sử dụng là vĩ độ trắc địa.

- **Đặc trưng nồng độ Pb trung bình mỗi hai giờ - pb_mean_2h (ng/m^3):**

Đây là giá trị trung bình của nồng độ Pb trong không khí đo được trong các khoảng thời gian mỗi hai giờ trong ngày. Chỉ số này phản ánh sự biến động theo thời gian ngắn của hàm lượng Pb trong khí quyển, qua đó giúp đánh giá mức độ ô nhiễm không khí và phân tích xu hướng thay đổi nồng độ Pb theo chu kỳ ngày.

- **Đặc trưng nồng độ chất Zn trong không khí mỗi hai giờ - zn_mean_2h (ng/m^3):**

Đây là giá trị trung bình của nồng độ Zn trong không khí đo được trong các khoảng thời gian mỗi hai giờ trong ngày. Chỉ số này phản ánh sự biến động theo thời gian ngắn của hàm lượng Zn trong khí quyển, qua đó giúp đánh giá mức độ ô nhiễm không khí và phân tích xu hướng thay đổi nồng độ Zn theo chu kỳ ngày.

2.4. Mô tả dữ liệu thô

2.4.1. Lượng dữ liệu thu thập từ các trạng khí tượng theo thời gian

Dữ liệu sử dụng trong nghiên cứu này được thu thập từ 11 trạm khí tượng khác nhau, mỗi bản ghi tại một trạm tương ứng với các thông số khí tượng trong các khoảng thời gian đo mỗi 2 giờ trong một ngày cụ thể.

Bảng 2. 2. Lượng dữ liệu thu thập từ các trạm khí tượng theo thời gian

Trạm khí tượng	Ngày đầu tiên	Ngày cuối cùng	Số lượng năm	Số lượng mỗi 2 giờ
Chuncheon	01 – 06 – 2022	29 – 10 – 2025	4	14962

Seoul	01 – 01 – 2020	29 – 10 – 2025	6	25546
Incheon	01 – 01 – 2020	29 – 10 – 2025	6	25546
Ansan	01 – 01 – 2020	29 – 10 – 2025	6	25546
Seosan	01 – 01 – 2020	29 – 10 – 2025	6	25546
Cheongju	24 – 05 – 2023	29 – 10 – 2025	3	10672
Daejon	01 – 01 – 2020	29 – 10 – 2025	6	25546
Iksan	23 – 11 – 2020	29 – 10 – 2025	6	21614
Ulsan	01 – 01 – 2020	28 – 10 – 2025	6	25530
Gwangju	01 – 01 – 2020	23 – 10 – 2025	6	25470
Jeju	01 – 01 – 2020	23 – 10 – 2025	6	25469

Như vậy, hầu hết các trạm đều bắt đầu từ ngày 01 – 01 – 2020, 23 – 11 – 2020 hoặc 01 – 06 – 2022 và kết thúc vào ngày 23 – 10 – 2025, 28 – 10 – 2025 hoặc 29 – 10 – 2025. Thời gian thu thập dữ liệu dao động từ 3 năm đến 6 năm tùy vào từng trạm khí tượng. Do đó, số lượng giờ giữa các trạm không giống nhau, không đồng nhất khi thực hiện phân tích, so sánh hay làm đầu vào của mô hình.

2.4.2. Lượng dữ liệu thiếu tại các trạm

Bảng 2. 3. Lượng dữ liệu thiếu tại các trạm khí tượng

	pb_mean_2h	zn_mean_2h
Chuncheon	1414	1372
Seoul	1793	1701
Incheon	2755	2700
Ansan	2314	1797

Seosan	3273	3293
Cheongju	1591	1561
Daejon	1542	1573
Iksan	1656	1663
Ulsan	1595	1666
Gwangju	1201	1188
Jeju	4904	4729

Trong Bảng 2. 3, tôi tiến hành thống kê số lượng giá trị thiếu ở từng đặc trưng tại tất cả các trạm khí tượng. Kết quả cho thấy tất cả các trạm đều có ít nhất 1188 và tối đa 4904 giá trị thiếu ở tất cả các đặc trưng pb_mean_2h và zn_mean_2h. Do số lượng dữ liệu thiếu đáng kể, trong quá trình tiền xử lý, tôi đã thực hiện nội suy để đảm bảo tính liên tục của dữ liệu đầu vào.

2.4.3. Lượng bản ghi trùng lặp tại các trạm

Bảng 2. 4. Lượng bản ghi trùng lặp tại các trạm khí tượng

Trạm khí tượng	**Lượng bản ghi trùng lặp**
Chuncheon	0
Seoul	0
Incheon	0
Ansan	0
Seosan	0
Cheongju	0
Daejon	0

Iksan	0
Gwangju	0
Ulsan	0
Jeju	0

Trong Bảng 2. 4, tôi thực hiện thống kê số lượng bản ghi trùng lặp tại mỗi trạm. Kết quả cho thấy không có bất cứ bản ghi trùng lặp nào xuất hiện trong tất cả các tập dữ liệu

2.4.4. Thống kê mô tả đặc trưng trước tiền xử lý

Bảng 2. 5. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Chuncheon

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Chuncheon	YEAR	-	[2022; 2025]	2023	2024	2024	2023,61	1,03
	MONTH	-	[1; 12]	4	7	9	6,7	3,3
	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 423]	2	7	15	10,37	13,08
	zn_mean_2h	ng/m^3	[0; 675]	8	18	30	22,35	22,87

Bảng 2. 6. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Seoul

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Seoul	YEAR	-	[2020; 2025]	2021	2022	2024	2022,43	1,68
	MONTH	-	[1; 12]	3	6	9	6,38	3,39
	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 918]	2	8	17	14,01	21,72
	zn_mean_2h	ng/m^3	[0; 685]	12	23	40	29,6	26,5

Bảng 2. 7. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Incheon

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Incheon	YEAR	-	[2020; 2025]	2021	2022	2024	2022,43	1,68
	MONTH	-	[1; 12]	3	6	9	6,38	3,39

	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 486]	2	6	13	12,73	24,11
	zn_mean_2h	ng/m^3	[0; 444]	9	17	31	23,43	22,14

Bảng 2. 8. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Ansan

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Asan	YEAR	-	[2020; 2025]	2021	2022	2024	2022,43	1,68
	MONTH	-	[1; 12]	3	6	9	6,38	3,39
	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 666]	6	14	29	23,16	30,25
	zn_mean_2h	ng/m^3	[0; 783]	20	38	65	50,43	48,4

Bảng 2. 9. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Seosan

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Seosan	YEAR	-	[2020; 2025]	2021	2022	2024	2022,43	1,68
	MONTH	-	[1; 12]	3	6	9	6,38	3,39
	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 470]	4	10	20	16,13	20,99
	zn_mean_2h	ng/m^3	[0; 838]	12	24	42	34,11	37,57

Bảng 2. 10. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Cheongju

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Cheongju	YEAR	-	[2023; 2025]	2024	2024	2025	2024,09	0,76
	MONTH	-	[1; 12]	4	7	9	6,75	3,23

	DAY	-	[1; 31]	8	16	23,25	15,82	8,82
	HOUR	-	[0; 22]	6	12	16,5	11	6,9
	pb_mean_2h	ng/m^3	[0; 202]	2	6	14	10,74	14,33
	zn_mean_2h	ng/m^3	[0; 473]	13	26	44	32,66	29,5

Bảng 2. 11. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Daejon

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Daejon	YEAR	-	[2020; 2025]	2021	2022	2024	2022,43	1,68
	MONTH	-	[1; 12]	3	6	9	6,38	3,39
	DAY	-	[1; 31]	8	16	23	15,72	8,79
	HOUR	-	[0; 22]	4,5	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 761]	2	6	13	9,49	12,92
	zn_mean_2h	ng/m^3	[0; 1581]	14	26	46	34,95	35,15

Bảng 2. 12. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Iksan

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Iksan	YEAR	-	[2020; 2025]	2022	2023	2024	2022,87	1,44
	MONTH	-	[1; 12]	3	6	9	6,46	3,43
	DAY	-	[1; 31]	8	16	23	15,76	8,8
	HOUR	-	[0; 22]	6	12	17,5	11	6,9
	pb_mean_2h	ng/m^3	[0; 606]	4	8	16	12,2	14,28
	zn_mean_2h	ng/m^3	[0; 618]	10	21	38	28,29	27,22

Bảng 2. 13. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Ulsan

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Ulsan	YEAR	-	[2020; 2025]	2021	2022	2024	2022,42	1,68
	MONTH	-	[1; 12]	3	6	9	6,37	3,39

	DAY	-	[1; 31]	8	16	23	15,71	8,79
	HOUR	-	[0; 22]	4	10	16	101	6,9
	pb_mean_2h	ng/m^3	[0; 793]	2	6	13	12,29	25,04
	zn_mean_2h	ng/m^3	[0; 708]	13	28	55	41,62	46,58

Bảng 2. 14. Thống kê mô tả đặc trưng trước tiền xử lý của trạm Gwangju

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Gwangju	YEAR	-	[2020; 2025]	2021	2022	2024	2022,42	1,67
	MONTH	-	[1; 12]	3	6	9	6,36	3,39
	DAY	-	[1; 31]	8	16	23	15,69	8,79
	HOUR	-	[0; 22]	4	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 197]	1	5	9	6,92	8,55
	zn_mean_2h	ng/m^3	[0; 784]	14	26	47	36,07	37,31

Bảng 2. 15. Thống kê đặc trưng mô tả trước tiền xử lý của trạm Jeju

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Jeju	YEAR	-	[2020; 2025]	2021	2022	2024	2022,4w	1,67
	MONTH	-	[1; 12]	3	6	9	6,36	3,39
	DAY	-	[1; 31]	8	16	23	15,69	8,79
	HOUR	-	[0; 22]	4	10	16	11	6,9
	pb_mean_2h	ng/m^3	[0; 72]	0	2	5	3,9	5,06
	zn_mean_2h	ng/m^3	[0; 165]	3	7	15	11,06	12,42

2.5. Mô tả dữ liệu sau khi tiền xử lý

Qua quá trình mô tả dữ liệu thô, tôi nhận thấy tất cả trạm khí tượng đều có giá trị thiếu. Do vậy, hai bước tiền xử lý quan trọng cần được thực hiện trước khi tiến hành phân tích xu hướng, chi tiết cụ thể từng bước trong quá trình sẽ được trình bày trong Chương 4 – Phương pháp đề xuất:

Bước 1: Thay thế các bản ghi có giá trị thiếu

Bước 2: Xác định các mốc thời gian chung giữa các trạm quan trắc và thực hiện lọc dữ liệu

2.5.1. Bước 1 – Thay thế các bản ghi có giá trị thiếu

Tại tất cả các trạm khí tượng đều có giá trị thiếu tại các đặc trưng pb_mean_2h và zn_mean_2h, do đó tôi thực hiện thay thế các giá trị thiếu này bằng công thức sau:

$$y_i = y_{prev} + \frac{(x_i - x_{prev})}{(x_{next} - x_{prev})} \times (y_{next} - y_{prev}) \quad (2.1)$$

Trong đó:

- y_i: Giá trị thiếu cần nội suy
- y_{prev}: Giá trị đã biết trước đó
- y_{next}: Giá trị đã biết kế tiếp
- x_i, x_{prev}, x_{next}: chỉ số (hoặc giá trị index tương ứng)

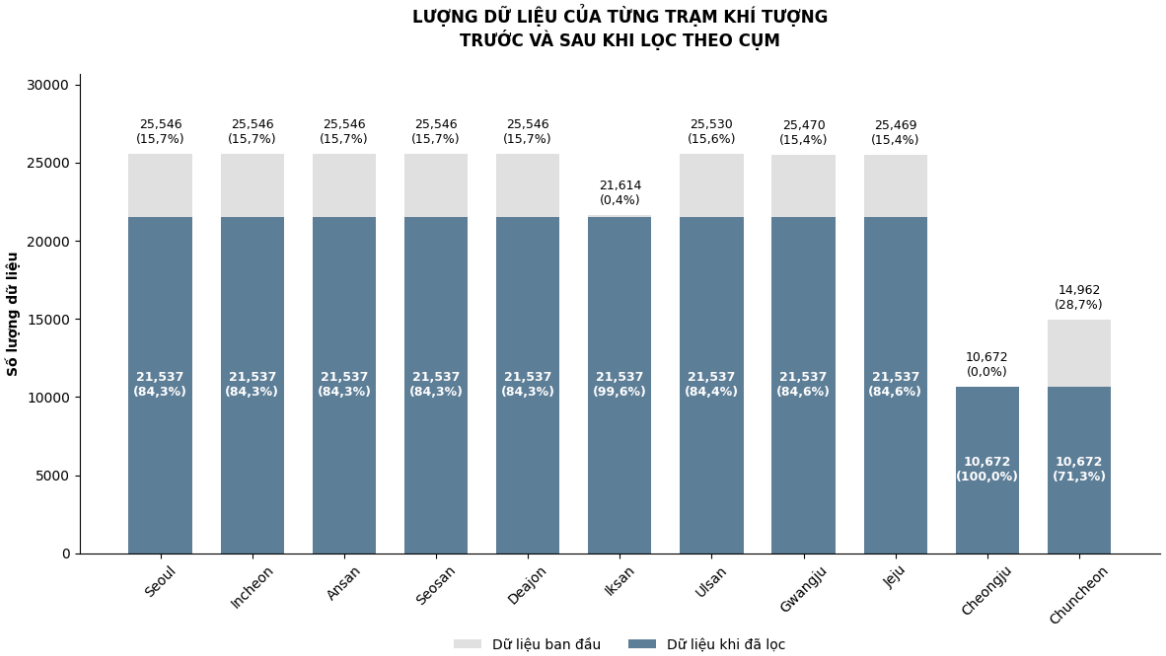
Phương pháp này chỉ được áp dụng cho các giá trị thiếu nằm giữa hai quan sát hợp lệ nhằm đảm bảo tính liên tục của chuỗi thời gian. Đối với các trường hợp thiếu ở đầu hoặc cuối chuỗi, dữ liệu được xử lý riêng bằng phương pháp điền giá trị gần nhất.

Việc lựa chọn nội suy tuyến tính xuất phát từ đặc điểm biến thiên liên tục và tương đối mượt của các đại lượng khí tượng, đồng thời phương pháp này giúp hạn chế việc tạo ra nhiễu nhân tạo, phù hợp cho các mô hình học máy và học sâu trong bài toán dự báo chuỗi thời gian.

2.5.2. Bước 2 – Xác định các mốc thời gian chung giữa các trạm quan trắc và thực hiện lọc dữ liệu

Để đảm bảo tính đồng nhất về mặt thời gian giữa các trạm khí tượng, tôi tiến hành xác định tập hợp các mốc thời gian chung xuất hiện đồng thời tại tất cả các trạm. Cụ thể, đối với từng trạm khí tượng, thông tin thời gian được tạo ra bằng cách kết hợp các thành phần dữ liệu gồm giờ, ngày, tháng và năm. Sau đó, phép giao giữa các tập hợp thời gian của từng trạm được thực hiện nhằm tìm ra những mốc thời gian xuất hiện đầy đủ trên toàn bộ các trạm khí tượng. Đối với các bản ghi chứa quá nhiều giá trị thiếu, dữ liệu sẽ được tách riêng để đảm bảo giữ lại tối đa các chuỗi bản ghi liên tục và đồng nhất giữa các trạm. Tiếp theo, dữ liệu tại mỗi trạm được lọc lại sao cho chỉ giữ những bản ghi thuộc tập thời gian chung đã xác định trước đó. Kết quả của quá trình này là một bộ dữ liệu được đồng bộ hoàn toàn về mặt thời gian giữa các

trạm khí tượng, tạo điều kiện thuận lợi cho việc phân tích và xây dựng mô hình dự báo chuỗi thời gian trong các bước tiếp theo.



Biểu đồ 2. 1. Lượng dữ liệu trước và sau khi lọc của các trạm khí tượng

Sau khi thực hiện quá trình xác định các mốc thời gian chung và tiến hành lọc dữ liệu tại tất cả các trạm khí tượng, kết quả cho thấy có 9 trạm thu được bộ dữ liệu đồng nhất sau khi áp dụng phép giao tập hợp thời gian. Cụ thể, mỗi trạm đều còn lại 1794 ngày 16 giờ dữ liệu, tương ứng với 21537 bản ghi. Tỷ lệ dữ liệu được giữ lại dao động từ 84,3% đến 99,6%, cho thấy số lượng bản ghi bị loại bỏ không quá lớn và vẫn đảm bảo đủ dữ liệu cần thiết cho việc phân tích xu hướng cũng như làm đầu vào cho mô hình học sâu trong quá trình học đặc trưng chuỗi thời gian. Tuy nhiên, đối với hai trạm khí tượng Chuncheon và Cheongju, số lượng dữ liệu thiếu xuất hiện quá nhiều, làm ảnh hưởng đáng kể đến tính liên tục và độ tin cậy của chuỗi dữ liệu. Vì vậy, tôi quyết định tách riêng hai trạm này thành trường hợp độc lập và không sử dụng trong quá trình phân tích dữ liệu, huấn luyện cũng như đánh giá mô hình.

Bảng 2. 16. Chi tiết lượng dữ liệu theo thời gian sau khi lọc

	Ngày đầu tiên	Ngày cuối cùng	Số lượng năm	Số lượng mỗi 2 giờ
Chuncheon	24 – 05 - 2023	29 – 10 - 2025	3	10672
Seoul	23 – 11 - 2020	23 – 10 - 2025	6	21537
Incheon	23 – 11 - 2020	23 – 10 - 2025	6	21537
Ansan	23 – 11 - 2020	23 – 10 - 2025	6	21537
Seosan	23 – 11 - 2020	23 – 10 - 2025	6	21537
Cheongju	24 – 05 - 2023	29 – 10 - 2025	3	10672
Daejon	23 – 11 - 2020	23 – 10 - 2025	6	21537
Iksan	23 – 11 - 2020	23 – 10 - 2025	6	21537
Ulsan	23 – 11 - 2020	23 – 10 - 2025	6	21537
Gwangju	23 – 11 - 2020	23 – 10 - 2025	6	21537
Jeju	23 – 11 - 2020	23 – 10 - 2025	6	21537

2.5.3. Thống kê mô tả đặc trưng sau khi tiền xử lý dữ liệu

Sau khi hoàn thành quá trình làm sạch và tiền xử lý dữ liệu, tôi thu được bộ dữ liệu đồng nhất và phù hợp để đưa vào phân tích. Kết quả thống kê mô tả các đặc trưng của tập dữ liệu sau tiền xử lý được trình bày như sau:

Bảng 2. 17. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Chuncheon

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)

Chuncheon	YEAR	-	[2023; 2025]	2024	2024	2025	2024,09	0,76
	MONTH	-	[1; 12]	4	7	9	6,75	3,23
	DAY	-	[1; 31]	8	16	23,25	15,82	8,82
	HOUR	-	[0; 22]	6	12	16,5	11	6,9
	pb_mean_2h	ng/m^3	[0; 170]	2	7	15	10,52	11,68
	zn_mean_2h	ng/m^3	[0; 675]	8	17	29	23,21	29,37

Bảng 2. 18. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Seoul

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Seoul	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 918]	2	7	16	13,75	22,67

	zn_mean_2h	ng/m^3	[0; 685]	12	22	38	28,73	26,59

Bảng 2. 19. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Incheon

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Incheon	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 486]	2	5	12,54	12,47	24,58
	zn_mean_2h	ng/m^3	[0; 305]	9	17	29	22,63	21,11

Bảng 2. 20. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Ansan

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**

			lớn nhất					
Asan	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 666]	5,77193	14	29	22,72	30,45
	zn_mean_2h	ng/m^3	[0; 783]	19	37	63	48,52	46,54

Bảng 2. 21. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Seosan

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Seoson	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9

	pb_mean_2h	ng/m^3	[0; 470]	4	9	20	15,87	21,19
	zn_mean_2h	ng/m^3	[0; 838]	12	23	42	33,66	37,47

Bảng 2. 22. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Cheongju

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Cheongju	YEAR	-	[2023; 2025]	2024	2024	2025	2024,1	0,76
	MONTH	-	[1; 12]	4	7	9	6,75	3,23
	DAY	-	[1; 31]	8	16	23,25	15,82	8,82
	HOUR	-	[0; 22]	6	12	16,5	11	6,9
	pb_mean_2h	ng/m^3	[0; 202]	2	6	14	10,54	13,49
	zn_mean_2h	ng/m^3	[0; 473]	14	29	46	33,84	28,18

Bảng 2. 23. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Daejon

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Daejon	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 761]	2	6	13	9,6	12,83
	zn_mean_2h	ng/m^3	[0; 1581]	13	27	47	35,01	34,64

Bảng 2. 24. Thống kê mô tả đặc trưng sau tiền xử lý của trạm Iksan

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Iksan	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43

	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 606]	4	9	16	12,09	13,95
	zn_mean_2h	ng/m^3	[0; 618]	11	22	38	28,55	26,94

Bảng 2. 25. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Ulsan

Trạm khí tượng	**Đặc trưng**	**Đơn vị**	**Giá trị nhỏ nhất, giá trị lớn nhất**	**Q1**	**Q2**	**Q3**	**Giá trị trung bình (Mean)**	**Độ lệch chuẩn (STD)**
Ulsan	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 680]	2	5,85	13	11,88	24,08
	zn_mean_2h	ng/m^3	[0; 670]	13	28	54	41,8	46,45

Bảng 2. 26. Thống kê mô tả đặc sau trước tiền xử lý của trạm Gwangju

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Gwangju	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43
	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 186]	1	4	9	6,58	8,27
	zn_mean_2h	ng/m^3	[0; 784]	14	26	46	36	37,88

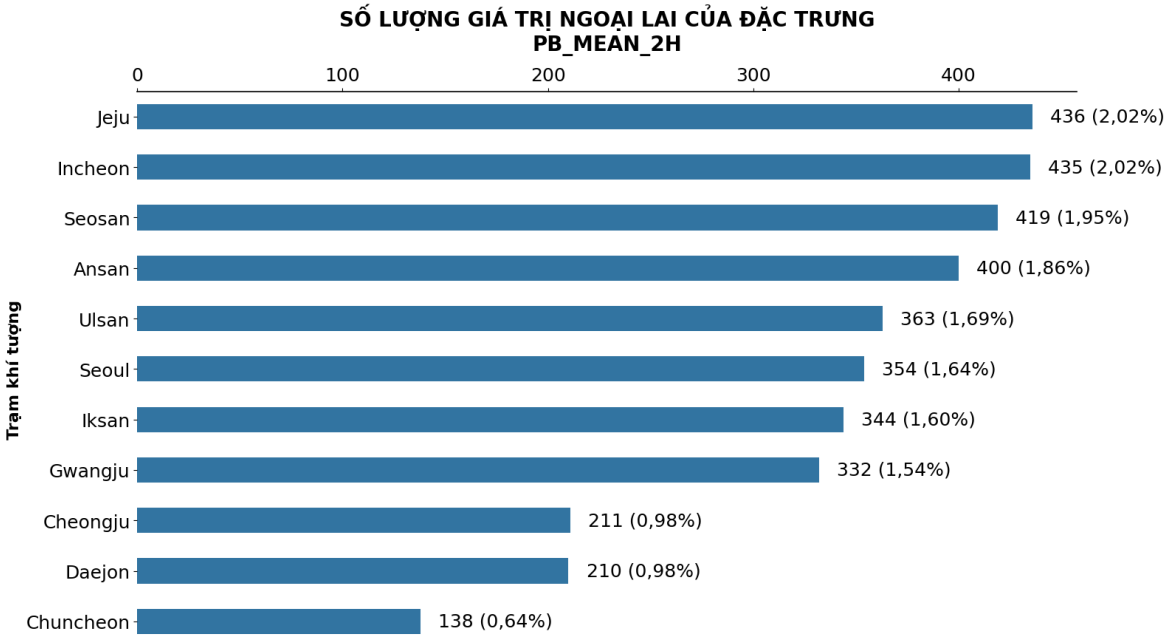
Bảng 2. 27. Thống kê đặc trưng mô tả sau tiền xử lý của trạm Jeju

Trạm khí tượng	Đặc trưng	Đơn vị	Giá trị nhỏ nhất, giá trị lớn nhất	Q1	Q2	Q3	Giá trị trung bình (Mean)	Độ lệch chuẩn (STD)
Jeju	YEAR	-	[2020; 2025]	2022	2023	2024	2022,86	1,43
	MONTH	-	[1; 12]	3	6	9	6,45	3,43

	DAY	-	[1; 31]	8	16	23	15,72	8,8
	HOUR	-	[0; 22]	4	10	18	11	6,9
	pb_mean_2h	ng/m^3	[0; 72]	0,08	2	5	3,49	4,81
	zn_mean_2h	ng/m^3	[0; 165]	3	7	14	10,76	12,63

2.5.4. Lượng giá trị ngoại lai của từng đặc trưng tại các trạm khí tượng

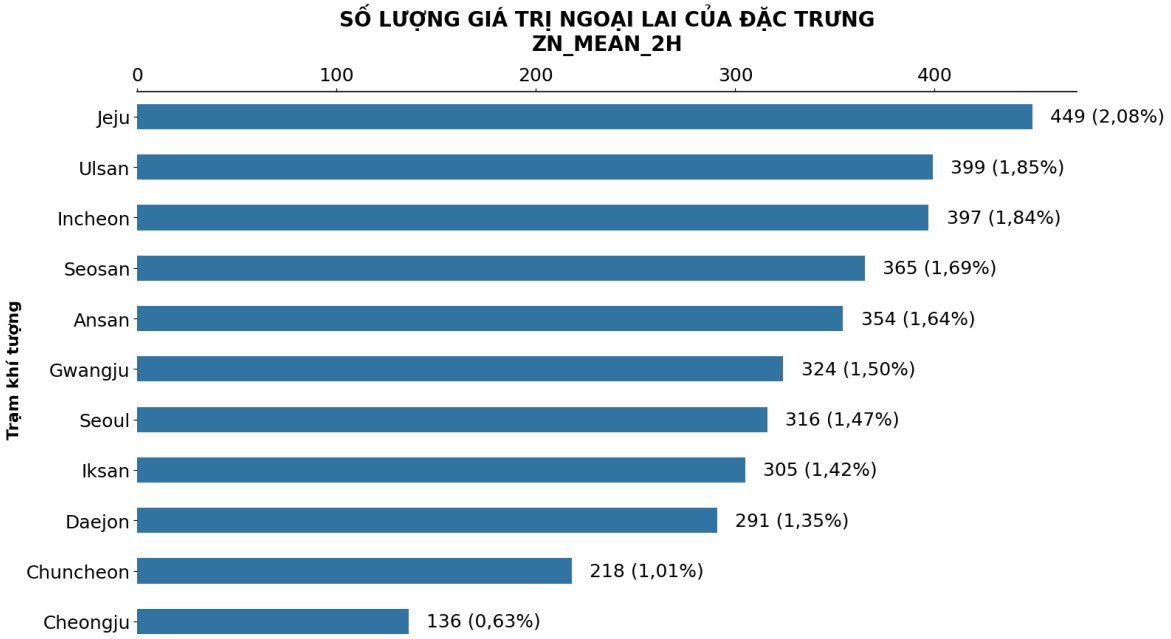
Trong đề tài này, các giá trị ngoại lai không được xem là nhiễu hay sai số thống kê, mà thường phản ánh những hiện tượng khí hậu cực đoan xảy ra trong thực tế. Đây là các thời điểm mà những đặc trưng khí tượng có sự biến động mạnh và vượt ra ngoài phạm vi dao động thông thường của tập dữ liệu.



Biểu đồ 2. 2. Lượng giá trị ngoại lai của đặc trưng pb_mean_2h sau tiền xử lý

Biểu đồ 2. 2 cho thấy số lượng giá trị ngoại lai của đặc trưng pb_mean_2h có sự khác biệt giữa các trạm khí tượng. Trong đó, trạm Chuncheon ghi nhận tỷ lệ giá trị ngoại lai thấp nhất, chỉ khoảng 0,95% tổng số bản ghi. Ngược lại, phần lớn các

trạm còn lại có tỷ lệ dao động trong khoảng 0,98% đến 2,02%, phản ánh mức độ biến động bất thường của đặc trưng này xuất hiện thường xuyên hơn trong dữ liệu.



Biểu đồ 2. 3. Lượng giá trị ngoại lai của đặc trưng zn_mean_2h sau tiền xử lý

Biểu đồ 2. 3 cho thấy tỷ lệ giá trị ngoại lai của đặc trưng zn_mean_2h có sự khác biệt giữa các trạm khí tượng. Trong đó, Chuncheon và Cheongju là hai trạm có tỷ lệ ngoại lai thấp nhất, lần lượt đạt khoảng 0,91% và 1,27% tổng số bản ghi. Ngược lại, các trạm còn lại ghi nhận tỷ lệ dao động từ 1,35% đến 2,08%, phản ánh mức độ biến động bất thường của đặc trưng này xuất hiện thường xuyên hơn trong dữ liệu.

Nhìn chung, các biểu đồ cho thấy các giá trị ngoại lai xuất hiện ở tất cả các trạm khí tượng với tỷ lệ tương đối thấp, chủ yếu dao động quanh mức 1 – 2% trên tổng số bản ghi. Điều này cho thấy dữ liệu sau tiền xử lý vẫn giữ lại được những biến động bất thường có ý nghĩa thực tiễn thay vì loại bỏ hoàn toàn như nhiễu. Sự khác biệt về tỷ lệ ngoại lai giữa các trạm phản ánh đặc điểm khí hậu và mức độ biến động thời tiết riêng của từng khu vực quan trắc. Vì vậy, việc bảo toàn các giá trị ngoại lai trong đề tài là cần thiết nhằm giúp mô hình học được đầy đủ các trạng thái bất thường của dữ liệu khí tượng, từ đó nâng cao khả năng dự đoán trong các điều kiện thời tiết cực đoan thực tế.

2.6. Tóm tắt chương

Trong chương này, bộ dữ liệu quan trắc khí tượng từ nhiều trạm với phân bố địa lý đa dạng đã được mô tả và đánh giá một cách toàn diện. Việc phân tích dữ liệu thô cũng chỉ ra những vấn đề tồn tại như giá trị thiếu, bản ghi trùng lặp và giá trị ngoại lai, đây là những thách thức phổ biến trong bộ dữ liệu quan trắc môi trường thực tế. Quy trình tiền xử lý gồm hai bước chính đã được thực hiện một cách có hệ thống nhằm khắc phục các vấn đề đó, đảm bảo tính đầy đủ và đồng nhất của dữ liệu theo cả chiều không gian lẫn chiều thời gian. Thống kê mô tả trước và sau tiền xử lý cho thấy sự cải thiện rõ rệt về chất lượng dữ liệu, đồng thời cung cấp cái nhìn sâu sắc về phân phối và đặc tính của từng đặc trưng.

CHƯƠNG 3: PHÂN TÍCH DỮ LIỆU

3.1. Giới thiệu

Trong chương này, dữ liệu khí tượng được phân tích nhằm làm rõ các đặc điểm quan trọng phục vụ cho bài toán dự đoán hàm lượng chất ô nhiễm trọng bụi PM_{10}.

Đầu tiên, phần 3.2 tập trung phân tích phân bố không gian của hàm lượng chất ô nhiễm giúp cung cấp cơ sở khoa học cho việc xây dựng cấu trúc đồ thị trong mô hình học sâu. Tiếp theo, phần 3.3 phân tích xu hướng biến đổi theo thời gian của hàm lượng chất ô nhiễm nhằm làm rõ các chu kỳ dao động và quy luật biến động theo mùa tại các trạm quan trắc. Cuối cùng phần 3.4 trình bày một số kết luận của chương này.

Thông qua việc khảo sát phân bố của các biến, mối quan hệ giữa các đặc trưng và xu hướng biến động theo thời gian, quá trình phân tích giúp nhận diện các yếu tố ảnh hưởng chính cũng như phát hiện các vấn đề tiềm ẩn trong dữ liệu. Kết quả của bước này sẽ là cơ sở quan trọng cho việc tiền xử lý và xây dựng mô hình dự đoán ở các chương tiếp theo.

3.2. Phân tích phân bố không gian của hàm lượng chất ô nhiễm tại các trạm khí tượng

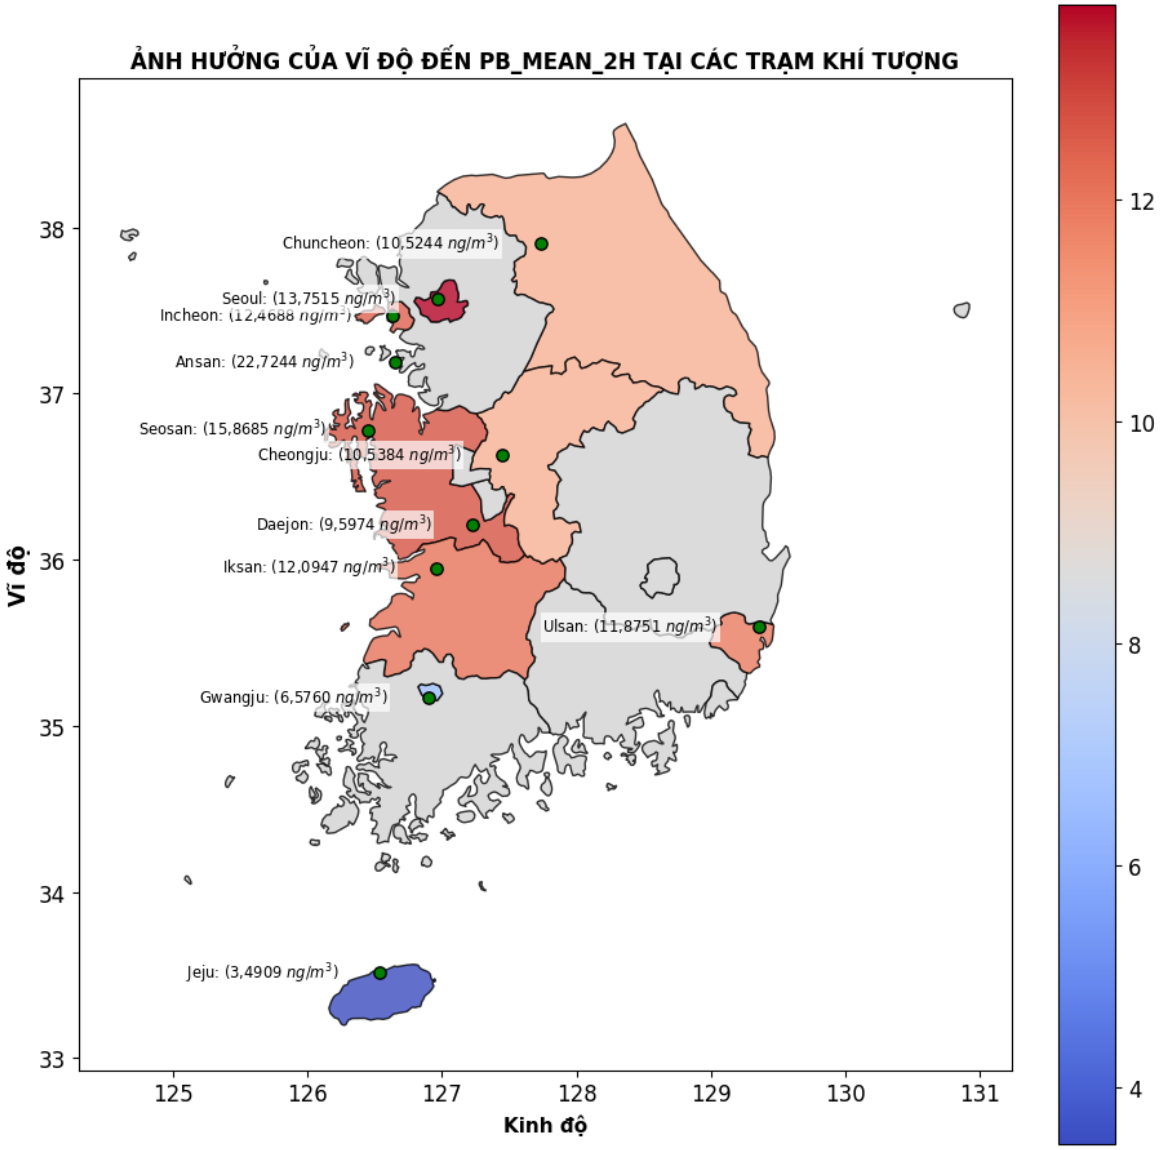
3.2.1. Sự ảnh hưởng của vĩ độ lên hàm lượng chất ô nhiễm tại các trạm khí tượng

Với kiểu khí hậu ôn đới đặc trưng cùng bốn mùa phân hóa rõ rệt, Hàn Quốc sở hữu địa hình đa dạng khi phần lớn diện tích là đồi núi tập trung ở khu vực phía đông và phía bắc, trong khi các vùng đồng bằng ven biển và lưu vực sông chủ yếu phân bố ở phía tây và phía nam. Bên cạnh đó, hệ thống bán đảo và quần đảo trải dài theo trục bắc – nam qua nhiều khu vực có độ vĩ khác nhau cũng góp phần tạo nên sự khác biệt rõ rệt về điều kiện khí tượng giữa các vùng miền. Sự thay đổi về vĩ độ này ảnh hưởng trực tiếp đến các yếu tố khí hậu và quá trình lan truyền chất ô nhiễm trong không khí, đặc biệt là nồng độ bụi mịn PM_{10}, từ đó hình thành sự phân hóa về mức độ ô nhiễm

không khí cũng như sự tích tụ các thành phần kim loại nặng trong bụi mịn trên phạm vi toàn quốc.

Với những phân tích trên, việc nghiên cứu chuyên sâu các đặc trưng khí tượng có ảnh hưởng đến nồng độ bụi mịn PM_{10} đóng vai trò quan trọng trong việc làm rõ bản chất của sự phân hóa chất lượng không khí theo không gian địa lý. Thay vì chỉ tập trung quan sát các chỉ số nồng độ bụi đơn lẻ, cách tiếp cận phân tích đa chiều các yếu tố khí tượng theo vĩ độ sẽ cung cấp góc nhìn toàn diện hơn về mối quan hệ và sự tương tác giữa các điều kiện khí tượng với nồng độ PM_{10}. Đồng thời, phương pháp này còn giúp đánh giá vai trò của vĩ độ trong việc hình thành đặc trưng ô nhiễm không khí riêng biệt tại từng khu vực ở Hàn Quốc. Qua đó, không chỉ hỗ trợ hiểu rõ hiện trạng ô nhiễm bụi mịn mà còn tạo nền tảng khoa học cho các bài toán dự báo hàm lượng chất ô nhiễm trong bụi PM_{10} trong tương lai.

- Sự ảnh hưởng của vĩ độ lên hàm lượng chất ô nhiễm tại các trạm khí tượng:



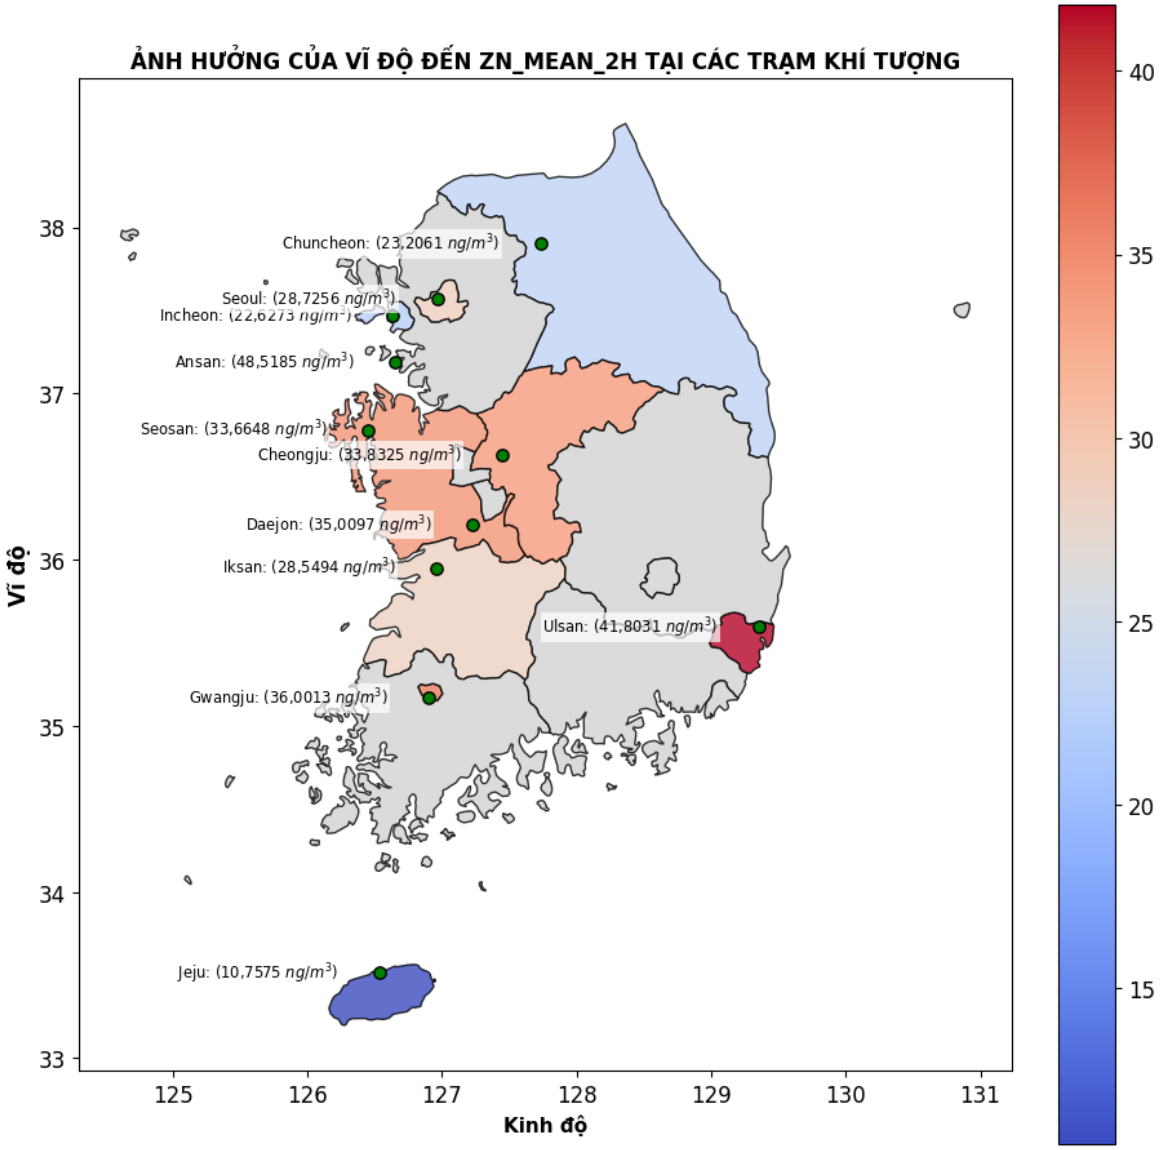
Biểu đồ 3. 1. Sự ảnh hưởng của vĩ độ đến pb_mean_2h trong ngày tại các trạm khí tượng

Biểu đồ 3. 1 cho thấy nồng độ Pb trong không khí tại các trạm khí tượng ở Hàn Quốc có xu hướng giảm dần theo chiều từ Bắc xuống Nam. Nhìn chung, các khu vực có vĩ độ cao, đặc biệt là vùng thủ đô và khu vực phía Tây Bắc ghi nhận nồng độ Pb cao hơn đáng kể so với các khu vực phía Nam. Điều này cho thấy tồn tại mối liên hệ tương đối rõ giữa vị trí địa lý, mức độ đô thị hóa và sự phân bố nồng độ Pb trong PM_{10}.

Cụ thể, khu vực thủ đô ghi nhận mức Pb cao nhất trong toàn bộ các trạm quan trắc, với giá trị dao động từ khoảng 13,75 ng/m^3 đến 22,72 ng/m^3. Trong đó, trạm Ansan đạt giá trị cao nhất là 22,72 ng/m^3, cao hơn khoảng 3,5 đến 6,5 lần so với nhiều khu vực phía Nam. Bên cạnh đó, Seoul và Incheon cũng duy trì nồng độ Pb ở mức cao, điều này phản ánh ảnh hưởng mạnh của quá trình đô thị hóa, hoạt động công nghiệp và mật độ giao thông lớn tại khu vực này.

Ngoài vùng thủ đô, trạm Seosan cũng ghi nhận nồng độ Pb tương đối cao dù không thuộc khu vực đô thị hóa mạnh. Giá trị Pb tại đây đạt khoảng 15,87 ng/m^3, cao hơn đáng kể so với nhiều khu vực có vị trí địa lý tương tự. Điều này cho thấy ngoài các nguồn phát thải nội địa, Seosan có thể còn chịu tác động từ các yếu tố ngoại sinh, đặc biệt là hiện tượng ô nhiễm xuyên biên giới thông qua luồng gió Tây Bắc từ lục địa Trung Quốc qua biển Hoàng Hải.

Ngược lại, các khu vực phía Nam có xu hướng ghi nhận nồng độ Pb thấp hơn rõ rệt, dao động khoảng 6,58 – 12,09 ng/m^3. Đặc biệt, trạm Jeju có giá trị thấp nhất chỉ khoảng 3,49 ng/m^3, điều này phản ánh đặc điểm của khu vực đảo biệt lập, ít chịu ảnh hưởng từ hoạt động công nghiệp quy mô lớn cũng như các nguồn ô nhiễm xuyên biên giới.



Biểu đồ 3. 2. Sự ảnh hưởng của vĩ độ đến zn_mean_2h trong ngày tại các trạm khí tượng

Biểu đồ 3. 2 cho thấy sự phân bố nồng độ Zn trong không khí tại các trạm khí tượng không hình thành xu hướng rõ rệt theo chiều vĩ độ như đặc trưng Pb trước đó. Nhìn chung, nồng độ Zn có sự dao động đáng kể giữa các khu vực và không đơn thuần giảm dần từ Bắc xuống Nam. Điều này cho thấy yếu tố vĩ độ không đóng vai trò chi phối chính đối với sự phân bố Zn trong PM_{10} mà còn bởi đặc điểm công nghiệp của từng khu vực có ảnh hưởng rõ rệt hơn.

Cụ thể, trạm Ansan ghi nhận nồng độ Zn cao nhất với khoảng 48,52 ng/m^3. Đây là khu vực tập trung nhiều hoạt động công nghiệp và sản xuất quy mô lớn, do đó có khả năng phát thải Zn cao hơn so với các khu vực khác. Bên cạnh đó, Ulsan cũng ghi nhận giá trị rất cao, đạt khoảng 41,80 ng/m^3 và đứng thứ hai trong toàn bộ các trạm quan trắc. Kết quả này phản ánh ảnh hưởng mạnh của các khu công nghiệp nặng và hoạt động sản xuất công nghiệp tại khu vực phía Đông Nam Hàn Quốc.

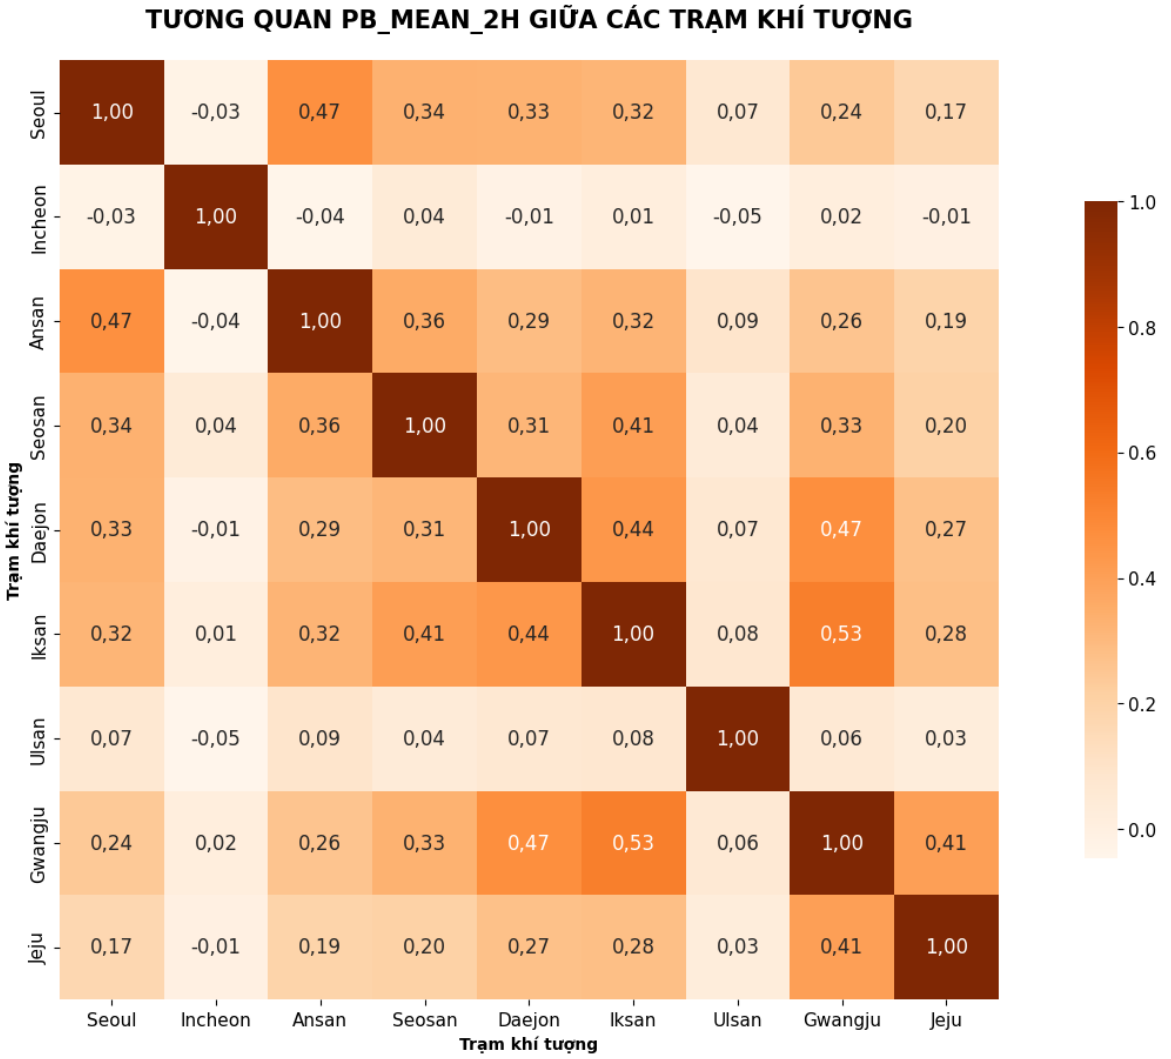
Ngoài ra, một số khu vực không thuộc nhóm trung tâm công nghiệp lớn nhất như Daejeon và Gwangju vẫn ghi nhận nồng độ Zn ở mức tương đối cao, lần lượt khoảng 35,01 ng/m^3 và 36,00 ng/m^3. Trong khi đó, các khu vực phía Bắc như Chuncheon chỉ ghi nhận khoảng 23,21 ng/m^3, thấp hơn đáng kể so với nhiều khu vực phía Nam hoặc miền Trung. Điều này cho thấy sự phân bố Zn không phụ thuộc hoàn toàn vào vị trí địa lý theo vĩ độ mà chịu tác động lớn từ cơ cấu và cường độ hoạt động công nghiệp tại từng địa phương.

Đáng chú ý, Jeju tiếp tục là khu vực có nồng độ Zn thấp nhất với khoảng 10,76 ng/m^3, phản ánh đặc điểm của khu vực đảo biệt lập, ít chịu ảnh hưởng từ các nguồn phát thải công nghiệp quy mô lớn. Kết quả này tương đồng với xu hướng quan sát được đối với Pb trước đó.

3.2.2. Sự tương quan đặc trưng giữa các trạm khí tượng

Để đánh giá mức độ đồng nhất cũng như sự phân hóa nồng độ các chất ô nhiễm giữa những khu vực địa lý khác nhau, việc phân tích tương quan giữa các trạm khí tượng thuộc ba miền Bắc, Trung và Nam đóng vai trò quan trọng trong nghiên cứu ô nhiễm không khí tại Hàn Quốc. Mối tương quan giữa các trạm cho thấy mức độ biến động đồng thời của nồng độ Pb và Zn theo không gian, qua đó hỗ trợ xác định phạm vi ảnh hưởng của các nguồn phát thải cũng như nâng cao khả năng dự báo xu hướng ô nhiễm theo từng khu vực.

- Mức độ tương quan hàm lượng chất ô nhiễm giữa các trạm khí tượng:



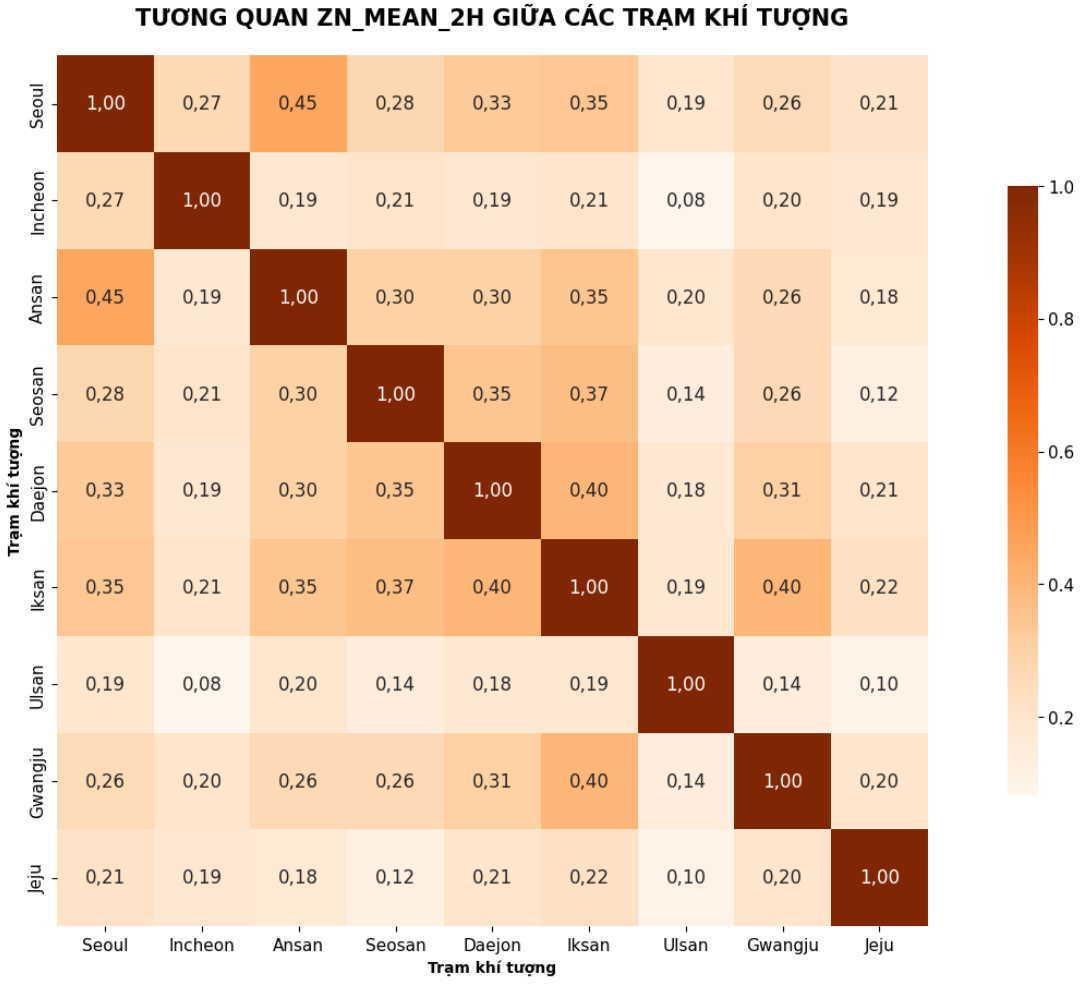
Biểu đồ 3. 3. Tương quan pb_mean_2h giữa các trạm khí tượng

Biểu đồ 3. 3 cho thấy ma trận tương quan của nồng độ Pb giữa các trạm khí tượng đại diện cho ba miền của Hàn Quốc. Nhìn chung, phần lớn các trạm có mức tương quan dương từ thấp đến trung bình, điều này cho thấy nồng độ Pb giữa các khu vực có xu hướng biến động cùng chiều nhưng mức độ đồng bộ không hoàn toàn giống nhau như sau: các trạm nằm ở khu vực phía Tây và Tây Nam thường có hệ số tương quan cao hơn so với các trạm ven biển phía Đông.

Trong đó, cặp trạm Iksan – Gwangju ghi nhận hệ số tương quan cao nhất đạt 0,53, điều này phản ánh sự đồng bộ rõ rệt về biến động nồng độ Pb giữa hai khu vực thuộc miền Tây Nam. Ngoài ra, các cặp Seoul – Ansan và Daejeon – Gwangju cũng

cho hệ số tương quan tương đối cao lần lượt đạt 0,47, cho thấy các khu vực này có thể chịu ảnh hưởng từ những điều kiện khí tượng hoặc nguồn phát thải tương đồng. Bên cạnh đó, các cặp Seosan – Iksan và Daejeon – Iksan đạt mức tương quan từ 0,41 đến 0,44, điều này hình thành một cụm liên kết tương đối rõ giữa các trạm thuộc hành lang phía Tây.

Ngược lại, một số trạm thể hiện mức tương quan rất thấp với phần còn lại. Đáng chú ý, Ulsan chỉ dao động từ 0,03 đến 0,09 với hầu hết các trạm khác, điều này cho thấy đặc điểm biến động Pb tại khu vực này mang tính riêng biệt hơn. Tương tự, Incheon cũng ghi nhận hệ số tương quan gần bằng 0 hoặc âm nhẹ với nhiều trạm, điều này phản ánh sự khác biệt nhất định về nguồn phát thải hoặc điều kiện lan truyền ô nhiễm.



Biểu đồ 3. 4. Tương quan zn_mean_2h giữa các trạm khí tượng

Biểu đồ 3. 4 cho thấy ma trận tương quan của nồng độ Zn giữa các trạm khí tượng đại diện cho ba miền của Hàn Quốc. Nhìn chung, phần lớn các trạm có mức tương quan dương từ thấp đến trung bình, điều này cho thấy sự biến động của nồng độ Zn giữa các khu vực có xu hướng phân tán hơn trong không gian.

Xét về các cặp trạm có mức tương quan cao hơn, Seoul và Ansan ghi nhận hệ số lớn nhất ngoài đường chéo chính (r = 0,45), điều này phản ánh mối liên hệ tương đối chặt chẽ giữa hai khu vực đô thị – công nghiệp thuộc vùng thủ đô. Ngoài ra, các cặp Iksan – Daejeon và Iksan – Gwangju cũng thể hiện mức tương quan từ trung bình đến khá (dao động khoảng 0,40), điều này cho thấy khu vực phía Tây vẫn duy trì xu hướng đồng biến động ô nhiễm rõ rệt đối với Zn, tương tự như đặc điểm đã quan sát ở Pb.

Ngược lại, Ulsan là trạm có mức tương quan thấp nhất với phần lớn các trạm còn lại, đặc biệt chỉ đạt 0,08 với Incheon và khoảng 0,14 – 0,20 với nhiều khu vực khác. Kết quả này cho thấy nguồn phát thải Zn tại Ulsan mang tính đặc thù địa phương cao, ít có sự liên kết khu vực. Tương tự, Jeju cũng ghi nhận hệ số tương quan thấp với toàn mạng lưới, điều này phản ánh đặc điểm biệt lập về mặt địa lý của khu vực đảo, khiến biến động nồng độ Zn tại đây diễn ra tương đối độc lập so với các khu vực đất liền.

3.3. Phân tích xu hướng biến đổi hàm lượng chất ô nhiễm theo thời gian tại các trạm khí tượng

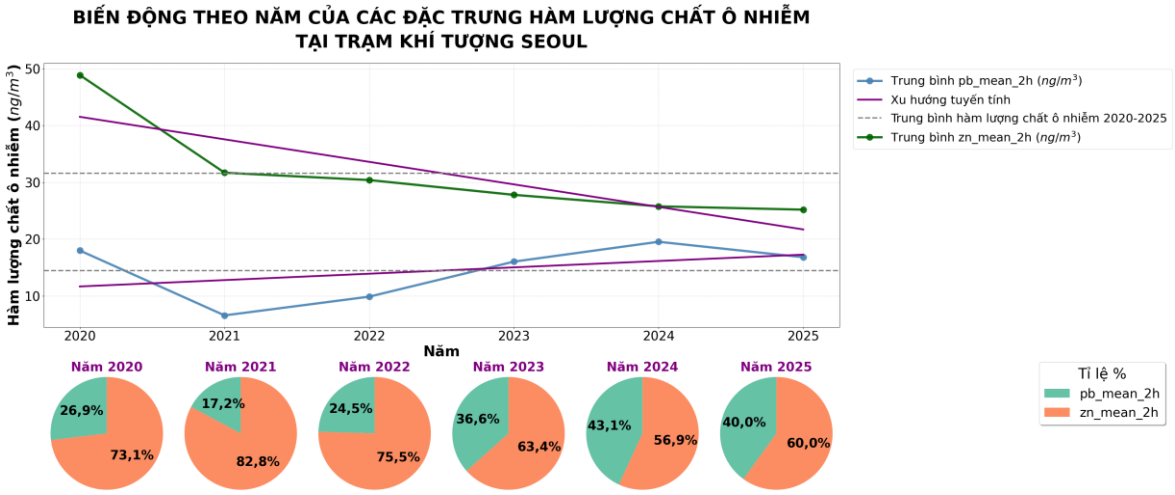
3.3.1. Xu hướng biến đổi hàm lượng chất ô nhiễm theo giờ trong giai đoạn 2020 – 2025 tại các trạm khí tượng

Như đã trình bày ở các phần trước, hàm lượng các chất ô nhiễm trong bụi PM_{10} được xem là một chỉ tiêu khí quyển nhạy cảm, nó phản ánh đồng thời tác động của cả yếu tố không gian và thời gian. Về phương diện không gian, sự phân bố nồng độ các kim loại nặng phụ thuộc đáng kể vào vị trí địa lý cũng như đặc điểm nguồn phát thải của từng khu vực. Trong khi đó, xét theo thời gian, nồng độ Pb và Zn biến đổi

theo các chu kỳ khác nhau như theo giờ, ngày, tháng, mùa và năm, điều này cho thấy tính chất biến động liên tục và phức tạp của ô nhiễm không khí.

Trong bối cảnh đó, việc phân tích xu hướng biến đổi nồng độ các chất ô nhiễm dựa trên chuỗi số liệu dài hạn tại các trạm quan trắc là cần thiết nhằm nhận diện các đặc điểm biến động mang tính quy luật cũng như những dao động bất thường tại từng khu vực cụ thể. Kết quả phân tích không chỉ giúp làm rõ đặc trưng biến động ô nhiễm theo thời gian giữa các vùng miền mà còn tạo cơ sở cho việc đối chiếu, so sánh giữa các trạm quan trắc. Từ đó, nghiên cứu có thể hỗ trợ nâng cao độ tin cậy của các mô hình dự báo hàm lượng Pb và Zn trong bụi PM_{10}.

3.3.1.1. Trạm khí tượng Seoul



Biểu đồ 3. 5. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Seoul

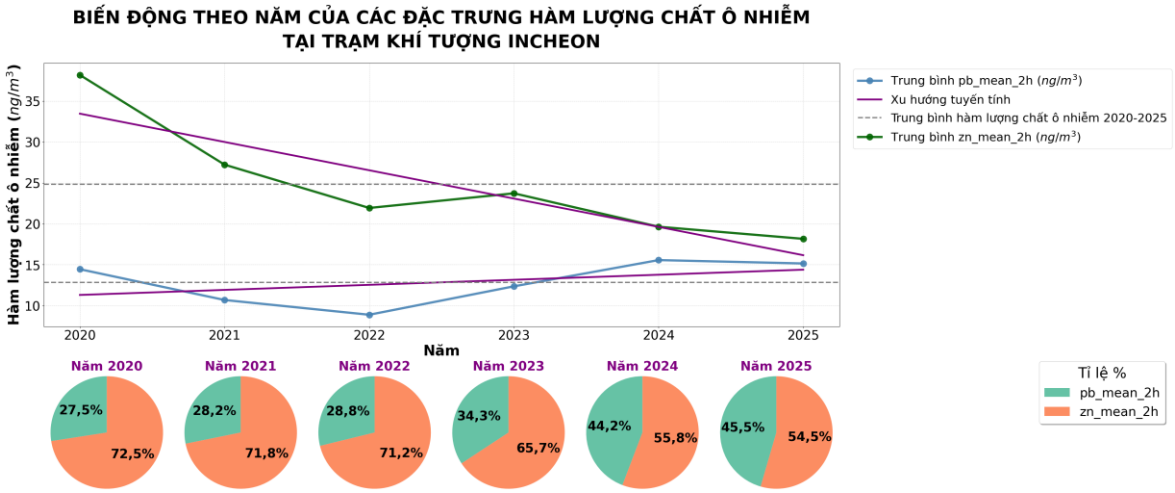
Biểu đồ 3. 5 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Seoul trong giai đoạn 2020 – 2025. Nhìn chung, hai kim loại nặng thể hiện xu hướng trái ngược nhau: Pb có xu hướng tăng dần theo thời gian, trong khi Zn giảm liên tục qua các năm.

Đối với Pb, nồng độ trung bình tăng từ khoảng 11,68 ng/m^3 năm 2020 lên 17,28 ng/m^3 vào năm 2025 với giá trị trung bình toàn giai đoạn đạt khoảng 14,48 ng/m^3. Tuy nhiên, chuỗi số liệu không biến động hoàn toàn tuyến tính khi năm 2021

ghi nhận mức giảm mạnh xuống còn 6,59 ng/m^3 trước khi phục hồi trở lại từ năm 2022.

Ngược lại, Zn cho thấy xu hướng giảm rõ rệt và ổn định hơn so với Pb. Nồng độ Zn giảm từ khoảng 41,52 ng/m^3 năm 2020 xuống còn 21,71 ng/m^3 vào năm 2025, tương đương mức giảm gần 48%, trong khi giá trị trung bình toàn giai đoạn đạt khoảng 31,62 ng/m^3. Bên cạnh đó, tỷ trọng Zn trong tổng hàm lượng kim loại nặng vẫn chiếm ưu thế tại Seoul, dù có xu hướng giảm dần qua từng năm, trong khi tỷ lệ Pb tăng tương đối rõ rệt từ sau năm 2022.

3.3.1.2. Trạm khí tượng Incheon



Biểu đồ 3. 6. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Incheon

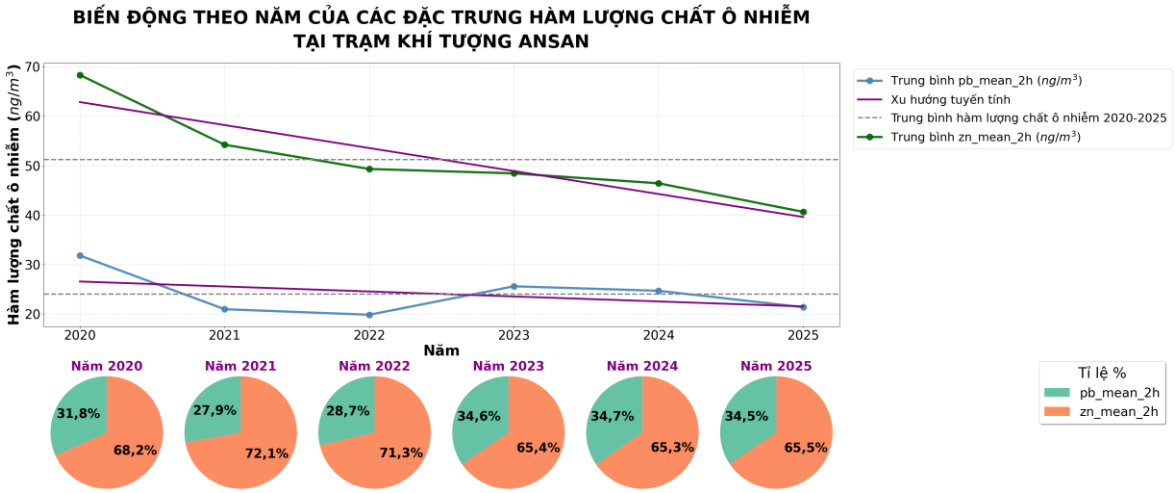
Biểu đồ 3. 6 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Incheon trong giai đoạn 2020 – 2025. Nhìn chung, Pb có xu hướng tăng nhẹ theo thời gian trong khi Zn giảm rõ rệt và liên tục trong toàn bộ giai đoạn nghiên cứu.

Đối với Pb, nồng độ trung bình tăng từ khoảng 11,30 ng/m^3 năm 2020 lên 14,39 ng/m^3 vào năm 2025 với giá trị trung bình toàn giai đoạn đạt khoảng 12,85 ng/m^3. Tuy nhiên, diễn biến thực tế giữa các năm không hoàn toàn ổn định khi Pb giảm xuống mức thấp nhất khoảng 8,88 ng/m^3 vào năm 2022 trước khi tăng trở lại

trong các năm sau đó. Điều này cho thấy hàm lượng Pb tại Incheon có mức dao động tương đối lớn và phứt tạp.

Ngược lại, Zn thể hiện xu hướng giảm liên tục và rõ ràng nhất trong số các trạm nghiên cứu. Nồng độ Zn giảm từ khoảng 33,45 ng/m^3 năm 2020 xuống còn 16,16 ng/m^3 vào năm 2025, tương đương mức giảm hơn 50%, trong khi giá trị trung bình toàn giai đoạn đạt khoảng 24,81 ng/m^3. Bên cạnh đó, tỷ trọng Pb trong bảng tỷ lệ phần trăm đóng góp so sánh có xu hướng tăng dần qua các năm trong khi Zn vẫn chiếm ưu thế nhưng giảm đáng kể vào cuối giai đoạn nghiên cứu.

3.3.1.3. Trạm khí tượng Ansan



Biểu đồ 3. 7. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Ansan

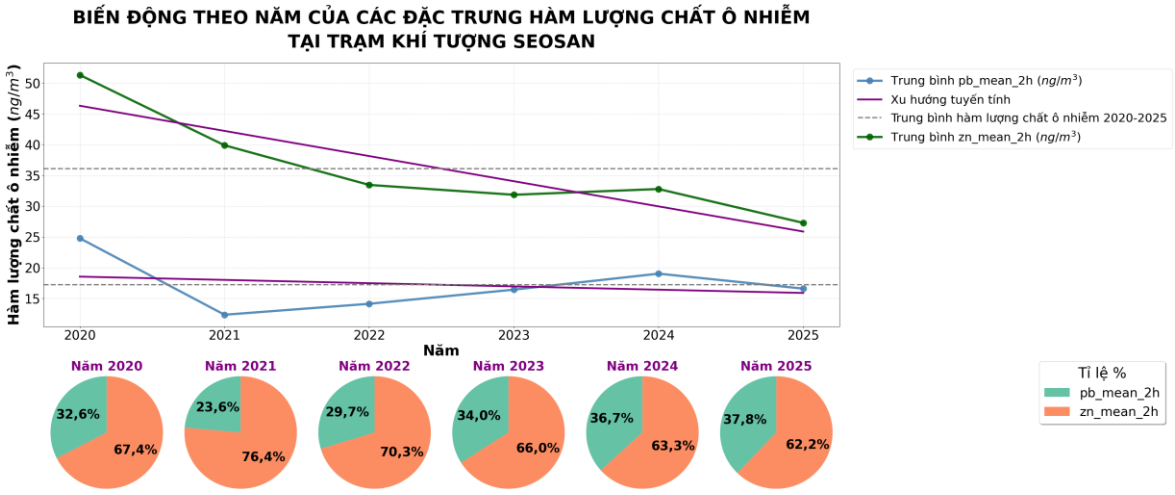
Biểu đồ 3. 7 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Ansan trong giai đoạn 2020 – 2025. Nhìn chung, cả Pb và Zn đều có xu hướng giảm theo thời gian, tuy nhiên Zn luôn ghi nhận nồng độ cao hơn đáng kể so với Pb. Bên cạnh xu hướng giảm dài hạn, dữ liệu của cả hai chất cũng xuất hiện các biến động mạnh ở giai đoạn đầu kỳ, đặc biệt trong năm 2020.

Đối với Pb, giá trị theo xu hướng tuyến tính giảm từ khoảng 26,56 ng/m^3 năm 2020 xuống còn 21,51 ng/m^3 vào năm 2025. Trên thực tế, nồng độ Pb năm 2020 đạt khoảng 31,80 ng/m^3, cao hơn đáng kể so với mức xu hướng, trước khi giảm mạnh

xuống 20,95 ng/m^3 vào năm 2021. Trong các năm tiếp theo, chỉ số này dao động tương đối thất thường trong khoảng 19,83 – 25,58 ng/m^3. Giá trị trung bình toàn giai đoạn đạt 24,03 ng/m^3, cao nhất trong số các trạm quan trắc, điều này cho thấy Pb tại Ansan không chỉ duy trì ở mức cao mà còn có độ biến động lớn với sự xuất hiện của các điểm dữ liệu cực trị.

Xu hướng giảm của Zn còn rõ rệt hơn khi nồng độ giảm từ khoảng 62,85 ng/m^3 xuống còn 39,60 ng/m^3 vào cuối giai đoạn, tương đương mức giảm gần 37%. Giá trị thực tế năm 2020 lên tới 68,32 ng/m^3 trước khi giảm mạnh ngay trong năm kế tiếp và tiếp tục suy giảm dần qua các năm sau. Mặc dù có xu hướng cải thiện, giá trị trung bình toàn kỳ của Zn vẫn đạt khoảng 51,22 ng/m^3, tiếp tục là mức cao nhất trong hệ thống quan trắc. Điều này cho thấy Ansan vẫn là khu vực có mức độ ô nhiễm kim loại nặng nghiêm trọng nhất, đồng thời là trạm có tính phức tạp cao đối với các mô hình dự báo do sự tồn tại của các biến động phi tuyến và các giai đoạn chuyển trạng thái rõ rệt.

3.3.1.4. Trạm khí tượng Seosan



Biểu đồ 3. 8. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Seosan

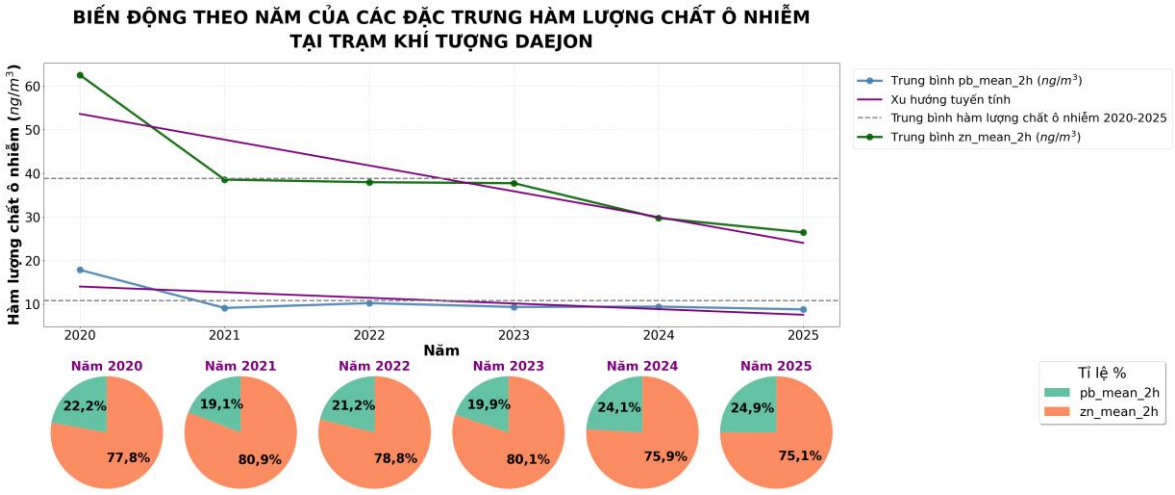
Biểu đồ 3. 8 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Seosan trong giai đoạn 2020 – 2025. Nhìn chung, Zn luôn duy trì nồng độ cao hơn

Pb trong toàn bộ thời kỳ quan sát và thể hiện xu hướng suy giảm ổn định hơn. Trong khi đó, Pb biến động thất thường hơn với các giai đoạn giảm và phục hồi xen kẽ, cho thấy chất lượng không khí tại Seosan chịu tác động đồng thời từ nhiều nguồn phát thải khác nhau.

Đối với Pb, xu hướng tuyến tính giảm nhẹ từ khoảng 18,55 ng/m^3 năm 2020 xuống còn 15,89 ng/m^3 vào năm 2025, với giá trị trung bình toàn giai đoạn đạt khoảng 17,20 ng/m^3. Tuy nhiên, dữ liệu thực tế cho thấy sự dao động đáng kể qua từng năm. Cụ thể, nồng độ Pb đạt mức cao khoảng 24,78 ng/m^3 vào năm 2020 trước khi giảm mạnh xuống 12,35 ng/m^3 trong năm 2021. Sau đó, chỉ số này tăng dần trở lại trong giai đoạn 2022 – 2024, dao động từ khoảng 14,13 đến 19,03 ng/m^3 rồi giảm nhẹ vào năm cuối kỳ.

Trái lại, đặc trưng Zn thể hiện xu hướng giảm rõ rệt và ổn định hơn trong toàn bộ giai đoạn nghiên cứu. Nồng độ Zn giảm từ khoảng 46,32 ng/m^3 xuống còn 25,87 ng/m^3 vào năm 2025, tương đương mức giảm gần 44%, trong khi giá trị trung bình toàn kỳ đạt khoảng 36,10 ng/m^3. Giá trị thực tế của Zn cũng giảm liên tục từ 51,32 ng/m^3 năm 2020 xuống còn 27,28 ng/m^3 vào cuối giai đoạn mà không xuất hiện sự đảo chiều đáng kể.

3.3.1.5. Trạm khí tượng Daejon



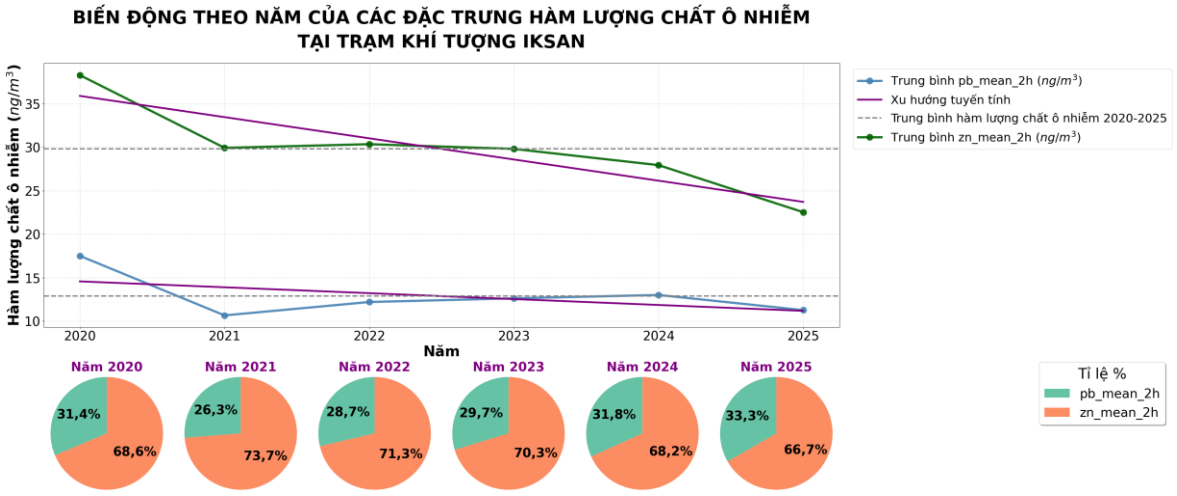
Biểu đồ 3. 9. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Daejon

Biểu đồ 3. 9 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Daejon trong giai đoạn 2020 – 2025. Nhìn chung, Daejeon thể hiện mức suy giảm đồng đều hơn với ít biến động bất thường, điều này phản ánh xu hướng cải thiện bền vững của hàm lượng kim loại nặng trong không khí.

Đối với Pb, xu hướng tuyến tính giảm từ khoảng 14,04 ng/m^3 năm 2020 xuống còn 7,57 ng/m^3 vào năm 2025, tương đương mức giảm khoảng 46%. Giá trị trung bình toàn giai đoạn đạt khoảng 10,80 ng/m^3. Dữ liệu thực tế cho thấy nồng độ Pb đạt mức khá cao vào năm 2020 với khoảng 17,86 ng/m^3 trước khi giảm mạnh xuống 9,13 ng/m^3 trong năm 2021. Từ sau thời điểm này, hàm lượng Pb duy trì ở mức thấp và dao động tương đối ổn định trong các năm tiếp theo.

Xu hướng của Zn còn nổi bật hơn khi nồng độ giảm từ khoảng 53,65 ng/m^3 xuống chỉ còn 24,05 ng/m^3 vào năm 2025, tương đương mức giảm hơn 55%, trong khi giá trị trung bình toàn kỳ đạt khoảng 38,85 ng/m^3. Tương tự Pb, giá trị Zn thực tế năm 2020 ở mức rất cao, khoảng 62,57 ng/m^3, trước khi giảm mạnh và tiếp tục suy giảm đều qua các năm sau đó. Nhìn chung, cả Pb và Zn tại Daejeon đều thể hiện xu hướng giảm liên tục với mức độ dao động thấp hơn đáng kể so với các trạm khác.

3.3.1.6. Trạm khí tượng Iksan



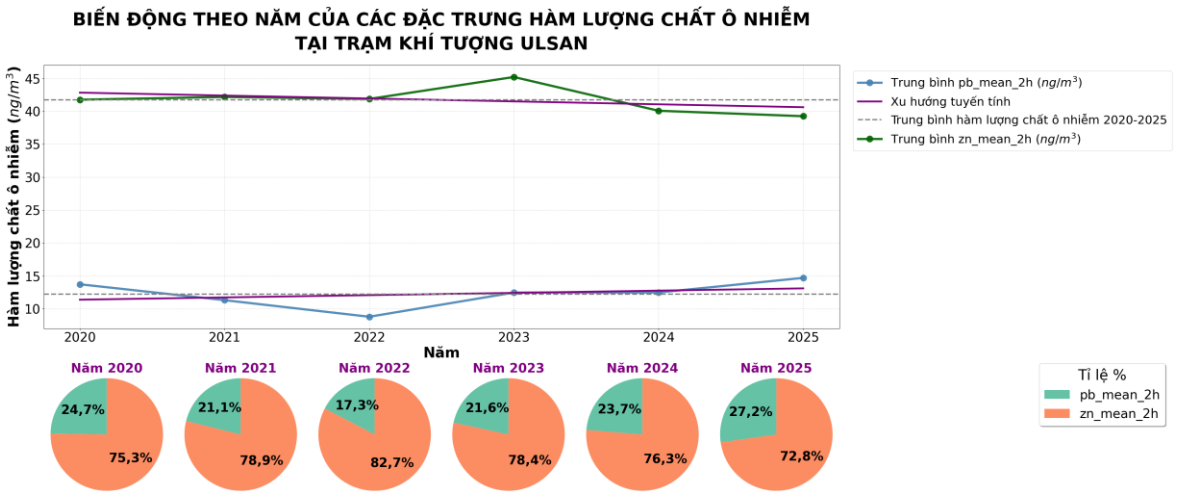
Biểu đồ 3. 10. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Iksan

Biểu đồ 3. 10 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Iksan trong giai đoạn 2020 – 2025. Nhìn chung, cả hai kim loại đều có xu hướng giảm theo thời gian, tuy nhiên tốc độ suy giảm diễn ra tương đối chậm và ổn định hơn so với nhiều trạm miền Trung khác.

Đối với Pb, giá trị trung bình theo xu hướng tuyến tính giảm từ khoảng 14,57 ng/m^3 năm 2020 xuống còn 11,18 ng/m^3 vào năm 2025 với mức trung bình toàn kỳ đạt 12,87 ng/m^3. Dữ liệu thực tế cho thấy Pb giảm mạnh trong năm đầu tiên, từ 17,5 ng/m^3 xuống 10,66 ng/m^3 vào năm 2021. Sau đó, nồng độ Pb tăng nhẹ và dao động quanh mức 12 – 13 ng/m^3 trong giai đoạn 2022 – 2024 trước khi giảm nhẹ còn 11,26 ng/m^3 vào năm 2025. Diễn biến này phản ánh xu hướng giảm tương đối yếu, chủ yếu đi kèm các dao động ngắn hạn quanh mức trung bình.

Trong khi đó, Zn giảm rõ rệt hơn khi giá trị xu hướng tuyến tính đi từ 35,91 ng/m^3 xuống 23,72 ng/m^3, tương đương mức giảm gần 34%, với giá trị trung bình toàn giai đoạn đạt 29,81 ng/m^3. Thực tế, nồng độ Zn giảm mạnh trong năm 2021 rồi duy trì tương đối ổn định quanh ngưỡng 29 – 30 ng/m^3 trong giai đoạn 2021 – 2023 trước khi tiếp tục giảm đáng kể ở hai năm cuối.

3.3.1.7. Trạm khí tượng Ulsan



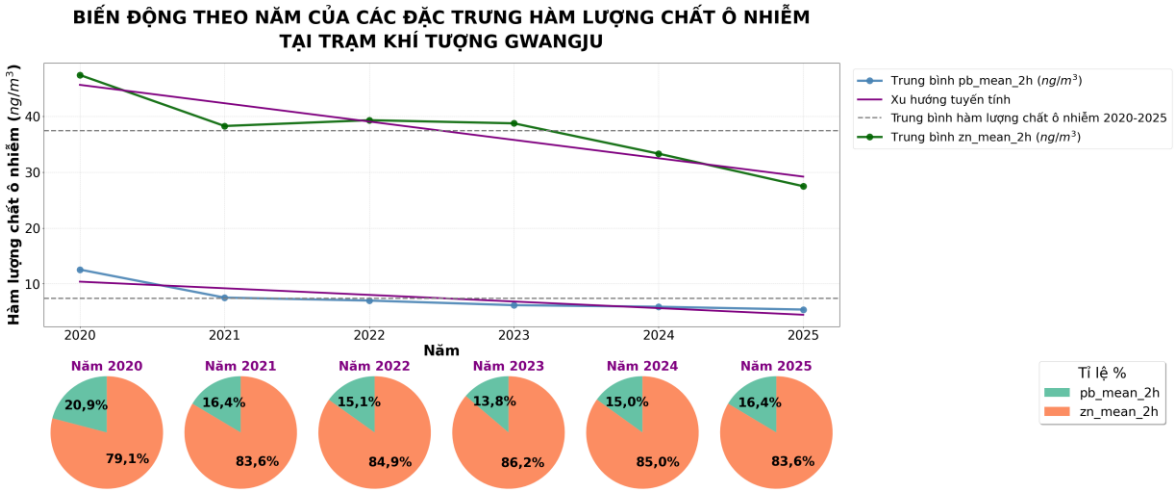
Biểu đồ 3. 11. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Ulsan

Biểu đồ 3. 11 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Ulsan trong giai đoạn 2020 – 2025. Nhìn chung, Ulsan cho thấy đặc điểm ô nhiễm khác biệt so với phần lớn các trạm còn lại khi nồng độ Zn duy trì ở mức rất cao và gần như ổn định trong toàn kỳ, trong khi Pb có xu hướng tăng nhẹ về cuối giai đoạn.

Đối với Pb, giá trị theo xu hướng tuyến tính tăng nhẹ từ khoảng 11,38 ng/m^3 năm 2020 lên 13,10 ng/m^3 vào năm 2025, với mức trung bình toàn giai đoạn đạt 12,24 ng/m^3. Dữ liệu thực tế cho thấy Pb giảm xuống mức thấp nhất 8,79 ng/m^3 vào năm 2022 trước khi phục hồi nhanh trong các năm tiếp theo và đạt khoảng 14,75 ng/m^3 vào năm 2025.

Trong khi đó, nồng độ Zn gần như không thay đổi đáng kể trong toàn bộ giai đoạn nghiên cứu. Đường xu hướng tuyến tính chỉ giảm nhẹ từ 42,82 ng/m^3 xuống 40,61 ng/m^3, tương đương mức giảm dưới 5%, với giá trị trung bình đạt 41,71 ng/m^3. Trên thực tế, nồng độ Zn dao động trong biên độ hẹp, quanh mức 40 – 45 ng/m^3 và đạt đỉnh khoảng 45 ng/m^3 vào năm 2023 trước khi giảm nhẹ ở hai năm cuối.

3.3.2.8. Trạm khí tượng Gwangju



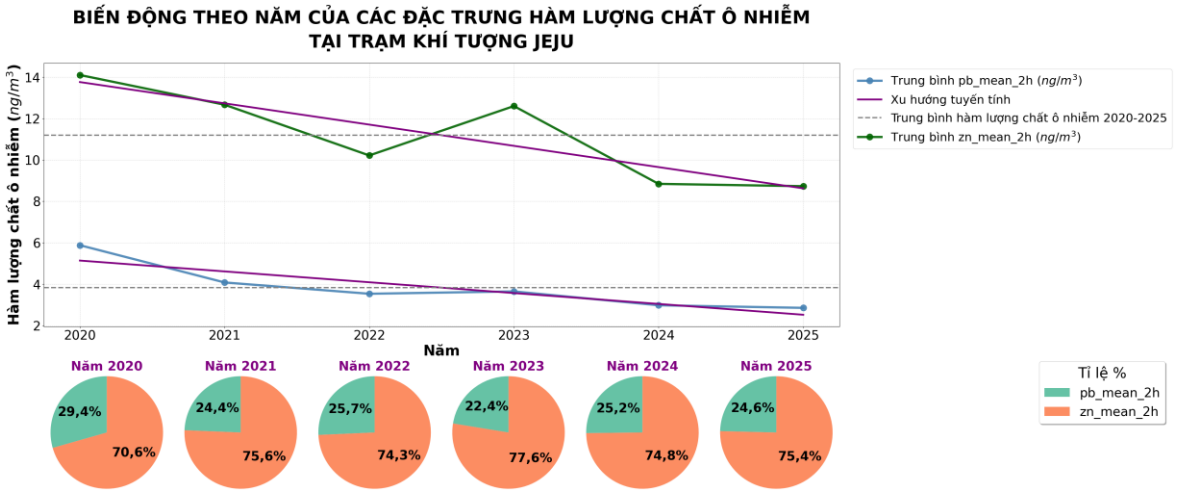
Biểu đồ 3. 12. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Gwangju

Biểu đồ 3. 12 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Gwangju trong giai đoạn 2020 – 2025. Nhìn chung, cả hai kim loại đều ghi nhận xu hướng giảm rõ rệt theo thời gian, điều này phản ánh sự cải thiện tích cực và tương đối đồng đều về chất lượng không khí tại khu vực này.

Đối với Pb, đường xu hướng tuyến tính giảm liên tục từ khoảng 10,40 ng/m^3 năm 2020 xuống còn 4,46 ng/m^3 vào năm 2025, điều này tương đương mức giảm khoảng 57%. Giá trị trung bình toàn giai đoạn đạt 7,43 ng/m^3, thuộc nhóm thấp nhất trong mạng lưới quan trắc. Dữ liệu thực tế cũng phản ánh xu hướng giảm khá nhất quán khi nồng độ Pb giảm đều từ 12,56 ng/m^3 xuống còn khoảng 5,40 ng/m^3 vào cuối kỳ mà hầu như không xuất hiện biến động lớn hay sự phục hồi đáng kể giữa các năm.

Tương tự, Zn cũng giảm đáng kể từ 45,66 ng/m^3 xuống khoảng 29,22 ng/m^3 trong giai đoạn nghiên cứu, với giá trị trung bình toàn kỳ đạt 37,44 ng/m^3. Tuy nhiên, diễn biến thực tế của Zn cho thấy sự khác biệt giữa hai giai đoạn: nồng độ duy trì tương đối ổn định quanh mức 38 – 39 ng/m^3 trong giai đoạn 2021 – 2023 trước khi giảm mạnh ở hai năm cuối.

3.3.2.9. Trạm khí tượng Jeju



Biểu đồ 3. 13. Xu hướng biến đổi theo năm của hàm lượng chất ô nhiễm tại trạm khí tượng Jeju

Biểu đồ 3. 13 cho thấy sự biến động theo năm của hàm lượng Pb và Zn tại trạm Jeju trong giai đoạn 2020 – 2025. Nhìn chung, cả hai kim loại đều có xu hướng giảm theo thời gian, trong đó Zn luôn duy trì ở mức cao hơn đáng kể so với Pb.

Đối với Pb, giá trị trung bình thực tế giảm tương đối ổn định từ khoảng 5,88 ng/m^3 vào năm 2020 xuống còn 2,85 ng/m^3 vào năm 2025. Đường xu hướng tuyến tính cũng cho thấy mức giảm đều, từ 5,14 ng/m^3 xuống 2,52 ng/m^3 với giá trị trung bình toàn giai đoạn chỉ đạt khoảng 3,83 ng/m^3.

Trong khi đó, Zn cũng ghi nhận xu hướng giảm rõ rệt, từ khoảng 14,1 ng/m^3 năm 2020 xuống còn gần 8,7 ng/m^3 năm 2025, tương ứng mức giảm khoảng 37%. Tuy nhiên, dữ liệu thực tế cho thấy một số dao động nhẹ trong giai đoạn nghiên cứu, đặc biệt vào các năm 2021 và 2023 khi nồng độ tăng trở lại so với xu hướng chung.

3.3.2. Xu hướng biến đổi hàm lượng chất ô nhiễm theo tháng trong giai đoạn 2020 – 2025 tại các trạm khí tượng

Qua quá trình phân tích chuỗi số liệu hàm lượng chất ô nhiễm trong bụi PM_{10} theo mỗi hai giờ tại các trạm khí tượng trên Hàn Quốc trong giai đoạn 2020 – 2025, tôi nhận thấy sự biến động của hàm lượng chất ô nhiễm không khí không diễn ra ổn định theo thời gian mà thường xuất hiện các pha thay đổi rõ rệt theo từng năm. Đặc biệt, trong những năm gần đây, mức độ dao động có xu hướng mạnh hơn và mang tính cực đoan cao hơn so với các giai đoạn trước. Vì vậy, để phản ánh chính xác đặc điểm biến đổi theo thời gian của dữ liệu, chuỗi số liệu được chia thành các giai đoạn nhỏ nhằm phục vụ cho việc phân tích chuyên sâu hơn.

Cụ thể, chuỗi thời gian gồm 6 năm được phân thành 6 giai đoạn riêng biệt cùng 1 giai đoạn tổng hợp như sau:

Giai đoạn 1: 2000

Giai đoạn 2: 2021

Giai đoạn 3: 2022

Giai đoạn 4: 2023

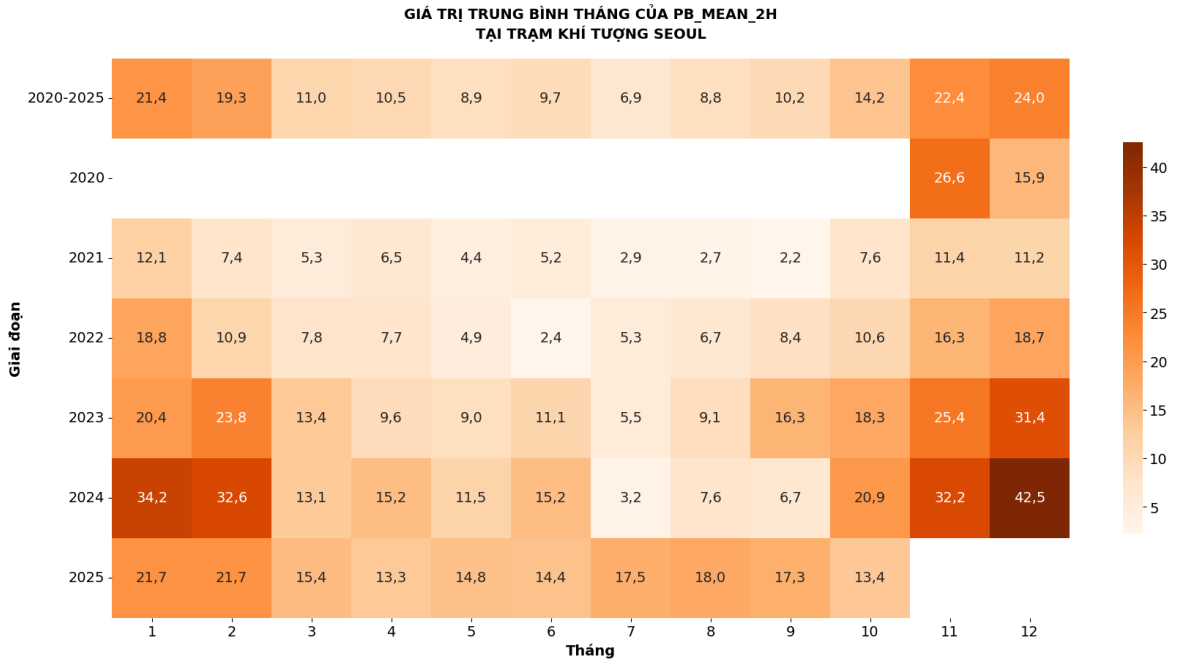
Giai đoạn 5: 2024

Giai đoạn 6: 2025

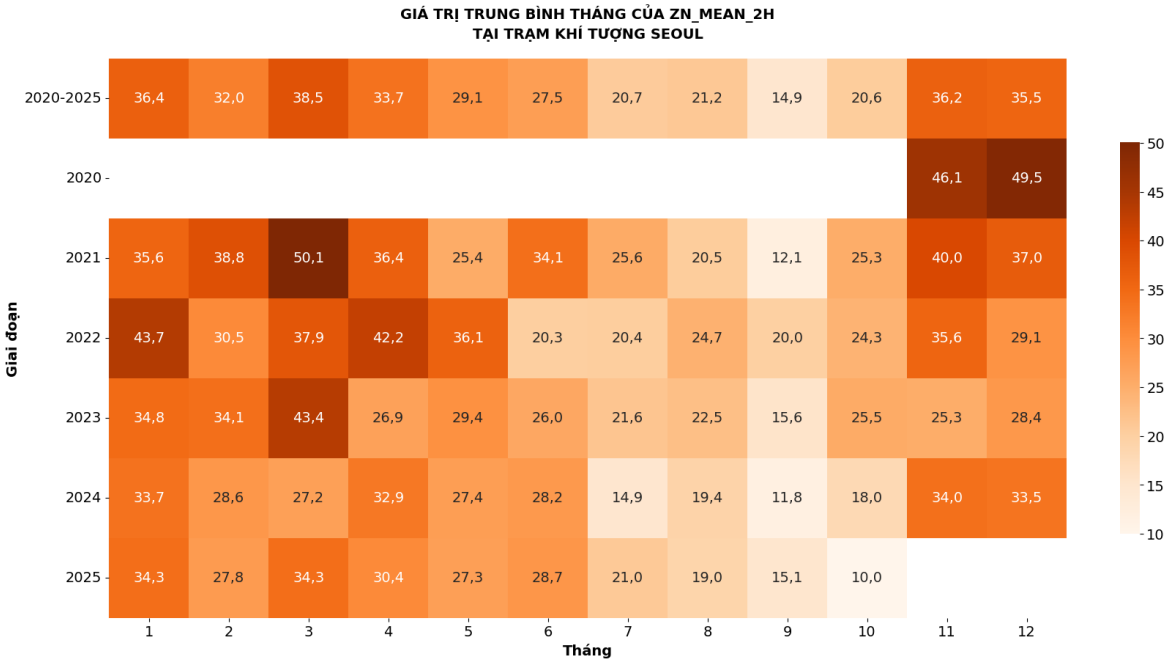
Giai đoạn tổng: 2020 – 2025

Việc phân chia này cho phép đánh giá chi tiết hơn xu hướng biến động hàm lượng chất ô nhiễm theo từng tháng trong mỗi giai đoạn, qua đó hỗ trợ nhận diện rõ hơn các quy luật biến đổi theo mùa cũng như sự khác biệt về mức độ ô nhiễm giữa các khu vực trên lãnh thổ Hàn Quốc.

3.3.2.1. Trạm khí tượng Seoul



Biểu đồ 3. 14. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Seoul (2020 – 2025)



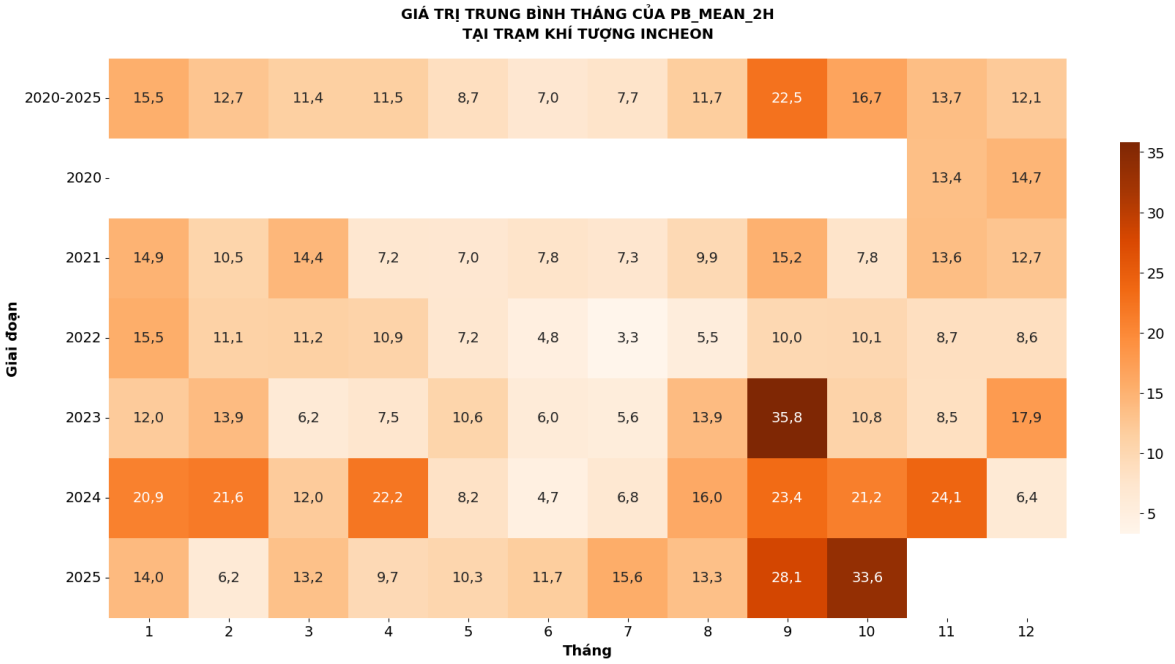
Biểu đồ 3. 15. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Seoul (2020 – 2025)

Biểu đồ 3. 14 và Biểu đồ 3. 15 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Seoul trong giai đoạn 2020 – 2025 có sự biến thiên theo mùa khá rõ rệt. Nhìn chung, cả hai kim loại đều đạt giá trị cao vào mùa đông và giảm mạnh vào mùa hè, điều này phản ánh ảnh hưởng của điều kiện khí hậu ôn đới và hoạt động vận chuyển ô nhiễm khu vực. Tuy nhiên, Pb thể hiện mức dao động mạnh hơn và có xu hướng gia tăng rõ rệt ở các năm cuối giai đoạn, trong khi Zn biến động phức tạp và thiếu tính ổn định giữa các năm.

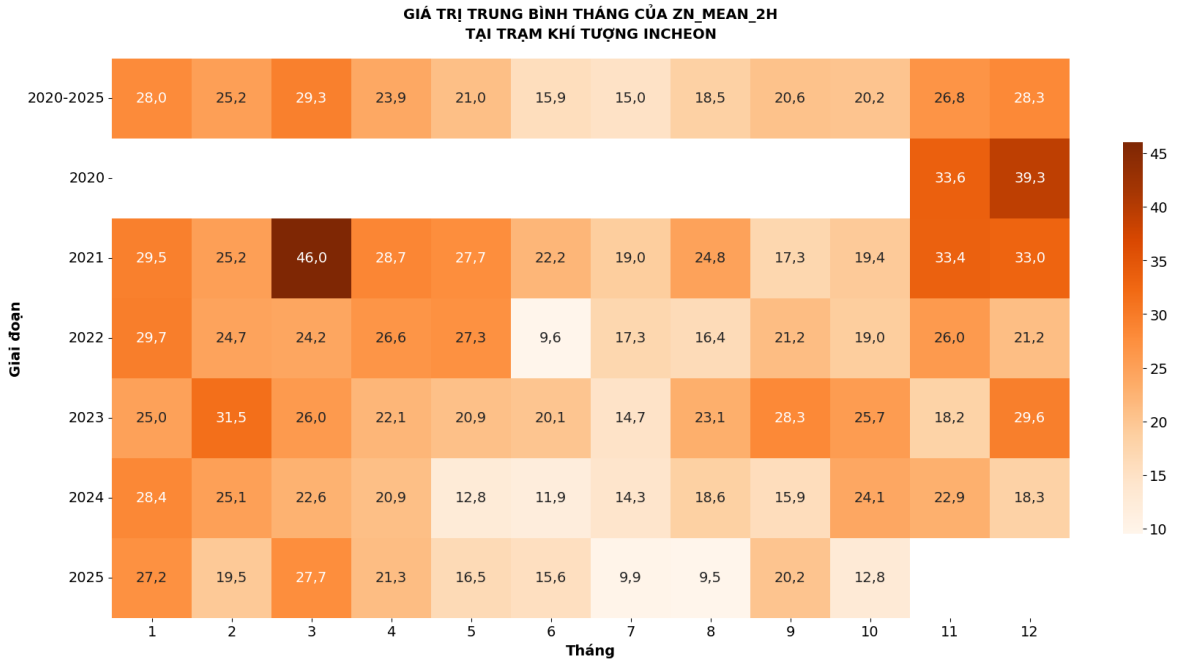
Đối với Pb, giá trị trung bình tháng cao nhất thường xuất hiện vào các tháng 11, 12 và 1, trong khi mức thấp nhất tập trung vào khoảng tháng 5 đến tháng 7. Trong toàn bộ giai đoạn, mức Pb trung bình dao động từ khoảng 3 – 9 ng/m^3 vào mùa hè lên trên 20 ng/m^3 trong mùa đông. Đáng chú ý, nồng độ Pb tăng mạnh trong các năm 2023 – 2024, đặc biệt tháng 12/2024 đạt khoảng 42,5 ng/m^3 – cao nhất trong toàn bộ chuỗi số liệu. Xu hướng này cho thấy tình trạng ô nhiễm Pb vào mùa đông tại Seoul ngày càng nghiêm trọng hơn, nhiều khả năng liên quan đến gió mùa Đông Bắc và sự gia tăng tích tụ bụi ô nhiễm từ lục địa Đông Bắc Á.

Trong khi đó, Zn cũng thể hiện tính mùa vụ tương đối rõ, với các giá trị cao thường xuất hiện vào tháng 1, tháng 3, tháng 11 và tháng 12, còn mức thấp nhất chủ yếu rơi vào tháng 7 và tháng 9. Tuy nhiên, so với Pb, Zn có biên độ dao động nhỏ hơn và thay đổi thất thường hơn giữa các năm. Chẳng hạn, tháng 3/2021 ghi nhận mức rất cao khoảng 50,1 ng/m^3, nhưng đến tháng 3/2024 chỉ còn khoảng 27,2 ng/m^3.

3.3.2.2. Trạm khí tượng Incheon



Biểu đồ 3. 16. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Incheon (2020 – 2025)



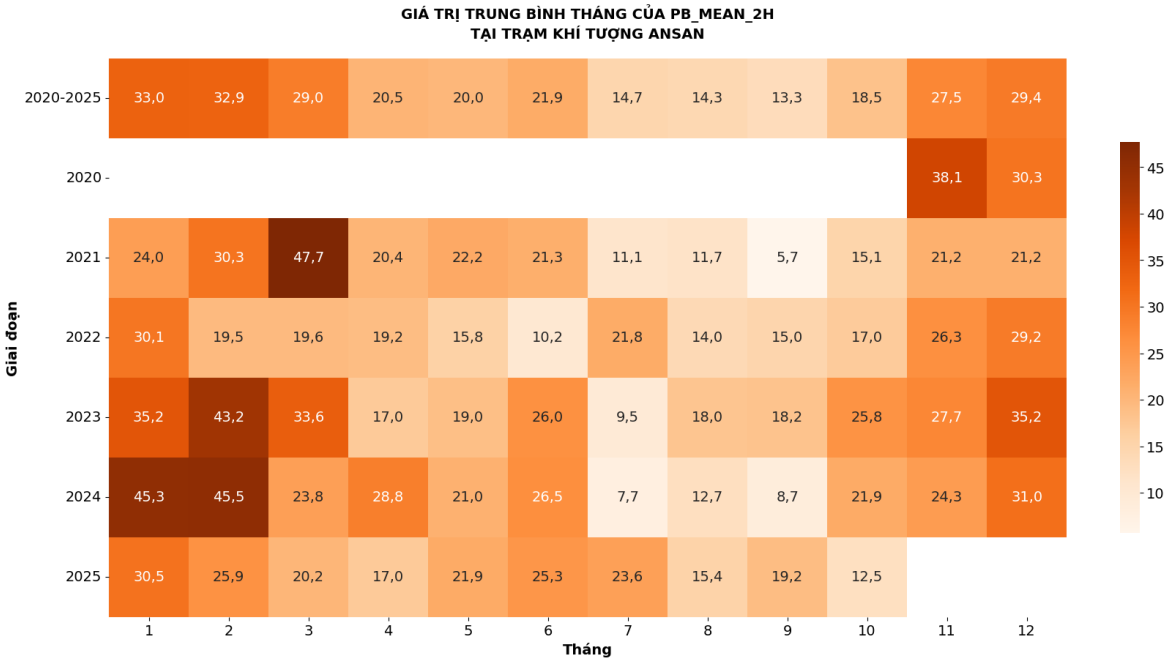
Biểu đồ 3. 17. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Incheon (2020 – 2025)

Biểu đồ 3. 16 và Biểu đồ 3. 17 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Incheon trong giai đoạn 2020 – 2025 có sự biến động theo mùa tương đối rõ, tuy nhiên đặc điểm phân bố của hai kim loại không hoàn toàn giống nhau. Nhìn chung, Pb tại Incheon có xu hướng biến động thất thường và xuất hiện các đỉnh ô nhiễm bất thường vào đầu mùa thu trong khi Zn thể hiện quy luật mùa đông – xuân rõ ràng hơn và có xu hướng giảm dần theo thời gian.

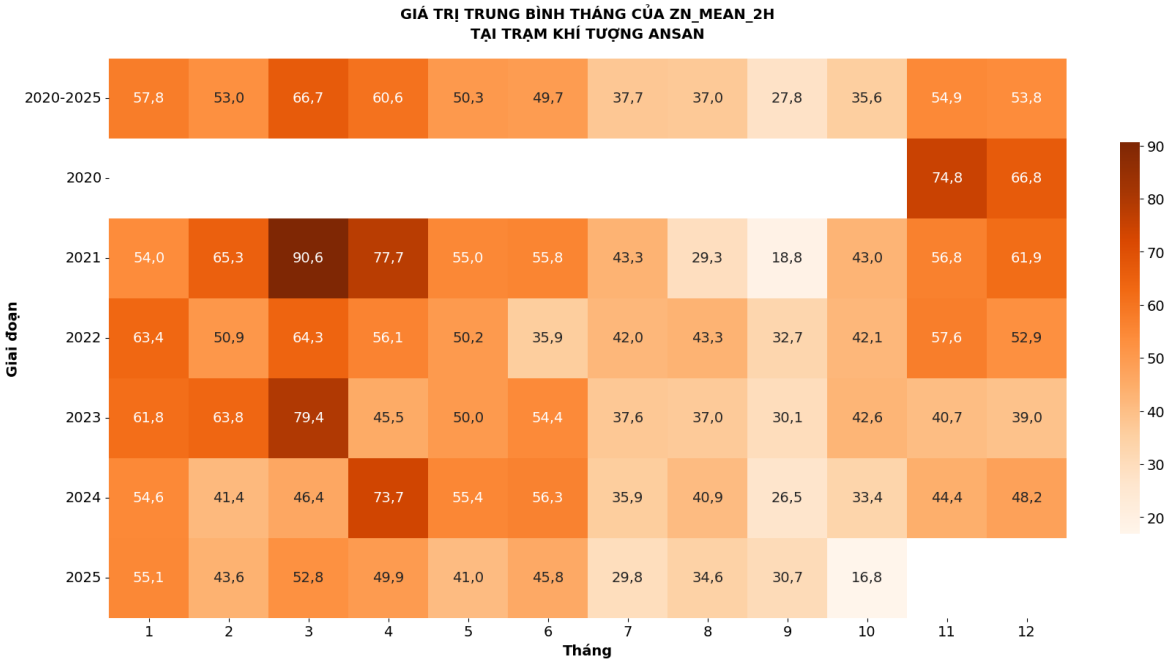
Đối với Pb, các giá trị cao thường xuất hiện vào tháng 1 và đặc biệt là tháng 9, khác với mô hình mùa vụ điển hình quan sát tại nhiều trạm khác. Trong khi các tháng 6 và 7 ghi nhận mức thấp nhất, nồng độ Pb lại tăng mạnh vào cuối mùa hè và đầu mùa thu. Đáng chú ý, tháng 9/2023 đạt khoảng 35,8 ng/m^3 và các tháng 9 – 10/2025 tiếp tục ghi nhận mức cao lần lượt khoảng 28,1 và 33,6 ng/m^3.

Trong khi đó, Zn có tính mùa vụ ổn định hơn, với các giá trị cao chủ yếu xuất hiện vào tháng 1, tháng 3 và tháng 12, còn mức thấp nhất tập trung vào tháng 6 và tháng 7. So với Pb, Zn có biên độ dao động nhỏ hơn và cho thấy xu hướng giảm dần qua các năm, đặc biệt trong các tháng mùa hè từ sau năm 2022.

3.3.2.3. Trạm khí tượng Ansan



Biểu đồ 3. 18. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Ansan (1990 – 2025)



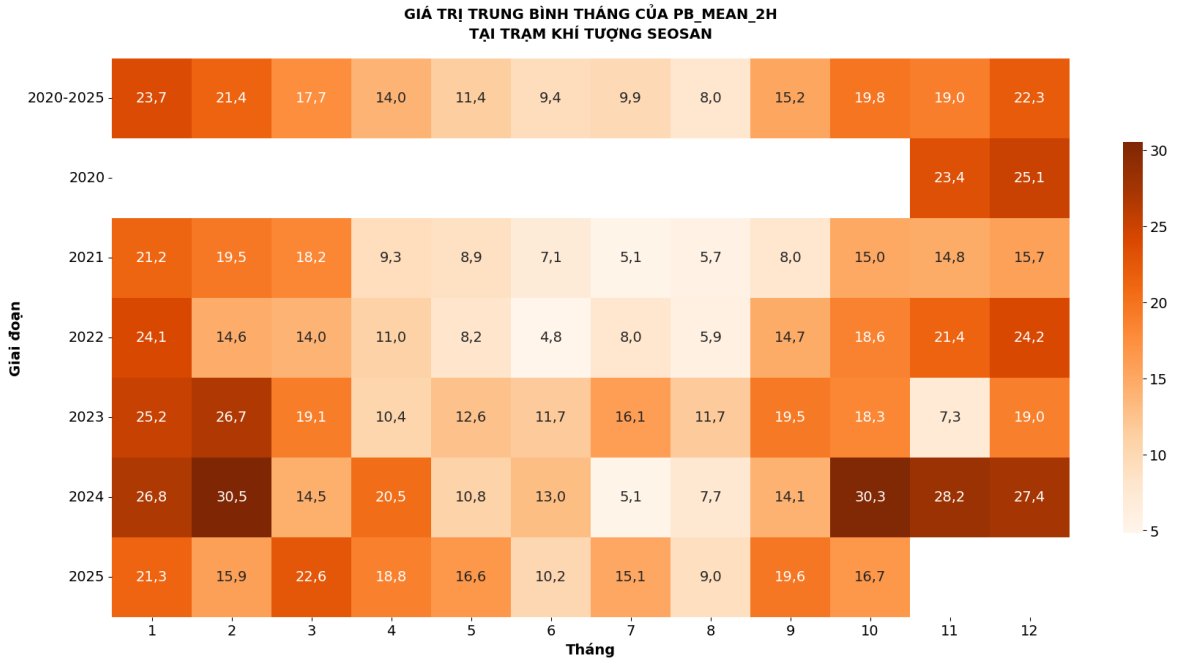
Biểu đồ 3. 19. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Ansan (2020 – 2025)

Biểu đồ 3. 18 và Biểu đồ 3. 19 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Ansan trong giai đoạn 2020 – 2025 có xu hướng biến động mạnh nhất trong toàn bộ mạng lưới quan trắc. Nhìn chung, cả hai kim loại đều đạt giá trị cao vào mùa đông – đầu xuân và giảm rõ rệt vào mùa hè, cho thấy tính mùa vụ rất rõ ràng. Biên độ dao động lớn giữa các tháng cũng cho thấy dữ liệu tại Ansan vừa tạo ra thách thức cho các mô hình dự báo, vừa cung cấp nguồn dữ liệu huấn luyện phong phú nhờ dải giá trị rộng.

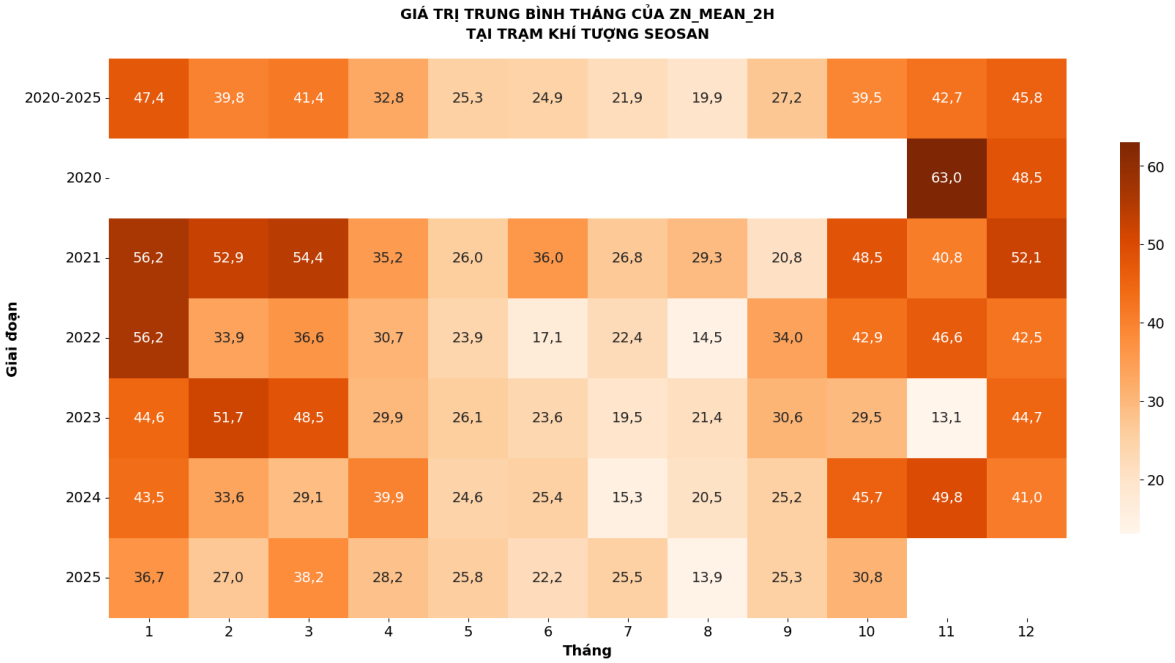
Đối với Pb, nồng độ cao nhất tập trung chủ yếu từ tháng 1 đến tháng 3, trong khi giai đoạn tháng 7 đến tháng 9 ghi nhận mức thấp nhất. Đáng chú ý, các năm gần đây xuất hiện nhiều giá trị đầu năm tương đối cao, tiêu biểu là tháng 1 năm 2023 và tháng 2 năm 2024, phản ánh xu hướng gia tăng ô nhiễm vào đầu mùa xuân.

Tương tự, Zn cũng thể hiện xu hướng đạt đỉnh vào mùa đông – xuân, với tháng 3 là thời điểm có giá trị cao nhất trong toàn bộ chuỗi dữ liệu của trạm. Ngoài ra, các tháng 1, 2 và 11 cũng ghi nhận nồng độ Zn tương đối cao. Nhìn chung, Ansan là trạm có tính mùa vụ nổi bật nhất, với các đỉnh ô nhiễm lặp lại tương đối ổn định theo chu kỳ năm.

3.3.2.4. Trạm khí tượng Seosan



Biểu đồ 3. 20. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Seosan (2020 – 2025)



Biểu đồ 3. 21. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Seosan (2020 – 2025)

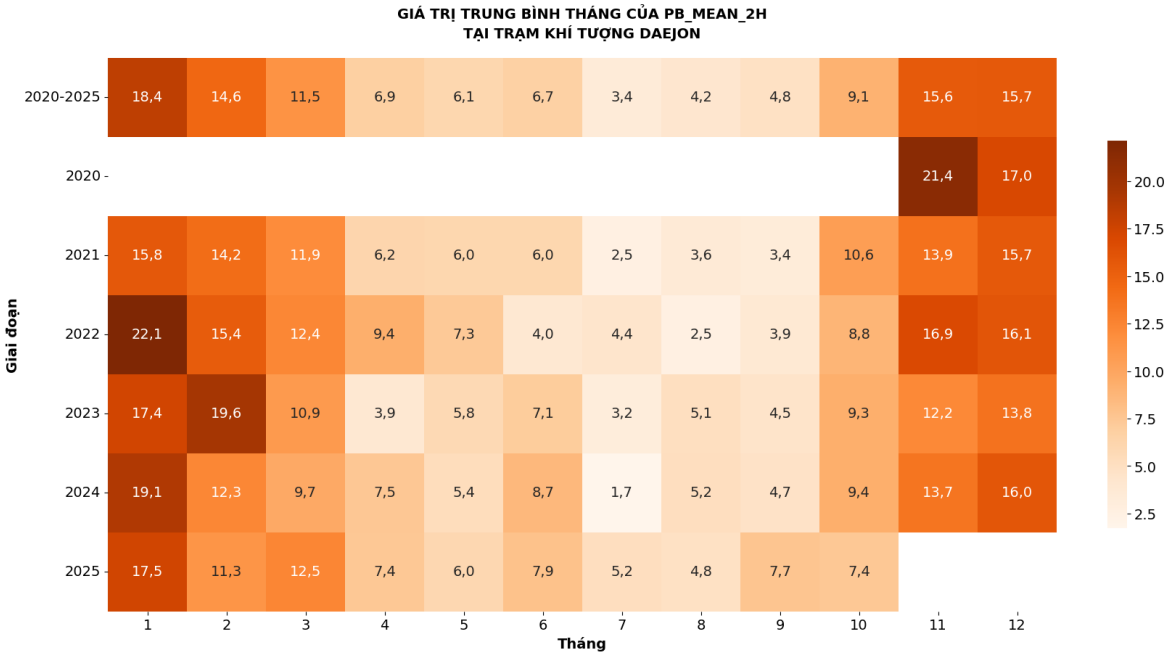
Biểu đồ 3. 20 và Biểu đồ 3. 21 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Seosan trong giai đoạn 2020 – 2025 thể hiện đặc trưng biến động theo tháng khá rõ rệt đối với cả Pb và Zn. Nhìn chung, nồng độ của cả hai kim loại đều có xu hướng đạt mức cao vào mùa đông – đầu xuân và giảm mạnh trong mùa hè. Tuy nhiên, dữ liệu giữa các năm vẫn tồn tại sự chênh lệch đáng kể, cho thấy mức độ biến động liên năm tương đối lớn tại khu vực duyên hải này.

Đối với Pb, giá trị trung bình tháng cao nhất thường xuất hiện vào tháng 1, tháng 2 và tháng 12, trong khi giai đoạn tháng 6 đến tháng 8 ghi nhận mức thấp nhất. Trung bình toàn giai đoạn 2020 – 2025 cho thấy Pb dao động từ khoảng 8,0 – 9,9 ng/m^3 trong mùa hè lên đến hơn 22 ng/m^3 vào mùa đông. Bên cạnh xu hướng mùa vụ rõ ràng, Seosan còn xuất hiện nhiều giá trị ngoại lệ đáng chú ý. Cụ thể, năm 2024 ghi nhận mức Pb tăng đột biến vào tháng 10 với giá trị 30,3 ng/m^3, cao hơn đáng kể

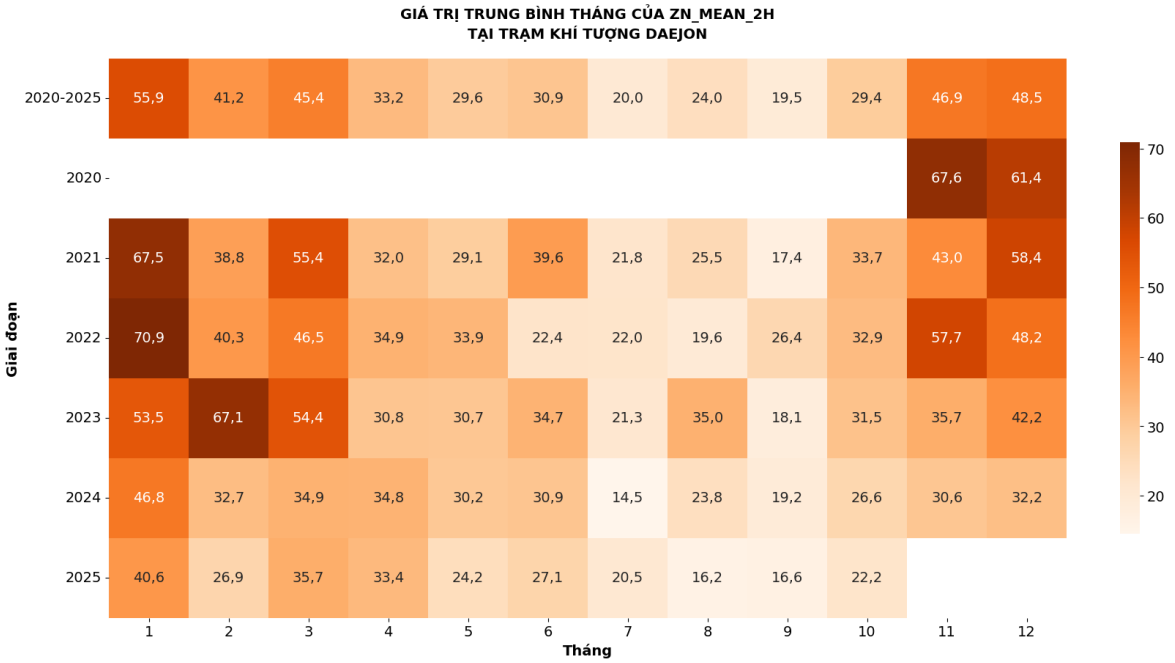
so với trung bình nhiều năm của cùng tháng. Ngoài ra, tháng 3 năm 2025 cũng cho thấy nồng độ Pb tăng mạnh bất thường so với các năm còn lại.

Tương tự Pb, Zn tại Seosan cũng đạt đỉnh trong giai đoạn đông – xuân và giảm xuống mức thấp nhất vào mùa hè. Giá trị Zn trung bình toàn giai đoạn đạt khoảng 47,4 ng/m^3 vào tháng 1 và giảm xuống còn khoảng 19,9 – 21,9 ng/m^3 trong tháng 7 và tháng 8. Tuy nhiên, dữ liệu Zn cho thấy sự thay đổi rõ rệt giữa các năm. Năm 2021 ghi nhận nồng độ Zn rất cao trong các tháng đầu năm, đặc biệt tháng 1 và tháng 2 vượt trên 50 ng/m^3, trong khi các năm 2024 – 2025 có xu hướng giảm đáng kể. Mặc dù vậy, các đỉnh mùa đông vẫn duy trì tương đối ổn định qua các năm.

3.3.2.5. Trạm khí tượng Daejon



Biểu đồ 3. 22. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Daejon (2020 – 2025)



Biểu đồ 3. 23. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Daejon (2020 – 2025)

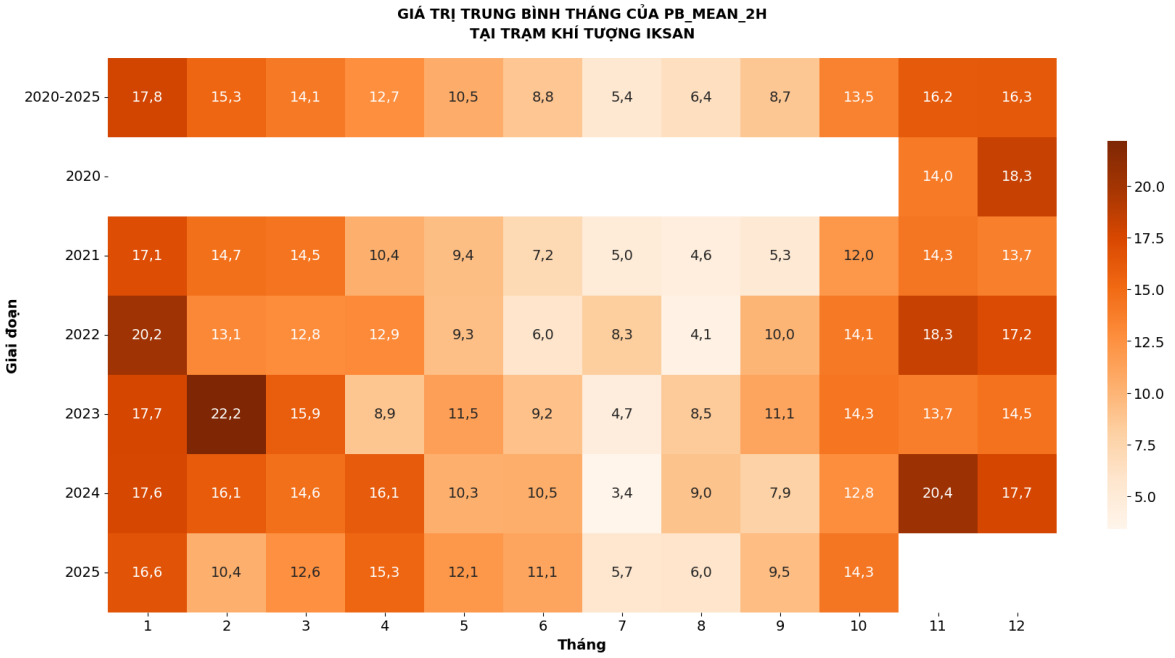
Biểu đồ 3. 22 và Biểu đồ 3. 23 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Seoul trong giai đoạn 2020 – 2025 có xu hướng biến động theo tháng ổn định và rõ rệt nhất trong toàn bộ mạng lưới quan trắc đối với cả Pb và Zn. Nhìn chung, nồng độ hai kim loại đều đạt mức cao vào mùa đông – đầu xuân và giảm mạnh trong mùa hè. So với các trạm khác, dữ liệu tại Daejeon có mức độ nhất quán liên năm cao hơn với các đỉnh và đáy mùa vụ lặp lại tương đối đồng đều qua từng năm, điều này cho thấy đây là khu vực có tín hiệu mùa vụ rõ ràng và dễ nhận diện.

Đối với Pb, giá trị trung bình tháng cao nhất xuất hiện vào tháng 1 và giảm xuống mức thấp nhất vào khoảng tháng 7. Trung bình giai đoạn 2020 – 2025 cho thấy Pb đạt khoảng 18,4 ng/m^3 vào tháng 1 nhưng chỉ còn khoảng 3,4 ng/m^3 vào tháng 7 tương ứng mức chênh lệch hơn 5 lần giữa mùa đông và mùa hè. Các tháng cuối năm và đầu năm như tháng 11, tháng 12, tháng 1 và tháng 2 luôn duy trì nồng độ cao, hình thành đỉnh mùa đông rõ rệt, trong khi giai đoạn mùa hè hầu như luôn thấp dưới 7 ng/m^3 ở tất cả các năm quan sát. Ngoài ra, dữ liệu từng năm cho thấy cấu trúc mùa

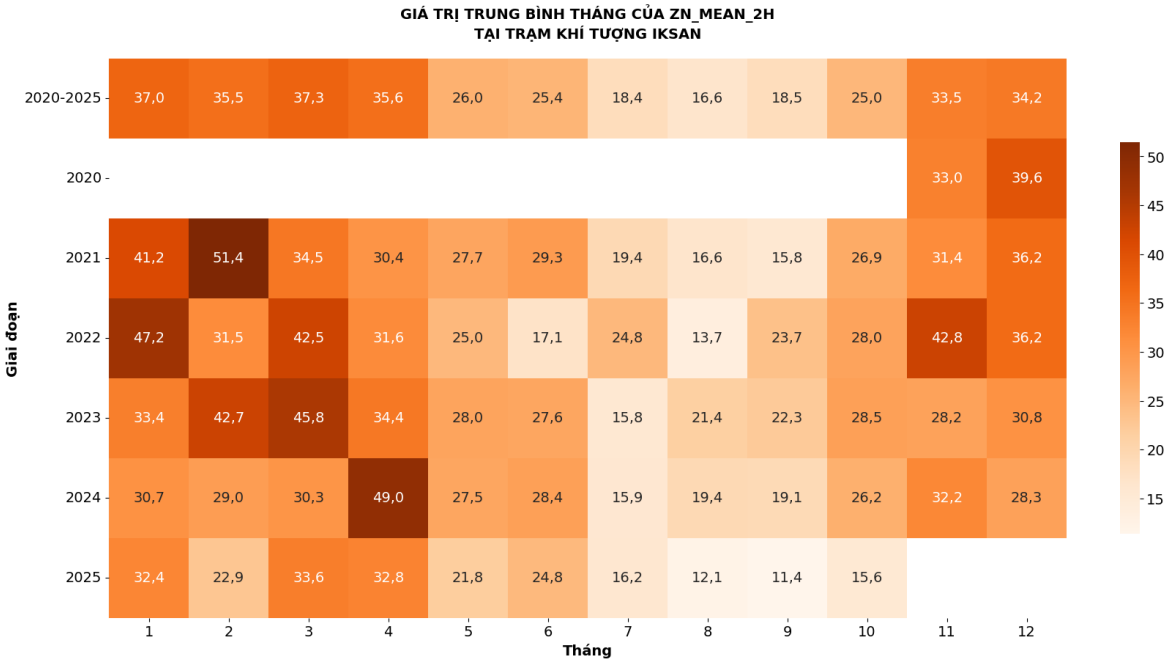
vụ của Pb tại Daejeon gần như không thay đổi, mặc dù biên độ có xu hướng giảm nhẹ theo thời gian do nồng độ Pb giảm dần qua các năm.

Tương tự Pb, Zn tại Daejeon cũng thể hiện mô hình mùa vụ rất rõ ràng với các giá trị cao tập trung vào tháng 11, tháng 12 và tháng 1, trong khi tháng 7 và tháng 9 thường ghi nhận mức thấp nhất. Trung bình toàn giai đoạn cho thấy Zn đạt khoảng 55,9 ng/m^3 vào tháng 1 nhưng giảm xuống khoảng 19,5 – 20,0 ng/m^3 trong mùa hè. Tuy nhiên, dữ liệu vẫn xuất hiện một số giá trị ngoại lệ đáng chú ý. Cụ thể, năm 2023 ghi nhận nồng độ Zn tăng mạnh vào tháng 2 và tháng 3 với giá trị lần lượt đạt 67,1 ng/m^3 và 54,4 ng/m^3, cao hơn đáng kể so với các năm còn lại. Những biến động này cho thấy mặc dù Daejeon có tính mùa vụ ổn định, mô hình dự báo vẫn cần đủ khả năng xử lý các sự kiện bất thường phát sinh ngoài xu hướng chung.

3.3.2.6. Trạm khí tượng Iksan



Biểu đồ 3. 24. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Iksan (2020 – 2025)



Biểu đồ 3. 25. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Iksan (2020 – 2025)

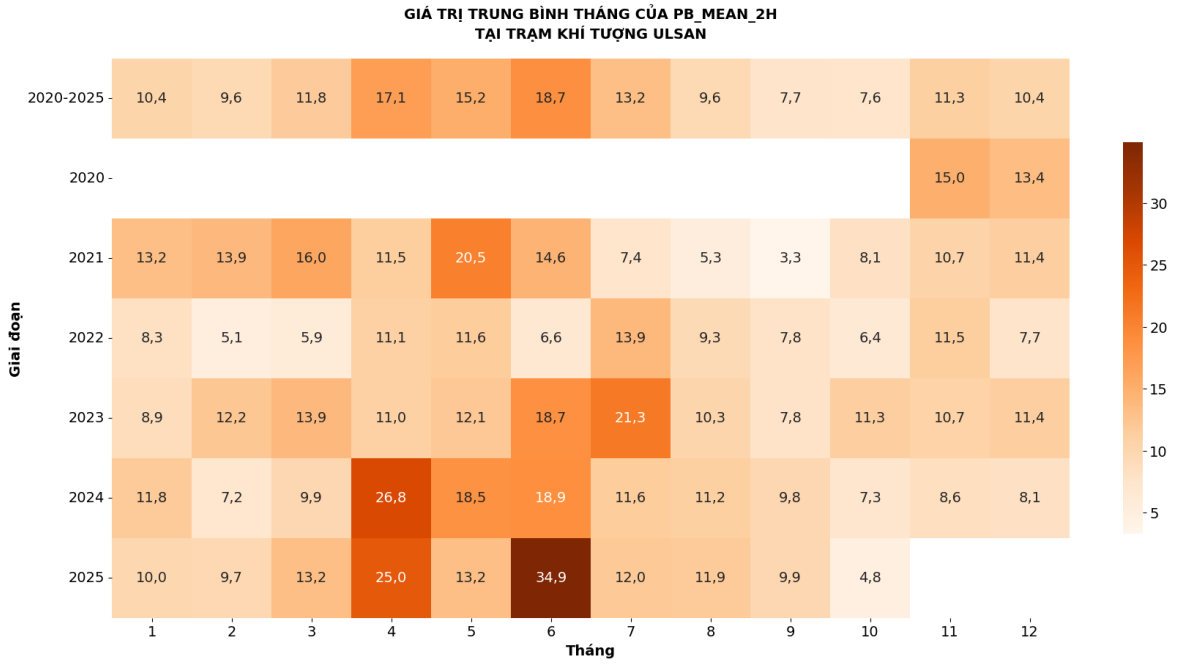
Biểu đồ 3. 24 và Biểu đồ 3. 25 cho thấy nồng độ trung bình tháng của Pb và Zn tại Iksan trong giai đoạn 2020 – 2025 có tính mùa vụ khá rõ rệt. Nhìn chung, cả hai kim loại đều đạt giá trị cao vào mùa đông – đầu xuân và giảm mạnh trong mùa hè. Tuy nhiên, biên độ dao động của Zn lớn hơn đáng kể so với Pb, điều này cho thấy Zn nhạy cảm hơn với các điều kiện khí tượng và vận chuyển ô nhiễm khu vực. Trong toàn bộ chu kỳ năm, tháng 7 thường là thời điểm ghi nhận nồng độ thấp nhất đối với cả hai chất ô nhiễm.

Đối với Pb, nồng độ trung bình dao động tương đối ổn định qua các năm, với các đỉnh xuất hiện chủ yếu vào tháng 1, tháng 2, tháng 11 và tháng 12. Giá trị trung bình giai đoạn 2020 – 2025 đạt khoảng 17,8 ng/m^3 vào tháng 1 trước khi giảm dần xuống mức thấp nhất 5,4 ng/m^3 vào tháng 7, sau đó tăng trở lại vào cuối năm. Một điểm đáng chú ý là tháng 2 năm 2023 ghi nhận mức Pb lên tới 22,2 ng/m^3, cao hơn rõ rệt so với các năm khác cùng kỳ, điều này cho thấy khả năng xuất hiện một đợt ô nhiễm cục bộ hoặc điều kiện khí tượng bất thường. Dù vậy, mô hình phân bố tháng

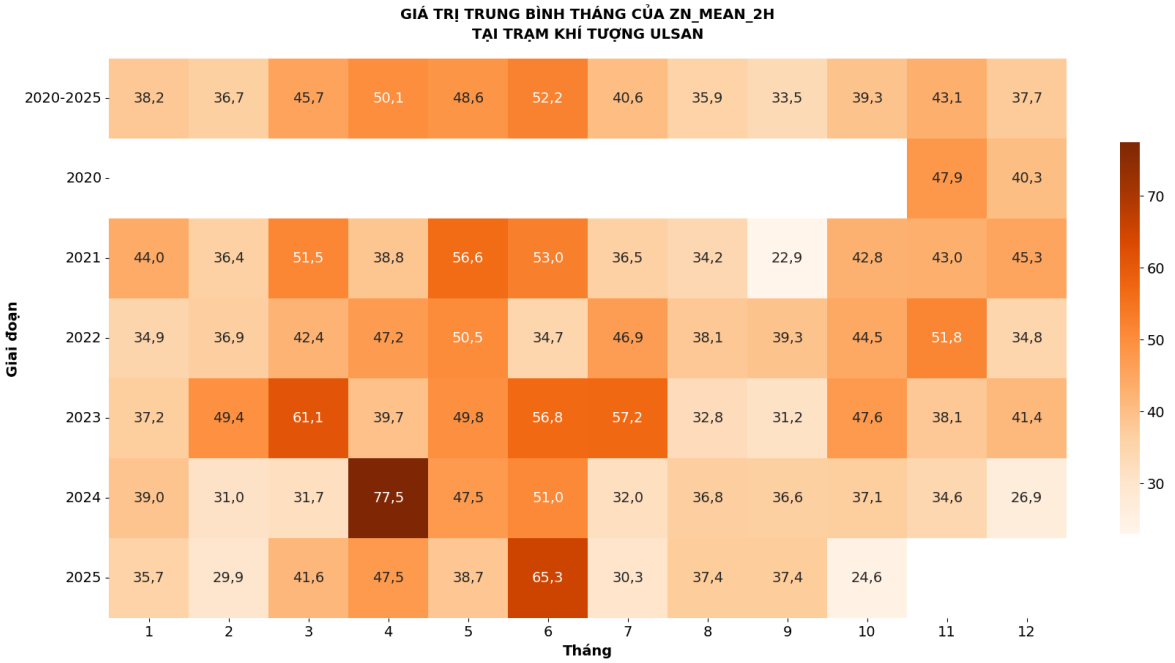
của Pb nhìn chung vẫn khá nhất quán, phản ánh tính ổn định mùa vụ cao tại trạm Iksan.

Trong khi đó, Zn thể hiện biến động mạnh và phạm vi mùa cao điểm rộng hơn. Ngoài các tháng cuối năm như tháng 11 và tháng 12 với giá trị trung bình lần lượt khoảng 33,5 – 34,2 ng/m^3, Zn còn duy trì nồng độ rất cao trong suốt mùa xuân, đặc biệt từ tháng 1 đến tháng 4. Giá trị trung bình toàn giai đoạn đạt 37,0 ng/m^3 vào tháng 1 và vẫn duy trì quanh mức 35 – 37 ng/m^3 đến tháng 4 trước khi giảm mạnh vào mùa hè, chạm mức thấp nhất 16,6 ng/m^3 vào tháng 8. Đặc điểm này cho thấy Zn tại Iksan chịu ảnh hưởng đồng thời từ nguồn phát thải địa phương và các quá trình vận chuyển bụi khu vực, làm cho mùa ô nhiễm kéo dài hơn so với Pb. Nhìn chung, dữ liệu tại Iksan phản ánh một chu kỳ mùa vụ ổn định nhưng có sự khác biệt đáng kể giữa Pb và Zn về độ rộng và cường độ của giai đoạn nồng độ cao.

3.3.2.7. Trạm khí tượng Ulsan



Biểu đồ 3. 26. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Ulsan (2020 - 2025)



Biểu đồ 3. 27. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Ulsan (2020 - 2025)

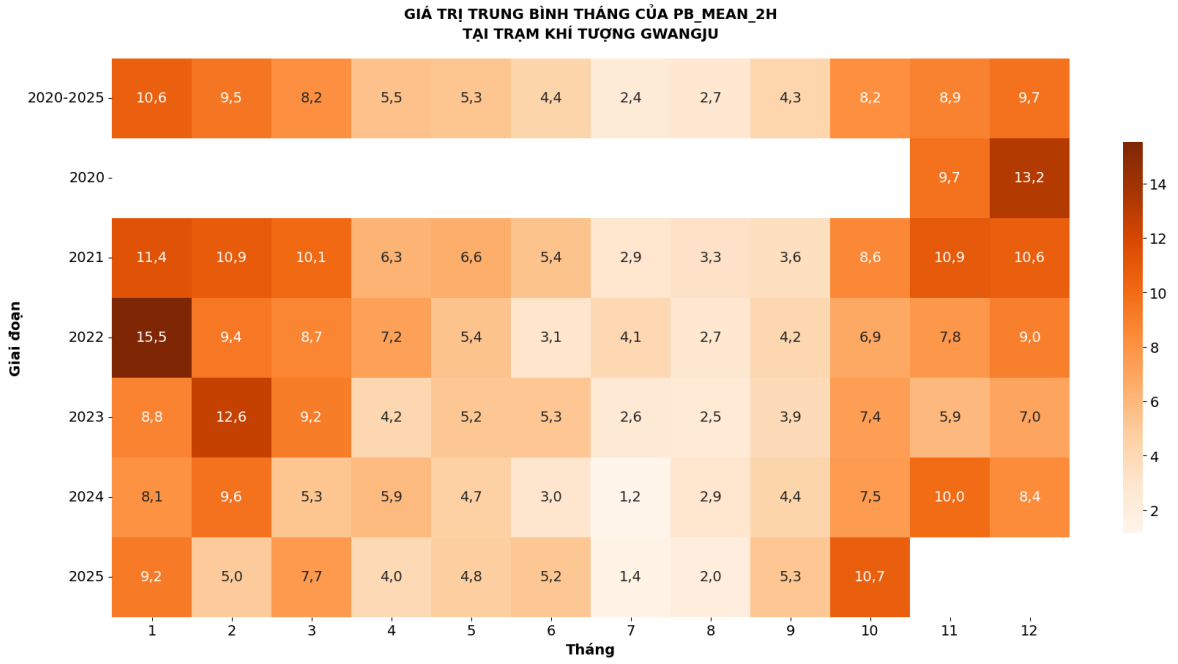
Biểu đồ 3. 26 và Biểu đồ 3. 27 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Ulsan trong giai đoạn 2020 – 2025 có đặc điểm mùa vụ khá điển hình khi cả Pb và Zn đều đạt nồng độ cao vào mùa đông và giảm xuống mức thấp vào mùa hè. So với nhiều trạm đô thị miền Nam khác, mức độ dao động tại Gwangju tương đối nhỏ và nồng độ nhìn chung ổn định hơn. Điều này tạo nên một bộ dữ liệu ít nhiễu, đồng thời phản ánh điều kiện chất lượng không khí tương đối đồng nhất trong toàn giai đoạn nghiên cứu. Bên cạnh đó, cả hai kim loại đều cho thấy xu hướng giảm dần theo thời gian, đặc biệt rõ rệt sau năm 2022.

Đối với Pb, các giá trị cao thường xuất hiện vào tháng 1, tháng 2, tháng 11 và tháng 12, trong khi mức thấp nhất tập trung vào giai đoạn tháng 7 – 8. Giá trị trung bình giai đoạn 2020 – 2025 dao động từ khoảng 2,4 – 2,7 ng/m^3 trong mùa hè lên khoảng 9,5 – 10,6 ng/m^3 vào mùa đông, tương đương mức chênh lệch khoảng bốn lần giữa hai mùa. Mặc dù quy luật mùa vụ khá rõ ràng, biên độ dao động này vẫn thấp hơn nhiều trạm khác, cho thấy môi trường không khí tại Gwangju ổn định hơn theo thời gian. Ngoài ra, xu hướng suy giảm theo năm cũng được thể hiện khá nhất

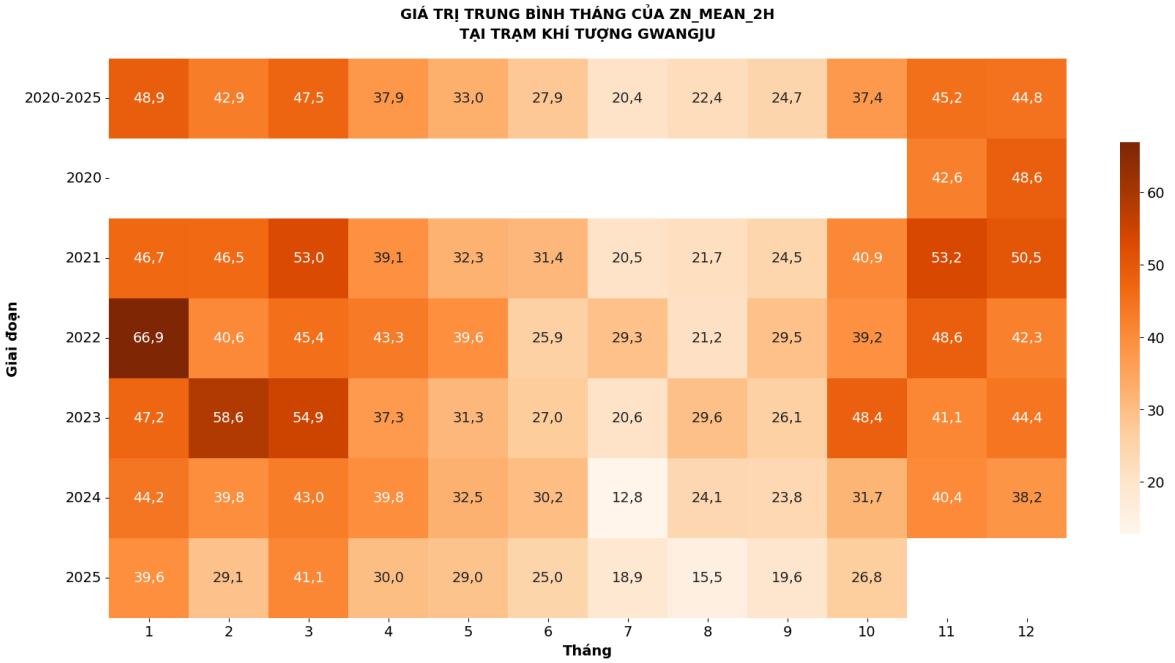
quán, tiêu biểu là giá trị Pb tháng 1 giảm mạnh từ 15,5 ng/m^3 năm 2022 xuống còn 8,8 ng/m^3 vào năm 2023 và tiếp tục duy trì ở mức thấp trong các năm tiếp theo.

Đối với Zn, quy luật biến động nhìn chung tương đồng với Pb khi nồng độ tăng cao trong mùa đông – xuân và giảm vào mùa hè. Các tháng 1, 3, 11 và 12 thường ghi nhận giá trị cao nhất, trong khi tháng 7 – 8 là giai đoạn có nồng độ thấp nhất trong năm. Giá trị trung bình toàn giai đoạn dao động khoảng 20 – 22 ng/m^3 vào mùa hè và tăng lên gần 45 – 49 ng/m^3 trong mùa đông. Đáng chú ý, tháng 3 thường có nồng độ Zn cao hơn rõ rệt so với tháng 2, điều này cho thấy khả năng chịu tác động của hiện tượng bụi châu Á tương tự một số trạm khác. Tuy nhiên, biến động Zn giữa các năm vẫn tương đối ổn định và hiếm xuất hiện giá trị ngoại lệ lớn.

3.3.2.8. Trạm khí tượng Gwangju



Biểu đồ 3. 28: Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Gwangju (2020 - 2025)



Biểu đồ 3. 29. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Gwangju (2020 - 2025)

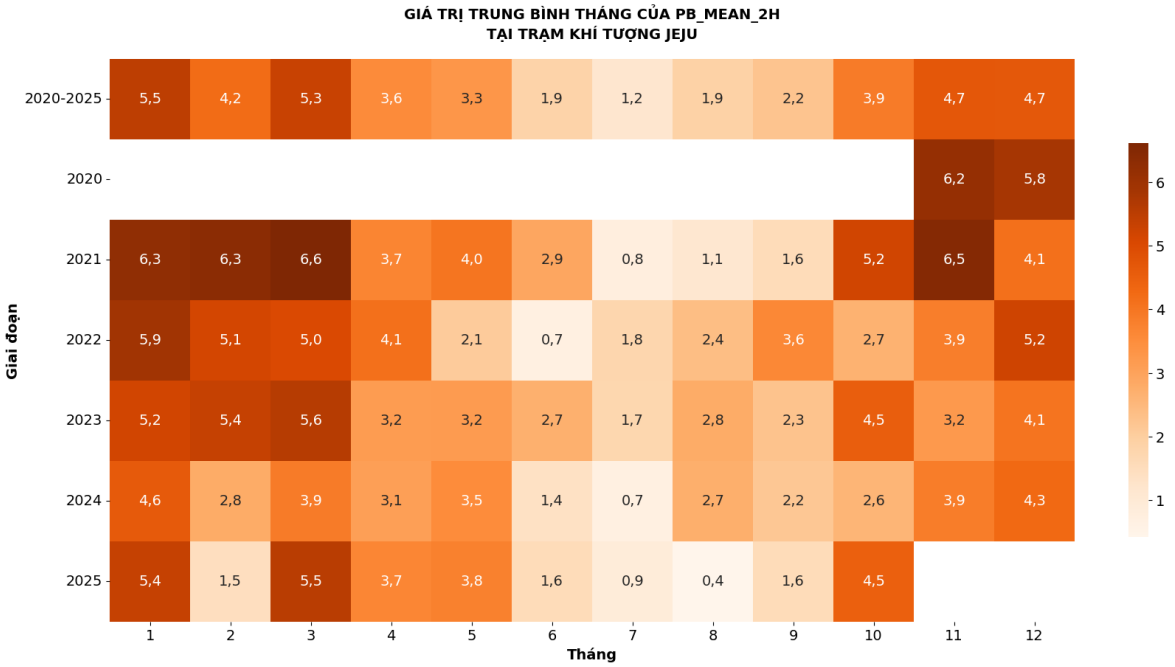
Biểu đồ 3. 28 và Biểu đồ 3. 29 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Gwangju trong giai đoạn 2020 – 2025 cho thấy cả Pb và Zn đều có tính mùa vụ rõ rệt với nồng độ cao vào mùa đông và thấp vào mùa hè. So với các trạm đô thị miền Nam khác, Gwangju có biên độ dao động thấp hơn và mức nồng độ nhìn chung khá ổn định, qua đó tạo nên bộ dữ liệu ít nhiễu và phù hợp cho quá trình huấn luyện cũng như đánh giá mô hình học sâu. Đồng thời, cả hai kim loại đều thể hiện xu hướng giảm dần theo thời gian, đặc biệt rõ sau năm 2022.

Đối với Pb, các giá trị cao tập trung chủ yếu vào tháng 1, tháng 2, tháng 11 và tháng 12, trong khi mức thấp nhất xuất hiện vào tháng 7 – 8. Giá trị trung bình giai đoạn 2020 – 2025 dao động từ khoảng 2,4 – 2,7 ng/m^3 vào mùa hè lên khoảng 9,5 – 10,6 ng/m^3 vào mùa đông, điều này tương đương biên độ chênh lệch khoảng 4 lần. Mặc dù sự khác biệt mùa vụ tương đối rõ, mức dao động này vẫn thấp hơn nhiều trạm khác, phản ánh điều kiện chất lượng không khí tương đối ổn định tại Gwangju. Ngoài ra, xu hướng giảm theo năm xuất hiện khá nhất quán. Chẳng hạn, giá trị Pb

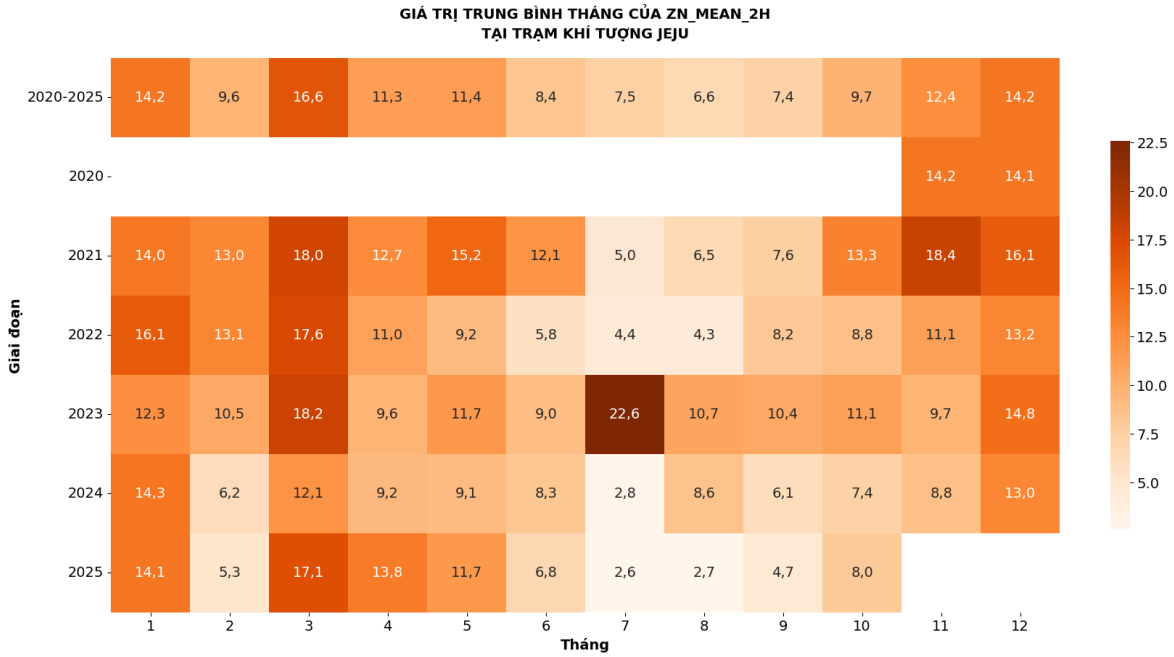
tháng 1 giảm mạnh từ 15,5 ng/m^3 năm 2022 xuống 8,8 ng/m^3 năm 2023, sau đó tiếp tục duy trì ở mức thấp hơn trong các năm kế tiếp.

Tương tự, Zn cũng đạt đỉnh vào mùa đông – xuân, đặc biệt ở tháng 1, tháng 3, tháng 11 và tháng 12, trong khi tháng 7 – 8 ghi nhận mức thấp nhất. Giá trị trung bình toàn giai đoạn dao động từ khoảng 20 – 22 ng/m^3 vào mùa hè lên gần 45 – 49 ng/m^3 vào mùa đông. Một đặc điểm đáng chú ý là tháng 3 thường có nồng độ Zn cao hơn rõ rệt so với tháng 2, điều này cho thấy khả năng chịu ảnh hưởng của hiện tượng bụi châu Á tương tự các trạm như Iksan và Ansan. Tuy nhiên, biến động Zn qua các năm vẫn tương đối ổn định và ít xuất hiện giá trị ngoại lệ lớn.

3.3.2.9. Trạm khí tượng Jeju



Biểu đồ 3. 30. Giá trị trung bình tháng của pb_mean_2h tại trạm khí tượng Jeju (2020 - 2025)



Biểu đồ 3. 31. Giá trị trung bình tháng của zn_mean_2h tại trạm khí tượng Jeju (2020 - 2025)

Biểu đồ 3. 30 và Biểu đồ 3. 31 cho thấy nồng độ trung bình tháng của Pb và Zn tại trạm Seoul trong giai đoạn 2020 – 2025 có mức biến thiên theo tháng thấp nhất trong số các trạm quan trắc, phản ánh môi trường không khí tương đối ổn định và ít chịu ảnh hưởng trực tiếp từ các nguồn phát thải công nghiệp nội địa. Nhìn chung, cả hai kim loại đều thể hiện tính mùa vụ nhẹ, với nồng độ cao hơn vào mùa đông – đầu xuân và giảm xuống vào mùa hè. Biên độ dao động của Pb khá nhỏ, trong khi Zn có biến động lớn hơn nhưng vẫn duy trì xu hướng theo mùa tương đối rõ rệt.

Đối với Pb, nồng độ trung bình cao nhất tập trung vào các tháng 1 – 3, đạt khoảng 4,2 – 5,5 ng/m^3 trong trung bình toàn giai đoạn 2020 – 2025 trước khi giảm xuống mức thấp nhất vào tháng 7 và tháng 8 (khoảng 1,2 – 1,9 ng/m^3). Tỷ lệ giữa tháng cao nhất và thấp nhất vào khoảng 4,7 lần, tương đối thấp so với nhiều trạm lục địa, cho thấy mức dao động mùa vụ hạn chế. Ngoài ra, phân bố tháng của Pb nhìn chung ổn định qua các năm và chỉ xuất hiện một vài giá trị cao bất thường, đáng chú ý là tháng 3/2021 (6,6 ng/m^3) và tháng 3/2025 (5,5 ng/m^3).

Trong khi đó, Zn cũng ghi nhận nồng độ cao vào mùa đông và đầu xuân, đặc biệt ở các tháng 1, 3 và 12, với giá trị trung bình toàn giai đoạn dao động từ khoảng 14 – 17 ng/m^3. Ngược lại, tháng 7 và tháng 8 là giai đoạn thấp nhất, chỉ khoảng 6 – 8 ng/m^3. Tuy nhiên, dữ liệu Zn xuất hiện một ngoại lệ đáng chú ý vào tháng 7/2023 khi nồng độ tăng vọt lên 22,6 ng/m^3, gần gấp đôi mức trung bình tháng 7 của toàn giai đoạn. Đây được xem là giá trị bất thường cần được xử lý cẩn thận trước khi đưa vào huấn luyện mô hình. Nhìn chung, việc Zn thường đạt đỉnh vào tháng 3 tại Jeju, tương tự nhiều trạm khác trên lãnh thổ Hàn Quốc, cho thấy ảnh hưởng đồng bộ của bụi hoàng thổ mùa xuân.

3.4. Tóm tắt chương

Chương 3 đã cung cấp những phân tích toàn diện và có giá trị về đặc tính không gian – thời gian của dữ liệu nồng độ chất ô nhiễm tại các trạm khí tượng.

Kết quả phân tích không gian cho thấy tồn tại sự phụ thuộc không gian có ý nghĩa giữa các trạm, khẳng định sự cần thiết của việc đưa thông tin không gian vào mô hình học sâu. Các phân tích tương quan giữa các trạm cung cấp cơ sở định lượng cho việc xây dựng ma trận kề trong kiến trúc GCN và GAT. Về phân tích thời gian, xu hướng biến đổi theo giờ và theo tháng đã chỉ ra các chu kỳ dao động rõ ràng, phản ánh ảnh hưởng của các hoạt động nhân sinh cũng như điều kiện khí hậu theo mùa. Những quy luật này là cơ sở quan trọng để xác định độ dài chuỗi đầu vào phù hợp cho mô hình.

CHƯƠNG 4: PHƯƠNG PHÁP ĐỀ XUẤT

4.1. Giới thiệu

Trong chương này, tôi sẽ trình bày phương pháp đề xuất để giải quyết bài toán dự báo hàm lượng chất ô nhiễm trong bụi PM_{10}.

Đầu tiên, phần 4.2 mô tả hai quy trình tiền xử lý riêng biệt gồm các bước tiền xử lý phục vụ phân tích xu hướng và các bước tiền xử lý dữ liệu cho quá trình huấn luyện mô hình học sâu. Tiếp theo, phần 4.3 là phần trọng tâm của chương, trình bày chi tiết các kiến trúc mô hình được đề xuất sử dụng, bao gồm mô hình GCN cải tiến kết hợp LSTM/BiLSTM và MHA cùng mô hình GAT tinh chỉnh kết hợp LSTM/BiLSTM và MHA, kiến trúc mô hình cải tiến đề xuất và các mô hình thử nghiệm bổ sung. Cuối cùng phần 4.4 đưa ra một số kết luận về chương này.

4.2. Các bước tiền xử lý

4.2.1. Các bước tiền xử lý dữ liệu cho quá trình phân tích xu hướng

Do dữ liệu được thu thập từ nhiều trạm quan trắc khác nhau, quá trình ghi nhận có thể phát sinh tình trạng thiếu dữ liệu do lỗi kỹ thuật, gián đoạn truyền tải hoặc sự khác biệt về số lượng bản ghi giữa các khu vực. Điều này khiến mức độ đầy đủ và tính đồng nhất của dữ liệu giữa các trạm không hoàn toàn giống nhau. Vì vậy, tôi thực hiện quy trình tiền xử lý dữ liệu nhằm nâng cao độ tin cậy và đảm bảo tính nhất quán của dữ liệu trước khi tiến hành phân tích xu hướng như sau:

Bước 1: Thay thế các bản ghi có giá trị thiếu.

Bước 2: Xác định các mốc thời gian chung giữa các trạm quan trắc và thực hiện lọc dữ liệu.

4.2.1.1. Thay thế các bản ghi có giá trị thiếu

Giá trị thiếu trong tập dữ liệu có thể xuất hiện dưới nhiều dạng khác nhau như Null, NaN, -9999,… Đây đều là những giá trị biểu thị tình trạng không ghi nhận được

dữ liệu do các lỗi phát sinh trong quá trình quan trắc hoặc truyền tải. Khi một bản ghi xuất hiện các giá trị này, toàn bộ bản ghi tương ứng sẽ được xử lý thay thế nhằm đảm bảo tính liên tục và tính tuần tự của chuỗi dữ liệu tại trạm khí tượng tương ứng.

4.2.1.2. Xác định các mốc thời gian chung giữa các trạm quan trắc và thực hiện lọc dữ liệu

Sau khi hoàn tất quá trình xử lý và thay thế các giá trị thiếu hoặc bất thường, tôi tiến hành xác định các mốc thời gian của từng trạm khí tượng dựa trên các thành phần giờ, ngày, tháng và năm. Tiếp theo, phép giao giữa các tập mốc thời gian này được thực hiện nhằm tìm ra khoảng thời gian xuất hiện đồng thời tại tất cả các trạm.

Đối với mỗi tập dữ liệu, chỉ những bản ghi thuộc khoảng thời gian chung vừa xác định mới được giữ lại, trong khi các bản ghi nằm ngoài khoảng này sẽ bị loại bỏ. Cách xử lý này giúp đảm bảo tính đồng bộ về mặt thời gian giữa các trạm khí tượng, từ đó làm tăng tính nhất quán của dữ liệu đầu vào cho quá trình phân tích và huấn luyện mô hình dự báo.

Tuy nhiên, việc chỉ giữ lại các mốc thời gian giao nhau cũng có thể dẫn đến một số hạn chế như làm suy giảm đáng kể số lượng dữ liệu hoặc khiến chuỗi thời gian bị phân đoạn và mất tính liên tục. Những vấn đề này có thể ảnh hưởng trực tiếp đến khả năng phân tích xu hướng cũng như hiệu quả học của mô hình. Vì vậy, sau bước tiền xử lý này, tôi tiếp tục đánh giá mức độ liên tục của chuỗi thời gian và số lượng bản ghi còn lại để đảm bảo dữ liệu vẫn đáp ứng yêu cầu cho quá trình nghiên cứu.

4.2.2. Các bước tiền xử lý dữ liệu cho quá trình dự đoán bằng mô hình học sâu

Trong giai đoạn này, tôi tiếp tục sử dụng bộ dữ liệu đã được xử lý ở bước phân tích xu hướng trước đó. Dựa trên tập dữ liệu đã được làm sạch và đồng bộ, tôi tiến hành thực hiện thêm các bước tiền xử lý nhằm xây dựng dữ liệu đầu vào phù hợp cho các mô hình học sâu.

Cụ thể, đầu vào của mô hình là chuỗi dữ liệu quan sát lịch sử trong một khoảng thời gian cố định, trong đó mỗi bản ghi bao gồm các đặc trưng mô tả cùng các giá trị trễ theo thời gian. Đầu ra tương ứng là giá trị hàm lượng chất ô nhiễm cần dự báo tại các bước thời gian tiếp theo.

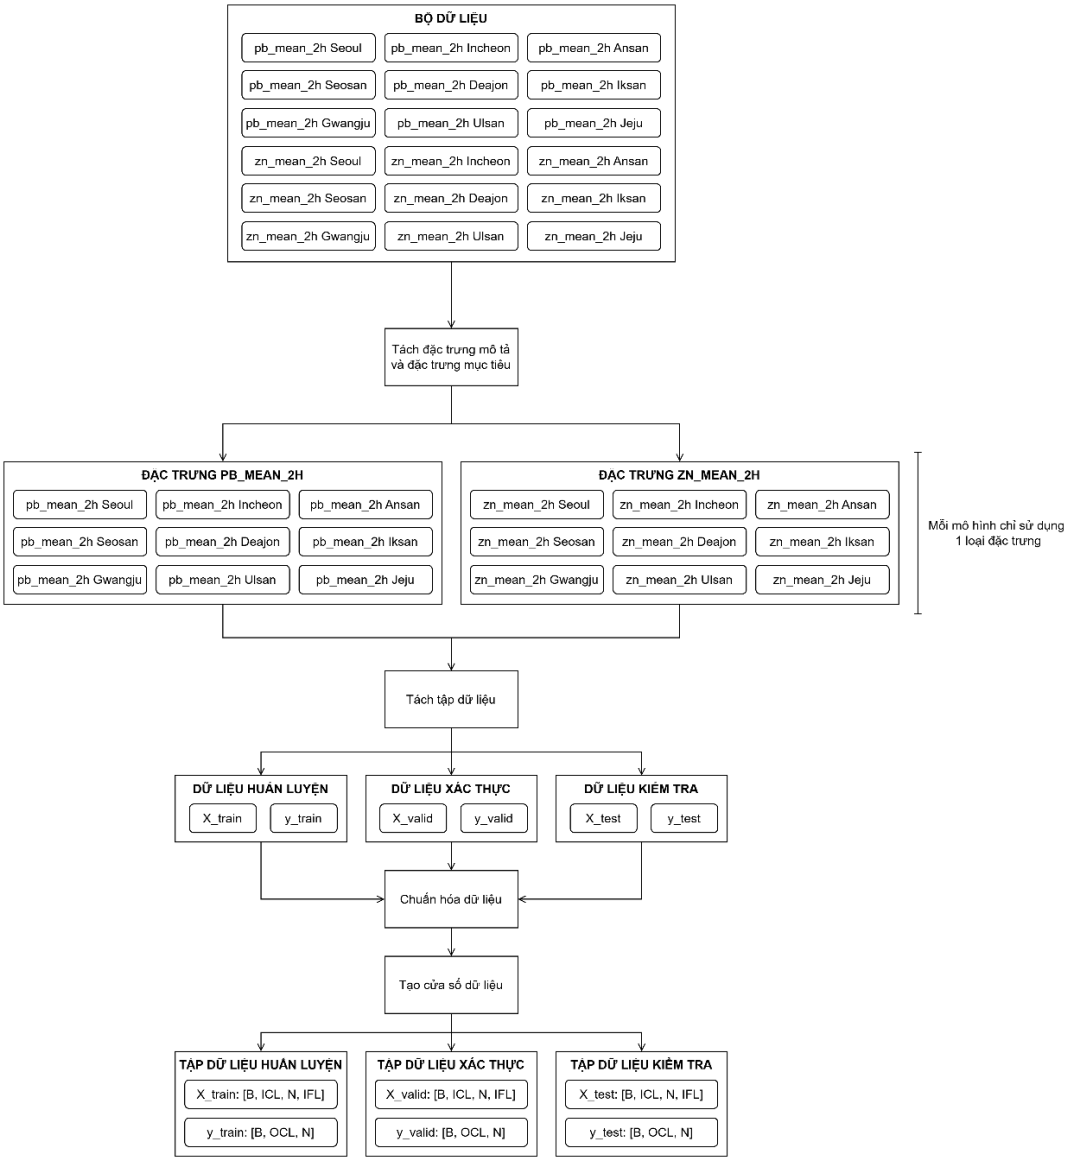
Các bước tiền xử lý trên thông qua các bước chính như sau:

Bước 1: Tách đặc trưng mô tả và đặc trưng mục tiêu.

Bước 2: Tách tập huấn luyện, xác thực và kiểm tra.

Bước 3: Chuẩn hóa dữ liệu.

Bước 4: Triển khai tạo cửa sổ dữ liệu.



Sơ đồ 4. 1. Tổng quan tiền xử lý đầu vào cho mô hình

4.2.2.1. Tách đặc trưng

Tôi thực hiện tách riêng biệt bộ dữ liệu thành 2 tập đặc trưng pb_mean_2h và đặc trưng zn_mean_2h. Sau đó, mỗi mô hình sẽ đảm nhiệm huấn luyện duy nhất 1 loại đặc trưng tại 9 trạm khí tượng.

Bên cạnh đó, cả 2 tập pb_mean_2h và zn_mean_2h đều được sắp xếp theo các mốc thời gian từ xa đến gần nhất để đảm bảo đặc tính thời gian của dữ liệu.

4.2.2.2. Tách tập huấn luyện, xác thực và kiểm tra

Trong khóa luận này, dữ liệu được phân chia thành ba tập huấn luyện, xác thực và kiểm tra theo tỷ lệ lần lượt là 63,15%, 20,39% và 16,46%. Trong đó, tập huấn luyện được sử dụng để xây dựng mô hình, tập xác thực phục vụ quá trình hiệu chỉnh tham số, còn tập kiểm tra được dùng để đánh giá khả năng dự báo của mô hình. Quá trình phân chia dữ liệu không thực hiện ngẫu nhiên mà tuân theo trình tự thời gian, từ các mốc dữ liệu cũ đến các mốc gần hiện tại, nhằm duy trì tính liên tục và đặc trưng phụ thuộc thời gian của chuỗi dữ liệu.

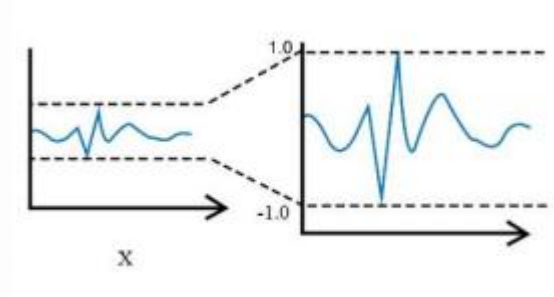
4.2.2.3. Chuẩn hóa dữ liệu

Sau khi hoàn tất quá trình tiền xử lý phục vụ cho phân tích xu hướng, dữ liệu của cả 9 trạm khí tượng đều được đồng bộ về số lượng bản ghi cũng như số lượng đặc trưng. Tiếp theo, tôi tiến hành xây dựng và huấn luyện các mô hình riêng biệt cho từng trạm khí tượng, trong đó các đặc trưng đầu vào được chuẩn hóa tương ứng với pb_mean_2h hoặc zn_mean_2h.

- Chuẩn hóa khoảng giá trị:

Tuy nhiên, do các đặc trưng trong tập dữ liệu có sự khác biệt về phạm vi giá trị, việc đưa trực tiếp vào mô hình có thể khiến những đặc trưng có giá trị lớn chi phối quá trình huấn luyện, từ đó làm giảm hiệu quả học của mô hình. Ngoài ra, quá trình chuẩn hóa còn giúp cân bằng tỷ lệ giữa các đặc trưng, cải thiện tốc độ hội tụ và nâng cao khả năng học của mô hình trong quá trình huấn luyện.

Trong đề tài này, tôi sử dụng phương pháp chuẩn hóa MinMaxScaler để đưa toàn bộ các đặc trưng về khoảng giá trị [-1; 1]. Khoảng chuẩn hóa này đủ rộng để vẫn giữ được đặc tính biến động của dữ liệu, đồng thời hỗ trợ mô hình phân biệt tốt hơn giữa các mẫu dữ liệu khác nhau, đặc biệt trong các trường hợp dữ liệu có mức biến động lớn. Công thức của phương pháp này được trình bày như sau:



Hình 4. 1. Minh họa quá trình chuẩn hóa dữ liệu trong khoảng [-1; 1]

$$X_{new} = \frac{X_{old} - X_{min}}{X_{max} - X_{min}} \quad (4.1)$$

Trong đó:

- X_{max} là giá trị lớn nhất của đặc trưng.
- X_{min} là giá trị nhỏ nhất của đặc trưng.

Trong quá trình chuẩn hóa dữ liệu, bộ chuẩn hóa chỉ được xây dựng và học tham số trên tập dữ liệu huấn luyện. Sau đó, cùng bộ chuẩn hóa này sẽ được áp dụng cho tập dữ liệu xác thực và tập dữ liệu kiểm tra nhằm đảm bảo không xảy ra hiện tượng rò rỉ dữ liệu trong quá trình huấn luyện và đánh giá mô hình.

4.2.2.2. Tách đặc trưng

Tôi tiến hành tách dữ liệu thành hai nhóm đặc trưng riêng biệt gồm pb_mean_2h và zn_mean_2h. Đối với mỗi nhóm đặc trưng, các mô hình sẽ được huấn luyện độc lập trên dữ liệu của 8 trạm khí tượng tương ứng.

Bên cạnh đó, cả 2 tập dữ liệu đều được sắp xếp theo các mốc thời gian từ xa đến gần nhất để đảm bảo đặc tính thời gian của dữ liệu.

4.2.2.3. Tách tập huấn luyện, xác thực và kiểm tra

Tôi áp dụng tách tập huấn luyện, xác thực và kiểm tra theo tỷ lệ 63,15 – 20,39 – 16,46%, trong đó 63,15% dữ liệu dùng để huấn luyện, 20,39% dữ liệu dùng để xác thực và 16,46% dữ liệu còn lại dùng để kiểm tra dữ liệu dự đoán. Khi tách không thực

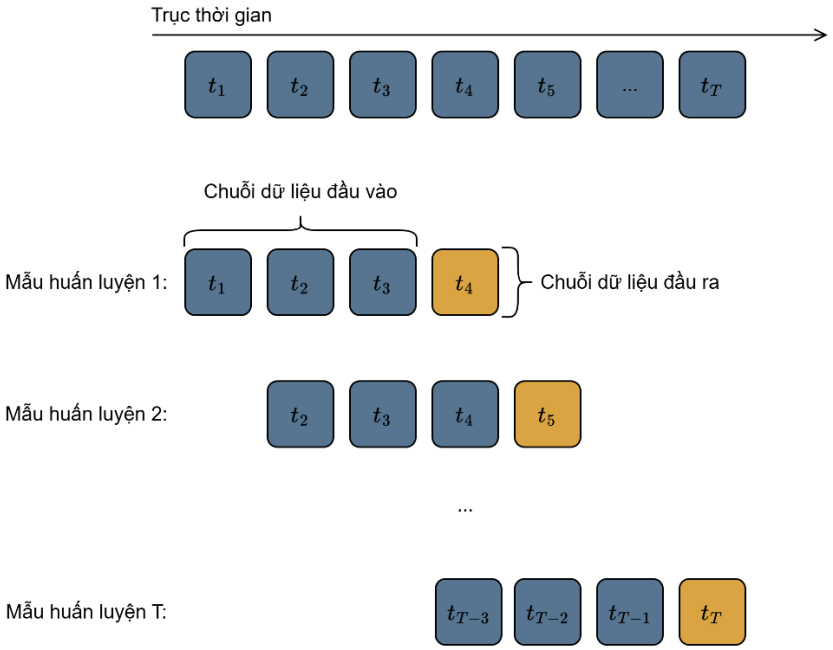
hiện tách ngẫu nhiên mà dữ liệu được chia theo trình tự thời gian, bắt đầu từ mốc thời gian xa nhất đến mốc thời gian gần nhất để đảm bảo tính tuần tự của dữ liệu.

4.2.2.4. Triển khai tạo cửa sổ dữ liệu

Để tạo lập dữ liệu đầu vào cho mô hình, tôi áp dụng phương pháp cửa sổ trượt (sliding window) nhằm nâng cao khả năng dự báo. Cách tiếp cận này cho phép mô hình không chỉ khai thác thông tin ở một thời điểm đơn lẻ mà còn xem xét đồng thời chuỗi giá trị của nhiều bước thời gian trước đó, từ đó học được xu hướng biến động cũng như các quy luật theo thời gian trong dữ liệu.

Giả sử tập dữ liệu gồm T bước thời gian và độ dài cửa sổ đầu vào được xác định là k, phương pháp cửa sổ trượt sẽ lần lượt dịch chuyển theo trục thời gian để tạo ra các mẫu huấn luyện. Với mỗi mẫu, mô hình sử dụng k giá trị liên tiếp làm đầu vào và dự đoán giá trị ở bước thời gian kế tiếp.

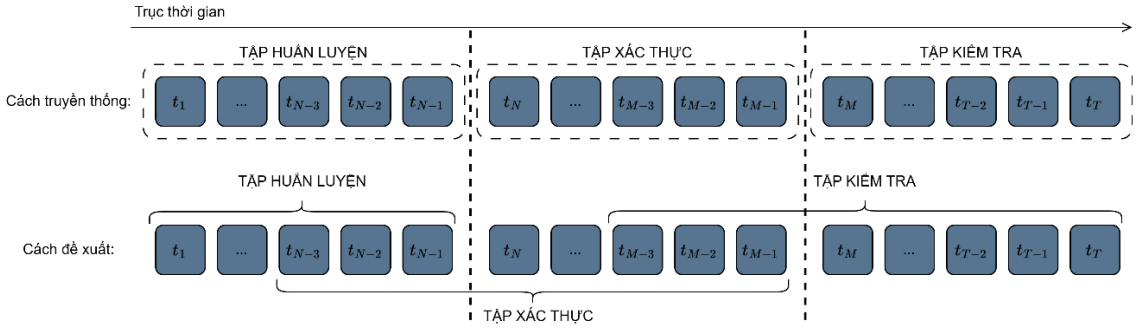
Cụ thể, mỗi chuỗi đầu vào bao gồm k bước thời gian liên tục, trong khi đầu ra tương ứng là giá trị tại bước thứ $k + 1$, đại diện cho đại lượng cần dự báo tại trạm khí tượng đang được xét.



Hình 4. 2. Mô tả cửa sổ dữ liệu với k = 3

Tuy nhiên, phương pháp cửa sổ trượt có một hạn chế là làm mất một số mẫu dữ liệu tại ranh giới giữa các tập huấn luyện, xác thực và kiểm tra do không đủ số bước thời gian để hình thành đầy đủ cửa sổ đầu vào. Điều này có thể làm giảm số lượng mẫu sử dụng cho quá trình huấn luyện và đánh giá mô hình.

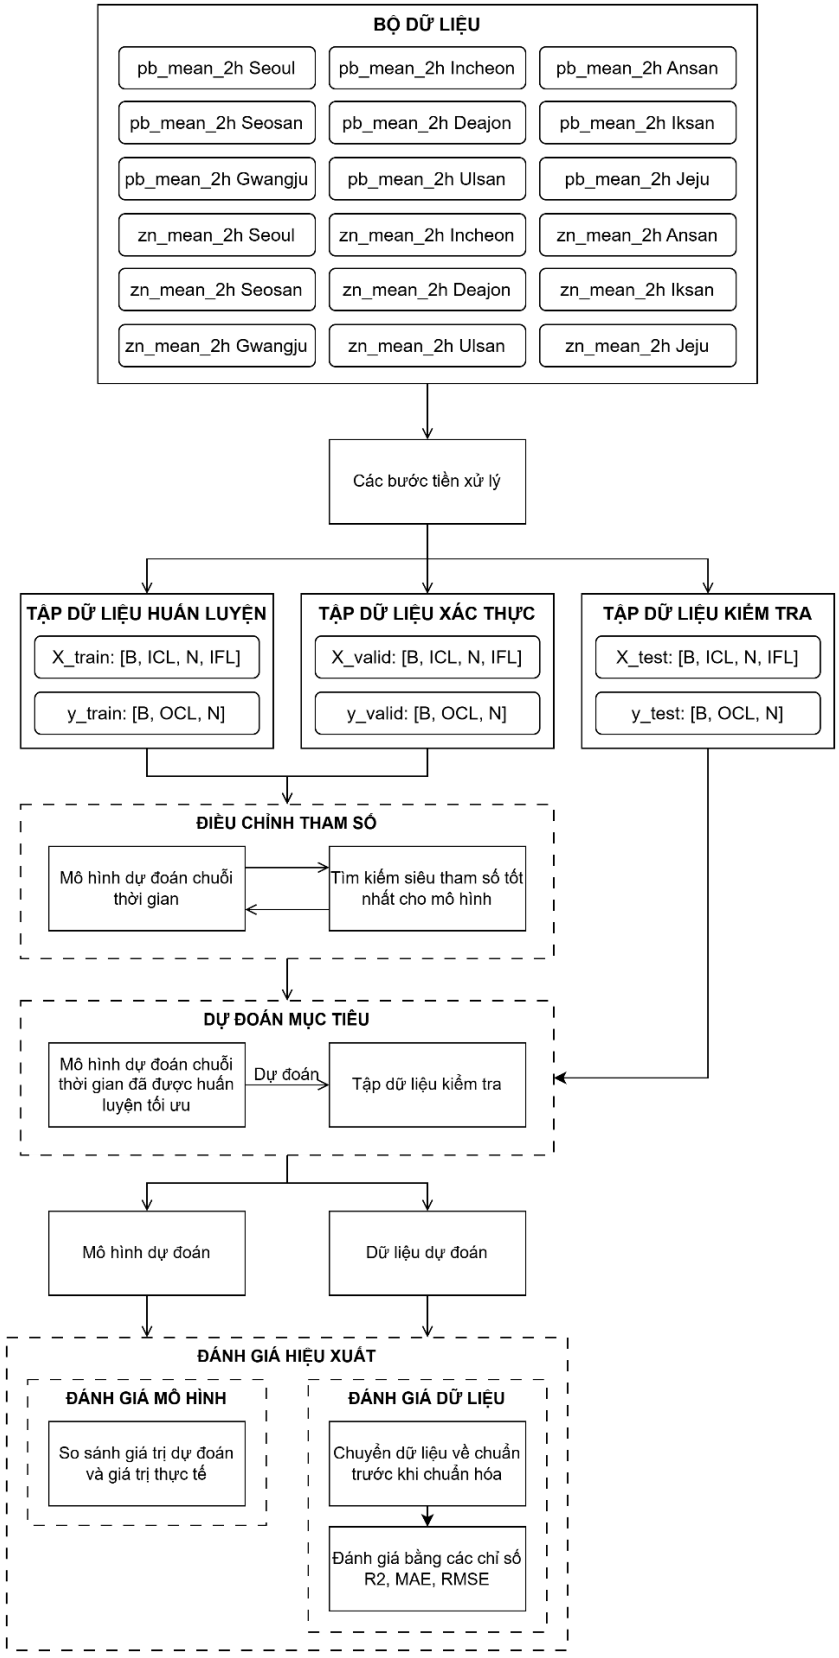
Để khắc phục vấn đề này, tôi thực hiện bổ sung dữ liệu tại ranh giới giữa các tập bằng cách nối k bước thời gian cuối cùng của tập huấn luyện vào đầu tập xác thực, đồng thời nối k bước thời gian cuối cùng của tập xác thực vào đầu tập kiểm tra. Cách tiếp cận này giúp duy trì tính liên tục của chuỗi thời gian khi áp dụng phương pháp cửa sổ trượt và hạn chế việc thất thoát dữ liệu trong quá trình tạo mẫu đầu vào cho mô hình. Nhờ đó, các mẫu dữ liệu tại thời điểm bắt đầu của tập xác thực và tập kiểm tra vẫn có đủ thông tin lịch sử cần thiết để xây dựng cửa sổ đầu vào, góp phần nâng cao tính ổn định và độ tin cậy của quá trình đánh giá mô hình.



Hình 4. 3. Mô tả so sánh cách tạo cửa sổ dữ liệu theo cách truyền thống và cách đề xuất với k = 3

4.3. Đề xuất mô hình sử dụng trong đề tài

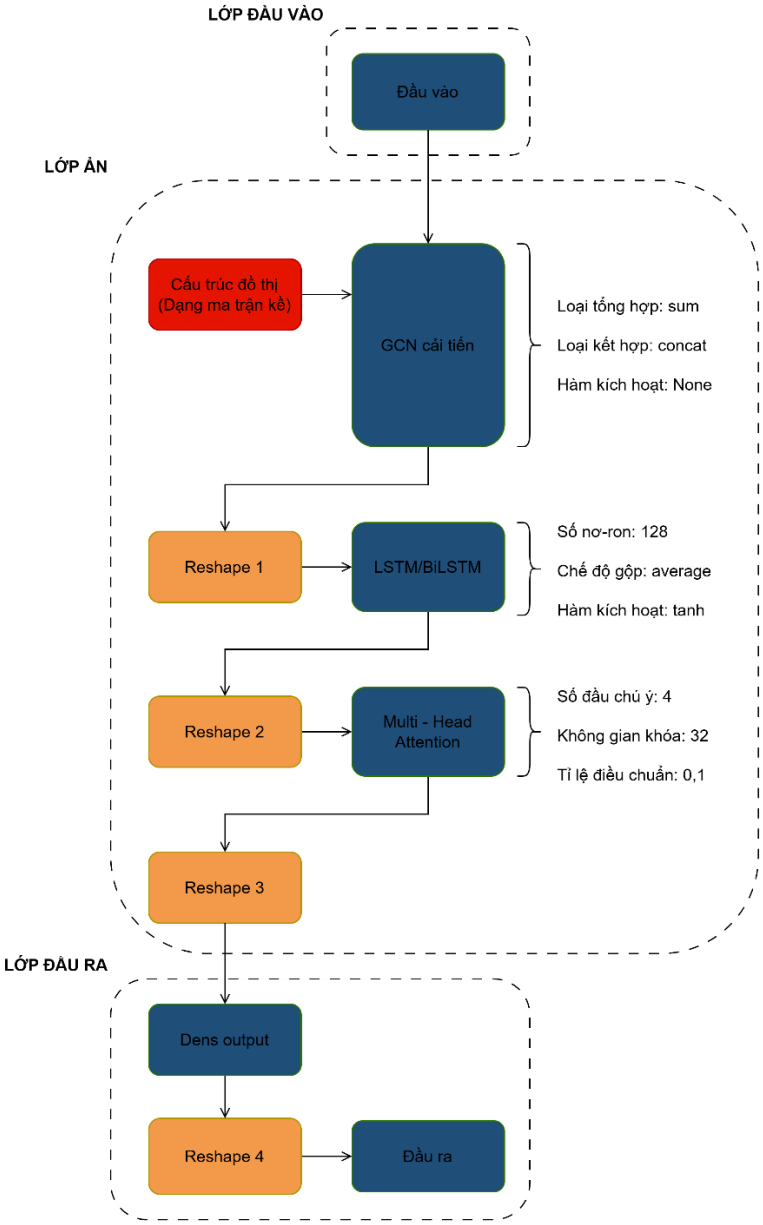
Sau khi hoàn tất quá trình tiền xử lý dữ liệu đầu vào, tôi tiến hành xây dựng và đề xuất mô hình áp dụng trong đề tài, đồng thời mô tả quy trình thiết kế và triển khai mô hình như sau:



Sơ đồ 4. 2. Quy trình xây dựng mô hình và đánh giá hiệu xuất

4.3.1. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM + MHA

Để thực hiện so sánh với mô hình cải tiến được sử dụng trong đề tài, tôi sử dụng kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM + MHA kết hợp với cấu trúc đồ thị được đề xuất từ Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] để khai thác mối quan hệ phi tuyến của xu hướng biến đổi hàm lượng chất ô nhiễm. Kiến trúc trên được biểu diễn qua sơ đồ sau:



Sơ đồ 4. 3. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM + MHA do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất

Bảng 4. 1. Kích thước đầu vào, đầu ra của mô hình GCN cải tiến – LSTM/BiLSTM + MHA

Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GCN cải tiến (Có reshape lại đầu vào)	[N, B, ICL, IFL]	[N, B, ICL, OFL]
Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, LSTM_unit]
Reshape 2	[N*B, LSTM_unit]	[B, N, att_unit]
Multi – Head Attention	[B, N, att_unit]	[B, N, att_unit]
Reshape 3	[B, N, att_unit]	[B*N, att_unit]
Dense output	[B*N, att_unit]	[B*N, OCL]
Reshape 4	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

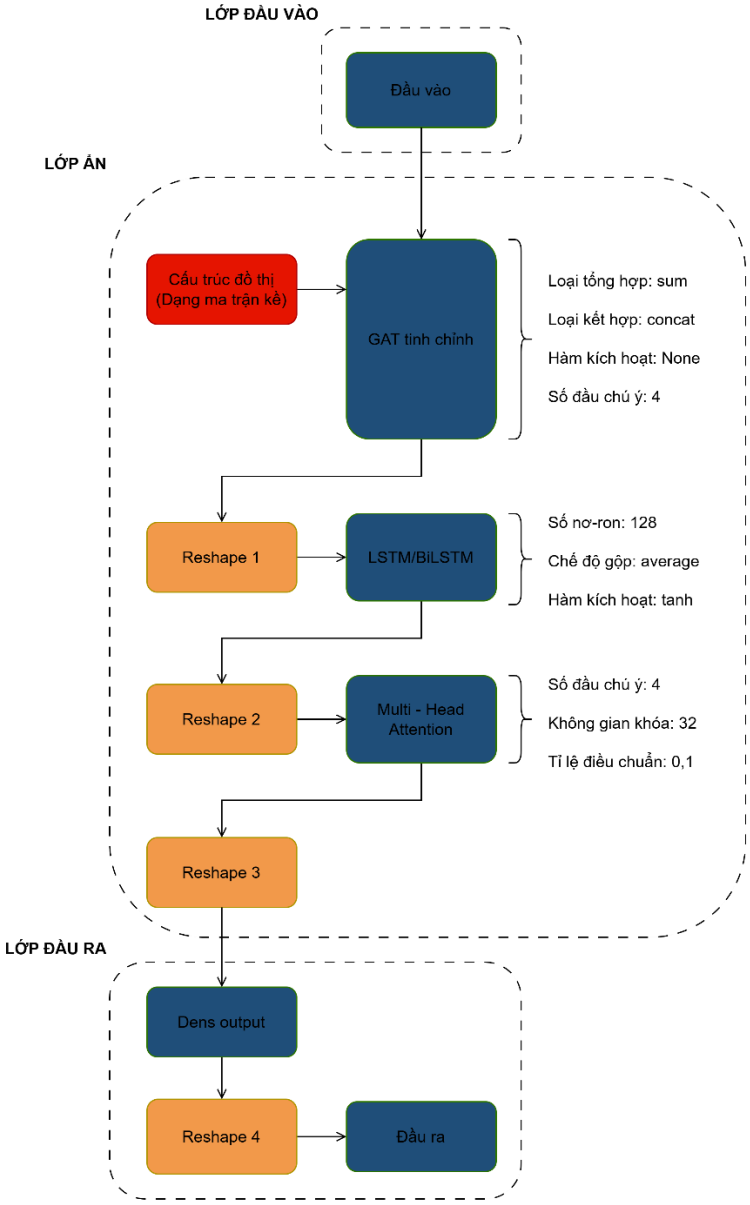
Bảng 4. 2. Các tham số đầu vào trong mô hình GCN cải tiến – LSTM/BiLSTM + MHA

Siêu tham số	Giá trị
Số lượng lớp GCN cải tiến	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam

Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE
Patience (Early Stopping)	15

4.3.2. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA

Tương tự kiến trúc GCN cải tiến – LSTM/BiLSTM + MHA vừa đề cập, tôi cũng đã tiến hành xây dựng mô hình sử dụng kiến trúc GAT tinh chỉnh – LSTM/BiLSTM + MHA kết hợp với cấu trúc đồ thị được đề xuất từ Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] để khai thác mối quan hệ phi tuyến của xu hướng biến đổi hàm lượng chất ô nhiễm. Kiến trúc trên được biểu diễn qua sơ đồ sau:



Sơ đồ 4. 4. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA được sử dụng trong đề tài

Bảng 4. 3. Kích thước đầu vào, đầu ra của mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA

Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GAT tinh chỉnh	[N, B, ICL, IFL]	[N, B, ICL, OFL]

(Có reshape lại đầu vào)

Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, unit]
Reshape 2	[N*B, unit]	[B, N, att_unit]
Multi – Head Attention	[B, N, att_unit]	[B, N, att_unit]
Reshape 3	[B, N, att_unit]	[B*N, att_unit]
Dense output	[B*N, att_unit]	[B*N, OCL]
Reshape 4	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

Bảng 4. 4. Các tham số đầu vào trong mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA

Siêu tham số	**Giá trị**
Số lượng lớp GAT tinh chỉnh	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam
Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE

4.3.3. Kiến trúc mô hình cải tiến đề xuất

Dựa vào các kiến trúc mô hình đã đề xuất bên trên, tôi nhận thấy mô hình khai thác mối quan hệ không gian – thời gian sẽ giải thích được đầy đủ xu hướng biến động của dữ liệu hàm lượng chất ô nhiễm tại tất cả các trạm khí tượng. Do đó, tôi vẫn sẽ sử dụng nền tảng mô hình GAT tinh chỉnh – LSTM/ BiLSTM + MHA cùng với đề xuất cải tiến sau:

- **Cải tiến: Tích hợp cơ chế độ lệch khoảng cách thích nghi**

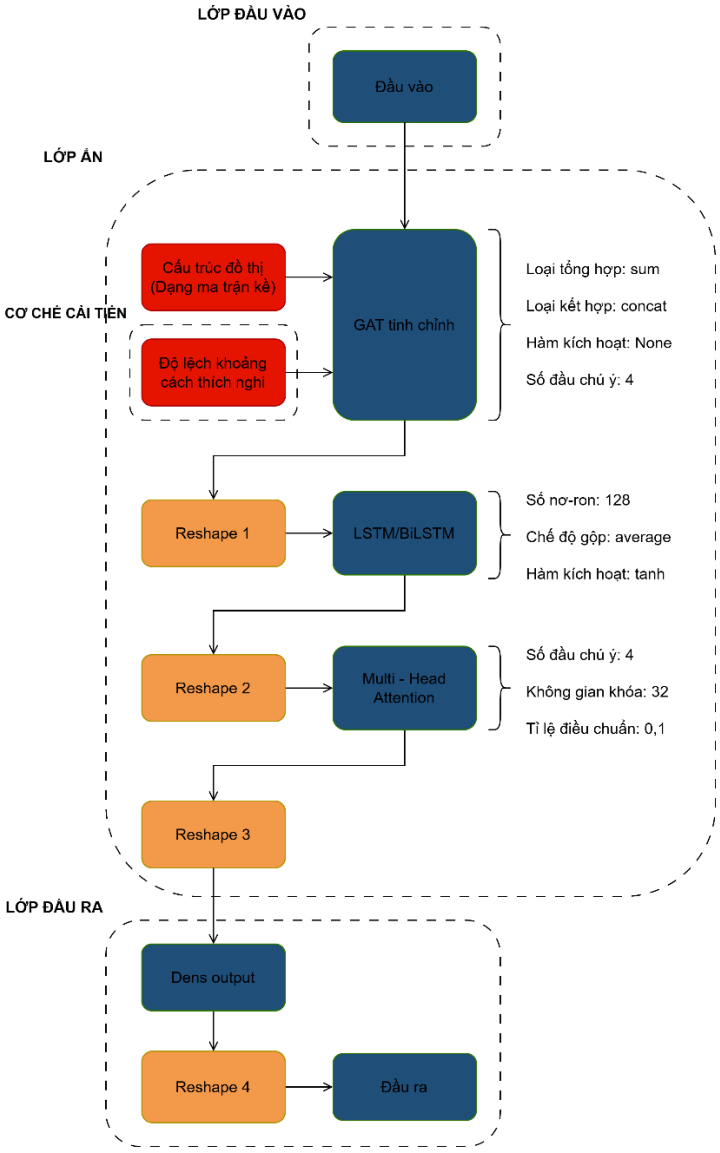
Tôi nhận thấy rằng việc bổ sung ma trận khoảng cách giữa các trạm để xác định trọng số liên kết như trong mô hình GCN cải tiến đã giúp mô hình học được cấu trúc địa lý tĩnh của mạng lưới quan trắc. Tuy nhiên, cách tiếp cận này vẫn tồn tại một hạn chế quan trọng: mối quan hệ giữa các trạm được giả định là cố định theo không gian, trong khi trên thực tế mức độ tương tác giữa các khu vực luôn biến đổi theo thời gian dưới tác động của các yếu tố khí tượng và môi trường.

Cụ thể, việc hai trạm có vị trí gần nhau không đồng nghĩa rằng chúng luôn có mức độ ảnh hưởng tương tự nhau trong mọi thời điểm. Trong một số trường hợp, trạm A có thể có mối liên hệ mạnh với trạm B, và trạm B lại có tương quan cao với trạm C, nhưng điều đó không đảm bảo rằng trạm A cũng sẽ duy trì mối quan hệ trực tiếp với trạm C. Sự lan truyền ô nhiễm trong khí quyển chịu ảnh hưởng lớn từ hướng gió, tốc độ gió, hoàn lưu không khí và các nguồn phát thải cục bộ, khiến cho cấu trúc phụ thuộc không gian thay đổi liên tục theo từng thời điểm. Vì vậy, nếu mô hình chỉ dựa trên khoảng cách địa lý cố định để lan truyền thông tin, quá trình học có thể vô tình khuếch đại các liên kết không còn phù hợp tại thời điểm hiện tại, dẫn đến hiện tượng truyền nhiễu và làm suy giảm hiệu quả dự báo.

Từ nhận định đó, cơ chế "Độ lệch khoảng cách thích nghi" được đề xuất nhằm xây dựng một cấu trúc đồ thị linh hoạt hơn. Thay vì duy trì trọng số liên kết cố định, cơ chế này liên tục đánh giá mức độ đồng pha hoặc lệch pha trong biến thiên dữ liệu

giữa các trạm theo thời gian thực. Khi hai trạm xuất hiện xu hướng biến động khác biệt, hệ thống sẽ tự động áp dụng một hệ số phạt dựa trên khoảng cách và mức độ tương quan tức thời để làm suy giảm cường độ liên kết giữa chúng. Ngược lại, các trạm có xu hướng biến động đồng pha sẽ được tăng cường khả năng chia sẻ thông tin. Nhờ đó, đồ thị không gian không còn là cấu trúc tĩnh mà trở thành một mạng liên kết động, phản ánh sát hơn trạng thái thực tế của môi trường và giúp mô hình học được quan hệ không gian–thời gian hiệu quả hơn.

Ý tưởng cải tiến trên được biểu diễn qua sơ đồ kiến trúc sau:



Sơ đồ 4. 5. Tổng quan kiến trúc mô hình đề xuất cải tiến

Bảng 4. 5. Kích thước đầu vào, đầu ra của mô hình đề xuất cải tiến

Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GAT tinh chỉnh (Có reshape lại đầu vào)	[N, B, ICL, IFL]	[N, B, ICL, OFL]
Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, unit]
Reshape 2	[N*B, unit]	[B, N, att_unit]
Multi – Head Attention	[B, N, att_unit]	[B, N, att_unit]
Reshape 3	[B, N, att_unit]	[B*N, att_unit]
Dense output	[B*N, att_unit]	[B*N, OCL]
Reshape 4	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

Bảng 4. 6. Các tham số đầu vào trong mô hình đề xuất cải tiến

Siêu tham số	Giá trị
Số lượng lớp GAT tinh chỉnh	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam

Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE
Patience (Early Stopping)	15

- **Chi tiết xử lý trong lớp GAT tinh chỉnh:**

Dựa vào nền tảng lý thuyết của lớp GAT tinh chỉnh như đã trình bày trong Chương 1 – Cơ sở lý thuyết, tôi vẫn giữ lại các giai đoạn xử lý chính của mô hình GAT tinh chỉnh như sau:

Giai đoạn 1 – Tính toán hệ số chú ý kết hợp độ lệch khoảng cách thích nghi.

Giai đoạn 2 – Thu thập thông tin từ các nút láng giềng.

Giai đoạn 3 – Tổng hợp thông tin từ các nút láng giềng.

Giai đoạn 4 – Cập nhật biểu diễn đặc trưng nút.

Giai đoạn 2, 3 và 4 tôi vẫn giữ nguyên cách thức xử lý theo GAT tinh chỉnh. Tuy nhiên, ở giai đoạn 1 tôi đã cải tiến bằng cách tích hợp cơ chế độ lệch thích nghi vào quá trình xác định trọng số liên kết. Cụ thể, tôi đề xuất một cơ chế điều chỉnh động dựa trên sự tương quan biến thiên dữ liệu giữa các nút. Điều này cho phép mô hình không chỉ học từ cấu trúc tô-pô của đồ thị và bố cục không gian thực tế mà còn có khả năng tự thích nghi với những biến động thời tiết cục bộ, giúp việc truyền dẫn thông tin giữa các trạm đạt độ chính xác cao hơn trong các điều kiện thực tế phứt tạp.

+ **Tạo độ lệch khoảng cách thích nghi:**

Để định lượng hóa mức độ ảnh hưởng của khoảng cách địa lý theo thời gian, tôi thực hiện quy trình xác định Độ lệch khoảng cách thích nghi qua các bước sau:

Bước 1: Tính toán gia tốc biến thiên dữ liệu

Đầu tiên, mô hình tính sai phân bậc nhất (first-order difference) của dữ liệu đầu vào X giữa hai thời điểm liên tiếp nhằm phản ánh tốc độ biến thiên tức thời của nồng độ chất ô nhiễm tại từng trạm quan trắc.

$$\Delta X_t = X_t - X_{t-1} \tag{4.2}$$

Trong đó, ΔX_t đại diện cho "gia tốc" biến thiên của nồng độ chất ô nhiễm. Đối với thời điểm đầu tiên, một kỹ thuật đệm (padding) được áp dụng để đảm bảo tính đồng nhất về tensor.

Bước 2: Xác định hệ số đồng pha thời gian

Sau đó, tại mỗi cạnh (i, j) nối giữa trạm nguồn và trạm đích, mô hình thực hiện tính toán bình phương sai lệch giữa các vector biến thiên:

$$S_{ij,t} = \left(\Delta X_{i,t} - \Delta X_{j,t}\right)^2 \tag{4.3}$$

Nhằm loại bỏ nhiễu cục bộ và thu thập thông tin ngữ cảnh, mô hình sử dụng hai lớp tích chập một chiều để quét qua cửa sổ thời gian theo hai hướng: tiến và lùi. Sau đó, tôi thực hiện làm mịn bằng cách lấy trung bình kết quả từ hai hướng:

$$\bar{S}_{ij,t} = \frac{Conv1D_{fwd}\left(S_{ij,t}\right) + Conv1D_{bwd}\left(S_{ij,t}\right)}{2} \tag{4.4}$$

Bước 3: Tính toán sai lệch hiệu chỉnh

Tiếp theo, dựa trên sai lệch bình phương giữa gia tốc của trạm đích i và trạm láng giềng j, tôi tính toán hệ số đồng pha thông qua hàm mũ âm. Hệ số này đóng vai trò đo lường sự tương quan về mặt diễn biến dữ liệu; giá trị $M_{i,j}$ tiệm cận về 1 khi hai trạm có xu hướng biến thiên đồng nhất và tiệm cận về 0 khi có sự lệch pha rõ rệt.

Từ giá trị sai lệch đã làm mịn, mô hình tính toán căn bậc hai và lấy trung bình trên tất cả đặc trưng để thu được một hệ số vô hướng, sau đó chuẩn hóa qua hàm mũ âm:

$$M_{i,j} = exp\left(-\frac{mean\left(\sqrt{\bar{s}_{ij,t}}\right)}{\tau}\right) \quad (4.5)$$

Trong đó, τ là tham số học được trong quá trình huấn luyện được biểu diễn dưới dạng tham số vô hướng, đóng vai trò điều phối cường độ tác động và độ nhạy của cơ chế thích nghi.

Cuối cùng, độ lệch khoảng cách thích nghi được hình thành bằng cách kết hợp ma trận khoảng cách tương đối $dist_mask_{i,j}$ với hệ số nghịch đảo của sự đồng pha là $1 - M_{i,j}$. Thành phần này đóng vai trò như một bộ lọc động: nếu hai trạm lệch pha, mô hình sẽ tăng cường "hình phạt" dựa trên khoảng cách địa lý để hạn chế nhiễu; ngược lại, nếu hai trạm đồng pha, ảnh hưởng tiêu cực của khoảng cách sẽ được giảm thiểu, cho phép luồng thông tin được chia sẻ mạnh mẽ hơn.

$$dist_mask_{i,j} = \frac{d_{i,j}}{mean(d)} \quad (4.6)$$

$$dynamic_bias_{i,j} = \lambda . dist_mask_{i,j} . \left(1 - M_{i,j}\right) \quad (4.7)$$

Trong đó, λ là tham số học được trong quá trình huấn luyện được biểu diễn dưới dạng tham số vô hướng, đóng vai trò điều phối mức độ ảnh hưởng của thành phần độ lệch khoảng cách thích nghi đối với hệ số chú ý cuối cùng.

+ **Áp dụng vao giai đoạn 1 – tính toán hệ số chú ý:**

Thay vì chỉ sử dụng hệ số chú ý thô được tính toán dựa trên đặc trưng của các nút, tôi thực hiện kết hợp thêm thành phần không gian động bằng cách tạo ra hệ số chú ý đã hiệu chỉnh:

$$e_{i,j}^{new} = e_{i,j}^{old} + dynamic_bias_{i,j} \quad (4.8)$$

Trong đó, $e_{i,j}$ là điểm chú ý thô biểu thị mối quan hệ giữa nút nguồn i và nút láng giềng j, còn $dynamic_bias_{i,j}$ là độ lệch khoảng cách thích nghi đã được tính toán dựa trên sự tương quan biến thiên dữ liệu.

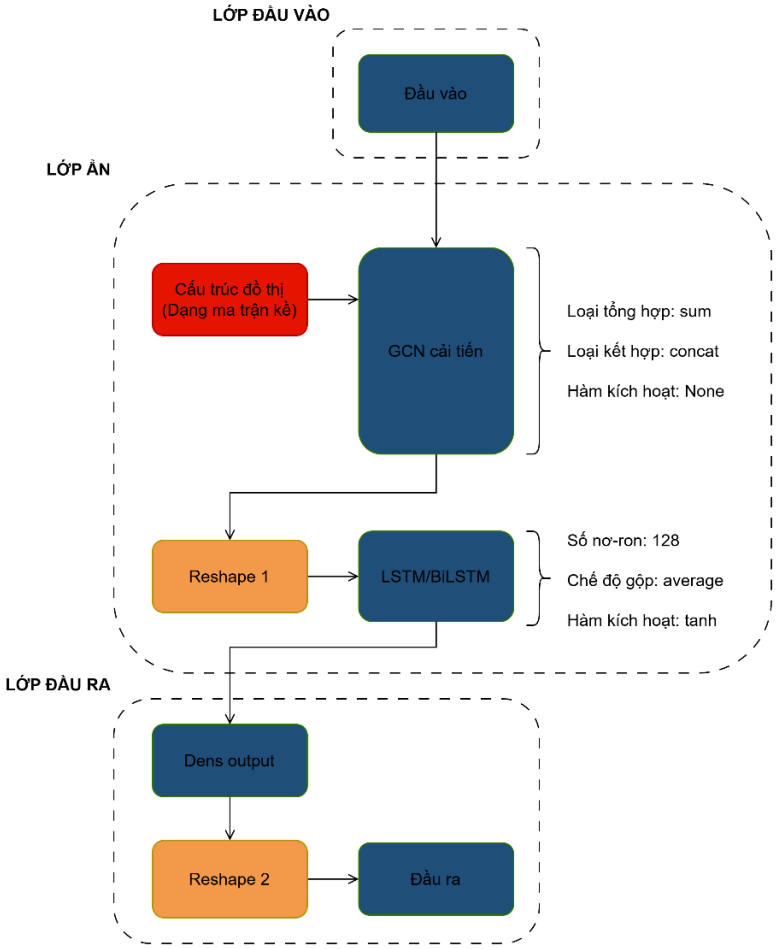
Sau đó, các đặc trưng $e_{i,j}^{new}$ sẽ được chuẩn hóa trên toàn bộ tập láng giềng $N(i)$ thông qua hàm Softmax để thu được trọng số chú ý cuối cùng:

$$\alpha_{i,j} = \frac{exp\left(e_{i,j}^{new}\right)}{\sum_{k \in N(i)} exp\left(e_{i,j}^{new}\right)} \tag{4.9}$$

4.3.4. Các mô hình thử nghiệm khác

Bên cạnh các mô hình đề xuất được sử dụng như trên, tôi đề xuất so sánh kết quả dự báo được trình bày trong Chương 5 – Thiết lập, kết quả và đánh giá thực nghiệm của các biến thể không có MHA như: GCN tinh chỉnh – LSTM/BiLSTM, GCN cải tiến – LSTM/BiLSTM, GAT tinh chỉnh – LSTM/BiLSTM và GAT đề xuất – LSTM/BiLSTM. Những đề xuất so sánh là cơ sở nhằm mục đích kiểm chứng lại độ hiệu quả của mô hình đề xuất.

Đối với các mô hình GCN cải tiến – LSTM/BiLSTM, kiến trúc của mô hình được minh họa thông qua sơ đồ dưới đây:



Sơ đồ 4. 6. Kiến trúc mô hình GCN cải tiến – LSTM/BiLSTM do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất

Bảng 4. 7. Kích thước đầu vào, đầu ra của mô hình GCN cải tiến – LSTM/BiLSTM

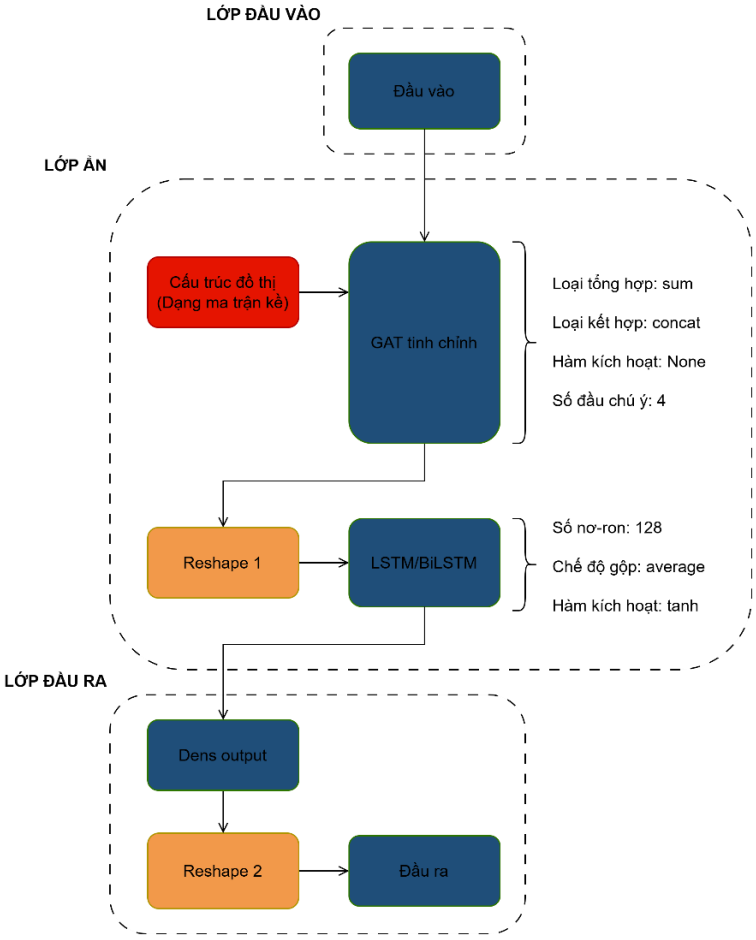
Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GCN cải tiến (Có reshape lại đầu vào)	[N, B, ICL, IFL]	[N, B, ICL, OFL]
Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, unit]
Dense output	[N*B, unit]	[N*B, OCL]

Reshape 2	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

Bảng 4. 8. Các tham số đầu vào trong mô hình GCN cải tiến – LSTM/BiLSTM

Siêu tham số	**Giá trị**
Số lượng lớp GCN cải tiến	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam
Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE
Patience (Early Stopping)	15

Đối với mô hình GAT đề xuất – LSTM/BiLSTM, kiến trúc của mô hình được minh họa thông qua sơ đồ dưới đây:



Sơ đồ 4. 7. Kiến trúc mô hình GAT tinh chỉnh – LSTM/BiLSTM do Bùi Hữu Đạt and Huỳnh Thị Tuyết Ngọc, (2025) [3] đề xuất

Bảng 4. 9. Kích thước đầu vào, đầu ra của mô hình GAT tinh chỉnh – LSTM/BiLSTM

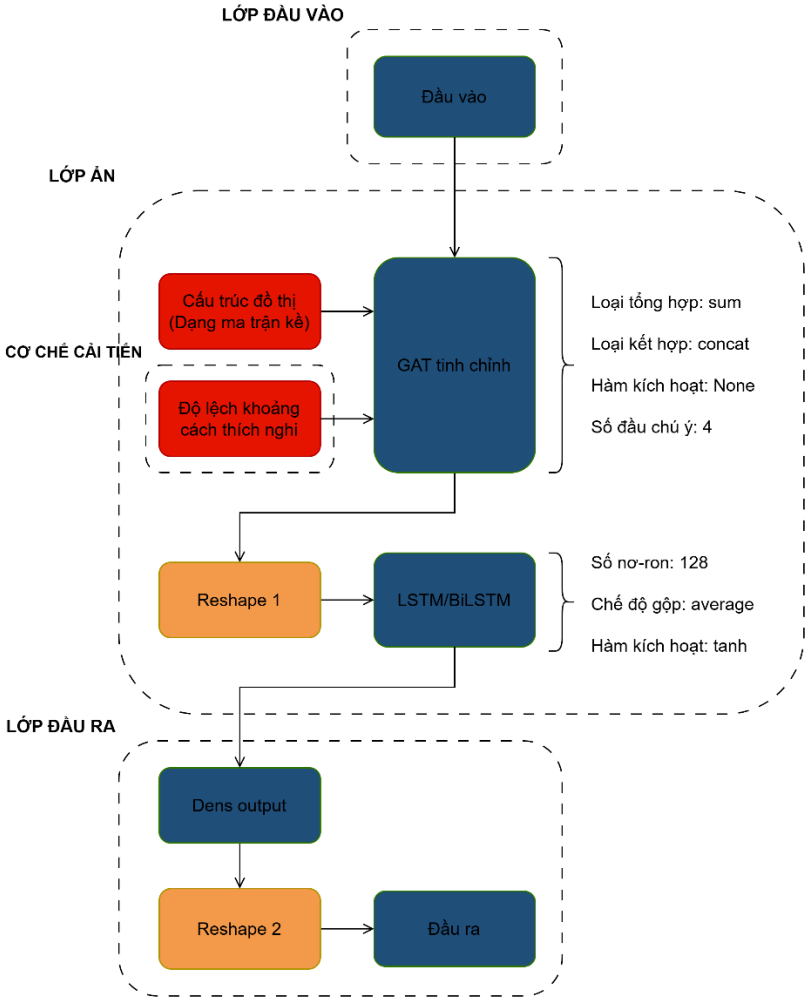
Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GAT tinh chỉnh (Có reshape lại đầu vào)	[N, B, ICL, IFL]	[N, B, ICL, OFL]
Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, unit]
Dense output	[N*B, unit]	[N*B, OCL]

Reshape 2	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

Bảng 4. 10. Các tham số đầu vào trong mô hình GAT tinh chỉnh – LSTM/BiLSTM

Siêu tham số	**Giá trị**
Số lượng lớp GAT tinh chỉnh	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam
Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE
Patience (Early Stopping)	15

Đối với mô hình GAT đề xuất – LSTM/BiLSTM, kiến trúc của mô hình được minh họa thông qua sơ đồ dưới đây:



Sơ đồ 4. 8. Kiến trúc mô hình GAT đề xuất – LSTM/BiLSTM

Bảng 4. 11. Kích thước đầu vào, đầu ra của mô hình GAT đề xuất – LSTM/BiLSTM

Lớp	Kích thước đầu vào	Kích thước đầu ra
Đầu vào	[B, ICL, N, IFL]	-
GCN cải tiến (Có reshape lại đầu vào)	[N, B, ICL, IFL]	[N, B, ICL, OFL]
Reshape 1	[N, B, ICL, OFL]	[N*B, ICL, OFL]
LSTM/BiLSTM	[N*B, ICL, OFL]	[N*B, unit]
Dense output	[N*B, unit]	[N*B, OCL]

Reshape 2	[B*N, OCL]	[N, B, OCL]
Đầu ra (reshape)	[N, B, OCL]	[B, N, OCL]

Bảng 4. 12. Các tham số đầu vào trong mô hình GAT đề xuất – LSTM/BiLSTM

Siêu tham số	**Giá trị**
Số lượng lớp GAT đề xuất	1
Số lượng lớp LSTM/BiLSTM	1
Số lượng lớp Dense	1
Số lượng lớp Dropout	0
Bộ tối ưu hóa	Adam
Tốc độ học	0,001
Norm clipping	1
Hàm mất mát	MSE
Patience (Early Stopping)	15

4.4. Tóm tắt chương

Chương 4 đã trình bày đầy đủ và có hệ thống phương pháp đề xuất của nghiên cứu, từ quy trình tiền xử lý dữ liệu đến kiến trúc mô hình học sâu kết hợp không gian – thời gian.

Quy trình tiền xử lý được thiết kế riêng biệt cho hai mục đích phân tích và dự đoán, đảm bảo tính phù hợp của dữ liệu đầu vào với từng loại bài toán. Bên cạnh đó, kiến trúc GCN cải tiến và GAT tinh chỉnh kết hợp với LSTM/BiLSTM và cơ chế MHA đề xuất sử dụng đã tận dụng đồng thời ưu thế của học đặc trưng không gian trên đồ thị và khả năng mô hình hóa phụ thuộc dài hạn theo thời gian. Cuối cùng, mô

hình cải tiến đề xuất được xây dựng dựa trên sự tích hợp có chọn lọc các thành phần trên, hướng đến nâng cao độ chính xác dự đoán so với các kiến trúc cơ sở.

CHƯƠNG 5: THIẾT LẬP, KẾT QUẢ VÀ ĐÁNH GIÁ THỰC NGHIỆM

5.1. Giới thiệu

Trong chương này, tôi sẽ tập trung trình bày chi tiết về môi trường thực nghiệm được sử dụng trong đề tài.

Đầu tiên, phần 5.2 mô tả thiết lập thực nghiệm, bao gồm môi trường phần cứng cũng như định nghĩa dữ liệu đầu vào và đầu ra của mô hình. Tiếp theo, phần 5.3 trình bày chi tiết kết quả thực nghiệm và đánh giá lần lượt cho mô hình GCN cải tiến kết hợp LSTM/BiLSTM và MHA, mô hình GAT tinh chỉnh kết hợp LSTM/BiLSTM và MHA và mô hình GAT đề xuất kết hợp LSTM/BiLSTM và MHA. Sau đó, phần 5.4 thực hiện so sánh tổng hợp kết quả thực nghiệm giữa tất cả các mô hình trên hai đặc trưng mục tiêu là pb_mean_2h và zn_mean_2h, nhằm xác định mô hình có hiệu quả dự đoán tốt nhất. Cuối cùng phần 5.5 trình bày một số kết luận của chương này.

5.2. Thiết lập thực nghiệm

5.2.1. Môi trường thực nghiệm

Tôi thực nghiệm triển khai huấn luyện mô hình bằng ngôn ngữ Python (phiên bản 3.10.11) trên máy tính cá nhân. Cùng với các thư viện triển khai mô hình như sau:

Bảng 5. 1. Thư viện sử dụng trong đề tài

Thư viện	Phiên bản
Numpy	1.26.4
Pandas	2.3.3
Scikit-learn	1.7.1
Tensorflow	2.9.0

Keras	2.9.0

5.2.2. Dữ liệu đầu vào và đầu ra của mô hình

Trong khóa luận này, dữ liệu được phân chia thành ba tập huấn luyện, xác thực và kiểm tra theo tỷ lệ lần lượt là 63,15%, 20,39% và 16,46%. Trong đó, tập huấn luyện được sử dụng để xây dựng mô hình, tập xác thực phục vụ quá trình hiệu chỉnh tham số, còn tập kiểm tra được dùng để đánh giá khả năng dự báo của mô hình. Quá trình phân chia dữ liệu không thực hiện ngẫu nhiên mà tuân theo trình tự thời gian, từ các mốc dữ liệu cũ đến các mốc gần hiện tại, nhằm duy trì tính liên tục và đặc trưng phụ thuộc thời gian của chuỗi dữ liệu.

Tôi xây dựng song song 2 mô hình độc lập, tương ứng với từng đặc trưng đầu vào khác nhau. Mỗi mô hình sử dụng dữ liệu của một đặc trưng được thu thập tại 9 trạm khí tượng nhằm khai thác đồng thời mối quan hệ không gian giữa các trạm và xu hướng biến đổi theo thời gian của dữ liệu. Dữ liệu đầu vào được tổ chức dưới dạng tensor có kích thước [B, ICL, N, IFL] và được trình bày chi tiết thông qua Bảng 5. 2 và

Bảng 5. 3 như sau:

Bảng 5. 2. Các tham số đầu vào của mô hình

Tham số	Giá trị	Mô tả
B	64	Kích thước lô
ICL	30	Chuỗi dữ liệu đầu vào
N	9	Số lượng trạm khí tượng
IFL	1	Số lượng đặc trưng đầu vào
OFL	128	Kích thước Embedding

Bảng 5. 3. Số lượng chuỗi đầu vào

Tập dữ liệu	Số lượng mẫu đầu vào	Tỷ lệ
Tập huấn luyện	13600	63,15%
Tập xác thực	4392	20,39%
Tập kiểm tra	3545	16,46%

Đầu ra của các mô hình sẽ là 1 tensor có kích thước [B, N, OCL] và được trình bày như sau:

Bảng 5. 4. Các tham số đầu ra của mô hình

Tham số	Giá trị	Mô tả
B	64	Kích thước lô
N	9	Số lượng trạm khí tượng
OCL	1	Số lượng chuỗi đầu ra

Bên cạnh dữ liệu chuỗi thời gian, các mô hình GCN và GAT còn tiếp nhận thông tin đầu vào dưới dạng cấu trúc đồ thị được biểu diễn thông qua ma trận kề. Trong đó, mỗi nút đại diện cho một trạm khí tượng, còn các cạnh biểu thị mức độ liên kết giữa các trạm trong mạng lưới quan trắc. Dựa trên phương pháp xây dựng đồ thị đã trình bày trước đó, ngưỡng tương quan dữ liệu (threshold) được thiết lập ở mức 0,05 nhằm xác định sự tồn tại của liên kết giữa các nút, từ đó xây dựng ma trận kề tương ứng như sau:

Bảng 5. 5. Ma trận kề giữa các trạm khí tượng

	Seoul	Incheon	Ansan	Seosan	Daejon	Iksan	Ulsan	Gwangju	Jeju
Seoul	0	1	1	1	0	1	1	1	1
Incheon	1	0	1	1	0	1	1	1	1
Ansan	1	1	0	1	1	1	1	1	1
Seosan	1	1	1	0	0	1	1	1	1
Daejon	0	0	1	0	0	0	1	0	0
Iksan	1	1	1	1	0	0	1	1	0
Ulsan	1	1	1	1	1	1	0	1	1
Gwangju	1	1	1	1	0	1	1	0	1
Jeju	1	1	1	1	0	0	1	1	0

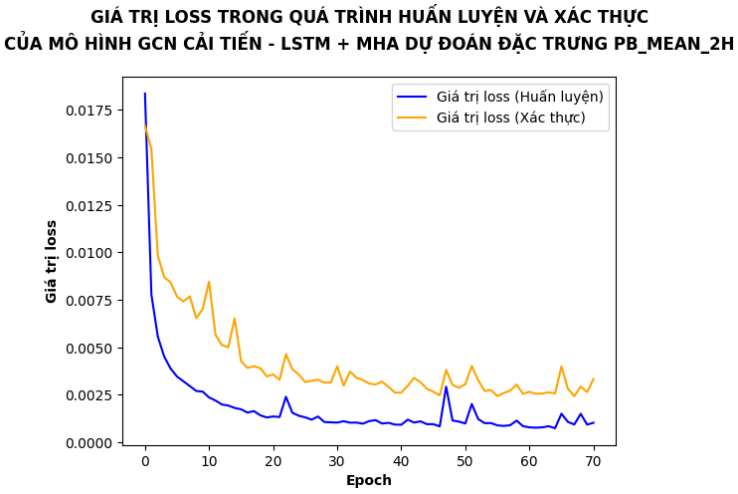
5.3. Kết quả thực nghiệm và đánh giá

Mô hình được huấn luyện lần lượt trên hai đặc trưng đầu vào gồm pb_mean_2h và zn_mean_2h, sau đó tiến hành xây dựng và đánh giá quá trình dự đoán riêng biệt cho từng đặc trưng.

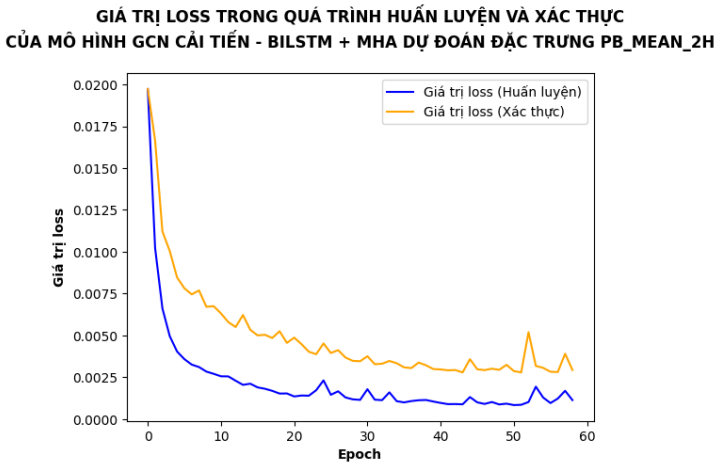
5.3.1. Kết quả thực nghiệm mô hình GCN cải tiến – LSTM/BiLSTM + MHA

5.3.1.1. Đặc trưng pb_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 1. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h



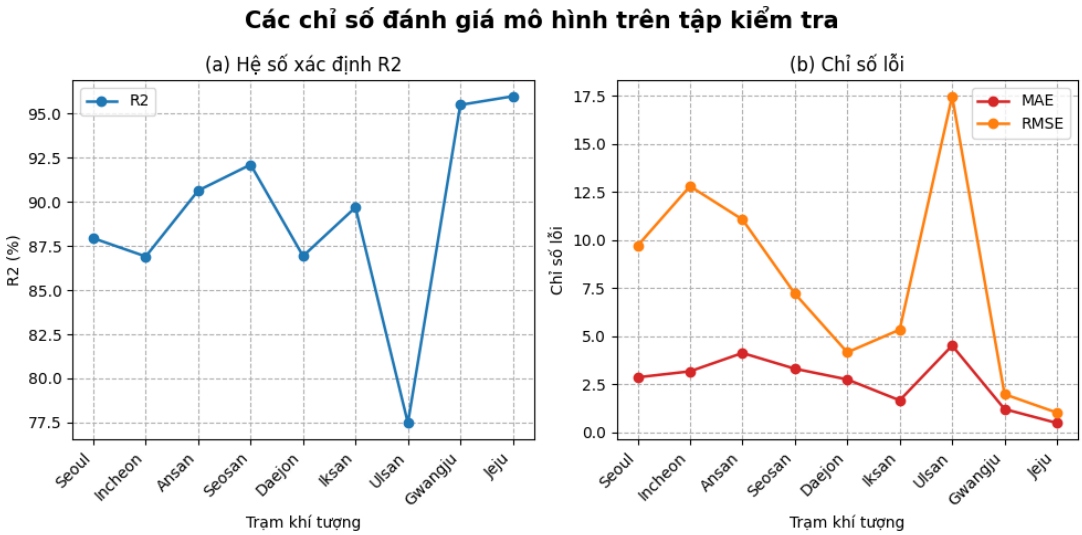
Biểu đồ 5. 2. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h

Biểu đồ 5. 1 và Biểu đồ 5. 2 thể hiện sự biến thiên của giá trị loss trong quá trình huấn luyện và xác thực đối với hai kiến trúc GCN cải tiến kết hợp lần lượt với LSTM + MHA và BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h. Nhìn chung, cả hai mô hình đều cho thấy xu hướng hội tụ rõ rệt khi giá trị loss giảm nhanh trong các epoch đầu tiên, sau đó ổn định dần ở các giai đoạn huấn luyện sau. Đồng thời, đường loss của tập xác thực luôn duy trì ở mức cao hơn tập huấn luyện nhưng không xuất hiện hiện tượng phân kỳ mạnh, cho thấy mô hình có khả năng học được đặc trưng dữ liệu mà chưa xảy ra overfitting nghiêm trọng.

Đối với mô hình GCN cải tiến – LSTM + MHA, giá trị loss của tập huấn luyện giảm mạnh từ khoảng 0,018 xuống dưới 0,005 chỉ sau vài epoch đầu tiên và tiếp tục giảm dần về khoảng 0,001 ở cuối quá trình huấn luyện. Trong khi đó, loss xác thực cũng giảm nhanh từ khoảng 0,016 xuống gần 0,003 và dao động ổn định quanh mức này ở các epoch cuối. Tuy vẫn xuất hiện một số dao động cục bộ tại các epoch trung gian, đặc biệt quanh epoch 20 và giai đoạn từ epoch 45 – 55 nhưng biên độ biến động tương đối nhỏ. Điều này cho thấy mô hình duy trì được tính ổn định trong quá trình tối ưu và có khả năng tổng quát hóa tương đối tốt trên tập dữ liệu xác thực.

Tương tự, mô hình GCN cải tiến – BiLSTM + MHA cũng thể hiện xu hướng hội tụ ổn định với tốc độ giảm loss nhanh ở giai đoạn đầu. Giá trị loss huấn luyện giảm từ gần 0,020 xuống khoảng 0,001 ở cuối quá trình học, trong khi loss xác thực giảm dần và ổn định quanh mức 0,003. So với mô hình LSTM + MHA, đường loss xác thực của BiLSTM + MHA có xu hướng mượt hơn trong phần lớn quá trình huấn luyện, mặc dù vẫn xuất hiện một số đỉnh dao động cục bộ ở các epoch cuối.

- **Hiệu suất khi dự đoán của mô hình GCN cải tiến – LSTM + MHA:**



Biểu đồ 5. 3. Mức độ hiệu quả của mô hình GCN cải tiến – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

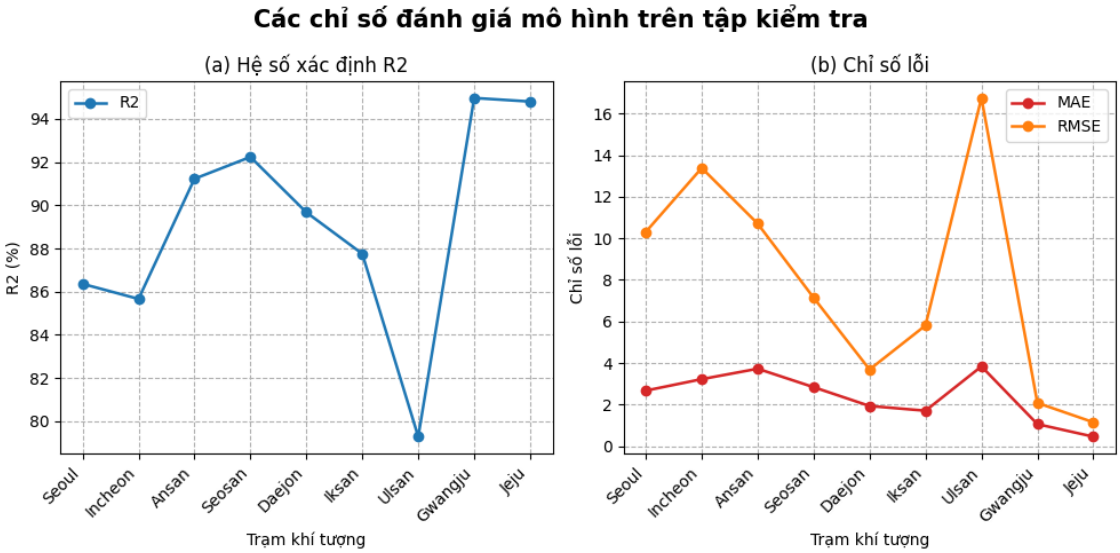
Số liệu chi tiết được trình bày ở Bảng PL - A. 1 và Biểu đồ PL - A. 1 trong PHỤ LỤC A.

Biểu đồ 5. 3 thể hiện mức độ hiệu quả của mô hình GCN cải tiến kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt kết quả dự báo tương đối tốt tại phần lớn các trạm khi hệ số xác định R^2 chủ yếu duy trì trên mức 85%, đồng thời các chỉ số sai số MAE và RMSE ở mức thấp. Tuy nhiên, hiệu suất mô hình vẫn có sự khác biệt đáng kể giữa các khu vực quan trắc, phản ánh mức độ phức tạp không đồng nhất của dữ liệu Pb theo từng trạm.

Về hệ số xác định R^2, mô hình đạt hiệu quả cao nhất tại Jeju và Gwangju với giá trị lần lượt đạt 95,98% và 95,49%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại hai khu vực này. Các trạm Seosan và Ansan cũng đạt kết quả khả quan với R^2 lần lượt khoảng 92,10% và 90,64%. Ngược lại, Ulsan là trạm có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 77,48%, thấp hơn đáng kể so với các trạm còn lại. Seoul, Incheon, Daejeon và Iksan duy trì mức R^2dao động quanh 86 – 89%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình trên phần lớn mạng lưới quan trắc.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,472 và RMSE đạt 1,01, điều này cho thấy sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng ghi nhận sai số thấp với MAE khoảng 1,20 và RMSE gần 1,97. Trong khi đó, Ulsan có mức sai số cao nhất khi MAE đạt 4,5 và RMSE lên tới 17,48, điều này phản ánh mức độ biến động dữ liệu lớn và khó dự báo hơn tại khu vực này. Các trạm còn lại như Seoul, Incheon, Ansan, Seosan, Daejeon và Iksan có RMSE dao động trong khoảng từ 4 đến 13, cho thấy mô hình vẫn duy trì được độ chính xác tương đối tốt. Nhìn tổng thể, mô hình GCN cải tiến – LSTM + MHA cho thấy khả năng học hiệu quả đặc trưng không gian – thời gian của dữ liệu Pb, đặc biệt tại các khu vực có tính mùa vụ ổn định và ít biến động bất thường.

- **Hiệu suất khi dự đoán của mô hình GCN cải tiến – BiLSTM + MHA:**



Biểu đồ 5. 4. Mức độ hiệu quả của mô hình GCN cải tiến – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - A. 2 và Biểu đồ PL - A. 2 trong PHỤ LỤC A.

Biểu đồ 5. 4 thể hiện mức độ hiệu quả của mô hình GCN cải tiến kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình cho kết quả dự báo khá tốt tại hầu hết các khu vực quan trắc khi hệ số xác định R^2 phần lớn đạt trên 85%, đồng thời các chỉ số sai số duy trì ở mức tương đối thấp. Tuy nhiên, hiệu suất mô hình vẫn có sự khác biệt giữa các trạm, cho thấy đặc điểm dữ liệu Pb tại từng khu vực có mức độ biến động không đồng đều.

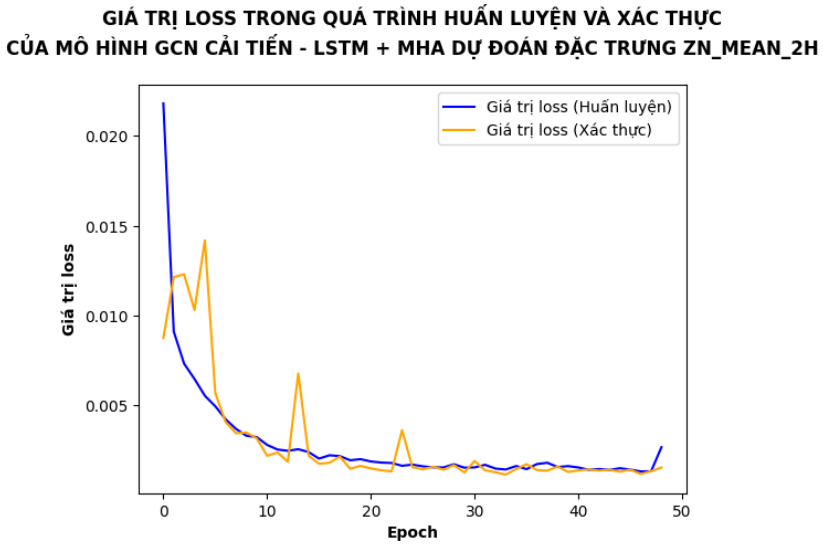
Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Gwangju và Jeju với giá trị lần lượt đạt khoảng 94,97% và 94,80%, điều này phản ánh khả năng giải thích phương sai dữ liệu rất tốt tại hai khu vực này. Các trạm Seosan và Ansan cũng ghi nhận hiệu suất tích cực với R^2 đạt khoảng 92,24% và 91,23%. Trong khi đó, Ulsan là khu vực có hiệu quả dự báo thấp nhất khi R^2 chỉ đạt khoảng 79,29%, thấp hơn đáng kể so với các trạm còn lại. Các trạm Seoul, Incheon, Daejeon và Iksan duy trì mức

R^2 dao động từ khoảng 85% đến gần 90%, điều này cho thấy mô hình vẫn đảm bảo được khả năng dự báo tương đối ổn định trên phần lớn tập dữ liệu kiểm tra.

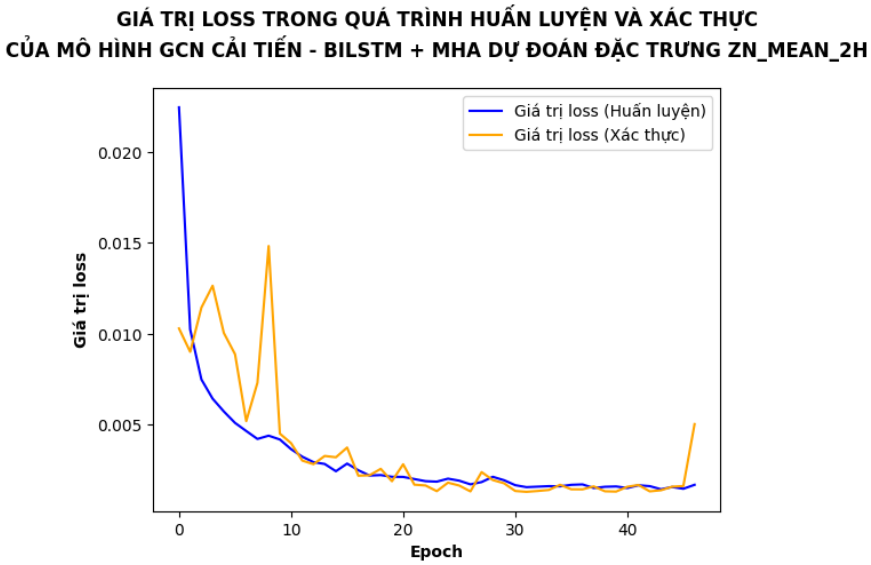
Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,45 và RMSE đạt gần 1,15, điều này cho thấy độ lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng đạt sai số thấp với MAE khoảng 1,06 và RMSE khoảng 2,08. Ngược lại, Ulsan ghi nhận mức sai số cao nhất khi MAE đạt khoảng 3,84 và RMSE lên tới 16,76, điều này phản ánh dữ liệu tại khu vực này có mức biến động lớn và khó dự báo hơn. Các trạm còn lại như Seoul, Incheon, Ansan, Seosan, Daejeon và Iksan có RMSE dao động từ khoảng 3,69 đến 13,39 cho thấy mô hình vẫn duy trì được độ chính xác tương đối tốt. Nhìn tổng thể, mô hình GCN cải tiến – BiLSTM + MHA cho thấy khả năng học hiệu quả các đặc trưng không gian – thời gian của dữ liệu Pb, đặc biệt tại những khu vực có xu hướng biến động ổn định hơn.

5.3.1.2. Đặc trưng zn_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 5. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h



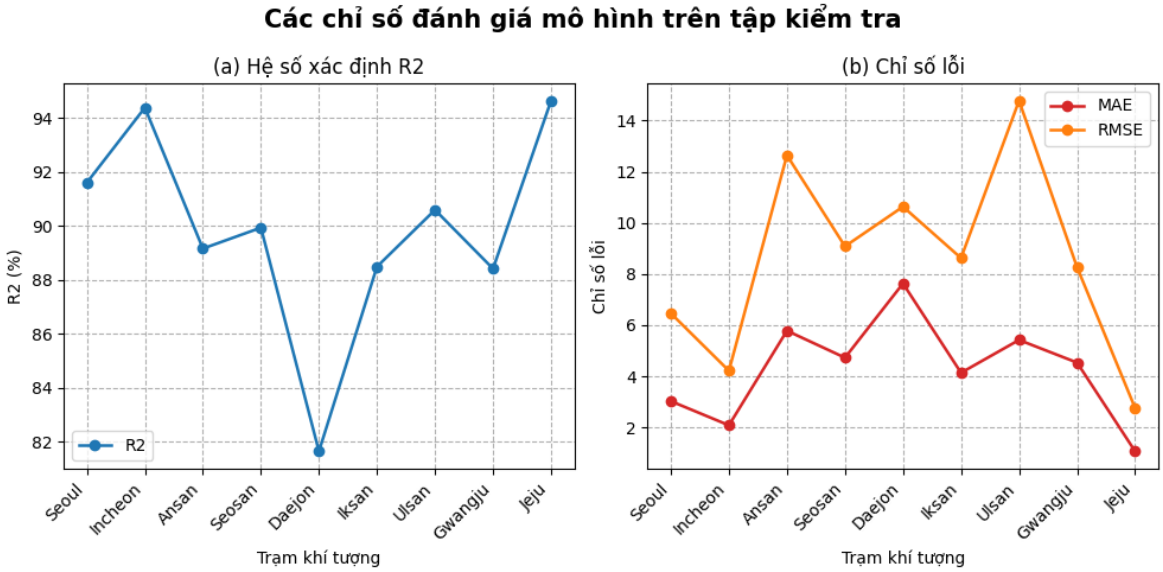
Biểu đồ 5. 6. Giá trị loss của quá trình huấn luyện mô hình GCN cải tiến – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h

Biểu đồ 5. 5 và Biểu đồ 5. 6 thể hiện sự thay đổi của giá trị loss trong quá trình huấn luyện và xác thực của hai mô hình GCN cải tiến kết hợp lần lượt với LSTM + MHA và BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h. Nhìn chung, cả hai mô hình đều cho thấy xu hướng hội tụ rõ rệt khi giá trị loss giảm mạnh trong những epoch đầu tiên và dần ổn định ở giai đoạn sau. Đồng thời, khoảng cách giữa loss huấn luyện và loss xác thực tương đối nhỏ trong phần lớn quá trình học, điều này cho thấy các mô hình có khả năng tổng quát hóa tốt và chưa xuất hiện hiện tượng overfitting đáng kể.

Đối với mô hình GCN cải tiến – LSTM + MHA, giá trị loss của tập huấn luyện giảm nhanh từ khoảng 0,022 xuống dưới 0,005 chỉ sau vài epoch đầu tiên, sau đó tiếp tục giảm và ổn định quanh mức 0,0015 – 0,002 ở cuối quá trình huấn luyện. Trong khi đó, loss xác thực ban đầu dao động tương đối mạnh, với một số đỉnh cục bộ ở các epoch đầu và quanh epoch 12 – 22 trước khi giảm dần và ổn định gần mức của tập huấn luyện. Mặc dù vẫn tồn tại một số biến động nhỏ ở giai đoạn giữa và cuối quá trình học, xu hướng chung vẫn thể hiện sự hội tụ ổn định và khả năng thích nghi tốt của mô hình đối với dữ liệu xác thực.

Tương tự, mô hình GCN cải tiến – BiLSTM + MHA cũng cho thấy khả năng hội tụ hiệu quả khi giá trị loss huấn luyện giảm liên tục từ khoảng 0,022 xuống gần 0,0015 ở các epoch cuối. Loss xác thực giảm theo xu hướng tương tự nhưng xuất hiện một số dao động lớn hơn ở giai đoạn đầu, đặc biệt quanh epoch 7 – 9 và tại epoch cuối cùng. Tuy nhiên, trong phần lớn quá trình huấn luyện, đường loss xác thực vẫn bám sát đường loss huấn luyện và duy trì ở mức thấp tương đối ổn định. So với mô hình LSTM + MHA, mô hình BiLSTM + MHA có đường loss huấn luyện mượt hơn và mức hội tụ cuối tương đương.

- **Hiệu suất khi dự đoán của mô hình GCN cải tiến – LSTM + MHA:**



Biểu đồ 5. 7. Mức độ hiệu quả của mô hình GCN cải tiến – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - A. 3 và Biểu đồ PL - A. 3 trong PHỤ LỤC A.

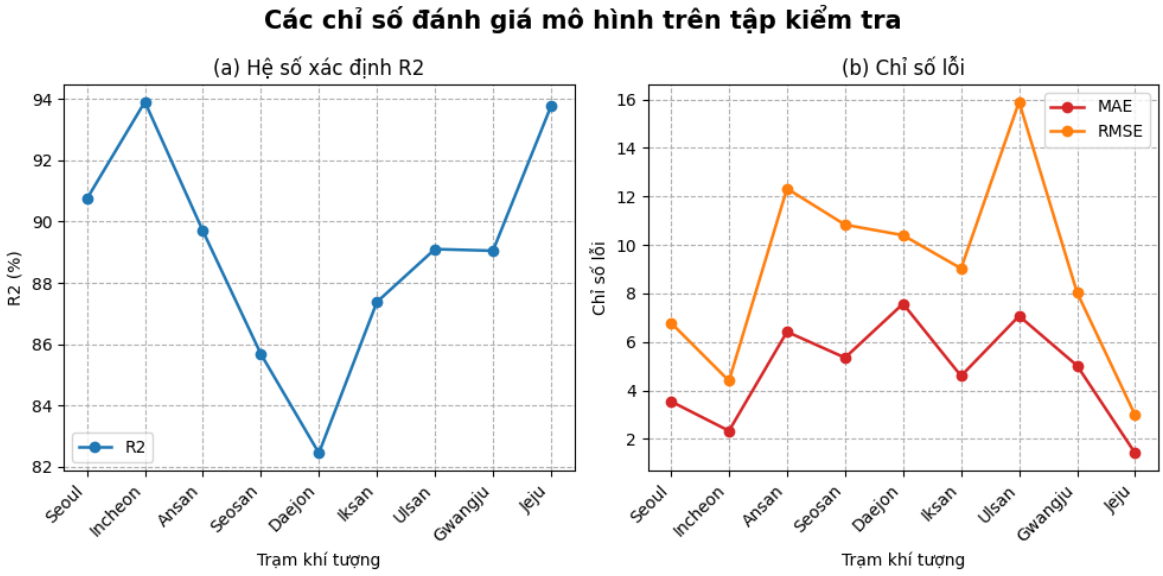
Biểu đồ 5. 7 thể hiện mức độ hiệu quả của mô hình GCN cải tiến kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt hiệu suất dự báo khá tốt trên phần lớn các trạm khi hệ số xác định R^2 chủ yếu dao động quanh mức 88 – 95%. Đồng thời, các chỉ số sai số MAE và

RMSE nhìn chung ở mức chấp nhận được, cho thấy mô hình có khả năng học tương đối hiệu quả đặc trưng không gian – thời gian của dữ liệu Zn. Tuy nhiên, sự khác biệt đáng kể giữa các trạm cho thấy mức độ ổn định của mô hình vẫn phụ thuộc vào đặc tính biến động dữ liệu tại từng khu vực quan trắc.

Về hệ số xác định R^2, Jeju là trạm đạt kết quả cao nhất với giá trị khoảng 94,64%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt. Incheon cũng ghi nhận hiệu suất cao với R^2 đạt khoảng 94,38%, tiếp theo là Seoul và Ulsan với giá trị lần lượt khoảng 91,60% và 90,59%. Các trạm Ansan, Seosan, Iksan và Gwangju duy trì mức R^2 dao động trong khoảng 88–90%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình. Ngược lại, Daejeon là khu vực có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 81,65%, thấp hơn đáng kể so với các trạm còn lại, điều này cho thấy mô hình gặp nhiều khó khăn hơn trong việc mô phỏng xu hướng dữ liệu tại khu vực này.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 1,07 và RMSE đạt gần 2,76, cho thấy độ sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng ghi nhận sai số thấp với MAE khoảng 2,09 và RMSE khoảng 4,22. Ngược lại, Daejeon là khu vực có MAE lớn nhất, đạt khoảng 7,63, trong khi Ulsan ghi nhận RMSE cao nhất với giá trị khoảng 14,78, điều này phản ánh dữ liệu tại hai khu vực này có mức độ biến động cao và khó dự báo hơn. Ansan và Seosan cũng có RMSE tương đối lớn với giá trị lần lượt khoảng 12,64 và 9,08. Trong khi đó, Seoul, Iksan và Gwangju duy trì sai số ở mức trung bình đến thấp, điều này cho thấy mô hình vẫn đảm bảo được độ chính xác khá tốt trên phần lớn các trạm khí tượng.

- **Hiệu suất khi dự đoán của mô hình GCN cải tiến – BiLSTM + MHA:**



Biểu đồ 5. 8. Mức độ hiệu quả của mô hình GCN cải tiến – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - A. 4 và Biểu đồ PL - A. 4 trong PHỤ LỤC A.

Biểu đồ 5. 8 thể hiện mức độ hiệu quả của mô hình GCN cải tiến kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt hiệu suất dự báo khá tốt tại hầu hết các trạm khi hệ số xác định R^2 chủ yếu dao động trong khoảng 85 – 94%. Đồng thời, các chỉ số sai số MAE và RMSE nhìn chung ở mức tương đối thấp, điều này cho thấy mô hình có khả năng học tốt mối quan hệ không gian – thời gian của dữ liệu Zn. Tuy nhiên, sự chênh lệch kết quả giữa các trạm cho thấy độ ổn định của mô hình vẫn chịu ảnh hưởng bởi đặc tính biến động dữ liệu tại từng khu vực quan trắc.

Về hệ số xác định R^2, Incheon là trạm đạt kết quả cao nhất với giá trị khoảng 93,91%, cho thấy khả năng giải thích phương sai dữ liệu rất tốt. Jeju cũng ghi nhận hiệu suất tương đương với R^2 đạt khoảng 93,77%, tiếp theo là Seoul với khoảng 90,74%. Các trạm Ansan, Ulsan và Gwangju duy trì mức R^2 xấp xỉ 89%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình. Trong khi đó, Seosan và

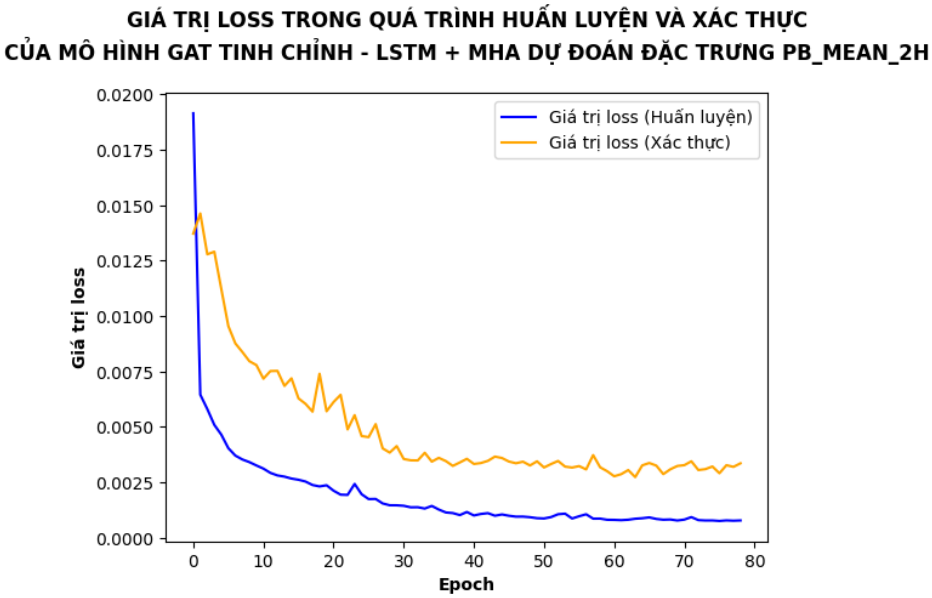
Iksan đạt mức trung bình với giá trị lần lượt khoảng 85,68% và 87,38%. Ngược lại, Daejeon là khu vực có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 82,45%, điều này cho thấy mô hình gặp nhiều khó khăn hơn trong việc mô phỏng xu hướng dữ liệu tại khu vực này.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 1,41 và RMSE đạt gần 2,98, điều này cho thấy độ sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng ghi nhận sai số thấp với MAE khoảng 2,33 và RMSE khoảng 4,39. Ngược lại, Ulsan là khu vực có RMSE lớn nhất với giá trị khoảng 15,90, đồng thời MAE cũng ở mức cao khoảng 7,07, điều này phản ánh dữ liệu tại khu vực này có mức độ biến động lớn và khó dự báo hơn. Daejeon cũng ghi nhận MAE cao nhất, đạt khoảng 7,57, mặc dù RMSE chỉ ở mức khoảng 10,40. Ansan và Seosan có RMSE tương đối lớn, lần lượt khoảng 12,33 và 10,83, điều này cho thấy mô hình vẫn còn tồn tại sai số đáng kể tại các khu vực này. Trong khi đó, Seoul, Iksan và Gwangju duy trì sai số ở mức trung bình đến thấp, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình trên phần lớn các trạm khí tượng.

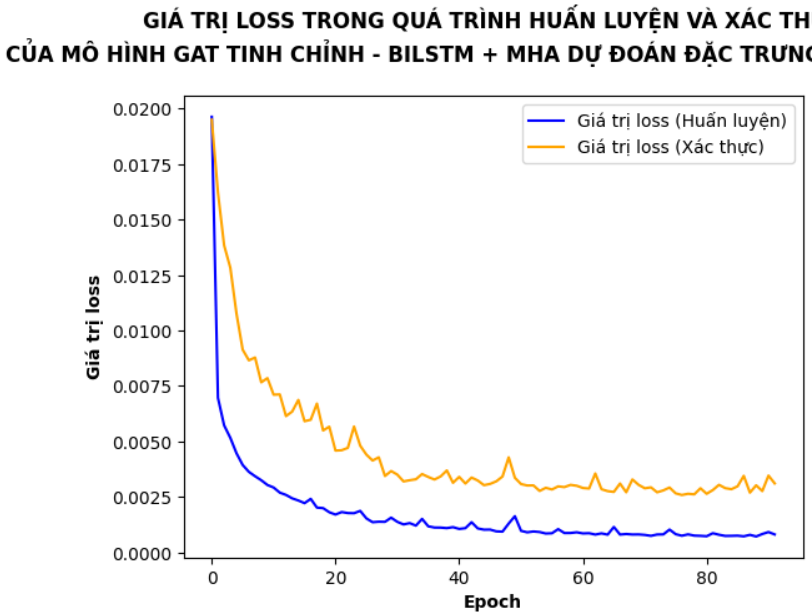
5.3.2. Kết quả thực nghiệm mô hình GAT tinh chỉnh – LSTM/BiLSTM + MHA

5.3.2.1. Đặc trưng pb_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 9. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h



Biểu đồ 5. 10. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h

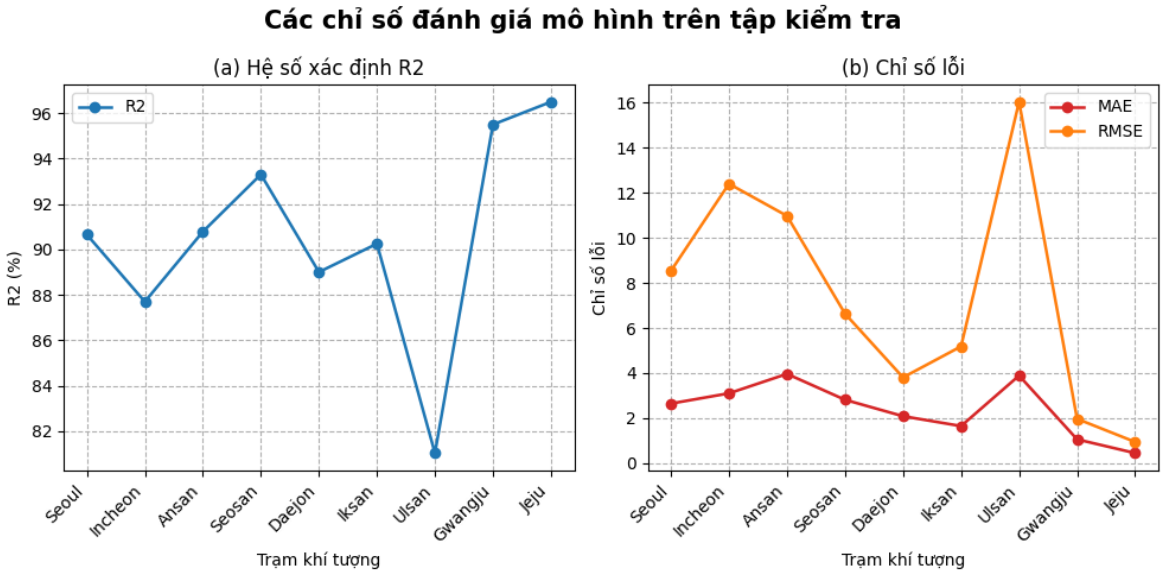
Biểu đồ 5. 9 và Biểu đồ 5. 10 trình bày sự thay đổi của giá trị loss trong quá trình huấn luyện và xác thực đối với hai kiến trúc GAT tinh chỉnh kết hợp lần lượt với LSTM + MHA và BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h. Nhìn

chung, cả hai mô hình đều cho thấy khả năng hội tụ tốt khi giá trị loss giảm mạnh trong các epoch đầu tiên và dần ổn định ở các giai đoạn sau. Đồng thời, khoảng cách giữa loss huấn luyện và loss xác thực được duy trì ở mức hợp lý, điều này cho thấy mô hình có khả năng tổng quát hóa tương đối tốt và chưa xuất hiện dấu hiệu overfitting nghiêm trọng.

Đối với mô hình GAT tinh chỉnh – LSTM + MHA, giá trị loss của tập huấn luyện giảm nhanh từ khoảng 0,019 xuống dưới 0,005 chỉ sau vài epoch đầu tiên và tiếp tục giảm dần về gần 0,001 ở cuối quá trình huấn luyện. Trong khi đó, loss xác thực giảm từ khoảng 0,014 xuống xấp xỉ 0,003 và duy trì ổn định quanh mức này trong phần lớn các epoch còn lại. Mặc dù vẫn xuất hiện một số dao động nhỏ ở các giai đoạn giữa và cuối quá trình huấn luyện, đường loss xác thực nhìn chung có xu hướng ổn định và không xảy ra hiện tượng tăng mạnh trở lại. Điều này cho thấy mô hình học được đặc trưng dữ liệu tương đối hiệu quả và duy trì khả năng dự báo ổn định trên tập xác thực.

Tương tự, mô hình GAT tinh chỉnh – BiLSTM + MHA cũng thể hiện tốc độ hội tụ nhanh với giá trị loss giảm đáng kể ngay từ các epoch đầu tiên. Loss huấn luyện giảm từ gần 0,020 xuống khoảng 0,001 ở cuối quá trình học, trong khi loss xác thực giảm dần và dao động quanh mức 0,003 sau giai đoạn hội tụ. So với mô hình kết hợp với LSTM + MHA, đường loss của mô hình kết hợp với BiLSTM + MHA có xu hướng mượt và ổn định hơn ở các epoch cuối, mặc dù vẫn xuất hiện một vài dao động cục bộ nhỏ trong quá trình tối ưu. Nhìn chung, cả hai mô hình GAT tinh chỉnh đều đạt khả năng hội tụ tốt.

- **Hiệu suất khi dự đoán của mô hình GAT tinh chỉnh – LSTM + MHA:**



Biểu đồ 5. 11. Mức độ hiệu quả của mô hình GAT tinh chỉnh – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - B. 1 và Biểu đồ PL - B. 1 trong PHỤ LỤC B.

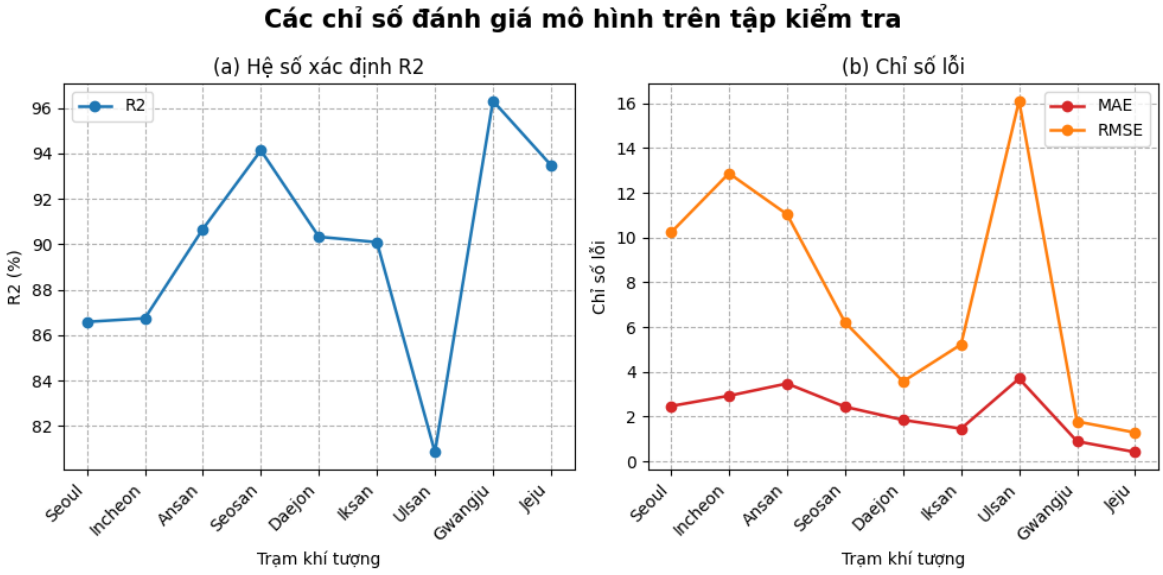
Biểu đồ 5. 11 thể hiện mức độ hiệu quả của mô hình GAT tinh chỉnh kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt hiệu suất dự báo khá tốt tại hầu hết các trạm khi hệ số xác định R^2 chủ yếu duy trì trên mức 89%, đồng thời các chỉ số sai số MAE và RMSE tương đối thấp. Tuy nhiên, kết quả giữa các trạm vẫn tồn tại sự chênh lệch đáng kể, điều này cho thấy mức độ biến động của dữ liệu Pb tại từng khu vực là không đồng đều.

Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Jeju và Gwangju với giá trị lần lượt đạt 96,50% và 95,50%, điều này phản ánh khả năng mô hình giải thích phương sai dữ liệu rất hiệu quả tại hai khu vực này. Trạm Seosan cũng ghi nhận hiệu suất cao với R^2đạt khoảng 93,31%. Trong khi đó, Ulsan là trạm có kết quả thấp nhất khi R^2 chỉ đạt 81,03%, thấp hơn đáng kể so với các trạm còn lại. Các trạm Seoul, Ansan, Iksan và Daejeon duy trì mức R^2 dao động quanh 89 – 91%, điều này cho

thấy khả năng dự báo tương đối ổn định của mô hình trên phần lớn mạng lưới quan trắc.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,45 và RMSE đạt 0,94, điều này cho thấy sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng đạt mức sai số thấp với MAE khoảng 1,06 và RMSE gần 1,97. Ngược lại, Ulsan ghi nhận sai số lớn nhất khi MAE đạt khoảng 3,89 và RMSE lên tới 16,04, điều này phản ánh dữ liệu tại khu vực này có mức độ biến động cao và khó dự báo hơn. Incheon và Ansan cũng có RMSE tương đối lớn, lần lượt khoảng 12,40 và 10,98. Các trạm còn lại như Seoul, Seosan, Daejeon và Iksan có sai số ở mức trung bình đến thấp, cho thấy mô hình vẫn duy trì được độ chính xác khá tốt.

- **Hiệu suất khi dự đoán của mô hình GAT tinh chỉnh – BiLSTM + MHA:**



Biểu đồ 5. 12. Mức độ hiệu quả của mô hình GAT tinh chỉnh – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - B. 2 và Biểu đồ PL - B. 2 trong PHỤ LỤC B.

Biểu đồ 5. 12 thể hiện mức độ hiệu quả của mô hình GAT tinh chỉnh kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra

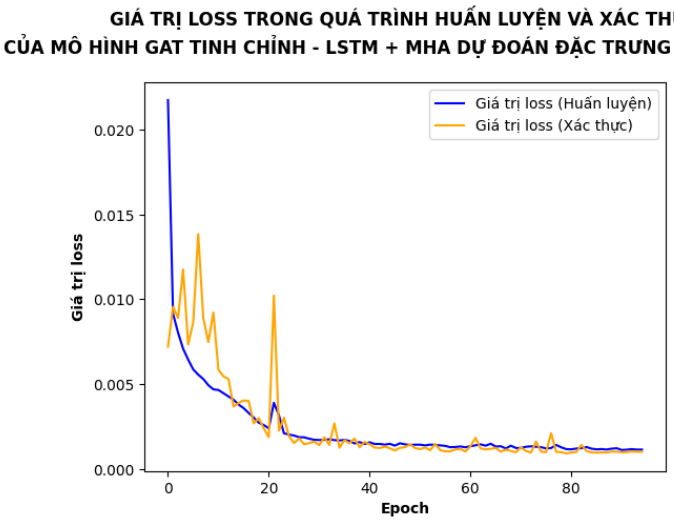
thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình cho thấy khả năng dự báo khá tốt tại phần lớn các trạm khi hệ số xác định R^2 chủ yếu đạt trên 86%, đồng thời các chỉ số sai số MAE và RMSE duy trì ở mức tương đối thấp. Tuy nhiên, hiệu suất mô hình vẫn có sự khác biệt rõ rệt giữa các khu vực quan trắc, điều này phản ánh tính không đồng nhất trong đặc trưng biến động dữ liệu Pb theo từng trạm khí tượng.

Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Gwangju với giá trị khoảng 96,31%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại khu vực này. Seosan và Jeju cũng đạt hiệu suất cao với R^2 lần lượt đạt 94,13% và 93,48%. Trong khi đó, Ulsan tiếp tục là trạm có kết quả thấp nhất khi R^2 chỉ đạt khoảng 80,85%, thấp hơn đáng kể so với các trạm còn lại. Các trạm Ansan, Daejeon và Iksan duy trì mức R^2 xấp xỉ 90%, điều này phản ánh khả năng dự báo ổn định của mô hình. Ngược lại, Seoul và Incheon có mức R^2 thấp hơn, dao động quanh 86 – 87%, điều này cho thấy độ chính xác của mô hình tại hai khu vực này còn hạn chế hơn so với phần lớn các trạm khác.

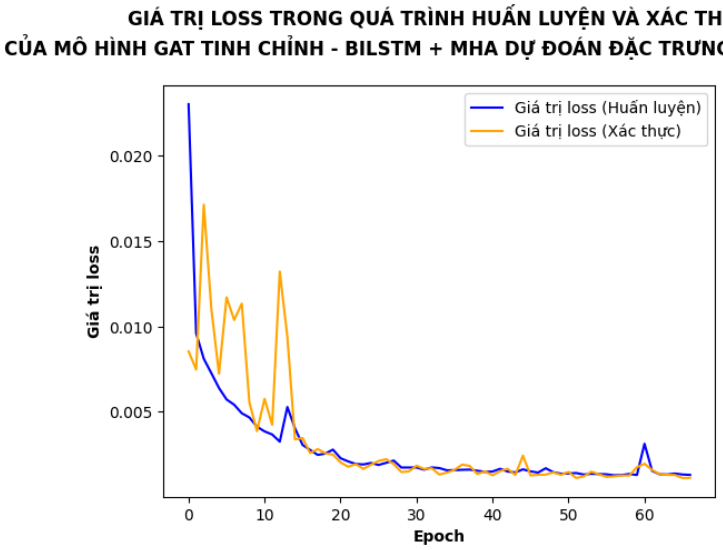
Đối với các chỉ số sai số, Jeju tiếp tục là trạm có hiệu suất tốt nhất với MAE chỉ khoảng 0,41 và RMSE đạt 1,15, điều này cho thấy sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng ghi nhận sai số thấp với MAE khoảng 0,89 và RMSE gần 2,08. Trong khi đó, Ulsan là khu vực có sai số lớn nhất khi MAE đạt khoảng 3,70 và RMSE lên tới 16,76, điều này phản ánh mức độ biến động dữ liệu cao và khó dự báo hơn tại trạm này. Incheon và Ansan cũng có RMSE tương đối lớn, lần lượt khoảng 13,39 và 10,71. Các trạm còn lại như Seoul, Seosan, Daejeon và Iksan có sai số ở mức trung bình đến thấp, điều này cho thấy mô hình vẫn duy trì được độ chính xác tương đối tốt trên phần lớn tập dữ liệu kiểm tra.

5.3.2.2. Đặc trưng zn_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 13. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h



Biểu đồ 5. 14. Giá trị loss của quá trình huấn luyện mô hình GAT tinh chỉnh – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h

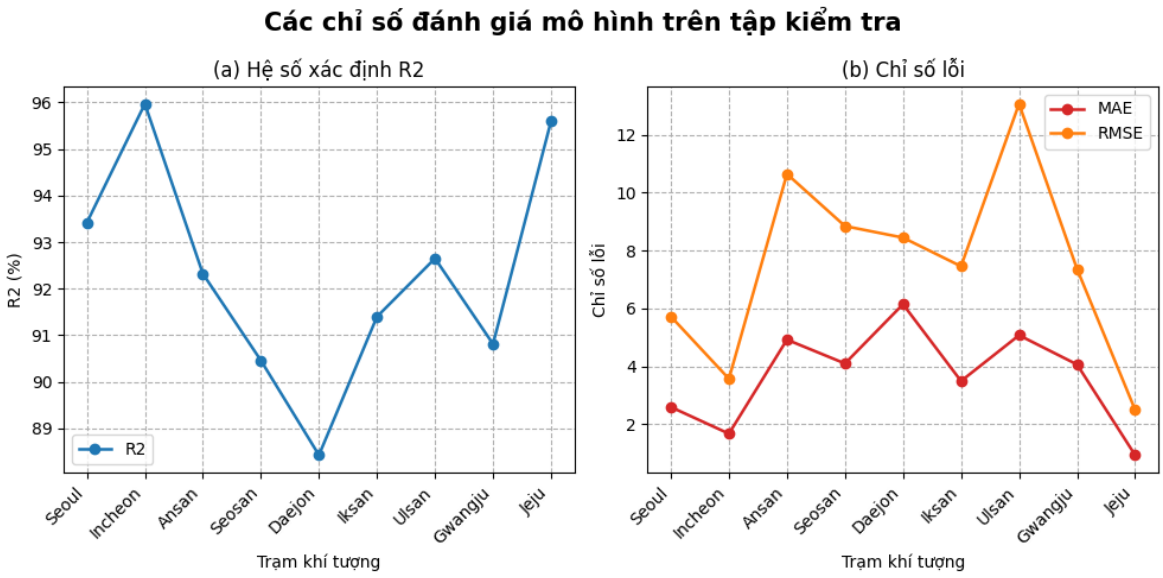
Biểu đồ 5. 13 và Biểu đồ 5. 14 minh họa sự thay đổi của giá trị loss trong quá trình huấn luyện và xác thực của hai mô hình GAT tinh chỉnh kết hợp lần lượt với LSTM + MHA và BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h. Nhìn chung, cả hai mô hình đều cho thấy xu hướng hội tụ rõ rệt khi giá trị loss giảm nhanh trong các epoch đầu tiên và dần ổn định ở giai đoạn sau. Đồng thời, khoảng cách giữa loss

huấn luyện và loss xác thực tương đối nhỏ trong hầu hết quá trình học, điều này cho thấy khả năng tổng quát hóa tốt và chưa xuất hiện hiện tượng overfitting đáng kể.

Đối với mô hình GAT tinh chỉnh – LSTM + MHA, giá trị loss của tập huấn luyện ban đầu ở mức khoảng 0,022 và giảm mạnh xuống dưới 0,005 chỉ sau khoảng 10 epoch đầu tiên. Sau đó, đường loss tiếp tục giảm chậm hơn và ổn định quanh mức 0.001 – 0.002 ở cuối quá trình huấn luyện. Trong khi đó, loss xác thực có xu hướng dao động mạnh hơn ở giai đoạn đầu, đặc biệt xuất hiện một số đỉnh cục bộ quanh các epoch 3 – 5 và khoảng epoch 20. Tuy nhiên, sau giai đoạn biến động ban đầu, đường loss xác thực dần bám sát đường loss huấn luyện và duy trì ở mức thấp ổn định, điều này cho thấy mô hình học hiệu quả và có khả năng thích nghi tốt với dữ liệu xác thực.

Tương tự, mô hình GAT tinh chỉnh – BiLSTM + MHA cũng thể hiện khả năng hội tụ tốt khi giá trị loss huấn luyện giảm liên tục từ khoảng 0,023 xuống gần 0,0015 ở các epoch cuối. Loss xác thực giảm theo xu hướng tương tự nhưng xuất hiện một số dao động đáng chú ý trong giai đoạn đầu, đặc biệt quanh epoch 2 – 6 và epoch 12. Sau khoảng epoch 15, cả hai đường loss đều trở nên ổn định và dao động rất nhỏ quanh mức thấp. So với mô hình LSTM + MHA, mô hình BiLSTM + MHA có tốc độ ổn định nhanh hơn và đường loss xác thực bám sát loss huấn luyện hơn ở giai đoạn cuối, cho thấy khả năng học ổn định và mức độ hội tụ tương đối tốt.

- **Hiệu suất khi dự đoán của mô hình GAT tinh chỉnh – LSTM + MHA:**



Biểu đồ 5. 15. Mức độ hiệu quả của mô hình GAT tinh chỉnh – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - B. 3 và Biểu đồ PL - B. 3 trong PHỤ LỤC B.

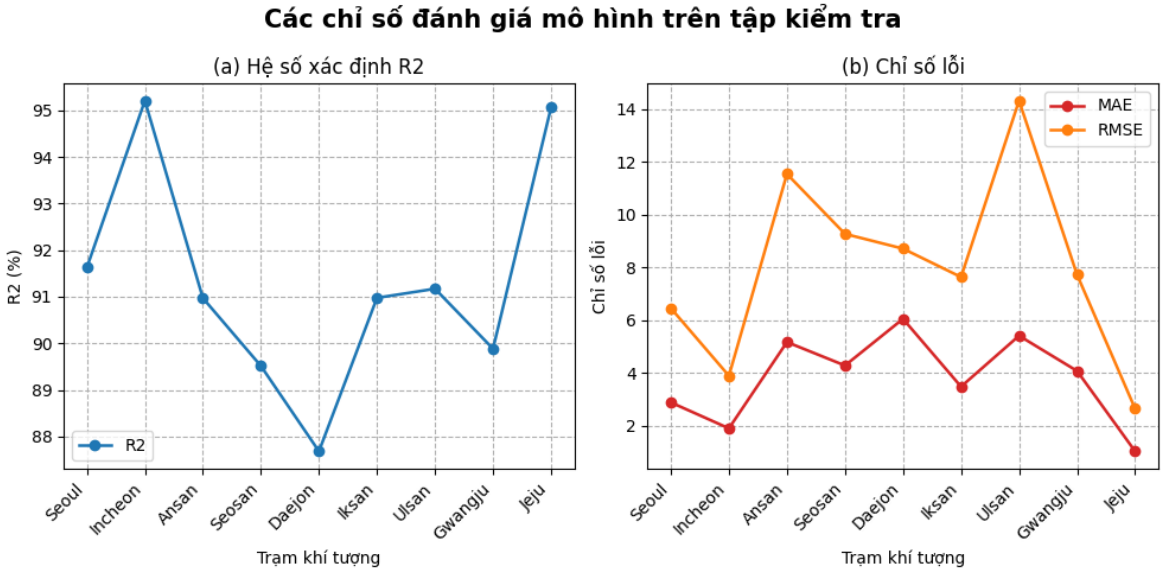
Biểu đồ 5. 15 thể hiện mức độ hiệu quả của mô hình GAT tinh chỉnh kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt hiệu suất dự báo rất tích cực khi hệ số xác định R^2 tại phần lớn các trạm đều vượt mức 90%, đồng thời các chỉ số sai số MAE và RMSE duy trì ở mức tương đối thấp. Tuy nhiên, mức độ hiệu quả của mô hình vẫn có sự khác biệt nhất định giữa các trạm do ảnh hưởng từ đặc tính biến động dữ liệu tại từng khu vực.

Về hệ số xác định R^2, Incheon là trạm đạt kết quả cao nhất với giá trị khoảng 95,97%, điều này cho thấy mô hình có khả năng giải thích phương sai dữ liệu rất tốt. Jeju cũng ghi nhận hiệu suất nổi bật với R^2 đạt khoảng 95,60%, tiếp theo là Seoul với khoảng 93,42%. Các trạm Ulsan, Ansan và Iksan duy trì mức R^2 dao động trong khoảng 91–93%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình. Trong khi đó, Seosan và Gwangju đạt mức trên 90%, điều này cho thấy mô hình vẫn đảm bảo được hiệu quả dự báo khá tốt tại các khu vực này. Ngược lại, Daejeon là

trạm có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 88,43%, thấp hơn đáng kể so với các trạm còn lại, điều này cho thấy dữ liệu tại khu vực này có độ phức tạp cao hơn và khó mô hình hóa chính xác.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,94 và RMSE đạt gần 2,50, điều này phản ánh độ sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng ghi nhận sai số thấp với MAE khoảng 1,68 và RMSE khoảng 3,57. Ngược lại, Ulsan là khu vực có RMSE lớn nhất với giá trị khoảng 13,06, đồng thời MAE cũng ở mức khá cao khoảng 5,08, điều này cho thấy dữ liệu tại đây có mức độ biến động lớn và khó dự báo hơn. Daejeon ghi nhận MAE cao nhất, đạt khoảng 6,15, mặc dù RMSE chỉ ở mức khoảng 8,45. Ansan và Seosan cũng có RMSE tương đối lớn, lần lượt khoảng 10,64 và 8,84, phản ánh mô hình vẫn tồn tại sai số nhất định tại các khu vực này. Trong khi đó, Seoul, Iksan và Gwangju duy trì sai số ở mức trung bình đến thấp, điều này cho thấy khả năng dự báo tương đối ổn định trên phần lớn các trạm khí tượng.

- **Hiệu suất khi dự đoán của mô hình GAT tinh chỉnh – BiLSTM + MHA:**



Biểu đồ 5. 16. Mức độ hiệu quả của mô hình GAT tinh chỉnh – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - B. 4 và Biểu đồ PL - B. 4 trong PHỤ LỤC B.

Biểu đồ 5. 16 thể hiện mức độ hiệu quả của mô hình GAT tinh chỉnh kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình đạt hiệu suất dự báo khá tốt trên phần lớn các trạm khi hệ số xác định R^2 chủ yếu dao động trong khoảng 88 – 95%. Đồng thời, các chỉ số sai số MAE và RMSE duy trì ở mức tương đối thấp, điều này cho thấy mô hình có khả năng học hiệu quả mối quan hệ không gian – thời gian của dữ liệu Zn. Tuy nhiên, sự chênh lệch kết quả giữa các trạm cho thấy mức độ ổn định của mô hình vẫn chịu ảnh hưởng bởi đặc điểm biến động dữ liệu tại từng khu vực quan trắc.

Về hệ số xác định R^2, Incheon là trạm đạt kết quả cao nhất với giá trị khoảng 95,21%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt. Jeju cũng ghi nhận hiệu suất nổi bật với R^2 đạt khoảng 95,06%, tiếp theo là Seoul với khoảng 91,62%. Các trạm Ulsan, Iksan và Ansan duy trì mức R^2 dao động quanh 91%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình. Trong khi đó, Gwangju và Seosan đạt mức gần 90%, điều này cho thấy mô hình vẫn đảm bảo hiệu quả dự báo khá tốt tại các khu vực này. Ngược lại, Daejeon là trạm có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 87,68%, thấp hơn đáng kể so với các trạm còn lại, điều này cho thấy dữ liệu tại khu vực này có độ phức tạp cao hơn và khó được mô hình hóa chính xác.

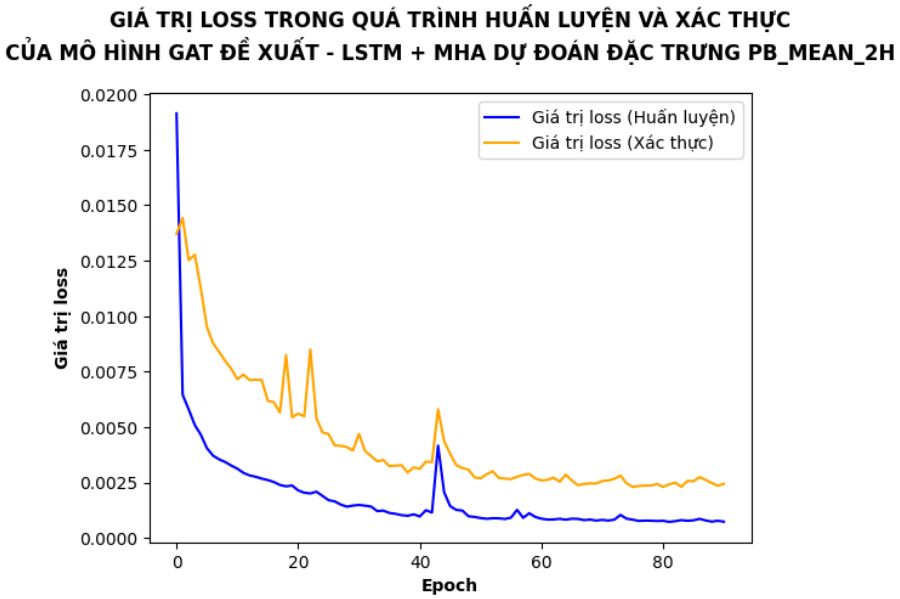
Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 1,04 và RMSE đạt gần 2,65, phản ánh độ sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng ghi nhận sai số thấp với MAE khoảng 1,91 và RMSE khoảng 3,90. Ngược lại, Ulsan là khu vực có RMSE lớn nhất với giá trị khoảng 14,32, đồng thời MAE cũng ở mức khá cao khoảng 5,42, cho thấy dữ liệu tại đây có mức độ biến động lớn và khó dự báo hơn. Daejeon ghi nhận MAE cao nhất, đạt khoảng 6,05, mặc dù RMSE chỉ ở mức khoảng 8,71. Ansan và Seosan cũng có RMSE tương đối

lớn, lần lượt khoảng 11,54 và 9,27, điều này phản ánh mô hình vẫn còn tồn tại sai số đáng kể tại các khu vực này. Trong khi đó, Seoul, Iksan và Gwangju duy trì sai số ở mức trung bình đến thấp, cho thấy khả năng dự báo tương đối ổn định trên phần lớn các trạm khí tượng.

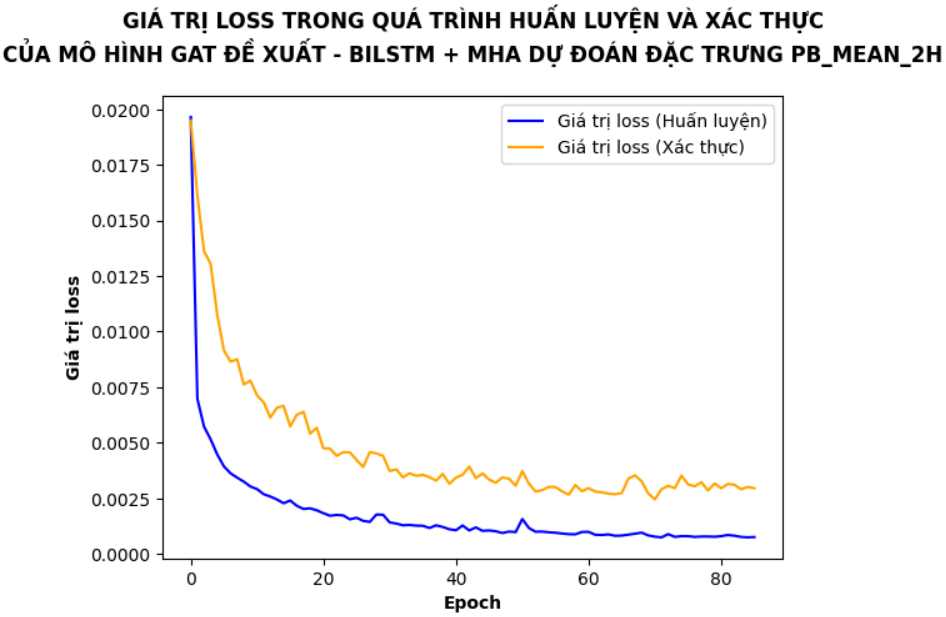
5.3.3. Kết quả thực nghiệm mô hình GAT đề xuất – LSTM/BiLSTM + MHA

5.3.3.1. Đặc trưng pb_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 17. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – LSTM + MHA trong dự đoán đặc trưng pb_mean_2h



Biểu đồ 5. 18. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – BiLSTM + MHA trong dự đoán đặc trưng pb_mean_2h

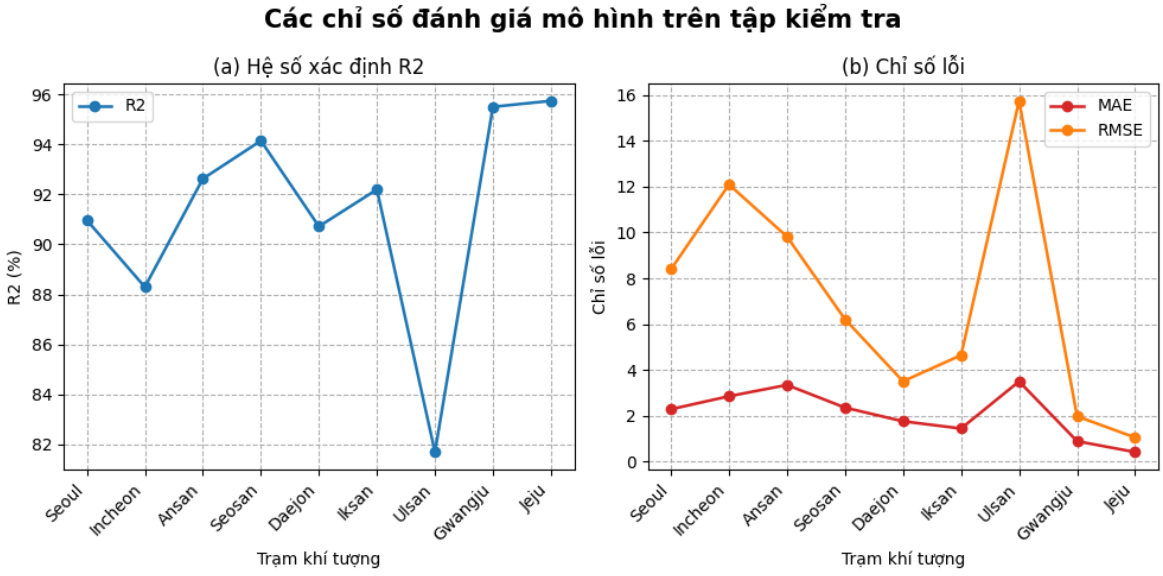
Biểu đồ 5. 17 và Biểu đồ 5. 18 trình bày sự thay đổi của giá trị loss trong quá trình huấn luyện và xác thực đối với hai kiến trúc GAT đề xuất kết hợp lần lượt với LSTM + MHA và BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h. Nhìn chung, cả hai mô hình đều thể hiện khả năng hội tụ tốt khi giá trị loss giảm mạnh trong các epoch đầu tiên và dần ổn định ở các giai đoạn sau của quá trình huấn luyện. Đồng thời, khoảng cách giữa loss huấn luyện và loss xác thực được duy trì ở mức tương đối hợp lý, điều này cho thấy mô hình có khả năng tổng quát hóa tốt và chưa xuất hiện dấu hiệu overfitting nghiêm trọng.

Đối với mô hình GAT đề xuất – LSTM + MHA, giá trị loss của tập huấn luyện giảm nhanh từ khoảng 0,019 xuống dưới 0,005 chỉ sau vài epoch đầu tiên và tiếp tục giảm dần về gần 0,001 ở cuối quá trình huấn luyện. Trong khi đó, loss xác thực giảm từ khoảng 0,014 xuống dao động quanh mức 0,0025 – 0,003 ở các epoch cuối. Mặc dù vẫn xuất hiện một số dao động cục bộ tại các giai đoạn giữa quá trình huấn luyện, đặc biệt quanh epoch 18 – 22 và gần epoch 43, nhưng biên độ biến động không lớn và đường loss nhanh chóng trở lại trạng thái ổn định. Điều này cho thấy mô hình duy

trì được tính ổn định trong quá trình tối ưu và học được đặc trưng dữ liệu tương đối hiệu quả trên tập xác thực.

Tương tự, mô hình GAT đề xuất – BiLSTM + MHA cũng cho thấy tốc độ hội tụ nhanh với giá trị loss giảm đáng kể ngay từ các epoch đầu tiên. Loss huấn luyện giảm từ gần 0,02 xuống khoảng 0,001 ở cuối quá trình học, trong khi loss xác thực giảm dần và ổn định quanh mức 0,003 sau giai đoạn hội tụ. So với mô hình kết hợp với LSTM + MHA, đường loss xác thực của mô hình kết hợp với BiLSTM + MHA có xu hướng mượt và ổn định hơn trong phần lớn quá trình huấn luyện nhưng vẫn tồn tại một số dao động nhỏ ở các epoch cuối. Nhìn chung, cả hai mô hình GAT đề xuất đều đạt khả năng hội tụ tốt và duy trì hiệu suất ổn định.

- **Hiệu suất khi dự đoán của mô hình GAT đề xuất – LSTM + MHA:**



Biểu đồ 5. 19. Mức độ hiệu quả của mô hình GAT đề xuất – LSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - C. 1 và Biểu đồ PL - C. 1 trong PHỤ LỤC C.

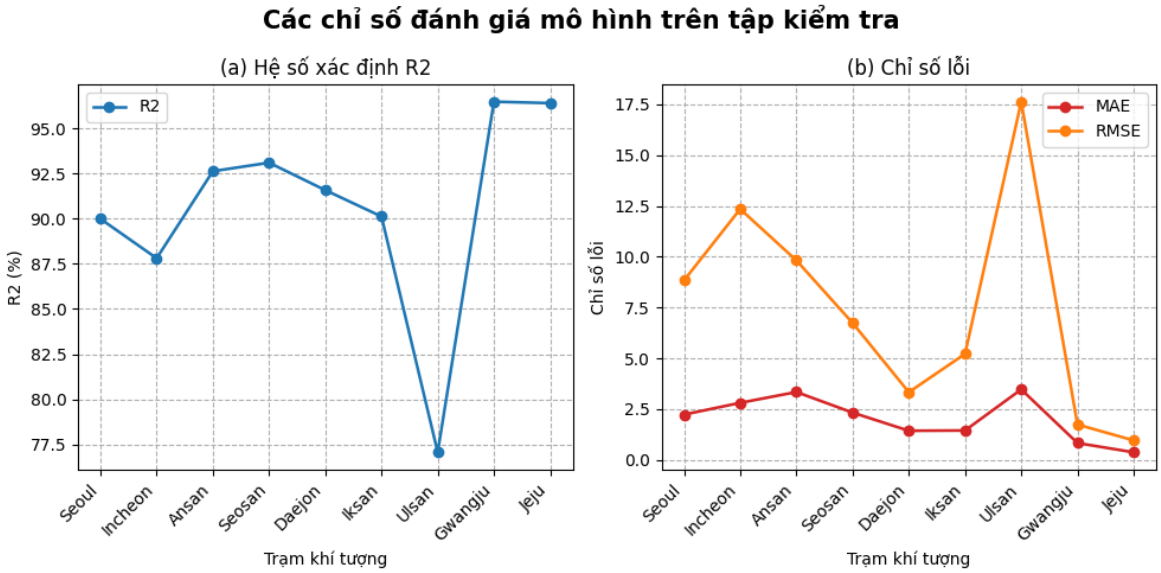
Biểu đồ 5. 19 thể hiện mức độ hiệu quả của mô hình GAT đề xuất kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau.

Nhìn chung, mô hình đạt hiệu suất dự báo tốt trên phần lớn các trạm khi hệ số xác định R^2 chủ yếu duy trì trên 90%, đồng thời các chỉ số sai số MAE và RMSE ở mức tương đối thấp. Điều này cho thấy mô hình có khả năng học hiệu quả đặc trưng không gian – thời gian của dữ liệu Pb. Tuy nhiên, sự khác biệt về hiệu suất giữa các trạm vẫn tồn tại, phản ánh mức độ biến động không đồng nhất của dữ liệu tại từng khu vực quan trắc.

Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Jeju và Gwangju với giá trị lần lượt đạt 95,73% và 95,50%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại hai khu vực này. Seosan và Ansan cũng ghi nhận hiệu suất cao với R^2 đạt khoảng 94,14% và 92,62%. Ngoài ra, Iksan đạt mức R^2 khoảng 92,19%, điều này phản ánh khả năng dự báo ổn định của mô hình. Trong khi đó, Ulsan tiếp tục là trạm có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 81,69%, thấp hơn đáng kể so với các trạm còn lại. Các trạm Seoul, Incheon và Daejeon duy trì mức R^2 dao động trong khoảng 88–91%, điều này cho thấy mô hình vẫn đạt độ chính xác tương đối tốt trên phần lớn mạng lưới quan trắc.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,40 và RMSE đạt 1,04, điều này cho thấy sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng ghi nhận sai số thấp với MAE khoảng 0,88 và RMSE gần 1,97. Ngược lại, Ulsan là khu vực có sai số lớn nhất khi MAE đạt khoảng 3,49 và RMSE lên tới 15,76, điều này phản ánh dữ liệu tại khu vực này có mức độ biến động cao và khó dự báo hơn. Incheon và Ansan cũng có RMSE tương đối lớn, lần lượt khoảng 12,10 và 9,82. Các trạm còn lại như Seoul, Seosan, Daejeon và Iksan có sai số ở mức trung bình đến thấp, điều này cho thấy mô hình vẫn duy trì được độ chính xác khá tốt trên tập dữ liệu kiểm tra.

- **Hiệu suất khi dự đoán của mô hình GAT đề xuất – BiLSTM + MHA:**



Biểu đồ 5. 20. Mức độ hiệu quả của mô hình GAT đề xuất – BiLSTM + MHA dự đoán pb_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - C. 2 và Biểu đồ PL - C. 2 trong PHỤ LỤC C.

Biểu đồ 5. 20 thể hiện mức độ hiệu quả của mô hình GAT đề xuất kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình cho thấy hiệu suất dự báo tương đối tốt trên hầu hết các trạm khi hệ số xác định R^2 chủ yếu đạt trên 90%, đồng thời các chỉ số sai số MAE và RMSE duy trì ở mức thấp. Điều này cho thấy mô hình có khả năng học hiệu quả đặc trưng không gian – thời gian của dữ liệu Pb. Tuy nhiên, sự chênh lệch hiệu suất giữa các khu vực vẫn tồn tại, đặc biệt tại Ulsan, phản ánh tính biến động phức tạp của dữ liệu tại từng trạm quan trắc.

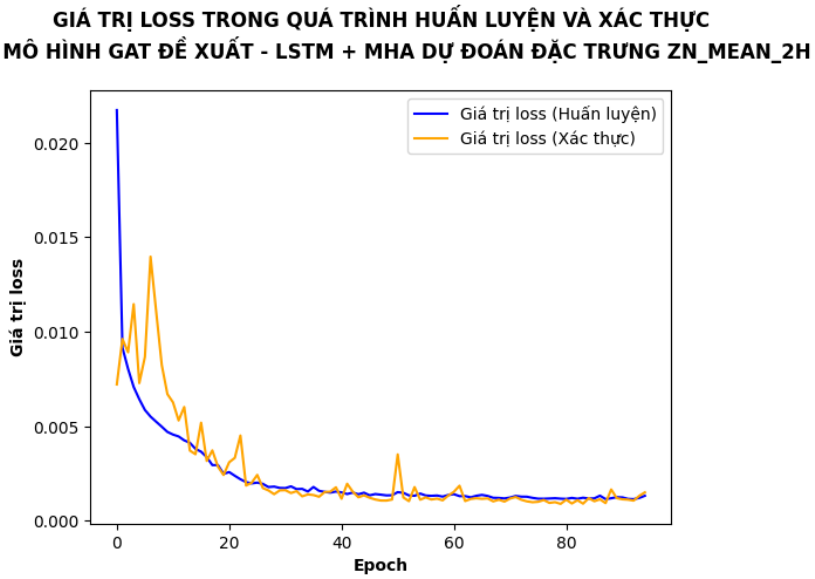
Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Gwangju và Jeju với giá trị lần lượt đạt 96,47% và 96,39%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại hai khu vực này. Seosan và Ansan cũng ghi nhận hiệu suất cao với R^2 đạt khoảng 93,09% và 92,62%, trong khi Daejeon và Iksan duy trì mức trên 90%, điều này phản ánh khả năng dự báo ổn định của mô hình. Seoul đạt gần 90%, còn

Incheon thấp hơn đôi chút với khoảng 87,81%. Ngược lại, Ulsan tiếp tục là trạm có hiệu suất thấp nhất khi R^2 chỉ đạt khoảng 77,07%, thấp hơn đáng kể so với các trạm còn lại, điều này cho thấy mô hình gặp khó khăn hơn trong việc mô phỏng xu hướng dữ liệu tại khu vực này.

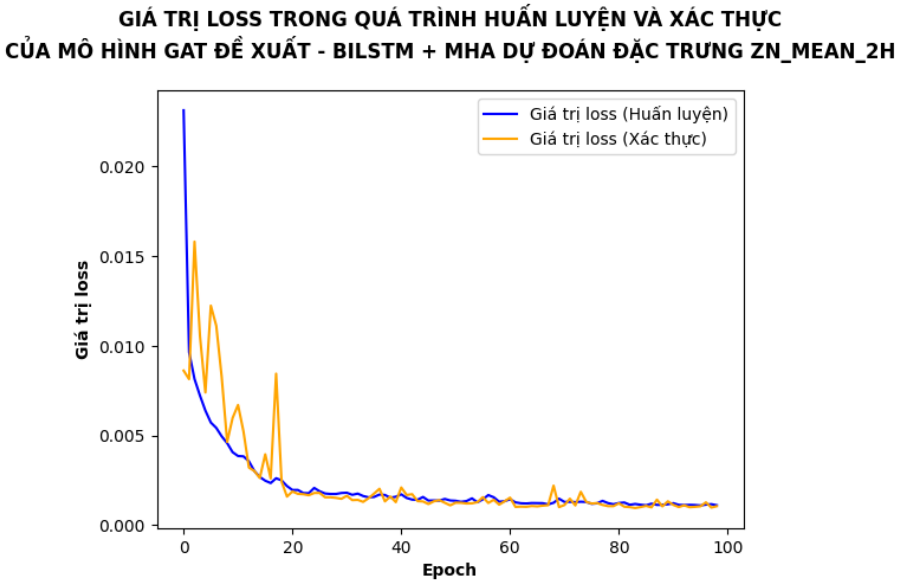
Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất với MAE chỉ khoảng 0,37 và RMSE đạt 0,96, cho thấy sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Gwangju cũng ghi nhận sai số thấp với MAE khoảng 0,83 và RMSE gần 1,74. Ngược lại, Ulsan là khu vực có sai số lớn nhất khi MAE đạt khoảng 3,47 và RMSE lên tới 17,63, phản ánh dữ liệu tại đây có mức độ biến động cao và khó dự báo hơn. Incheon và Ansan cũng có RMSE tương đối lớn, lần lượt khoảng 12,35 và 9,82. Trong khi đó, các trạm Seoul, Seosan, Daejeon và Iksan duy trì sai số ở mức trung bình đến thấp, với RMSE dao động từ khoảng 3,33 đến 8,84.

5.3.3.2. Đặc trưng zn_mean_2h

- **Quá trình huấn luyện mô hình:**



Biểu đồ 5. 21. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – LSTM + MHA trong dự đoán đặc trưng zn_mean_2h



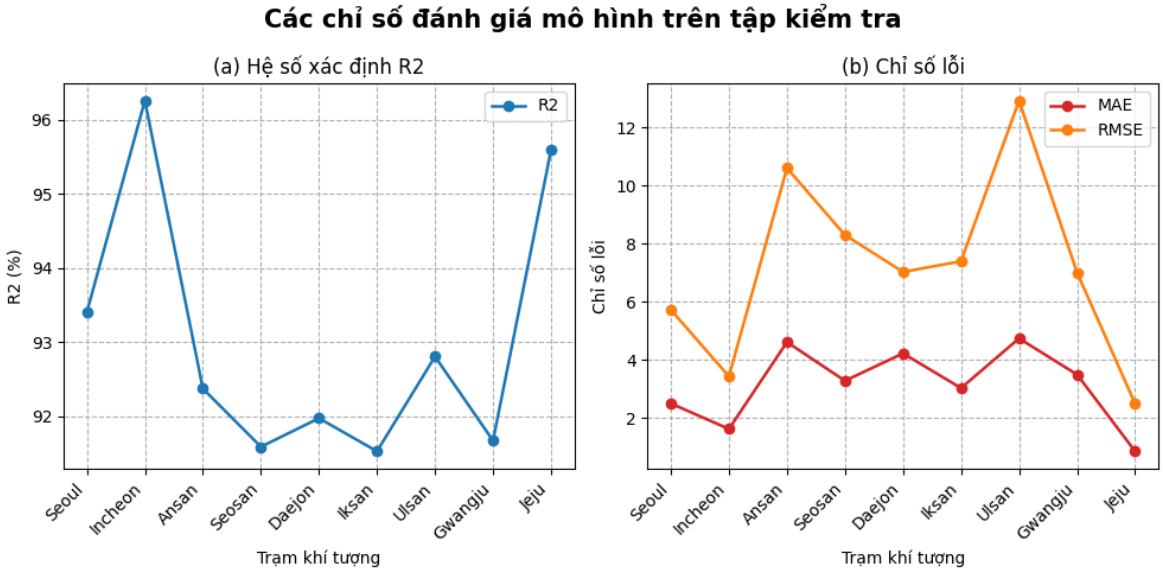
Biểu đồ 5. 22. Giá trị loss của quá trình huấn luyện mô hình GAT đề xuất – BiLSTM + MHA trong dự đoán đặc trưng zn _mean_2h

Biểu đồ 5. 21 và Biểu đồ 5. 22 minh họa sự thay đổi của giá trị loss trong quá trình huấn luyện và xác thực của hai mô hình GAT đề xuất kết hợp với LSTM + MHA và BiLSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h. Nhìn chung, cả hai mô hình đều cho thấy xu hướng hội tụ rõ rệt khi giá trị loss giảm mạnh ở các epoch đầu tiên và dần ổn định về cuối quá trình huấn luyện. Đồng thời, khoảng cách giữa đường loss huấn luyện và loss xác thực tương đối nhỏ, điều này cho thấy hai mô hình có khả năng tổng quát hóa tốt và chưa xuất hiện dấu hiệu overfitting đáng kể.

Đối với mô hình GAT – LSTM + MHA, giá trị loss huấn luyện ban đầu ở mức khoảng 0,022 và giảm nhanh xuống dưới 0,005 sau khoảng 10 epoch đầu tiên. Sau đó, tốc độ giảm chậm lại và đường loss dần ổn định quanh mức 0,001 – 0,002 ở giai đoạn cuối. Trong khi đó, loss xác thực có mức dao động lớn hơn ở thời gian đầu, với một số đỉnh tăng đáng chú ý xuất hiện quanh epoch 3 – 6 và gần epoch 20. Tuy nhiên, từ khoảng epoch 25 trở đi, đường loss xác thực bám khá sát loss huấn luyện và duy trì ở mức thấp ổn định, điều này cho thấy mô hình học hiệu quả và thích nghi tương đối tốt với dữ liệu xác thực.

Tương tự, mô hình GAT – BiLSTM + MHA cũng thể hiện khả năng hội tụ tốt khi loss huấn luyện giảm liên tục từ khoảng 0,023 xuống gần 0,001 ở các epoch cuối. Loss xác thực giảm theo xu hướng tương tự nhưng xuất hiện dao động mạnh hơn trong giai đoạn đầu, đặc biệt tại các epoch 2 – 5 và khoảng epoch 15 – 17. Sau khoảng epoch 20, cả hai đường loss trở nên ổn định và gần như chồng sát lên nhau. So với mô hình LSTM + MHA, mô hình BiLSTM + MHA cho thấy tốc độ hội tụ nhanh hơn và độ ổn định cao hơn ở giai đoạn cuối qua việc loss xác thực ít dao động và bám sát đường loss huấn luyện hơn.

- **Hiệu suất khi dự đoán của mô hình GAT đề xuất – LSTM + MHA:**



Biểu đồ 5. 23. Mức độ hiệu quả của mô hình GAT đề xuất – LSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - C. 3 và Biểu đồ PL - C. 3 trong PHỤ LỤC C.

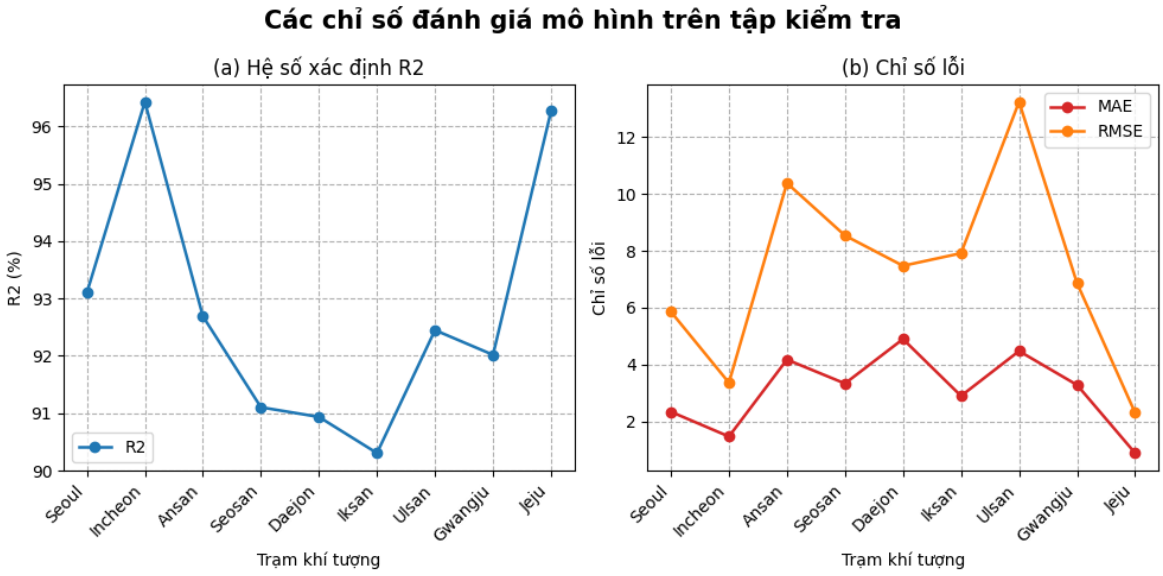
Biểu đồ 5. 23 thể hiện mức độ hiệu quả của mô hình GAT đề xuất kết hợp LSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình cho thấy hiệu suất dự báo rất tốt và ổn định khi hệ số xác định R^2 tại tất cả các trạm đều duy trì trên 91%, đồng thời các chỉ số sai số MAE và RMSE

ở mức tương đối thấp. Điều này cho thấy mô hình có khả năng học hiệu quả mối quan hệ không gian – thời gian của dữ liệu Zn. Tuy nhiên, sự khác biệt nhất định giữa các khu vực vẫn tồn tại, phản ánh mức độ biến động dữ liệu khác nhau tại từng trạm quan trắc.

Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Incheon với giá trị khoảng 96,26%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại khu vực này. Jeju cũng ghi nhận hiệu suất cao với R^2 đạt khoảng 95,60%, tiếp theo là Seoul với khoảng 93,40%. Các trạm Ulsan, Ansan, Daejeon và Gwangju duy trì mức R^2 dao động từ khoảng 91,67% đến 92,80%, điều này phản ánh khả năng dự báo tương đối ổn định của mô hình. Trong khi đó, Seosan và Iksan là hai khu vực có hiệu suất thấp nhất, với R^2 lần lượt đạt khoảng 91,59% và 91,52%, tuy nhiên mức này vẫn cho thấy mô hình có độ phù hợp cao đối với dữ liệu kiểm tra.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất khi MAE chỉ khoảng 0,87 và RMSE đạt khoảng 2,50, điều này cho thấy độ sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng ghi nhận sai số thấp với MAE khoảng 1,63 và RMSE khoảng 3,44. Ngược lại, Ulsan là khu vực có sai số lớn nhất khi MAE đạt khoảng 4,75 và RMSE lên tới 12,92, phản ánh dữ liệu tại đây có mức độ biến động cao và khó dự báo hơn. Ansan cũng có RMSE tương đối lớn với khoảng 10,61. Trong khi đó, các trạm Seoul, Seosan, Daejeon, Iksan và Gwangju duy trì sai số ở mức trung bình đến thấp, với RMSE dao động khoảng từ 5,73 đến 8,30.

- **Hiệu suất khi dự đoán của mô hình GAT đề xuất – BiLSTM + MHA:**



Biểu đồ 5. 24. Mức độ hiệu quả của mô hình GAT đề xuất – BiLSTM + MHA dự đoán zn_mean_2h thông qua các chỉ số đánh giá trên tập kiểm tra

Số liệu chi tiết được trình bày ở Bảng PL - C. 4 và Biểu đồ PL - C. 4 trong PHỤ LỤC C.

Biểu đồ 5. 24 thể hiện mức độ hiệu quả của mô hình GAT đề xuất kết hợp BiLSTM + MHA trong bài toán dự đoán đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE tại các trạm khí tượng khác nhau. Nhìn chung, mô hình cho thấy hiệu suất dự báo tốt và tương đối ổn định trên hầu hết các trạm khi hệ số xác định R^2 chủ yếu đạt trên 90%, đồng thời các chỉ số sai số MAE và RMSE được duy trì ở mức thấp đến trung bình. Điều này cho thấy mô hình có khả năng học hiệu quả đặc trưng không gian – thời gian của dữ liệu Zn. Tuy nhiên, mức độ hiệu quả giữa các khu vực vẫn có sự chênh lệch nhất định, phản ánh tính biến động khác nhau của dữ liệu tại từng trạm khí tượng.

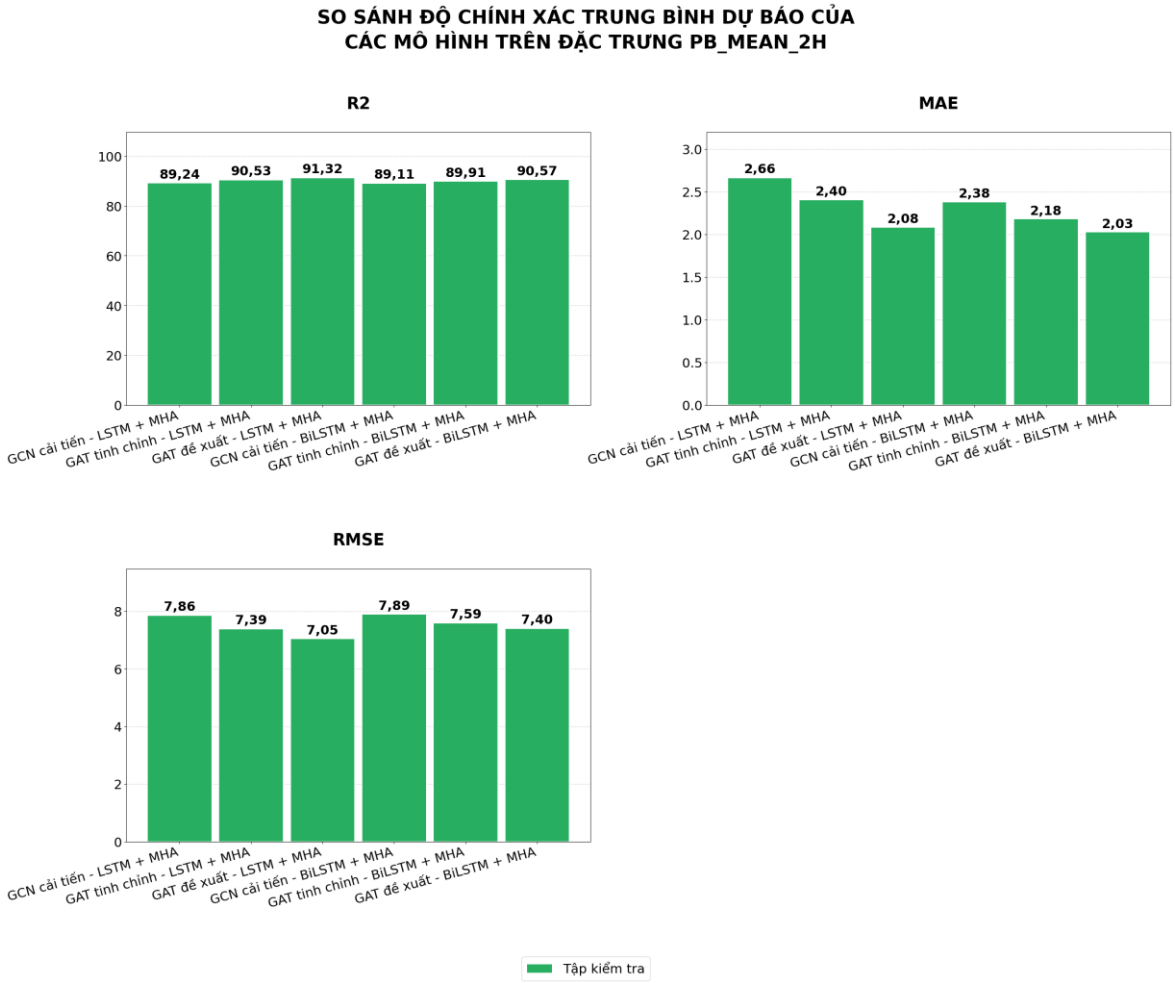
Về hệ số xác định R^2, mô hình đạt kết quả cao nhất tại Incheon với giá trị khoảng 96,43%, điều này cho thấy khả năng giải thích phương sai dữ liệu rất tốt tại khu vực này. Jeju cũng ghi nhận hiệu suất rất cao với R^2 đạt khoảng 96,27%, tiếp theo là Seoul với khoảng 93,10%. Các trạm Ansan, Ulsan và Gwangju duy trì mức R^2 dao động từ khoảng 92,02% đến 92,69%, điều này phản ánh khả năng dự báo ổn

định của mô hình. Trong khi đó, Seosan, Daejeon và Iksan là những khu vực có hiệu suất thấp hơn, với R^2 lần lượt đạt khoảng 91,10%, 90,94% và 90,31%, tuy nhiên các giá trị này vẫn cho thấy mô hình có độ phù hợp cao đối với dữ liệu kiểm tra.

Đối với các chỉ số sai số, Jeju tiếp tục là trạm có kết quả tốt nhất khi MAE chỉ khoảng 0,89 và RMSE đạt khoảng 2,31, cho thấy mức sai lệch giữa giá trị dự đoán và thực tế là rất nhỏ. Incheon cũng đạt sai số thấp với MAE khoảng 1,47 và RMSE khoảng 3,36. Ngược lại, Ulsan là khu vực có sai số lớn nhất khi MAE đạt khoảng 4,48 và RMSE lên tới 13,24, phản ánh dữ liệu tại đây có độ biến động cao và khó dự báo hơn so với các khu vực khác. Ansan cũng ghi nhận RMSE tương đối lớn với khoảng 10,38. Trong khi đó, các trạm Seoul, Seosan, Daejeon, Iksan và Gwangju duy trì sai số ở mức trung bình, với RMSE dao động khoảng từ 5,86 đến 8,54. Nhìn chung, mô hình GAT đề xuất – BiLSTM + MHA cho thấy khả năng dự báo hiệu quả và đáng tin cậy trên phần lớn các trạm khí tượng, đặc biệt tại các khu vực có dữ liệu ổn định và ít biến động bất thường.

5.4. So sánh kết quả thực nghiệm

5.4.1. Đặc trưng pb_mean_2h



Biểu đồ 5. 25: So sánh độ chính xác trung bình dự báo của các mô hình trên đặc trưng pb_mean_2h

Số liệu chi tiết được trình bày ở Bảng PL - D. 1 trong PHỤ LỤC D.

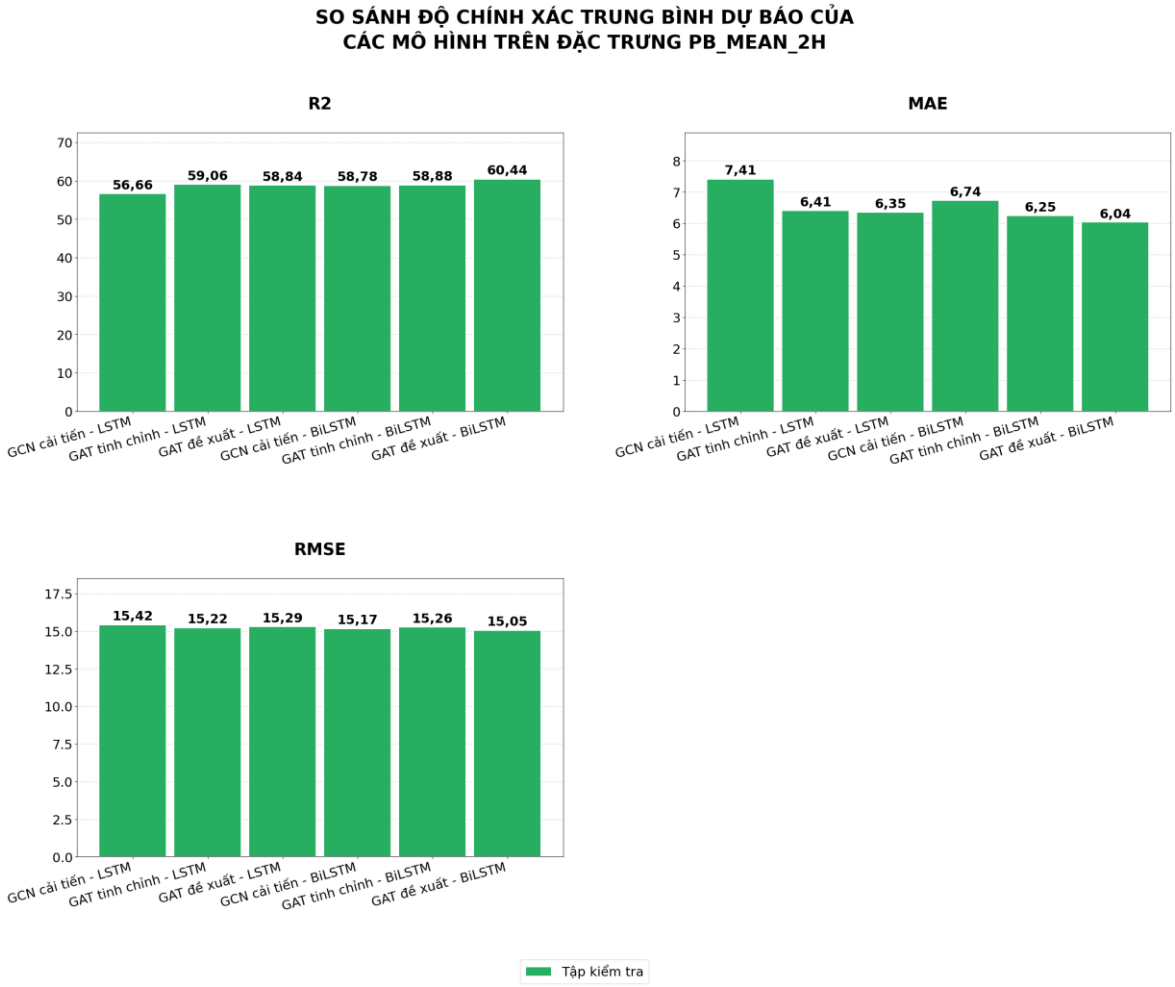
Biểu đồ 5. 25 thể hiện sự so sánh độ chính xác trung bình của sáu mô hình trong bài toán dự báo đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE. Nhìn chung, các mô hình sử dụng kiến trúc GAT đều cho kết quả tốt hơn so với các mô hình sử dụng GCN cải tiến, điều này cho thấy việc cải thiện cơ chế học biểu diễn trên đồ thị đã góp phần nâng cao khả năng dự báo của mô hình. Trong số đó, mô hình GAT đề xuất kết hợp với LSTM + MHA là mô

hình đạt hiệu quả nổi bật nhất, điều này cho thấy khả năng khai thác mối quan hệ không gian – thời gian giữa các nút trong đồ thị tốt hơn so với các cấu hình còn lại. Ngược lại, mô hình GCN cải tiến kết hợp với LSTM + MHA lại cho kết quả thấp nhất hoặc gần thấp nhất ở hầu hết các chỉ số đánh giá.

Đối với chỉ số R^2, mô hình GAT đề xuất – LSTM + MHA đạt giá trị cao nhất là 91,32%, cao hơn khoảng 2,08% so với mô hình GCN cải tiến – LSTM + MHA, vốn chỉ đạt 89,24%. Bên cạnh đó, mô hình GAT đề xuất - BiLSTM + MHA với 90,57% và mô hình GAT tinh chỉnh – LSTM + MHA với 90,53% cũng đã cho thấy hiệu quả vượt trội hơn rõ rệt so với nhóm mô hình GCN cải tiến. Xu hướng tương tự tiếp tục xuất hiện ở chỉ số MAE, trong đó mô hình GAT đề xuất – BiLSTM + MHA đạt giá trị thấp nhất là 2,03, theo sau là mô hình GAT đề xuất – LSTM + MHA với 2,08. Trong khi đó, mô hình GCN cải tiến – LSTM + MHA có giá trị MAE lớn nhất là 2,66, cao hơn khoảng 23,68% so với mô hình tốt nhất.

Đối với chỉ số RMSE, mô hình GAT đề xuất – LSTM + MHA tiếp tục đạt kết quả tốt nhất với giá trị thấp nhất là 7,05, tiếp theo là mô hình GAT tinh chỉnh – LSTM + MHA với 7,39 và mô hình GAT đề xuất – BiLSTM + MHA với 7,40. Trong khi đó, hai mô hình thuộc nhóm GCN cải tiến có RMSE cao hơn đáng kể, lần lượt đạt 7,86 và 7,89, điều này cho thấy mức độ sai lệch giữa giá trị dự báo và giá trị thực tế của nhóm mô hình này vẫn còn lớn hơn so với các mô hình sử dụng GAT. Nhìn chung, kết quả phân tích cho thấy việc cải tiến cơ chế biểu diễn đồ thị, đặc biệt là trong mô hình GAT đề xuất, đã mang lại sự cải thiện rõ rệt về chất lượng dự báo đối với đặc trưng pb_mean_2h. Bênh cạnh đó, kiến trúc LSTM, vốn có khả năng ghi nhớ phụ thuộc theo thời gian hiệu quả, nhìn chung vẫn cho kết quả nhỉnh hơn so với BiLSTM, mặc dù khoảng chênh lệch giữa hai biến thể này không quá lớn.

Ngoài ra, các biến thể của các mô hình không sử dụng cơ chế MHA cũng đã mang lại kết quả khá tích cực. Kết quả cụ thể được trình bày như sau:



Biểu đồ 5. 26. So sánh độ chính xác trung bình dự báo của các biến thể mô hình không có MHA trên đặc trưng pb_mean_2h

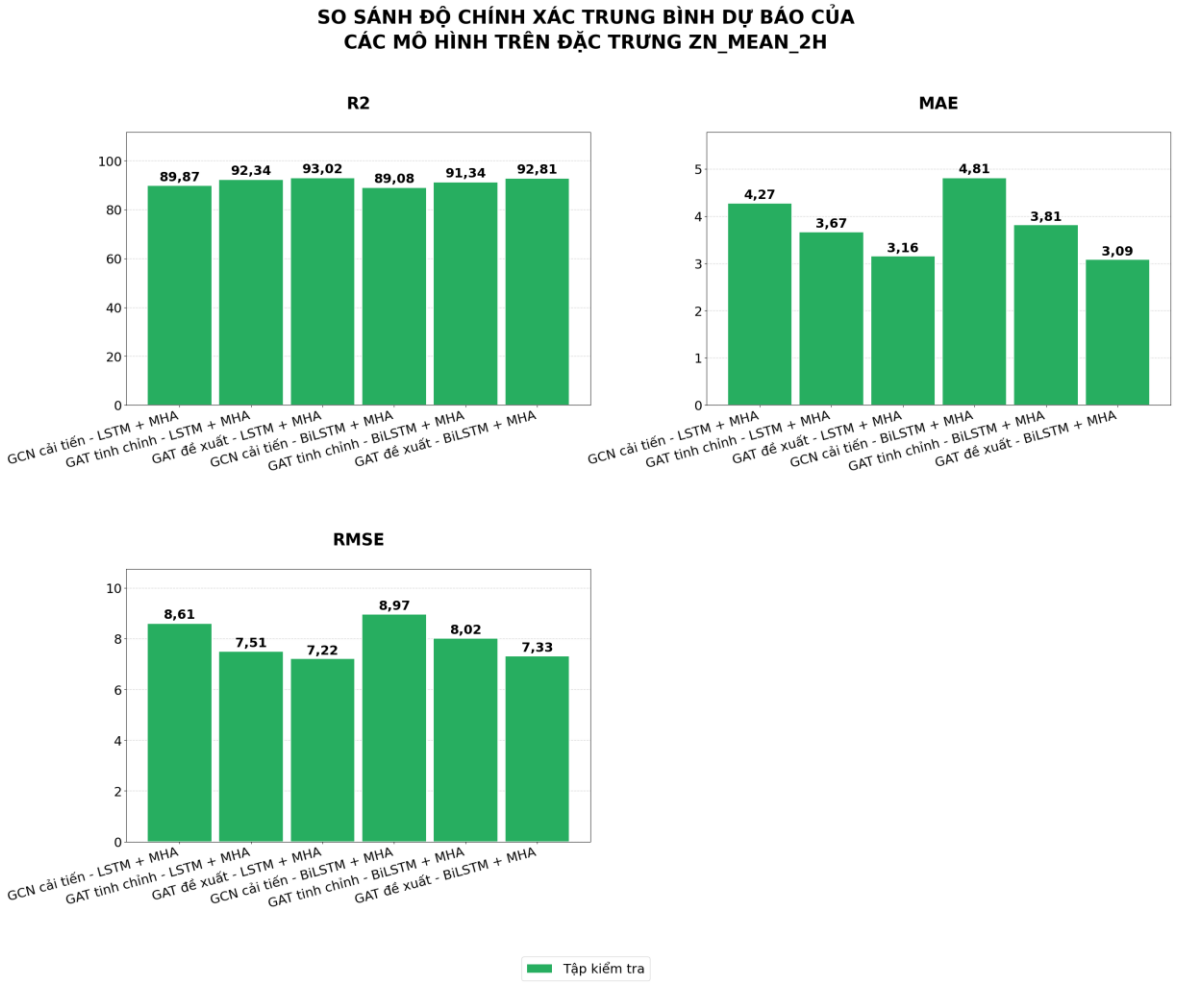
Số liệu chi tiết được trình bày ở Bảng PL - D. 2 trong PHỤ LỤC D.

Biểu đồ 5. 26 thể hiện sự so sánh độ chính xác trung bình của sáu biến thể mô hình không sử dụng cơ chế MHA trong bài toán dự báo đặc trưng pb_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE. Nhìn chung, các mô hình sử dụng kiến trúc GAT tiếp tục cho kết quả tốt hơn so với các mô hình sử dụng GCN cải tiến, điều này cho thấy cơ chế attention trên đồ thị vẫn phát huy hiệu quả ngay cả khi không kết hợp với MHA. Trong số đó, mô hình GAT đề xuất kết hợp với BiLSTM là mô hình đạt hiệu quả nổi bật nhất ở phần lớn các chỉ số, trong khi mô hình GCN cải tiến kết hợp với LSTM lại cho kết quả thấp nhất hoặc gần thấp nhất ở hầu hết các trường hợp đánh giá.

Đối với chỉ số R^2, mô hình GAT đề xuất – BiLSTM đạt giá trị cao nhất là 60,44%, cao hơn khoảng 3,78% so với mô hình GCN cải tiến – LSTM, vốn chỉ đạt 56,66%. Ngoài ra, mô hình GAT tinh chỉnh – LSTM đạt 59,06%, trong khi mô hình GAT đề xuất – LSTM đạt 58,84%, điều này cho thấy các biến thể thuộc nhóm GAT đều duy trì khả năng học đặc trưng tốt hơn so với nhóm GCN cải tiến. Xu hướng này cũng xuất hiện ở chỉ số MAE, trong đó mô hình GAT đề xuất – BiLSTM đạt giá trị thấp nhất là 6,04, tiếp theo là mô hình GAT tinh chỉnh – BiLSTM với 6,25 và mô hình GAT đề xuất – LSTM với 6,35. Trong khi đó, mô hình GCN cải tiến – LSTM có giá trị MAE lớn nhất là 7,41, cao hơn khoảng 22,68% so với mô hình đạt kết quả tốt nhất, điều này cho thấy khả năng dự báo của nhóm mô hình GAT ổn định và chính xác hơn đáng kể.

Đối với chỉ số RMSE, mô hình GAT đề xuất – BiLSTM tiếp tục đạt kết quả tốt nhất với giá trị thấp nhất là 15,05, theo sau là mô hình GCN cải tiến – BiLSTM với 15,17 và mô hình GAT tinh chỉnh – LSTM với 15,22. Trong khi đó, mô hình GCN cải tiến – LSTM có RMSE cao nhất là 15,42, điều này phản ánh mức độ sai lệch giữa giá trị dự báo và giá trị thực tế vẫn còn lớn hơn so với các mô hình còn lại. Tuy nhiên, có thể nhận thấy khoảng chênh lệch RMSE giữa các mô hình trong trường hợp không sử dụng MHA là không quá lớn, điều này cho thấy khả năng cải thiện của các kiến trúc GAT chủ yếu được thể hiện rõ hơn ở chỉ số R^2 và MAE. Nhìn chung, kết quả phân tích cho thấy việc áp dụng cơ chế chú ý trên đồ thị, đặc biệt là trong mô hình GAT đề xuất vẫn mang lại hiệu quả cải thiện chất lượng dự báo ngay cả khi không sử dụng MHA. Bên cạnh đó, kiến trúc BiLSTM trong trường hợp này nhìn chung cho kết quả tốt hơn so với LSTM, cho thấy khả năng khai thác thông tin hai chiều theo chuỗi thời gian đã hỗ trợ mô hình dự báo hiệu quả hơn.

5.4.2. Đặc trưng zn_mean_2h



Biểu đồ 5. 27. So sánh độ chính xác trung bình dự báo của các mô hình trên đặc trưng zn_mean_2h

Số liệu chi tiết được trình bày ở Bảng PL - D. 1 trong PHỤ LỤC D.

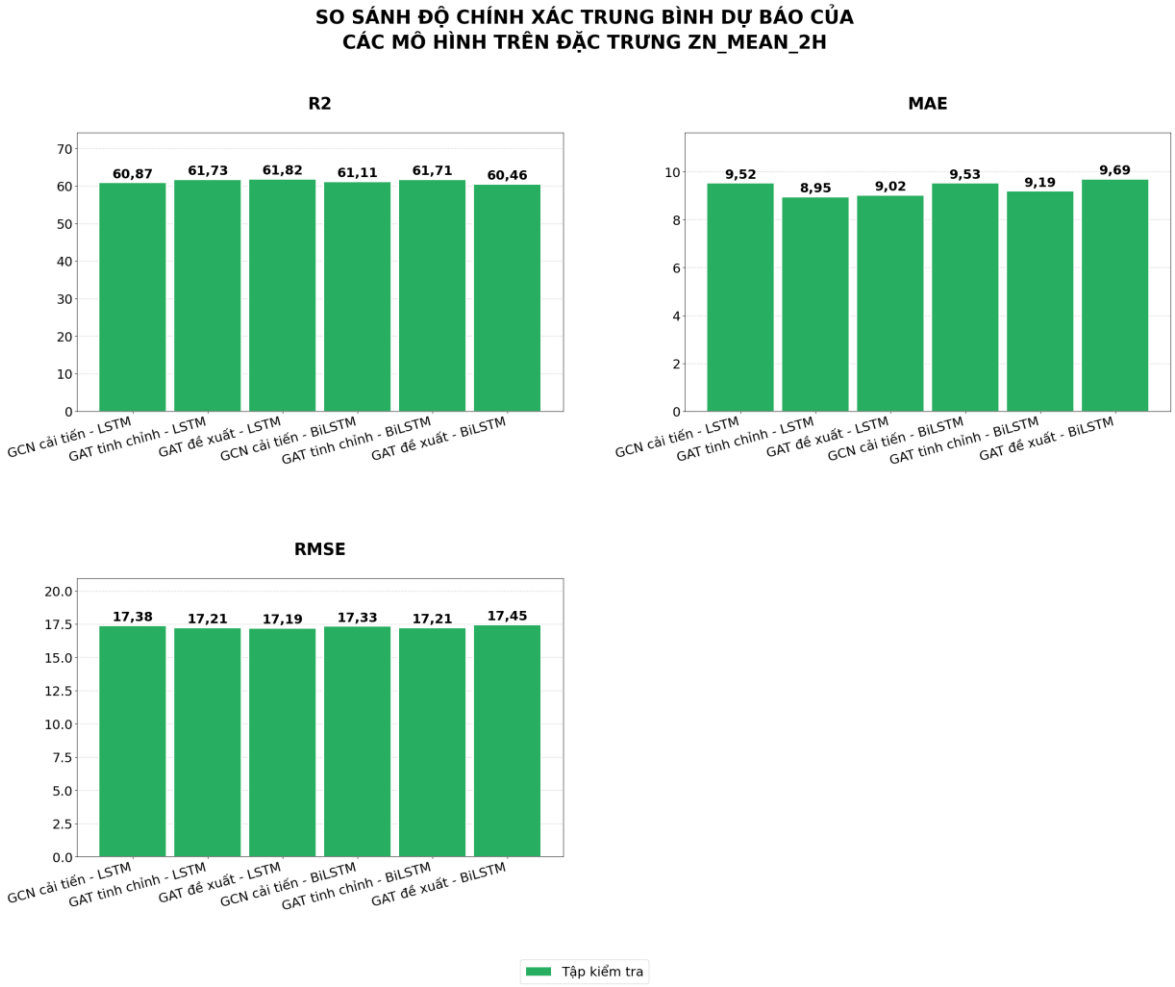
Biểu đồ 5. 27 thể hiện sự so sánh độ chính xác trung bình của sáu mô hình trong bài toán dự báo đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE. Nhìn chung, các mô hình sử dụng kiến trúc GAT tiếp tục cho kết quả vượt trội hơn so với nhóm mô hình GCN cải tiến ở hầu hết các chỉ số. Đặc biệt, mô hình GAT đề xuất kết hợp với LSTM + MHA cho thấy hiệu quả nổi bật nhất khi đồng thời đạt giá trị R^2 cao nhất và các sai số thấp nhất, cho thấy khả năng khai thác hiệu quả mối quan hệ không gian – thời gian trong dữ liệu

zn_mean_2h. Ngược lại, mô hình GCN cải tiến kết hợp với BiLSTM + MHA cho kết quả kém nhất ở cả MAE và RMSE.

Đối với chỉ số R^2, mô hình GAT đề xuất – LSTM + MHA đạt giá trị cao nhất là 93,02%, cao hơn khoảng 3,95% so với mô hình GCN cải tiến – BiLSTM + MHA chỉ đạt 89,08%. Ngoài ra, mô hình GAT tinh chỉnh – LSTM + MHA và mô hình GAT đề xuất – BiLSTM + MHA cũng cho kết quả rất tích cực, lần lượt đạt 92,34% và 92,81%. Xu hướng này tiếp tục được thể hiện ở chỉ số MAE khi mô hình GAT đề xuất – BiLSTM + MHA đạt giá trị thấp nhất là 3,09, theo sau là mô hình GAT đề xuất – LSTM + MHA với 3,16. Trong khi đó, mô hình GCN cải tiến - BiLSTM + MHA có MAE lớn nhất là 4,81, cao hơn khoảng 55,66% so với mô hình tốt nhất, cho thấy độ sai lệch trung bình trong dự báo của nhóm GCN cải tiến vẫn còn khá lớn.

Đối với chỉ số RMSE, mô hình GAT đề xuất – LSTM + MHA tiếp tục đạt kết quả tốt nhất với giá trị thấp nhất là 7,22, tiếp theo là mô hình GAT đề xuất – BiLSTM + MHA với 7,33 và mô hình GAT tinh chỉnh - LSTM + MHA với 7,51. Ngược lại, hai mô hình thuộc nhóm GCN cải tiến có RMSE cao hơn đáng kể, đặc biệt mô hình GCN cải tiến – BiLSTM + MHA đạt RMSE lớn nhất là 8,97. Điều này cho thấy sai số dự báo của nhóm mô hình GCN cải tiến vẫn còn chênh lệch khá lớn so với giá trị thực tế. Nhìn chung, kết quả phân tích cho thấy việc cải tiến cơ chế học đồ thị, đặc biệt là trong mô hình GAT đề xuất đã mang lại sự cải thiện rõ rệt về chất lượng dự báo đối với đặc trưng zn_mean_2h. Đồng thời, kiến trúc LSTM nhìn chung vẫn cho hiệu quả ổn định và chính xác hơn so với BiLSTM trong phần lớn các trường hợp thử nghiệm.

Ngoài ra, các biến thể của các mô hình không sử dụng cơ chế MHA cũng đã mang lại kết quả khá tốt. Kết quả cụ thể được trình bày như sau:



Biểu đồ 5. 28. So sánh độ chính xác trung bình dự báo của các biến thể mô hình không có MHA trên đặc trưng zn_mean_2h

Số liệu chi tiết được trình bày ở Bảng PL - D. 4 trong PHỤ LỤC D.

Biểu đồ 5. 28 thể hiện sự so sánh độ chính xác trung bình của sáu biến thể mô hình không sử dụng cơ chế MHA trong bài toán dự báo đặc trưng zn_mean_2h trên tập kiểm tra thông qua ba chỉ số đánh giá gồm R^2, MAE và RMSE. Nhìn chung, các mô hình sử dụng kiến trúc GAT tiếp tục cho kết quả tốt hơn so với các mô hình sử dụng GCN cải tiến, điều này cho thấy cơ chế chú ý trên đồ thị vẫn duy trì được hiệu quả trong việc học mối quan hệ không gian giữa các nút ngay cả khi không kết hợp với MHA. Trong số đó, mô hình GAT đề xuất kết hợp với LSTM là mô hình đạt hiệu quả nổi bật nhất ở phần lớn các chỉ số đánh giá, cho thấy khả năng dự báo đặc trưng zn_mean_2h ổn định và chính xác hơn so với các cấu hình còn lại. Ngược lại, mô

hình GAT đề xuất kết hợp với BiLSTM lại cho kết quả thấp hơn ở chỉ số MAE và RMSE mặc dù vẫn duy trì được giá trị R^2 tương đối cao.

Đối với chỉ số R^2, mô hình GAT đề xuất – LSTM đạt giá trị cao nhất là 61,82%, cao hơn khoảng 0,95% so với mô hình GCN cải tiến – LSTM, vốn chỉ đạt 60,87%. Ngoài ra, mô hình GAT tinh chỉnh – LSTM và mô hình GAT tinh chỉnh – BiLSTM cũng cho kết quả tương đối tích cực với giá trị R^2 lần lượt đạt 61,73% và 61,71%. Trong khi đó, mô hình GAT đề xuất – BiLSTM chỉ đạt 60,46%, thấp hơn nhẹ so với phần lớn các mô hình còn lại. Xu hướng tương tự tiếp tục xuất hiện ở chỉ số MAE, trong đó mô hình GAT tinh chỉnh – LSTM đạt giá trị thấp nhất là 8,95, theo sau là mô hình GAT đề xuất – LSTM với 9,02. Ngược lại, mô hình GAT đề xuất – BiLSTM có MAE lớn nhất là 9,69, cao hơn khoảng 8,27% so với mô hình đạt kết quả tốt nhất, điều này cho thấy độ sai lệch trung bình trong dự báo của mô hình này vẫn còn khá lớn.

Đối với chỉ số RMSE, mô hình GAT đề xuất – LSTM tiếp tục đạt kết quả tốt nhất với giá trị thấp nhất là 17,19, tiếp theo là hai mô hình GAT tinh chỉnh – LSTM và GAT tinh chỉnh – BiLSTM cùng đạt 17,21. Trong khi đó, mô hình GAT đề xuất – BiLSTM có RMSE lớn nhất là 17,45, điều này phản ánh mức độ sai lệch giữa giá trị dự báo và giá trị thực tế vẫn còn cao hơn so với các mô hình còn lại. Tuy nhiên, có thể nhận thấy khoảng chênh lệch RMSE giữa các mô hình là không quá lớn, điều này cho thấy các biến thể mô hình không sử dụng MHA vẫn có khả năng duy trì độ ổn định nhất định trong quá trình dự báo. Nhìn chung, kết quả phân tích cho thấy việc áp dụng cơ chế chú ý trên đồ thị, đặc biệt là trong mô hình GAT đề xuất – LSTM,đã mang lại hiệu quả cải thiện đáng kể về chất lượng dự báo đối với đặc trưng zn_mean_2h. Đồng thời, kiến trúc LSTM nhìn chung tiếp tục cho hiệu quả ổn định hơn so với BiLSTM trong phần lớn các trường hợp thử nghiệm khi không sử dụng MHA.

5.5. Tóm tắt chương

Chương 5 là chương thực nghiệm của nghiên cứu, nơi các kiến trúc mô hình đề xuất được kiểm chứng một cách toàn diện trên bộ dữ liệu quan trắc thực tế.

Kết quả thực nghiệm của ba nhóm mô hình chính đã cung cấp bức tranh rõ ràng về ưu và nhược điểm của từng kiến trúc trong bài toán dự đoán nồng độ bụi PM10 theo không gian và thời gian. Việc so sánh hệ thống trên cả hai đặc trưng pb_mean_2h và zn_mean_2h cho phép đánh giá tính tổng quát của các mô hình trên các loại chất ô nhiễm khác nhau. Các kết quả định lượng đã cho thấy sự đóng góp có ý nghĩa của từng thành phần trong kiến trúc đề xuất, đặc biệt là vai trò của cơ chế MHA và sự kết hợp giữa BiLSTM với các module học đặc trưng không gian dựa trên đồ thị.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Tóm tắt kết quả nghiên cứu

Trong đề tài "DỰ ĐOÁN HÀM LƯỢNG CHẤT Ô NHIỄM TRONG BỤI PM_{10} SỬ DỤNG MÔ HÌNH HỌC SÂU VÀ DỮ LIỆU QUAN TRẮC", tôi đã triển khai và đánh giá ba nhóm mô hình học sâu dựa trên kiến trúc đồ thị kết hợp chuỗi thời gian nhằm dự đoán hàm lượng chất ô nhiễm trong bụi PM_{10} tại 9 trạm khí tượng trong giai đoạn 2024 – 2025. Ba nhóm kiến trúc chính được xem xét gồm: GCN cải tiến, GAT tinh chỉnh và GAT đề xuất, mỗi nhóm được kết hợp với hai biến thể xử lý chuỗi thời gian là LSTM + MHA và BiLSTM + MHA.

1.1. Về mặt phân tích dữ liệu

Kết quả phân tích dữ liệu cho thấy sự phân hóa nồng độ chất ô nhiễm rõ rệt dựa trên đặc điểm địa lý và mức độ đô thị hóa. Các trạm khu vực phía Bắc và vùng thủ đô (Seoul, Incheon, Ansan) luôn ghi nhận hàm lượng Pb và Zn cao hơn đáng kể so với khu vực miền Nam. Đặc biệt, Ansan được xác định là khu vực ô nhiễm nhất với nồng độ Pb trung bình đạt 22,72 ng/m^3, cao hơn từ 3,5 đến 6,5 lần so với các trạm phía Nam, nguyên nhân chủ yếu do chịu tác động mạnh từ các hoạt động sản xuất công nghiệp quy mô lớn. Ngược lại, trạm Jeju cho thấy môi trường không khí ổn định và sạch nhất với nồng độ Pb thấp nhất (3,49 ng/m^3), điều này phản ánh đặc trưng của vùng đảo biệt lập ít nguồn thải công nghiệp. Ngoài ra, mức độ tương quan giữa các trạm miền Tây (Iksan – Gwangju) cũng đạt được hệ số cao (0,53) trong khi các trạm ven biển phía Đông như Ulsan lại thể hiện các biến động đặc thù và độc lập hơn.

Hơn thế nữa, nghiên cứu đã chỉ ra tính quy luật mùa vụ nhất quán tại tất cả các trạm quan trắc. Hàm lượng các chất ô nhiễm thường xuyên đạt đỉnh vào mùa Đông và đầu mùa Xuân (từ tháng 11 đến tháng 3 năm sau) và giảm mạnh vào mùa Hè (tháng 7 – 8) nhờ hiệu ứng rửa trôi của mưa. Xét về xu hướng dài hạn giai đoạn 2020 – 2025, đặc trưng Zn cho thấy sự suy giảm rõ rệt và bền vững tại hầu hết các trạm, tiêu biểu như Incheon giảm hơn 50% nồng độ sau 6 năm. Trong khi đó, biến động của Pb có

phần phức tạp hơn khi xuất hiện các giai đoạn phục hồi nồng độ vào cuối kỳ tại các trạm Seoul và Incheon, cho thấy áp lực ô nhiễm Pb vẫn còn hiện hữu và có xu hướng gia tăng cục bộ tại các đô thị lớn.

1.2. Về mặt thực nghiệm

Kết quả so sánh giữa các mô hình có và không có cơ chế MHA cho thấy việc tích hợp MHA mang lại cải thiện đáng kể về chất lượng dự báo. Các mô hình có MHA đều đạt R^2 cao hơn và sai số thấp hơn đáng kể so với các biến thể không sử dụng MHA, khẳng định vai trò quan trọng của cơ chế này trong việc tổng hợp thông tin theo thời gian.

Kết quả thực nghiệm cho thấy các mô hình thuộc nhóm GCN cải tiến đạt hiệu quả dự báo ở mức trung bình so với toàn bộ các kiến trúc được đánh giá. Đối với đặc trưng pb_mean_2h, mô hình GCN cải tiến – LSTM + MHA đạt R^2 trung bình 89,24%, MAE là 2,66 và RMSE là 7,86. Trong khi đó biến thể BiLSTM + MHA cải thiện nhẹ với R^2 đạt 90,53%, MAE là 2,40 và RMSE là 7,89. Đối với đặc trưng zn_mean_2h, mô hình GCN cải tiến – LSTM + MHA đạt R^2 trung bình 89,07%, MAE là 4,27 và RMSE là 8,61, trong khi biến thể BiLSTM + MHA cho kết quả thấp nhất trong toàn bộ thực nghiệm với R^2 chỉ đạt 89,08%, MAE lên tới 4,81 và RMSE là 8,97. Dù các mô hình GCN cải tiến vẫn duy trì được R^2 trên 85% tại phần lớn các trạm, chúng bộc lộ hạn chế trong việc phân biệt mức độ quan trọng khác nhau giữa các kết nối trong đồ thị, dẫn đến hiệu suất thấp hơn so với các kiến trúc GAT ở hầu hết chỉ số đánh giá.

Ngược lại, về nhóm mô hình GAT tinh chỉnh, việc áp dụng cơ chế chú ý trên đồ thị đã mang lại cải thiện rõ rệt so với GCN cải tiến. Cơ chế này cho phép mô hình học được trọng số khác nhau cho từng cạnh trong đồ thị, từ đó phản ánh chính xác hơn mức độ ảnh hưởng giữa các trạm quan trắc. Đối với đặc trưng pb_mean_2h, mô hình GAT tinh chỉnh – LSTM + MHA đạt R^2 trung bình 90,53%, MAE là 2,38 và RMSE là 7,39, trong khi biến thể BiLSTM + MHA đạt R^2 là 89,11%, MAE là 2,18 và RMSE là 7,59. Đối với đặc trưng zn_mean_2h, mô hình GAT tinh chỉnh – LSTM + MHA cho kết quả tích cực với R^2 đạt 92,34%, MAE là 3,67 và RMSE là 7,51, trong

khi biến thể BiLSTM + MHA đạt R^2 là 91,34%, MAE là 3,81 và RMSE là 8,02. Nhìn chung, nhóm GAT tinh chỉnh thể hiện sự ổn định tốt hơn giữa các trạm so với GCN cải tiến, đặc biệt tại các khu vực có mối quan hệ không gian phức tạp.

Đáng chú ý, về nhóm mô hình GAT đề xuất, đây là kiến trúc cải tiến sâu nhất được đề xuất trong đề tài và cũng là nhóm đạt hiệu quả dự báo cao nhất trong toàn bộ thực nghiệm. Đối với đặc trưng pb_mean_2h, mô hình GAT đề xuất – LSTM + MHA đạt R^2 trung bình cao nhất là 91,32%, RMSE thấp nhất là 7,05 và MAE là 2,08. Biến thể BiLSTM + MHA cũng cho kết quả rất tốt với R^2 đạt 90,57%, MAE thấp nhất toàn bộ thực nghiệm là 2,03 và RMSE là 7,40. Đối với đặc trưng zn_mean_2h, mô hình GAT đề xuất – LSTM + MHA tiếp tục dẫn đầu với R^2 đạt 93,02% — cao nhất trong tất cả các mô hình — RMSE thấp nhất là 7,22 và MAE là 3,16. Biến thể BiLSTM + MHA cũng ghi nhận kết quả xuất sắc với R^2 đạt 92,01%, MAE thấp nhất toàn bộ thực nghiệm là 3,09 và RMSE là 7,33. Sự vượt trội của GAT đề xuất so với hai nhóm còn lại cho thấy các cải tiến về kiến trúc đã giúp mô hình khai thác hiệu quả hơn cả mối quan hệ không gian giữa các nút lẫn phụ thuộc thời gian trong chuỗi dữ liệu.

Tổng thể, kết quả nghiên cứu khẳng định rằng việc cải tiến cơ chế biểu diễn đồ thị theo hướng attention-based, kết hợp với xử lý chuỗi thời gian hai chiều và cơ chế MHA là hướng tiếp cận hiệu quả cho bài toán dự báo hàm lượng chất ô nhiễm trong bụi PM_{10}. Đồng thời, quy trình xây dựng đồ thị dựa trên ngưỡng tương quan dữ liệu, cùng với việc phân chia dữ liệu theo trình tự thời gian và đánh giá đa chỉ số trên tập kiểm tra độc lập đã đảm bảo tính khách quan và khả năng tái lập của kết quả thực nghiệm.

2. Hạn chế của nghiên cứu

Mặc dù đạt được kết quả khả quan, đề tài vẫn tồn tại một số hạn chế sau đây:

1. Dữ liệu huấn luyện chỉ sử dụng một đặc trưng đầu vào duy nhất cho mỗi mô hình trong khi hàm lượng chất ô nhiễm trong bụi PM_{10} trên thực tế chịu tác động đồng thời của nhiều yếu tố khí tượng và môi trường như nhiệt độ, độ ẩm, hướng gió và các chất ô nhiễm khác.

2. Mô hình hiện tại chỉ thực hiện dự báo một bước thời gian phía trước, chưa đáp ứng được nhu cầu dự báo nhiều bước liên tiếp.
3. Ma trận kề được xây dựng dựa trên ngưỡng tương quan cố định (threshold = 0,05), chưa phản ánh được sự thay đổi động theo thời gian của mối liên kết giữa các trạm quan trắc, đặc biệt khi có sự thay đổi về điều kiện khí hậu theo mùa.

3. Hướng phát triển trong tương lai

Dựa trên những kết quả đạt được và hạn chế đã nhận diện, tôi đề xuất một số hướng nghiên cứu tiếp theo trong tương lai như sau:

1. Mở rộng đầu vào mô hình bằng cách tích hợp đồng thời nhiều đặc trưng khí tượng như nhiệt độ, độ ẩm, tốc độ gió và các chất ô nhiễm liên quan để khai thác đầy đủ hơn các mối tương quan đa chiều, từ đó nâng cao khả năng dự báo toàn diện về chất lượng không khí.
2. Hướng nghiên cứu về dự báo đa bước cần được ưu tiên phát triển nhằm tạo ra các dự báo trước nhiều giờ hoặc nhiều ngày phục vụ cảnh báo ô nhiễm.
3. Xây dựng đồ thị động thay vì ma trận kề tĩnh giúp mô hình thích nghi tốt hơn với sự thay đổi theo mùa của mối liên kết giữa các trạm.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

[1] B. Q. Trung*, và cộng sự.*, "Đánh giá thành phần kim loại và các bon trong bụi PM_{10} tại một khu vực đô thị ở Hà Nội trong giai đoạn mùa hè 2020," (in Vietnam), *Tạp chí Khoa học Công nghệ Xây dựng (TCKHCNXD)-ĐHXDHN,* vol. 15, no. 4V, pp. 62–70, 2021.

[2] N. Hoà, H. M. Trí, and N. Đ. Đông, *Giáo trình Lý thuyết đồ thị*. Trường Đại học Sài Gòn (in Vietnam), 2022.

[3] B. H. Đạt and H. T. T. Ngọc, "Ứng dụng mô hình học sâu dự báo nhiệt độ không khí cảm nhận tại Việt Nam," Khóa luận tốt nghiệp Kỹ sư Công nghệ thông tin, Trường Đại học Sài Gòn, 2025.

[4] Chính phủ. (2022). *Nghị định 06/2022/NĐ-CP ngày 7/1/2022 ban hành quy định giảm nhẹ phát thải khí nhà kính và bảo vệ tầng ô-dôn. Hà Nội*. [Trực tuyến] Địa chỉ: https://vanban.chinhphu.vn/?pageid=27160&docid=205421

[5] Bộ Tài nguyên và Môi trường, "Quy chuẩn kỹ thuật quốc gia về chất lượng không khí xung quanh," NXB Tài nguyên - Môi trường và Bản đồ Việt Nam, 2013. [Trực tuyến]. Địa chỉ: https://www.env.go.jp/air/tech/ine/asia/vietnam/files/law/QCVN%2005-2013.pdf#:~:text=1,h%C6%A1n%20ho%E1%BA%B7c%20b%E1%BA%B1ng%2010%20%CE%BCm

Tài liệu tiếng Anh

[6] N. a. Zaini, L. W. Ean, A. N. Ahmed, and M. A. Malek, "A systematic literature review of deep learning neural network for time series air quality forecasting," (in English), *Environmental Science and Pollution Research,* vol. 29, no. 4, pp. 4958–4990, 2022. [Online]. Available: https://www.researchgate.net/publication/356441214_A_systematic_literature_review_of_deep_learning_neural_network_for_time_series_air_quality_forecasting#:~:text=tackling%20the%20drawbacks%20of%20individual,The%20main%20objective%20of.

[7] A. Yenkikar, V. P. Mishra, M. Bali, and T. Ara, "Explainable forecasting of air quality index using a hybrid random forest and ARIMA model," (in English), *MethodsX,* p. 103517, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2215016125003619#:~:text=model%20adequacy,research%20contributes%20a%20replicable%2C%20explainable.

[8] G. Yang, H. Lee, and G. Lee, "A hybrid deep learning model to forecast particulate matter concentration levels in Seoul, South Korea," (in English), *Atmosphere,* vol. 11, no. 4, p. 348, 2020. [Online]. Available: https://www.mdpi.com/2073-4433/11/4/348#:~:text=proposed%20prediction%20model%20could%20predict,5.

[9] F. Wang, *và cộng sự.*, "Identification of regional atmospheric PM_{10} transport pathways using HYSPLIT, MM5-CMAQ and synoptic pressure pattern analysis," (in English), *Environmental Modelling & Software,* vol. 25, no. 8, pp. 927–934, 2010. [Online]. Available: https://www.researchgate.net/publication/238720075_Identification_of

_regional_atmospheric_PM_{10}_transport_pathways_using_HYSPLIT_MM5-CMAQ_and_synoptic_pressure_pattern_analysis.

[10] P. Veličković, *và cộng sự.*, "Graph attention networks," (in English), *arXiv preprint arXiv:1710.10903,* 2017.

[11] A. Vaswani, *và cộng sự.*, "Attention is all you need," (in English), *Advances in neural information processing systems,* vol. 30, 2017.

[12] M. T. Truong, L. S. P. Nguyen, T. T. Hien, T. D. H. Pham, and T. T. L. Do, "Source apportionment and risk estimation of heavy metals in PM_{10} at a Southern Vietnam megacity," (in English), *Aerosol and Air Quality Research,* vol. 22, no. 8, p. 220094, 2022.

[13] H.-V. Tran, H.-P. Nguyen, H.-H. Nguyen, and T.-V. Le, "Data-driven air quality prediction: deep learning solutions for pollution forecasting in Ho Chi Minh City," (in English), *International Journal of Information Technology,* vol. 17, no. 8, pp. 4887–4897, 2025. [Online]. Available: https://www.researchgate.net/publication/394387179_Data-driven_air_quality_prediction_deep_learning_solutions_for_pollution_forecasting_in_Ho_Chi_Minh_City#:~:text=effectively%20handle%20outliers%20and%20missing,for%20improving%20air%20quality%20forecasting.

[14] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," (in English), *nature,* vol. 323, no. 6088, pp. 533–536, 1986.

[15] R. Rakholia, Q. Le, B. Q. Ho, K. Vu, and R. S. Carbajo, "Multi-output machine learning model for regional air pollution forecasting in Ho Chi Minh City, Vietnam," (in English), *Environment international,* vol. 173, p. 107848, 2023. [Online]. Available:

https://www.sciencedirect.com/science/article/pii/S0160412023001216#:~:text=is%20the%20first%20model%20built,air%20quality%20forecasting%20of%20each.

[16] S. Park, J. Kim, and S. Kim, "Forecasting on PM_{10} in South Korea Using the CNN-BiGRU-LSTM Model," (in English), *Advances in Meteorology,* vol. 2026, no. 1, p. 6739605, 2026.

[17] J. Park, H. Kim, and H. J. Na, "Forecasting Future Corporate Value Including Information on Firm Environmental Activities: Using Machine Learning Techniques," (in English), *IEEE Access,* 2025.

[18] Paris Agreement, "Paris agreement," in *report of the conference of the parties to the United Nations framework convention on climate change (21st session, 2015: Paris). Retrived December*, 2015, vol. 4, no. 2017: HeinOnline, p. 2.

[19] E. MSCI, "ESG and Climate Trends to Watch for 2023," ed, 2022.

[20] N. T. P. Mai, B. T. Hieu, and N. D. Luong, "Pilot study on assessment of trace metals in PM_{10} at road sites in Bac Giang province, Vietnam," (in English), *Journal of Science and Technology in Civil Engineering (JSTCE)-HUCE,* vol. 15, no. 1, pp. 121–131, 2021. [Online]. Available: https://www.researchgate.net/publication/348697346_Pilot_study_on_assessment_of_trace_metals_in_PM10_at_road_sites_in_Bac_Giang_province_Vietnam#:~:text=period,The.

[21] Y. Luo, Y. Yang, L. Xu, C. Wu, and H. Li, "Can Public Environmental Concern Mitigate Air Pollution?? Evidence from the Daily Data of Yangtze River Delta Cities," (in English), *International Journal of Environmental Research,* vol. 19, no. 4, p. 149, 2025. [Online].

Available: https://link.springer.com/article/10.1007/s41742-025-00815-6.

[22] E. Kim, B.-U. Kim, Y.-H. Kang, H. C. Kim, and S. Kim, "Role of vertical advection and diffusion in long-range PM2. 5 transport in Northeast Asia," (in English), *Environmental Pollution,* vol. 320, p. 120997, 2023.

[23] Keras Team. "Traffic forecasting using graph neural networks and LSTM." https://keras.io/examples/timeseries/timeseries_traffic_forecasting/ (Truy cập April 17, 2025.

[24] S. Hochreiter and J. Schmidhuber, "Long short-term memory," (in English), *Neural computation,* vol. 9, no. 8, pp. 1735–1780, 1997.

[25] E. Hashim and T. Atia, "Enhancing Air Quality Prediction With A Multi Pollutant Attention-Based Model," (in English), *International Journal of Environmental Sciences,* pp. 3561–3587, August 2025, doi: 10.64252/kysvrt86.

[26] A. Graves and J. Schmidhuber, "Framewise phoneme classification with bidirectional LSTM and other neural network architectures," (in English), *Neural networks,* vol. 18, no. 5-6, pp. 602–610, 2005.

[27] P. Feng, J. Pang, and S. Jeon, "Public environmental concern and ESG rating divergence: the moderating role of negative online media coverage," (in English), *Total Quality Management & Business Excellence,* pp. 1–28, 2026. [Online]. Available: https://www.tandfonline.com/doi/abs/10.1080/14783363.2026.2621781 .

[28] W. G. A. b. t. G. R. Committee, "WHO global air quality guidelines: particulate matter (PM (25) and PM (10)), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide," (in English), *World Health Organization,* 2021. [Online]. Available: https://books.google.com.vn/books?hl=vi&lr=&id=s5pREAAAQBAJ&oi=fnd&pg=PR5&dq=WHO+Global+Air+Quality+Guidelines:+PM2.5+and+PM_{10}&ots=qAUHasJkrv&sig=3Z3jBC2CnDUlxVrkReR9NsV0rXY&redir_esc=y#v=onepage&q=WHO%20Global%20Air%20Quality%20Guidelines%3A%20PM2.5%20and%20PM_{10}&f=false.

[29] T. H. Bui and T. P. M. Nguyen, "Characterization of PM_{10} bounded trace metals in industrial, traffic, and residential areas in Bac Giang, Vietnam: Environmental and health implications," (in English), *Human and Ecological Risk Assessment: An International Journal,* vol. 29, no. 1, pp. 58–79, 2023. [Online]. Available: https://www.researchgate.net/publication/365384496_Characterization_of_PM_10_bounded_trace_metals_in_industrial_traffic_and_residential_areas_in_Bac_Giang_Vietnam_Environmental_and_health_implications#:~:text=The%20average%20PM_{10}%20concentration%20exhibited,The.

[30] T.-C. Bui, V.-D. Le, and S.-K. Cha, "A deep learning approach for air pollution forecasting in south korea using encoder-decoder networks & lstm," (in English), *arXiv preprint arXiv:1804.07891,* 2018. [Online]. Available: https://www.researchgate.net/publication/324716980_A_Deep_Learning_Approach_for_Air_Pollution_Forecasting_in_South_Korea_Using_Encoder-Decoder_Networks_LSTM#:~:text=Accordingly%2C%20PM_{10}%20%2

8R2%20%3D%200,quality%20parameters%20and%20works%20successfully.

[31] K. Bodor, Z. Bodor, and R. Szép, "Spatial distribution of trace elements (As, Cd, Ni, Pb) from PM_{10} aerosols and human health impact assessment in an Eastern European country, Romania," (in English), *Environmental monitoring and assessment,* vol. 193, no. 4, p. 176, 2021.

[32] I. U. Ajakwe, S. O. Ajakwe, J.-M. Lee, and D.-S. Kim, "Internet-of-Things-blockchain integration in environmental pollution monitoring data management: trends and techniques," (in English), *International Journal of Environmental Science and Technology,* vol. 22, no. 15, pp. 16123–16142, 2025.

PHỤ LỤC

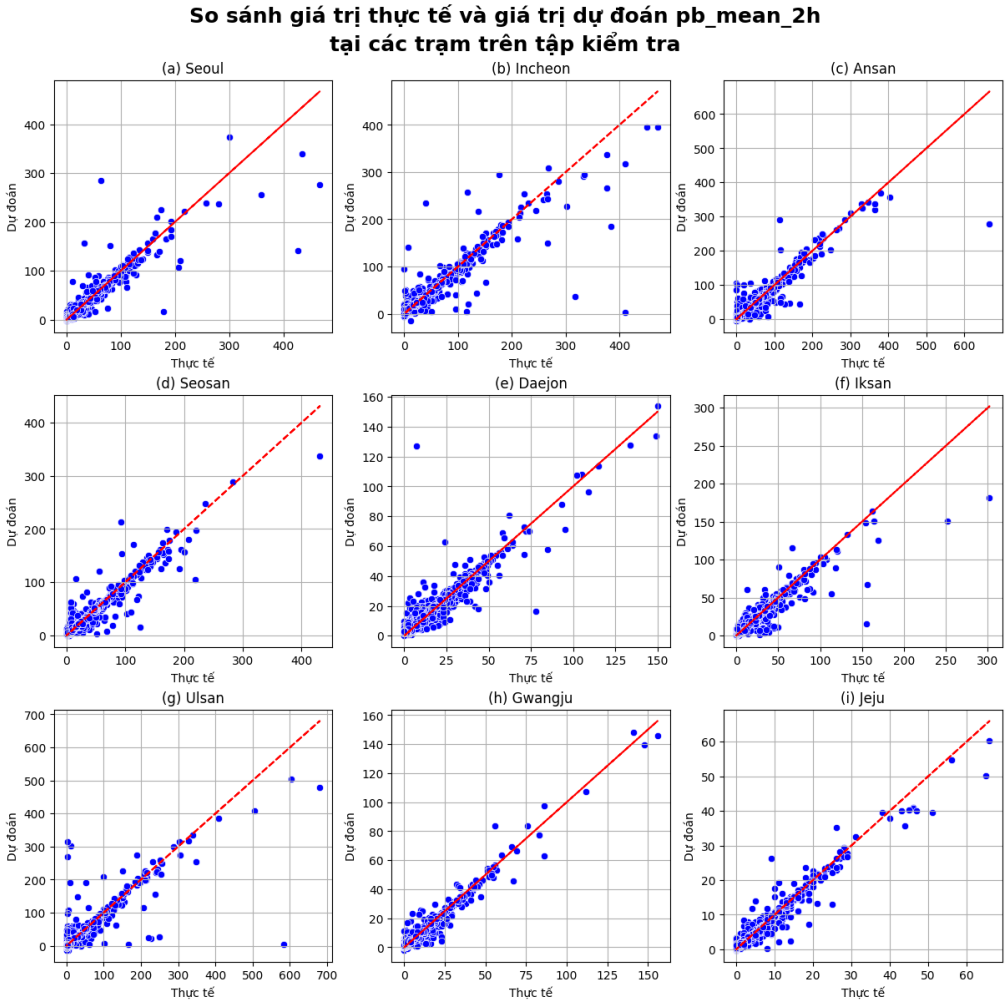
PHỤ LỤC A. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GCN CẢI TIẾN

A.1. Kết quả dự đoán với pb_mean_2h

A.1.1. GCN cải tiến – LSTM + MHA

Bảng PL - A. 1. Hiệu suất của mô hình GCN cải tiến – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	MAE	$RMSE$
Kiểm tra	Seoul	87,9376	2,849	9,6975
	Incheon	86,9054	3,1617	12,796
	Ansan	90,6378	4,1153	11,0626
	Seosan	92,1046	3,2962	7,2045
	Daejon	86,9285	2,7388	4,1487
	Iksan	89,6841	1,6509	5,3309
	Ulsan	77,4768	4,5007	17,4761
	Gwangju	95,4869	1,1955	1,9691
	Jeju	95,975	0,472	1,0102



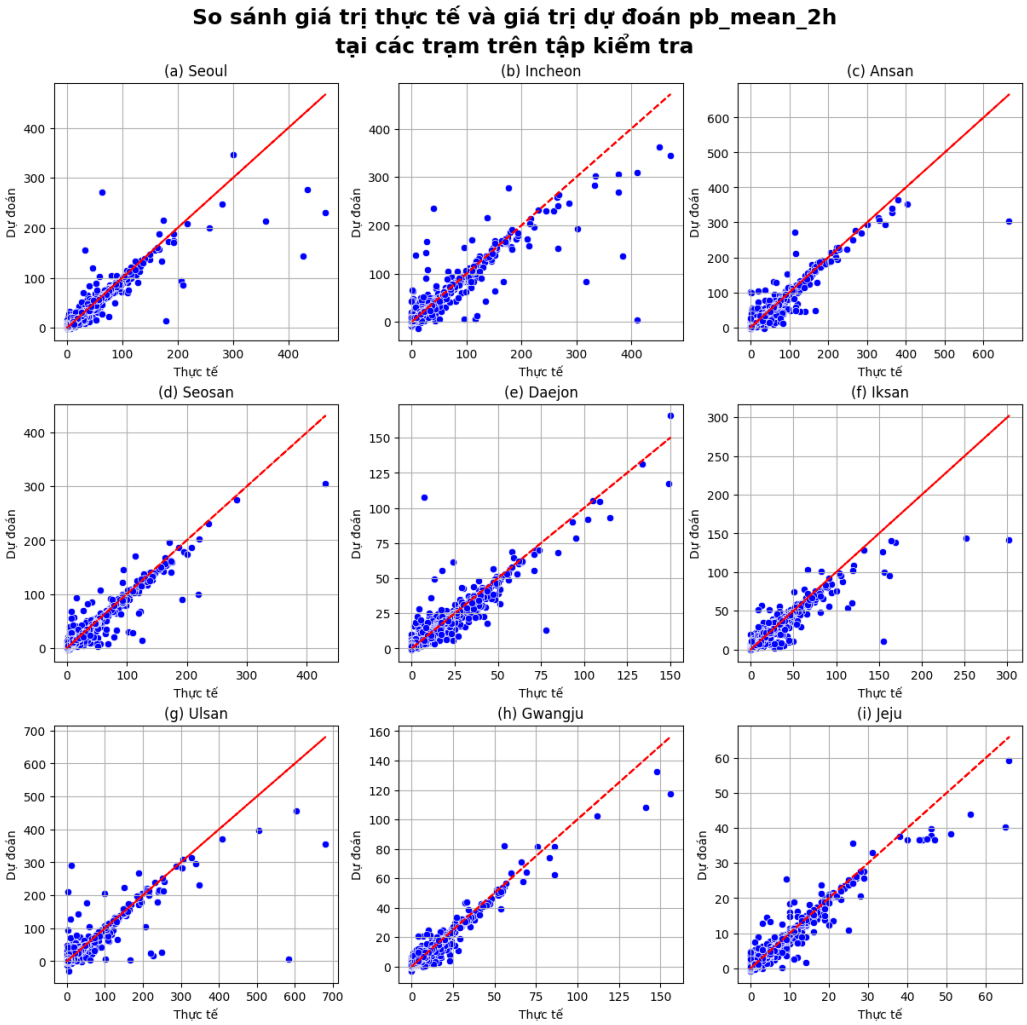
Biểu đồ PL - A. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GCN cải tiến – LSTM + MHA tại các trạm trên tập kiểm tra

A.1.2. GCN cải tiến – BiLSTM + MHA

Bảng PL - A. 2. Hiệu suất của mô hình GCN cải tiến – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2(%)	***MAE***	***RMSE***
Kiểm tra	Seoul	86,3607	2,6698	10,3118
	Incheon	85,6657	3,2224	13,3881
	Ansan	91,2269	3,7244	10,7089

	Seosan	92,2384	2,8364	7,1432
	Daejon	89,6747	1,9311	3,6872
	Iksan	87,7555	1,7032	5,8078
	Ulsan	79,2881	3,8354	16,7586
	Gwangju	94,969	1,0572	2,079
	Jeju	94,8042	0,4541	1,1478



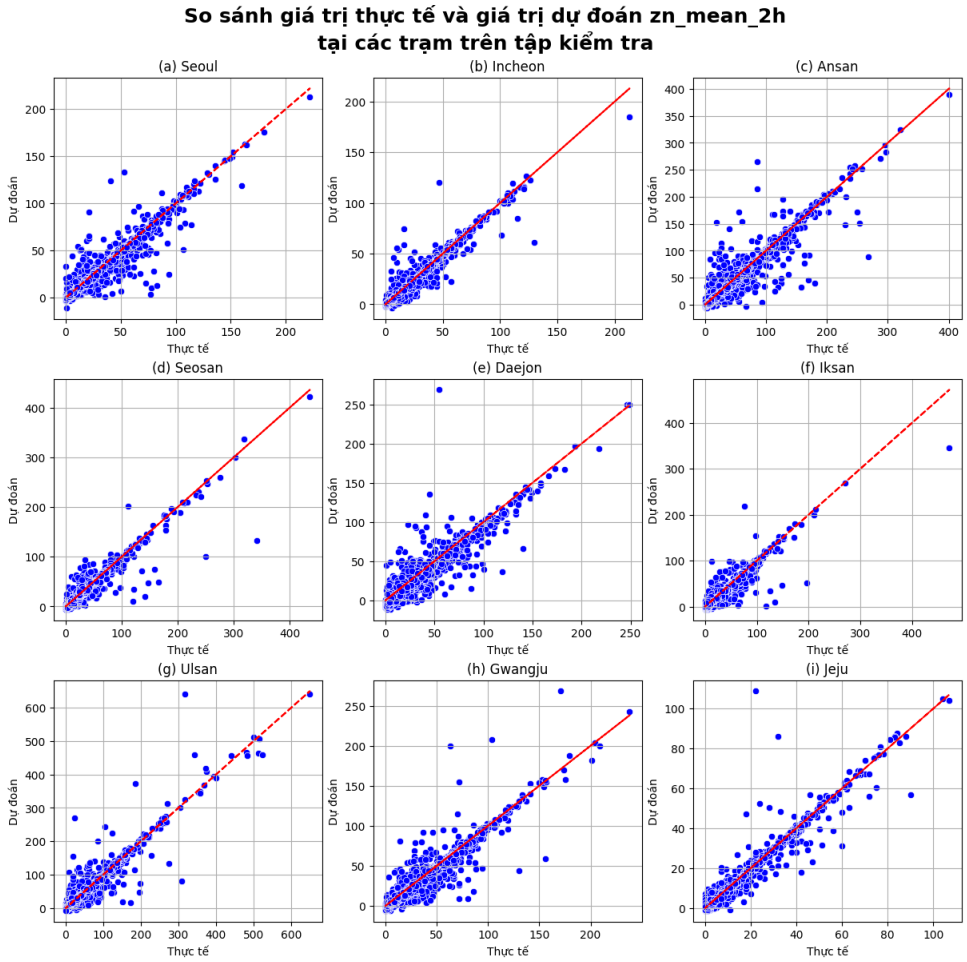
Biểu đồ PL - A. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GCN cải tiến – BiLSTM + MHA tại các trạm trên tập kiểm tra

A.2. Kết quả dự đoán với zn_mean_2h

A.2.1. GCN cải tiến – LSTM + MHA

Bảng PL - A. 3. Hiệu suất của mô hình GCN cải tiến – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	MAE	$RMSE$
Kiểm tra	Seoul	91,6021	3,0307	6,4633
	Incheon	94,3791	2,0887	4,2197
	Ansan	89,1613	5,7849	12,6419
	Seosan	89,9348	4,7304	9,0821
	Daejon	81,6547	7,6315	10,6322
	Iksan	88,491	4,1407	8,6241
	Ulsan	90,5939	5,4236	14,7755
	Gwangju	88,4164	4,5386	8,2634
	Jeju	94,6376	1,072	2,7628



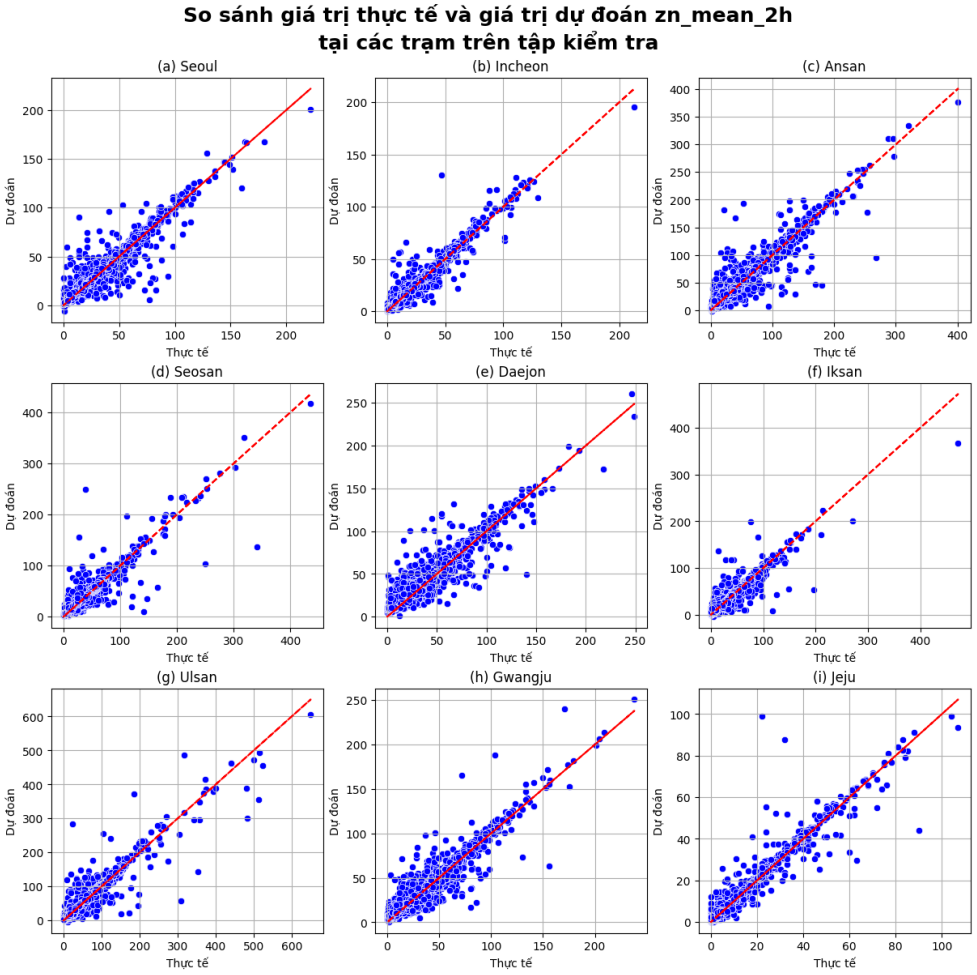
Biểu đồ PL - A. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GCN cải tiến – LSTM + MHA tại các trạm trên tập kiểm tra

A.2.2. GCN cải tiến – BiLSTM + MHA

Bảng PL - A. 4. Hiệu suất của mô hình GCN cải tiến – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	90,739	3,5441	6,7873
	Incheon	93,9078	2,3284	4,3931
	Ansan	89,6963	6,4169	12,326
	Seosan	85,6779	5,3469	10,8337

	Daejon	82,4463	7,5725	10,4003
	Iksan	87,3785	4,5943	9,0312
	Ulsan	89,1025	7,0693	15,9037
	Gwangju	89,0497	5,0209	8,0344
	Jeju	93,7657	1,4114	2,979



Biểu đồ PL - A. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GCN cải tiến – BiLSTM + MHA tại các trạm trên tập kiểm tra

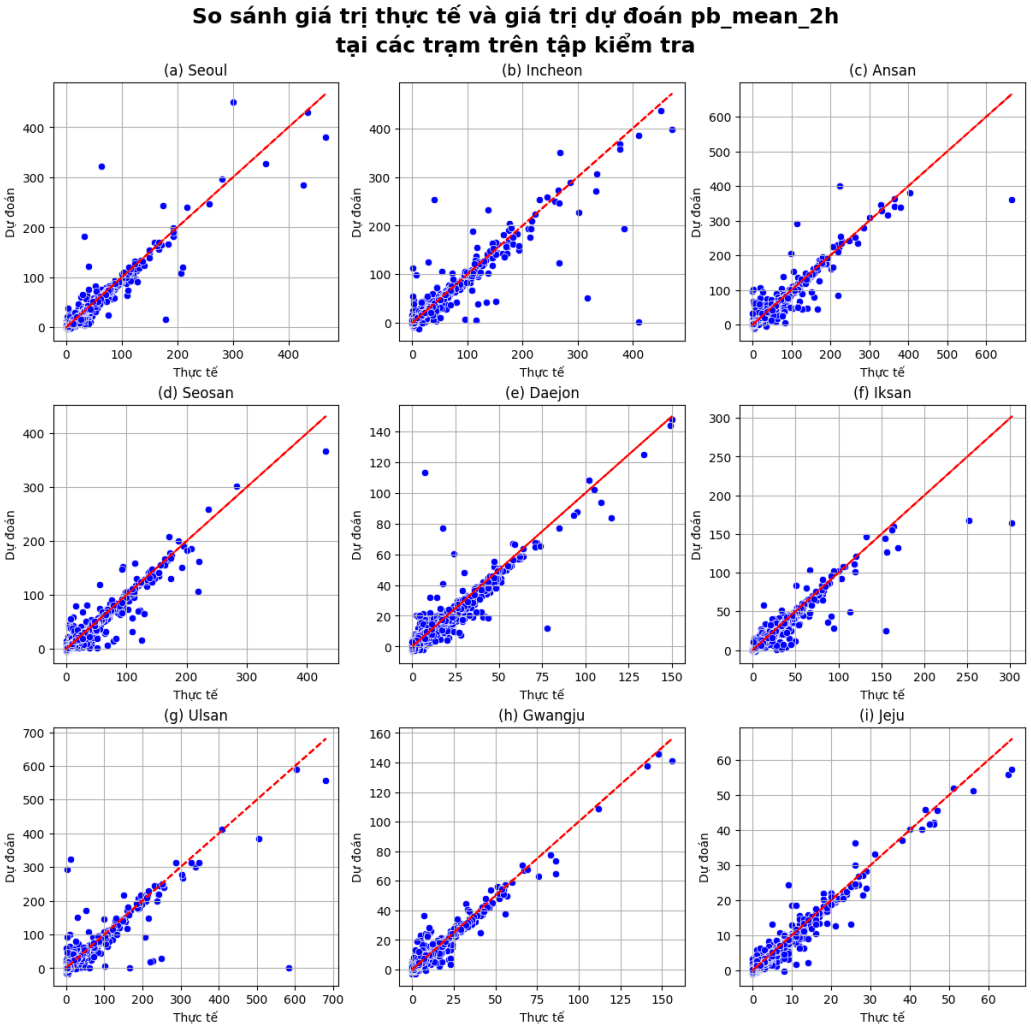
PHỤ LỤC B. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GAT TINH CHỈNH

B.1. Kết quả dự đoán với pb_mean_2h

B.1.1. GAT tinh chỉnh – LSTM + MHA

Bảng PL - B. 1. Hiệu suất của mô hình GAT tinh chỉnh – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	MAE	$RMSE$
Kiểm tra	Seoul	90,6559	2,6449	8,5351
	Incheon	87,7006	3,0993	12,4014
	Ansan	90,7855	3,9616	10,975
	Seosan	93,3053	2,8126	6,6341
	Daejon	89,0048	2,0843	3,805
	Iksan	90,2524	1,6459	5,1819
	Ulsan	81,0313	3,8868	16,0379
	Gwangju	95,5044	1,0556	1,9653
	Jeju	96,5021	0,4463	0,9418



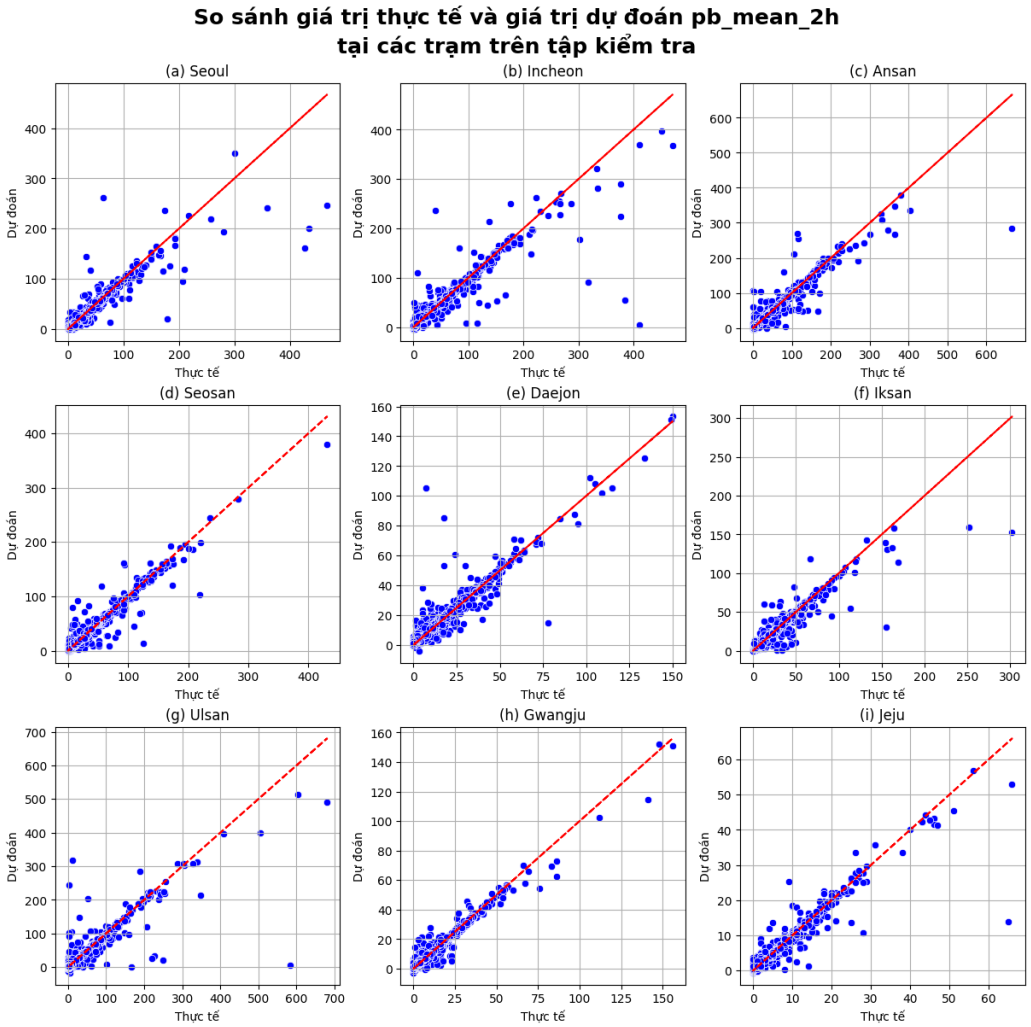
Biểu đồ PL - B. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT tinh chỉnh – LSTM + MHA tại các trạm trên tập kiểm tra

B.1.2. GAT tinh chỉnh – BiLSTM + MHA

Bảng PL - B. 2. Hiệu suất của mô hình GAT tinh chỉnh – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	86,5789	2,469	10,3118
	Incheon	86,737	2,931	13,3881
	Ansan	90,668	3,4779	10,7089

	Seosan	94,1312	2,4383	7,1432
	Daejon	90,3265	1,8496	3,6872
	Iksan	90,0877	1,4608	5,8078
	Ulsan	80,845	3,6998	16,7586
	Gwangju	96,3117	0,8921	2,079
	Jeju	93,4795	0,4129	1,1478



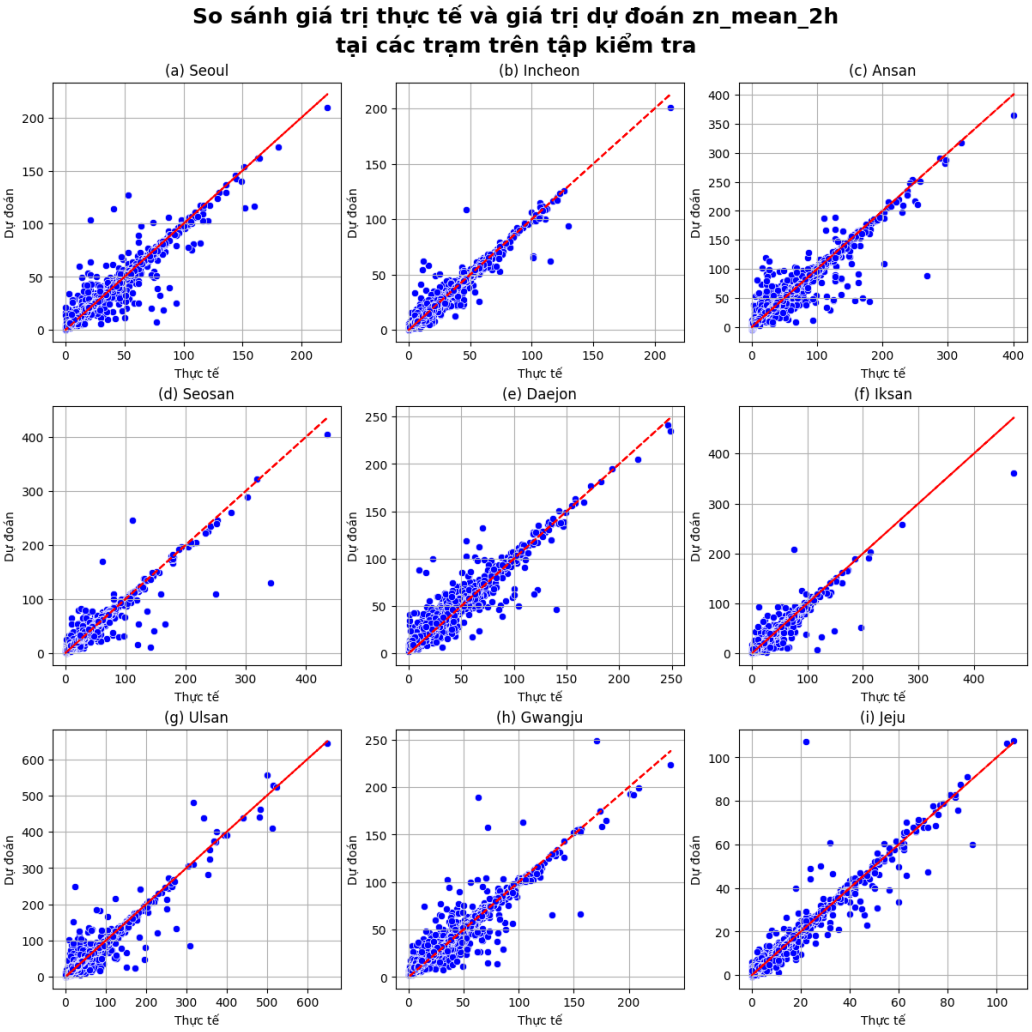
Biểu đồ PL - B. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT tinh chỉnh – BiLSTM + MHA tại các trạm trên tập kiểm tra

B.2. Kết quả dự đoán với zn_mean_2h

B.2.1. GAT tinh chỉnh – LSTM + MHA

Bảng PL - B. 3. Hiệu suất của mô hình GAT tinh chỉnh – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	MAE	$RMSE$
Kiểm tra	Seoul	93,4161	2,5982	5,7228
	Incheon	95,968	1,6789	3,5739
	Ansan	92,3196	4,9235	10,6418
	Seosan	90,4566	4,1011	8,8435
	Daejon	88,4262	6,1459	8,445
	Iksan	91,3978	3,4947	7,4559
	Ulsan	92,6495	5,0765	13,0616
	Gwangju	90,8114	4,0664	7,3598
	Jeju	95,5973	0,9405	2,5034



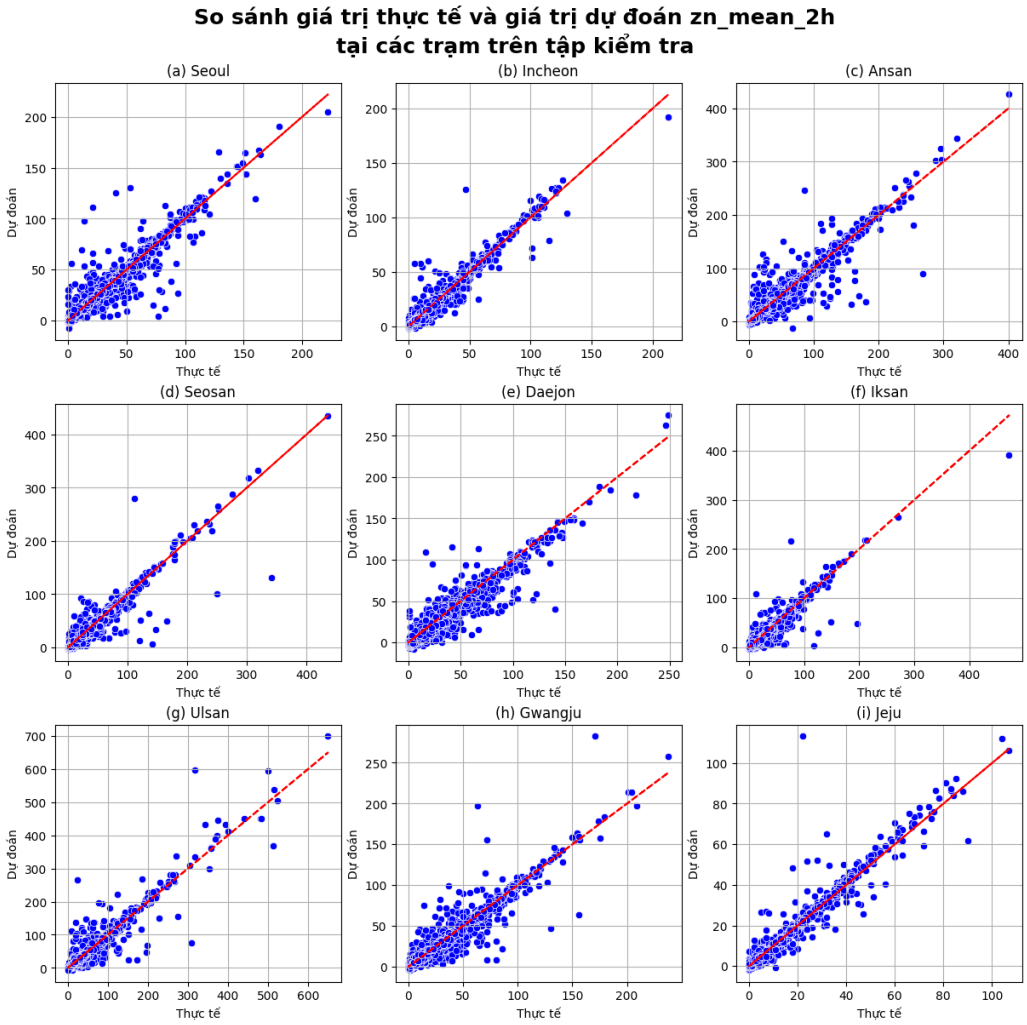
Biểu đồ PL - B. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT tinh chỉnh – LSTM + MHA tại các trạm trên tập kiểm tra

B.2.2. GAT tinh chỉnh – BiLSTM + MHA

Bảng PL - B. 4. Hiệu suất của mô hình GAT tinh chỉnh – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	91,6219	2,8885	6,4556
	Incheon	95,206	1,9065	3,897
	Ansan	90,9695	5,174	11,5393

	Seosan	89,5122	4,2862	9,2708
	Daejon	87,6814	6,0529	8,7125
	Iksan	90,9743	3,4862	7,6372
	Ulsan	91,1696	5,4153	14,3162
	Gwangju	89,8822	4,08	7,7229
	Jeju	95,0611	1,0378	2,6515



Biểu đồ PL - B. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT tinh chỉnh – BiLSTM + MHA tại các trạm trên tập kiểm tra

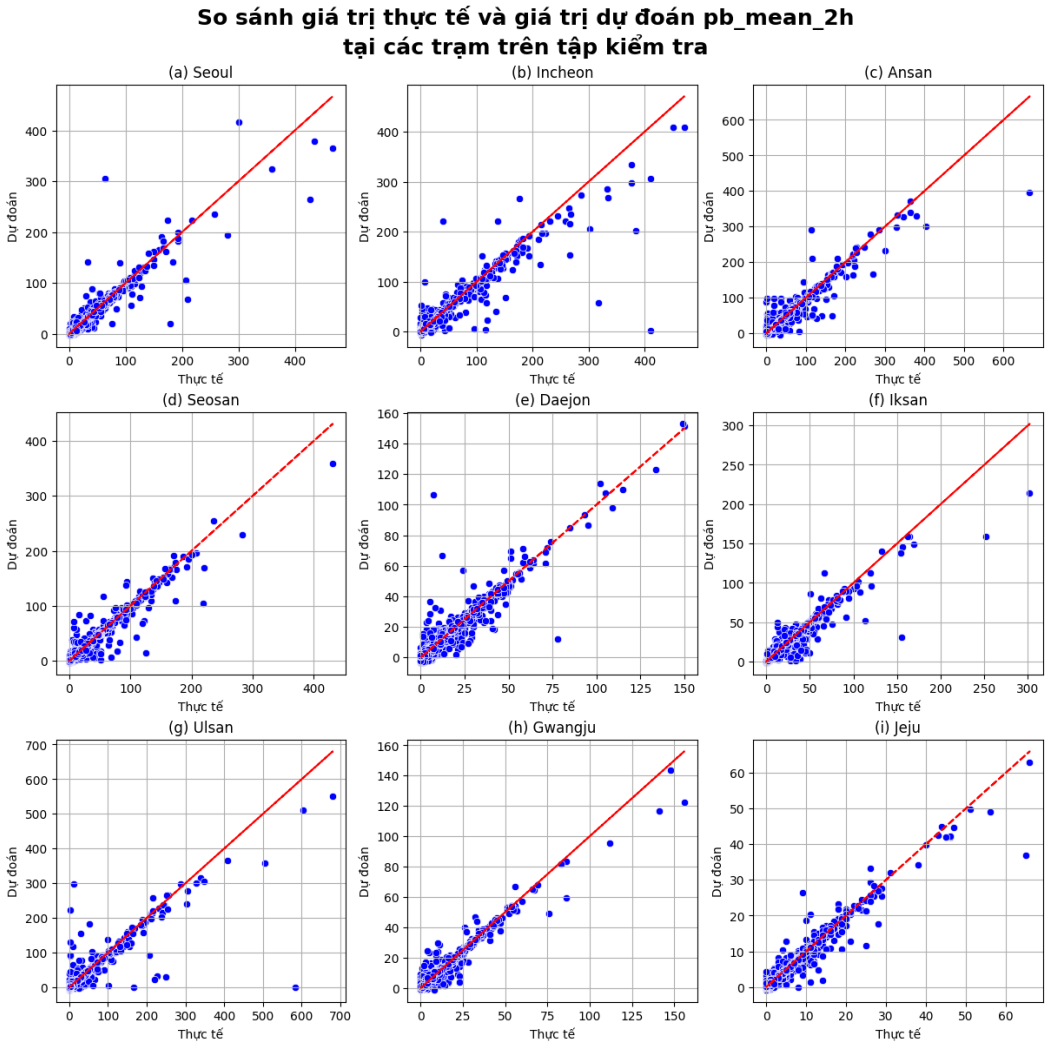
PHỤ LỤC C. KẾT QUẢ THỰC NGHIỆM MÔ HÌNH GAT ĐỀ XUẤT

C.1. Kết quả dự đoán với pb_mean_2h

C.1.1. GAT đề xuất – LSTM + MHA

Bảng PL - C. 1. Hiệu suất của mô hình GAT đề xuất – LSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	90,9655	2,2773	8,3925
	Incheon	88,2945	2,8446	12,0983
	Ansan	92,6215	3,3369	9,8209
	Seosan	94,1406	2,347	6,2064
	Daejon	90,7146	1,7496	3,4966
	Iksan	92,1931	1,4338	4,6375
	Ulsan	81,6942	3,4923	15,7552
	Gwangju	95,4974	0,879	1,9668
	Jeju	95,7349	0,4035	1,0399



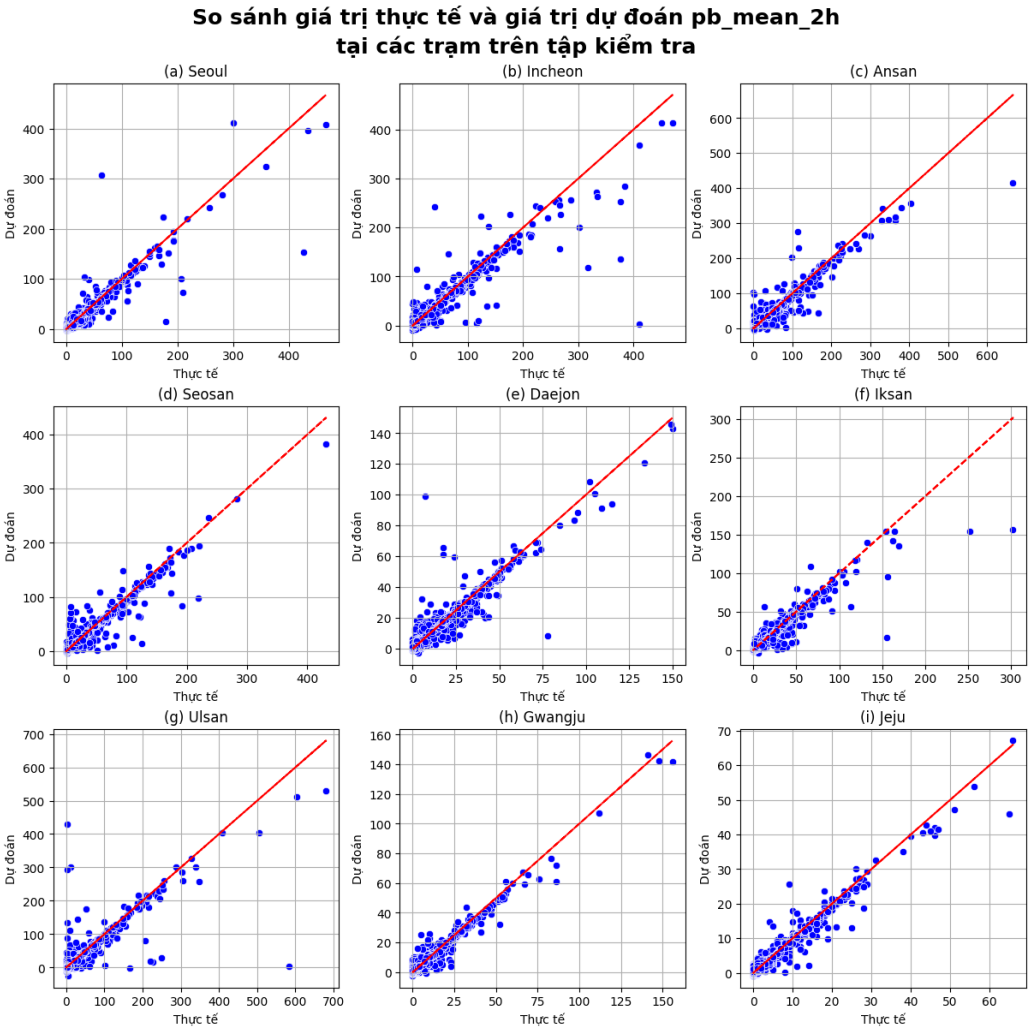
Biểu đồ PL - C. 1. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT đề xuất – LSTM + MHA tại các trạm trên tập kiểm tra

C.1.2. GAT đề xuất – BiLSTM + MHA

Bảng PL - C. 2. Hiệu suất của mô hình GAT đề xuất – BiLSTM + MHA khi dự đoán đặc trưng pb_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	89,9858	2,2286	8,8358
	Incheon	87,8062	2,8081	12,3481
	Ansan	92,6224	3,3399	9,8203

	Seosan	93,0931	2,3261	6,7384
	Daejon	91,5745	1,4332	3,3308
	Iksan	90,1163	1,4471	5,218
	Ulsan	77,0688	3,4689	17,6337
	Gwangju	96,4695	0,8294	1,7416
	Jeju	96,3891	0,3727	0,9568



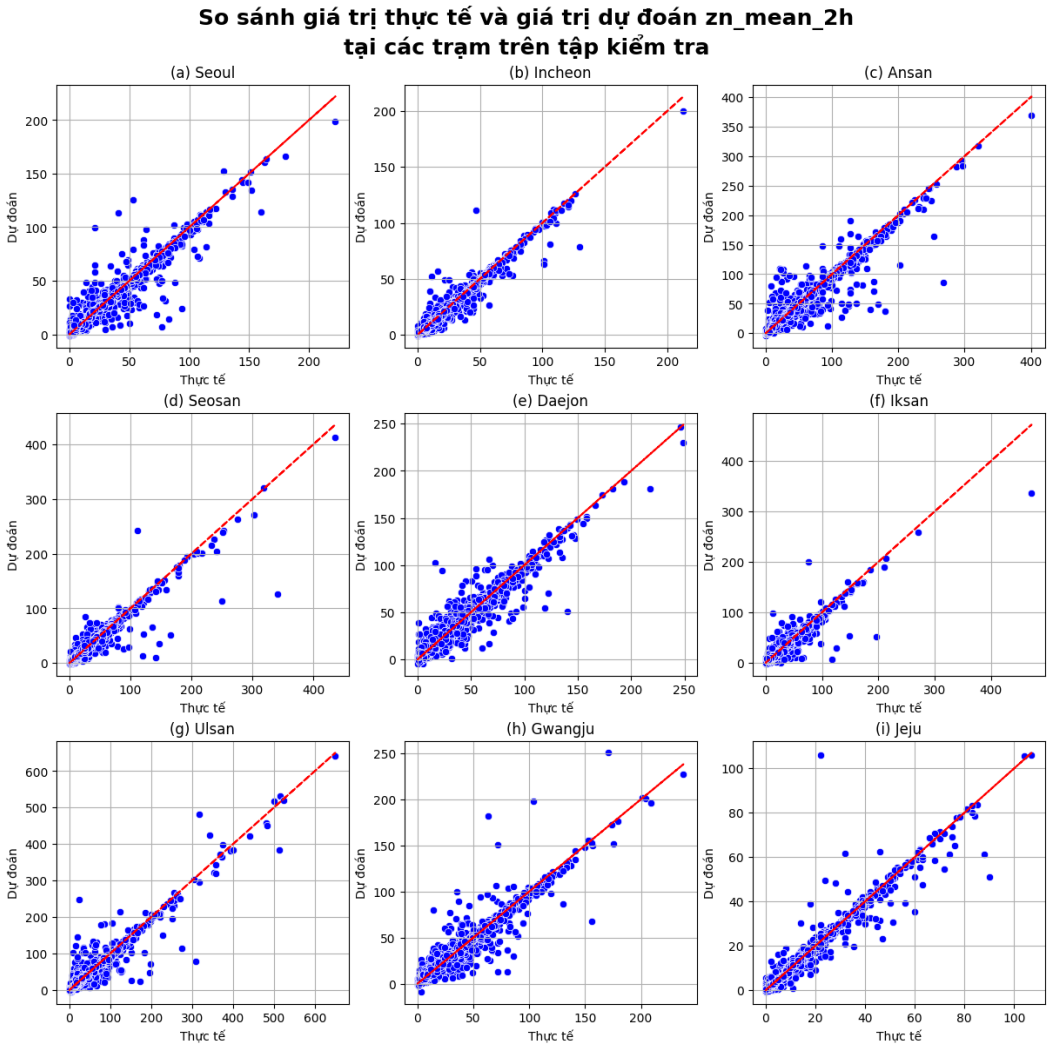
Biểu đồ PL - C. 2. So sánh giá trị thực tế và giá trị dự đoán pb_mean_2h của mô hình GAT đề xuất – BiLSTM + MHA tại các trạm trên tập kiểm tra

C.2. Kết quả dự đoán với zn_mean_2h

C.2.1. GAT đề xuất – LSTM + MHA

Bảng PL - C. 3. Hiệu suất của mô hình GAT đề xuất – LSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	MAE	$RMSE$
Kiểm tra	Seoul	93,4032	2,5101	5,7284
	Incheon	96,26	1,6331	3,4421
	Ansan	92,3707	4,6215	10,6064
	Seosan	91,5858	3,2909	8,3039
	Daejon	91,9711	4,2335	7,0338
	Iksan	91,5247	3,0392	7,4007
	Ulsan	92,8041	4,748	12,9234
	Gwangju	91,6688	3,5036	7,008
	Jeju	95,5953	0,8651	2,504



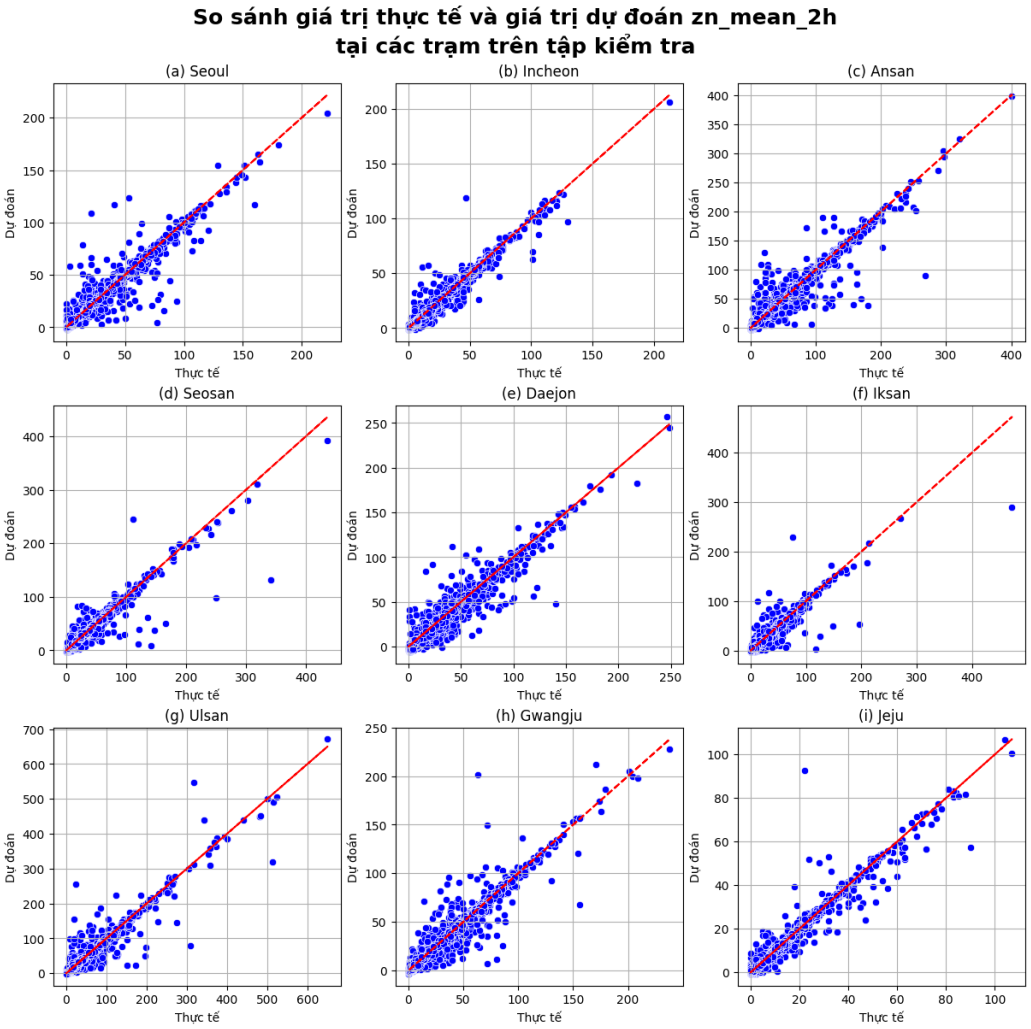
Biểu đồ PL - C. 3. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT đề xuất – LSTM + MHA tại các trạm trên tập kiểm tra

C.2.2. GAT đề xuất – BiLSTM + MHA

Bảng PL - C. 4. Hiệu suất của mô hình GAT đề xuất – BiLSTM + MHA khi dự đoán đặc trưng zn_mean_2h

Tập dữ liệu	**Trạm khí tượng**	R^2 (%)	***MAE***	***RMSE***
Kiểm tra	Seoul	93,0991	2,3409	5,8589
	Incheon	96,429	1,4711	3,3634
	Ansan	92,6904	4,1747	10,3818

	Seosan	91,1039	3,3354	8,5384
	Daejon	90,9357	4,8972	7,4736
	Iksan	90,3051	2,8984	7,9152
	Ulsan	92,4489	4,4759	13,2386
	Gwangju	92,0182	3,2832	6,8595
	Jeju	96,2672	0,8882	2,3051



Biểu đồ PL - C. 4. So sánh giá trị thực tế và giá trị dự đoán zn_mean_2h của mô hình GAT đề xuất – BiLSTM + MHA tại các trạm trên tập kiểm tra

PHỤ LỤC D. SO SÁNH KẾT QUẢ THỰC NGHIỆM

D.1. Đặc trưng pb_mean_2h

D.1.1. Nhóm mô hình đề xuất

Bảng PL - D. 1. So sánh hiệu quả khi dự báo pb_mean_2h của các mô hình đề xuất sử dụng trong đề tài

Mô hình	**Chỉ số đánh giá**	**Tập dữ liệu**		
		Huấn luyện	**Xác thực**	**Kiểm thử**
GCN cải tiến – LSTM + MHA	$Loss$	0,001	0,0033	0,0021
	$R^2(\%)$	91,4994	87,3584	89,2374
	MAE	2,0331	2,4928	2,6645
	$RMSE$	4,3827	7,5642	7,8551
GAT tinh chỉnh – LSTM + MHA	$Loss$	0,0008	0,0034	0,0019
	$R^2(\%)$	91,874	86,9143	90,5269
	MAE	1,9353	2,3813	2,4041
	$RMSE$	4,2935	7,6766	7,3864
GAT đề xuất – LSTM + MHA	$Loss$	0,0007	0,0024	0,0018
	$R^2(\%)$	93,0035	88,5942	91,3174
	MAE	1,5881	2,0349	2,0849
	$RMSE$	3,986	7,2148	7,046
	$Loss$	0,0011	0,0029	0,0023
	$R^2(\%)$	91,9968	86,5543	89,1092

GCN cải tiến – BiLSTM + MHA	MAE	1,7314	2,2314	2,3816
	$RMSE$	4,271	7,7891	7,8925
GAT tinh chỉnh – BiLSTM + MHA	$Loss$	0,0008	0,0031	0,0021
	$R^2(\%)$	92,9951	84,8473	89,9073
	MAE	1,6301	2,0787	2,1813
	$RMSE$	3,9938	7,8145	7,5934
GAT đề xuất – BiLSTM + MHA	$Loss$	0,0008	0,003	0,002
	$R^2(\%)$	92,9733	88,0761	90,5695
	MAE	1,4378	1,9303	2,0282
	$RMSE$	3,9993	7,3454	7,4026

D.1.2. Nhóm mô hình không sử dụng cơ chế MHA

Bảng PL - D. 2. So sánh hiệu quả khi dự báo pb_mean_2h của các mô hình không sử dụng MHA trong đề tài

Mô hình	**Chỉ số đánh giá**	**Tập dữ liệu**		
		Huấn luyện	**Xác thực**	**Kiểm thử**
GCN cải tiến – LSTM	$Loss$	0,003	0,0077	0,0081
	$R^2(\%)$	56,2212	55,8373	56,6622
	MAE	5,7962	6,9934	7,4138
	$RMSE$	9,9312	14,2766	15,4239
	$Loss$	0,003	0,0077	0,0082

GAT tinh chỉnh – LSTM	$R^2(\%)$	60,5939	57,8978	59,0585
	MAE	4,7492	6,0174	6,4105
	$RMSE$	9,488	14,0507	15,2224
GAT đề xuất – LSTM	$Loss$	0,003	0,0076	0,0082
	$R^2(\%)$	61,1157	58,1235	58,8414
	MAE	4,6678	5,949	6,3517
	$RMSE$	9,4314	14,0325	15,2865
GCN cải tiến – BiLSTM	$Loss$	0,003	0,0078	0,008
	$R^2(\%)$	59,3398	57,0301	58,7834
	MAE	5,1002	6,3457	6,7375
	$RMSE$	9,6317	14,142	15,1698
GAT tinh chỉnh – BiLSTM	$Loss$	0,0029	0,0077	0,0082
	$R^2(\%)$	61,3429	58,193	58,8765
	MAE	4,5621	5,8396	6,247
	$RMSE$	9,4142	14,0254	15,2579
GAT đề xuất – BiLSTM	$Loss$	0,003	0,0077	0,008
	$R^2(\%)$	61,1308	57,7855	60,4427
	MAE	4,3949	5,6824	6,0398
	$RMSE$	9,4543	14,0571	15,0506

D.2. Đặc trưng zn_mean_2h

D.2.1. Nhóm mô hình đề xuất

Bảng PL - D. 3. So sánh hiệu quả khi dự báo zn_mean_2h của các mô hình đề xuất sử dụng trong đề tài

Mô hình	Chỉ số đánh giá	Tập dữ liệu		
		Huấn luyện	Xác thực	Kiểm thử
GCN cải tiến – LSTM + MHA	$Loss$	0,0027	0,0016	0,0009
	$R^2(\%)$	91,343	88,6469	89,8745
	MAE	4,5609	4,506	4,2712
	$RMSE$	10,0721	10,162	8,6072
GAT tinh chỉnh – LSTM + MHA	$Loss$	0,0011	0,001	0,0007
	$R^2(\%)$	93,0666	91,2666	92,3381
	MAE	3,9453	4,0048	3,6695
	$RMSE$	9,0213	9,0365	7,512
GAT đề xuất – LSTM + MHA	$Loss$	0,0013	0,0015	0,0007
	$R^2(\%)$	93,567	91,8165	93,0204
	MAE	3,5373	3,5037	3,1606
	$RMSE$	8,7198	8,7542	7,2167
GCN cải tiến – BiLSTM + MHA	$Loss$	0,0017	0,005	0,0001
	$R^2(\%)$	89,9196	87,497	89,0849
	MAE	5,2998	5,2428	4,8116

	$RMSE$	10,8702	10,7413	8,9654
GAT tinh chỉnh – BiLSTM + MHA	$Loss$	0,0013	0,0011	0,0008
	$R^2(\%)$	92,1646	90,1572	91,342
	MAE	4,1751	4,1047	3,8142
	$RMSE$	9,5983	9,5875	8,0226
GAT đề xuất – BiLSTM + MHA	$Loss$	0,0011	0,0011	0,0007
	$R^2(\%)$	93,5258	91,0297	92,8108
	MAE	3,3631	3,3631	3,3884
	$RMSE$	8,7505	9,1242	7,3261

D.2.2. Nhóm mô hình không sử dụng cơ chế MHA

Bảng PL - D. 4. So sánh hiệu quả khi dự báo zn_mean_2h của các mô hình không sử dụng MHA trong đề tài

Mô hình	Chỉ số đánh giá	Tập dữ liệu		
		Huấn luyện	Xác thực	Kiểm thử
GCN cải tiến – LSTM	$Loss$	0,0053	0,0052	0,0039
	$R^2(\%)$	60,1341	54,2691	60,8748
	MAE	11,1481	10,7645	9,5227
	$RMSE$	21,8466	21,1299	17,378
GAT tinh chỉnh – LSTM	$Loss$	0,0051	0,0051	0,0038
	$R^2(\%)$	61,718	55,6259	61,7329
	MAE	10,6229	10,233	8,9511

	$RMSE$	21,4063	20,8699	17,2139
GAT đề xuất – LSTM	$Loss$	0,005	0,0051	0,0038
	$R^2(\%)$	61,9919	55,7541	61,8226
	MAE	10,6767	10,3109	9,0192
	$RMSE$	21,3332	20,8442	17,1903
GCN cải tiến – BiLSTM	$Loss$	0,0053	0,0052	0,0039
	$R^2(\%)$	60,5849	54,5326	61,1124
	MAE	11,0826	10,7417	9,527
	$RMSE$	21,7296	21,0833	17,3263
GAT tinh chỉnh – BiLSTM	$Loss$	0,005	0,0052	0,0038
	$R^2(\%)$	61,8957	55,5857	61,7111
	MAE	10,8128	10,459	9,1922
	$RMSE$	21,3618	20,8739	17,2094
GAT đề xuất – BiLSTM	$Loss$	0,0053	0,0053	0,0039
	$R^2(\%)$	59,916	53,8086	60,4623
	MAE	11,2911	10,9363	9,6929
	$RMSE$	21,896	21,2287	17,4504